

面向 AI Agent 轨迹的可配置语义剖析

AgentSight 研究原型

2026 年 7 月 4 日

摘要

AI agent 的执行历史已经不再只是一次 prompt 或一棵 trace tree。一个真实轨迹可能同时包含用户意图、LLM 响应、tool call、API 调用、GUI 动作、浏览器动作、进程、文件、网络、计划步骤、subagent 以及 benchmark 给出的成功、失败、安全、重复和冗余标签。现有 agent observability 工具通常把这些对象固定成 prompt、session 或 span 层级；传统 profiler 则固定成函数或进程层级。这两种做法都会把 profiling 问题过早绑定到某一种边界上，使同一段轨迹很难按任务、阶段、工具、动作、质量标签或人工分组递归折叠。

本文提出一种更小的语义剖析模型：系统只保留两个核心抽象，**operation** 和 **operation stack**。**operation** 是带字段和权重的观测，prompt、tool call、process、syscall、GUI action 和 plan step 可以是 operation 记录或派生字段；session、span、task 和 trace id 是 operation fields、交换容器或 baseline shape，不是新的 profiler 对象。**operation stack** 是用户从字段中选择的递归投影，mapping 和 tagging 在 stack 构造前派生字段，而不是创建第三种 profiler 对象。当用户不想给出固定 stack 字段链时，agentpprof 也可以从可见 evidence、semantic shift 和 query hint 中给相邻 operation boundary 打分，递归诱导多层 operation frames，再用 operation-only stack 折叠。关键点是聚合不是第三个对象，也不是固定 trace tree；聚合由 query time 选择的 stack 形态决定。因此本文的新意不在单纯 query-time aggregation 或 flamegraph renderer。它在于把 agent operation record、递归多字段 operation-stack 投影和 hidden-label profile-group scoring 放进同一个 profiler 评估问题。我们在 Rust agentpprof 中实现该模型，并用三个核心 profiling 实验和一个可重放性检查评估它。RQ1 验证泛化覆盖和递归 operation-stack 形成。在 15 个轻量采样的公开标注轨迹来源上，agentpprof 把 47,590 个 samples 投影到同一 operation layer；同一批 13,265 个 operations 可以从 9 个 dataset stacks 折叠为 57 个 phase stacks、226 个 semantic stacks、455 个 action stacks，或 3,757 个 fixed-session stacks，而不改变输入 operation。这说明 prompt、tool、GUI action、process 和人工边界都进入 operation layer；session/span 只作为字段、容器或对照视图参与 stack 查询，不是新的 profiler 抽象。

RQ2 是 hidden-label localization/ranking 主实验。在 AgentRewardBench、SATraj-OS、AgentNet 和 OSWorld-Human 的 4 个 oracle-rich 数据集、6 个任务、34,539 个 operations 和 3,699 个 positives 上，我们把 profile groups 当作 ranked localization outputs，比较 flat、fixed-session drilldown、dataset-native、raw-action 和 operation-stack views。Task-query operation-stack profiling 的 top-5 median work 为 0.0937，而 flat summary 为 1.0；相对 fixed-session drilldown，它在 5/6 tasks 上提高 top-5 recall，并把 median groups 从 285.0 降到 157.5。

RQ3 隔离机制和 profile-configuration actionability。Rank feature、stack depth、mapping、transfer、diagnostic lens、case view 和 counterfactual 分析显示：有效配置随 task 和 objective 变化，operation-stack 是 Pareto point，不是 universal default。Executable profile-spec patches 在 5/6 tasks 上改善 AP、top-5 lift 和 first-positive work；supervised held-out boundary-field ablation 把 OSWorld-Human AP 从 0.2402 提到 0.2583，并把 groups 从 108 降到 74，但保留 work 反例。Field-suitability synthesis 进一步把 mapping、stack-depth、rank-feature 和 boundary-field 证据变成 accept/caution/reject 配置决策。RQ4 验证可重放性、离线成本和复现边界。76 个 profile 配置在 deterministic replay 下保持语义和 byte-level 输出稳定，local-session、agent-trace 和 standard-trace 输入都通过同一 operation-stack path 重放。RQ4 只说明离线证据可重放，并约束数字、数据来源选择和主张边界，不作为第四个 empirical accuracy result。

因此本文支持的是有范围限定的 profiling 主张：operation-stack profiling 能在公开真实标注 trace 的 dataset-provided hidden labels 下定位、排序和解释任务相关 failure、quality problem 和 dataset-provided semantic boundary，并相对 flat summary 减少 inspection work、相对 fixed-session drilldown proxy 改善 median fragmentation tradeoff。本文不声称提升 human productivity，不声称自动发现所有 intent boundary，不声称 metric dominance，也不声称完整兼容现有 trace ecosystem。

1 问题

AI agent 轨迹的调试问题正在从单次调用回放变成跨任务剖析问题。开发者不只想知道某个 span 什么时候开始和结束，也想知道哪类任务导致最多重复点击，哪些 GUI 轨迹反复输入，哪个工具调用族对应失败，哪些安全攻击类型集中在某些操作阶段，或者一个 prompt 序列能否被折叠成 task、phase、action 和人工 subtask 等多个深度。如果 profiler 把 session、prompt 或 tool call 写死成核心层级，这些问题会被迫使用同一个边界。如果 profiler 只保留进程或函数栈，上层语义和 benchmark oracle 又会丢失。

本文的出发点是把 agent trace 中所有可剖析对象都降到同一层。一个 prompt 可以是 operation，一个 tool call 可以是 operation，一串 prompt 也可以通过 mapping 被派生为同一个 intent 或 task operation field。同样，GUI action、API call、browser action、process event、syscall、安全标签、step correctness 和人工 grouped-action id 都不是新的 profiler 抽象，而是 operation fields。Profiler 的核心任务不是决定唯一正确边界，而是让用户和实验可以在同一批 operations 上选择 stack 字段、派生 mappings，并得到不同深度的递归折叠。

这个问题有两个系统挑战。第一，抽象必须足够小，否则 prompt、session、tool call、plan、subagent 和 process 会各自形成独立 pipeline。第二，抽象又必须足够可配置，

否则 flamegraph 只会成为固定视图，不能回答边界、失败、安全和质量诊断问题。本文的目标不是证明某个单一 flamegraph 最好，而是证明 operation 和 operation stack 足以覆盖多类真实标注 agent 轨迹，并且 stack shape 与 aggregation 的选择会系统性改变质量、边界、定位、work 和碎片化分析结果。

2 设计

2.1 两个核心抽象

operation 是唯一的样本级对象。每个 operation 是一个带权重的字段集合，例如 `op=prompt`、`op=llm`、`op=tool`、`tool=browser`、`action=click`、`phase=navigate`、`status=failure` 或 `step_correct=incorrect`。这些字段可以来自本地 Codex/Claude session，也可以来自外部 benchmark 的标注轨迹。实现上，外部轨迹使用每行一个 JSON object 的 operation JSONL，并把原始任务文本、截图和长对话默认排除在提交复现包之外。

operation stack 是从 operation fields 中选择出的有序 frame 列表。例如同一批 operations 可以用 `project,dataset` 查看数据来源，也可以用 `project,dataset,task,phase,op,tool,action,status` 查看动作深度，或者加入 `human_group`、`step_correct`、`safety` 和 `looping` 做诊断视图。Stack 不是 trace tree，也不是 session hierarchy。自动 operation-stack induction 仍然只产生 operation stack: agentpprof 在当前连续 operation segment 内用可见 evidence、semantic shift、changed-field density 和 query hint 给相邻 cut 打分，要求左右 child 有足够权重和不同 dominant evidence，然后递归写入多层 operation frames。因此用户给的是 predicate、view 和 query hint，不是 `analysis_task,phase,action,status` 这样的固定 stack 字段链。它是一个查询结果，用户可以按问题改变深度和字段。

2.2 Mapping 和 tagging

Mapping 和 tagging 是派生 operation fields 的一等机制。它们在 stack 构造前运行，读取 operation 的 `key=value` 文本，并写入新的字段。例如 desktop action 中的 `type` 和 `key` 应先进入 `phase=input`，再考虑通用 web action verb；API/tool traces 应先进入 tool/API phase family，再处理 `search` 或 `create` 这类词。这一顺序来自跨 web、desktop、API/tool 和 step-quality 轨迹时暴露出的关键设计约束。如果通用 action rule 抢在 operation-family rule 前面运行，desktop、web 和 API 轨迹会被错误合并。

Mapping 不引入第三个抽象。它只是在 operation 上写字段，使同一个 stack specification 可以跨数据集复用。当前 Rust CLI 支持 `inline --op-map FIELD:LABEL=REGEX` 和文件形式 `--op-map-file`。`--where FIELD=REGEX` 和 `FIELD!=REGEX` 在 mapping 之后、stack 构造之前选择 operation 子集，多条 predicate 取 AND；它实现形式化模型里的 ϕ ，不是新的 profiler 对象。同一规则格式可以从已标注 operations 中派生出来，再用于 held-out 和 leave-dataset-out 泛化测试。`--profile-spec` 把 operation files、mapping files、predicate、view、stack 和输出路径打包成 JSON 配置，便于复现实验；命令行参数仍可覆盖 spec 默认值。`--deterministic-output` 或 spec 中的 `deterministic_output` 可以把 JSON generated_at 和 pprof profile time 固定为可复现值，用于 byte-stable replay。

它不改变模型本身，只是把已有 operation 和 operation-stack 查询显式记录下来。

2.3 Views 和非火焰图分析

--view 决定采样和权重，例如 operation count、token、file、network 或 time。--stack 决定递归折叠形状。Folded stack 和 SVG flamegraph 是其中一种输出，但不是唯一输出。我们同时生成 JSON profile、stack tree、top-field table、parent-child transition、depth sweep、boundary F1、V-measure、coverage report、grouped-action report 和 HTML quality report。这些视图共享同一 operation 输入和 stack 语法，因此 failure、safety、looping、redundancy 和 human group 可以被当作普通字段评分，而不是另建 failure profiler 或 safety profiler。

3 实现

agentpprof 是当前被测实现。它是 Rust CLI，读取本地 Codex/Claude 历史或外部 operation JSONL，并输出 pprof-compatible profile、folded stacks、SVG 和 JSON。核心命令形态如下：

```
agentpprof --operation-file ops.jsonl --view operations
--stack project,dataset,task,phase,op,tool,
action,status --op-map-file operation-map.txt
--where task=verify
-o out.folded
```

外部数据集进入系统前先被规范化为 operation JSONL。规范化过程只下载或流式读取所需公开文件的采样前缀。对于包含截图、长 prompt 或完整对话的数据集，默认保存 redacted rows 和 operation JSONL，不提交原始数据。本地 agent session 通过 `agent-session` 解析为 `agentsight.agent-session.trace.v1 trace`。agentpprof 可以用 `--export-trace` 写出 filesystem-normalized trace，用 `--trace-file` 读回，也可以把 trace 转成 operation JSONL 后折叠。这个 replay path 验证 filesystem/tool-command portability 和 folded-output equality，但不声称 prompt 或 LLM preview 已完整脱敏。标准 trace 也只是 exchange container。agentpprof 可以用 `--export-standard-trace` 写出 Chrome/Perfetto-style traceEvents，再用 `--standard-trace-file` 导入为普通 operations 后折叠。在一个真实标注 operation 前缀上，512 operations 可以导出为 512 个 Chrome complete events，并在导入后仍得到 byte-identical 的 512-sample / 11-stack folded 输出。这说明 exchange path 不改变 operation samples 或 stack shape，但不提供新的准确性主张。质量评估复用 agentpprof 的 operation mapping contract，并计算字段覆盖率、oracle V-measure 和序列相邻边界 F1。同一 profile output 还可以生成 flamegraph 之外的 tree、top-kind 和 transition 报告。

这个实现刻意保留简单接口。它不像 jq 那样完整表达 JSON 查询语言，但它把 profiler 的关键自由度暴露为 flags 和可提交配置。数据源由 `--trace-file` 或 `--operation-file` 选择，权重由 `--view` 选择，查询子集由 `--where` 选择，字段派生由 `--op-map` 选择，递归边界由 `--stack` 或 `--induce-operation-stack` 选择，JSON group 排序由 `--rank-rule`、`--rank-op-rule` 和 `--rank-mode` 选择，复现配置由 `--profile-spec` 固定。这些接口结果只说明 E1-E4 的实验配置可以经同一 profiler path 执行，而不是形成额外主实验。三类实现证据共同界定这个接口。Mapping-derived where_rules 可以在

folding 前选择 729/729、714/714 和 4,285/4,285 个预期 operations。Profile specs 可以组合 operation source、predicate、visible rank rule、rank mode 和显式 stack depth，并在 12/12 variants 中保持不引入 prompt/session frame。Standard-trace round trip 在真实标注 operation 前缀上保持 512 samples 和 11 stacks。这些结果支撑 E1 的接口边界，不另起一个 experiment block。

Ranker 和 actionability 的实现证据被归入 E3。Stack-text rule 与 rank-mode variants 可以从 profile spec 复现，但对 safety/side-effect 过粗。Operation-level visible feature density 在 folding 前匹配 mapped operation token，并在 semantic stack 上使 AP 赢 5/6 tasks、top-5 lift 赢 4/6、first-positive work 赢 5/6，coarse stack 也在 AP 上赢 4/6。Leave-one-feature、robustness 和 transfer results 说明 repeat_signal、write-action、status=success 等字段在不同 family 中作用不同，误导性 safety-like 或 input-phase features 会伤害 AP 或 first-positive work。Global/equal feature banks 常能保留收益，但 guided repair 使用离线评分反馈，因此不是 label-free automatic ranker。这些结果支撑 E3 的 mechanism/actionability 解释。

Profile-spec replay、输入来源 replay 和 deterministic output 归入 E4。76 个 profile specs 覆盖 view specs、rank-feature specs 和 robustness specs。Rust agentpprof --profile-spec 重复运行两次后 semantic profile hash 全部稳定，默认 raw-byte hash 只有 4/76 稳定，因为 JSON profile 包含生成时间戳。启用 --deterministic-output 后 raw-byte hash 达到 76/76。同一个 E4 复现检查进一步验证 profile spec 可以 replay session_files、trace_files、standard_trace_files、regex tag_rules、where_rules、rank rules、stack override 和 include_standard_trace_args。这些输入源最后仍归一成 operations，并由 operation stack 折叠。这关闭的是输出 byte-stability 缺口，不是新的 accuracy benchmark、live overhead benchmark 或第五个主实验。因此 prompt、session、toolcall、process、syscall、plan 和 subagent 都可以在同一套 mechanism 中出现，而不是成为互不兼容的 object model。

4 实验方法

评估把 profiler 输出当作 ranked localization targets，而不是把 flamegraph 图形本身当作结果。我们只使用公开的、别人已经标注好的 agent 轨迹或交互轨迹，并通过 Hugging Face Dataset Viewer、HF repo JSONL、公开 GitHub JSON 和公开 benchmark artifacts 做轻量采样。这种数据策略避免同步完整测试集、图片归档和 gated 数据，同时保留每个主张需要的顺序、动作、质量、安全或人工边界 oracle。

每个主张都对应一个可执行 oracle 和一个带范围的指标。Phase/action 结构用 V-measure 和相邻边界 F1 评分；grouped-action 用人工 group id 评分；looping、safety、step correctness 和 redundancy 使用数据集原生标签；递归深度使用同一批 operations 下 unique stack 和 compression 变化。我们从 AgentRewardBench、SATraj-OS、AgentNet 和 OSWorld-Human 的 operation JSONL 构造 6 个 oracle-backed analysis tasks，并把 flat、fixed-session、dataset-native hierarchy、raw action stack、operation-stack、label-drilldown oracle view 与 width、visible-risk、query-aware 和 oracle-upper-bound rankers 放在同一评分协议下比较。指标包括 precision@k、recall@operation-budget、

F1@k、AUPRC-style average precision、nDCG、work-to-first-positive、groups-to-50% recall、group count 和 task-level profile-configuration insight。

Hidden-label scoring 把答案字段从 profiler input 中隔离出来。非 oracle policies 只读取 status、repeat_signal、phase、action 和 environment 等可见 operation fields，不读取 looping、safety、step_correct 或 target_positive。因此 first-positive、first-enriched 和 high-lift results 都是同一 operation/operation-stack 输出的事后 oracle scoring，而不是 automatic detection、人类效用或答案泄漏。

机制实验把 field derivation 和 boundary derivation 都限制在两个抽象内。监督式 adjacent-boundary backend 只写回 learned_group_pattern、learned_segment_pattern、learned_segment_position 和 learned_boundary_prev 等 operation fields，递归折叠仍由 agentpprof 使用普通 --profile-spec 和 --stack 完成。每个候选标签家族还必须经过 suitability 和 simple-baseline comparison，防止把 safety、history context 或 repetition proxy 错当作语义边界。负结果也保留在论文中。AgentNet 的 task status 很弱地预测 per-step correctness，repeat signal 也很弱地预测 step redundancy。这些反例说明 profiler 能承载诊断字段，但简单 mapping 不能替代专门质量模型。

复现约束把论文主张连接回可重放结果。我们只把可重放 profile results 中已经存在的数字和数据来源选择写进论文主张与局限，并用 profile specs 固定 operation source、mapping、ranker、stack 和 deterministic output 选项。这个设置让论文检验 profiler 自身是否能在真实 workload 上相对 dataset-provided hidden labels 定位、排序并指导优化，而不是提前声称 analyst 使用它更快。

4.1 Hierarchy ablation baselines

本文比较的是 hierarchy choices，而不是把每个已有 observability 产品完整复刻一遍。Flat profile 把每个任务压成一个 summary group，用来检验 operation stack 是否比无层级摘要更 selective。Fixed-session drilldown 把 session 或 demo id 放进 stack，用来模拟 session/prompt-first 调试界面和传统 trace-tree drilldown 的碎片化风险。Prompt/session tree、tool-call hierarchy 和 OTel/span-like trace tree 在本实验中都建模型为不同 stack specs。它们仍然读取同一批 operations，只是把 session、prompt、tool、process 或 trace id 放在更靠前的 frames。Label-drilldown 是 oracle-aware upper-bound style view，它把 hidden label 直接放入 stack，用来界定“如果答案字段已经可见”时的上限，而不作为真实用户界面 baseline。这些 ablations 隔离边界选择对聚合、selectivity、recall 和 inspected work 的影响。因此本文不会声称 agentpprof 支配所有生产 observability UI，只声称 operation stack 把这些边界选择统一成可配置查询。

5 结果

本文按四个研究问题呈现结果，而不是按实验执行顺序展开。前三个问题是 empirical profiling experiments。RQ1 检查 operation generality、递归 stack folding、field derivation 和人工边界能否落在同一个两抽象模型中。RQ2 是 hidden-label localization/ranking 主实验。RQ3 用 ranker、stack、mapping、transfer、case 和 profile-spec patch 消融解释机制与 actionability。RQ4 检查 profile-spec 可复现性、离线

表 1: 公开标注轨迹数据源和当前用途。15 个来源支撑 E1 覆盖; ScaleCUA 是补充点。RQ2 hidden-label 主结论依赖 AgentRewardBench、SATraj-OS、OSWorld-Human 和 AgentNet 四个 oracle-rich 数据源。

数据源	原生标注	转换方式	主要用途
WebLINX, Mind2Web, AgentTrek, WebShop	web action, demo/task, reward 或 action history	HF Dataset Viewer 或 HF repo shard	web navigation 和 shopping trajectories 的跨源覆盖。
API-Bank, ToolBench, tau-bench	API/tool call, solution path, 多轮 user/assistant/tool messages, outcome	HF rows 或 repo JSONL	tool/API/dialogue phases 和 user-agent-tool operation 形态。
SWE-agent	issue trajectory, command action, success target	HF Dataset Viewer	software-agent command 轨迹。
AndroidControl, GUI-Odyssey	mobile/cross-app step action 与 instruction	public/HF samples	移动 GUI action depth 和跨 app scale。
AgentRewardBench	expert success, side-effect, looping, optimality	annotation rows 加 cleaned BrowserGym steps	failure, looping, side-effect 的非 flame-graph 诊断。
SATraj-OS	desktop action, success, safety, reward, attack type	HF safety config	桌面安全和 attack-type operation fields。
OSWorld-Human	human single-action 和 grouped-action 轨迹	GitHub JSON files	人工 grouped-action 边界 oracle。
AgentNet	human desktop PyAutoGUI, task outcome, step correctness, redundancy	HF repo JSONL streaming	最大 human desktop step-quality oracle。
ScaleCUA	GUI navigation action, previous-operation context, gold action	HF annotation JSONL streaming	补充多步 GUI history-depth 覆盖。

成本和主张边界。这种组织方式把正文集中在支撑主张的比较、消融、反例和复现实验上, 其他分析只作为补充证据。

评估证据按四步阅读。表 1 给出 workload sources, 表 2 对齐四个研究问题的主张和证据, 表 3 检查两抽象和递归折叠, 表 5 与图 1 左图给出 hidden-label fidelity 和 baseline tradeoff, 表 6 与图 1 右图给出 mechanism/actionability, 表 7 和表 8 给出 replay/cost 证据。Portfolio, case 和 verdict 视图只解释这些主图表的数据来源、反例和适用边界。如果 RQ2 的 Pareto 条件或 RQ3 的 mechanism/actionability 条件不成立, 本文应该收窄主张, 而不是扩大实验叙事。

5.1 RQ1/E1: 泛化覆盖、递归折叠和边界字段

RQ1 检查同一个 operation layer 能否覆盖异构 agent traces, 并避免把 prompt、session 或 tool 边界写死成 profiler 层级。它使用 public dataset labels、native trajectory fields、OSWorld-Human human boundary 和 AgentNet quality labels 作为 oracle, 比较 dataset-native stacks、no-map folding、fixed-session stacks、profile-spec replay 和 trace round trip。主要指标包括 operation coverage、unique-stack range、mapping compression、boundary F1/V-measure 和 replay equality。这个问题只支持 configurable operation-stack folding, 不支持完整生态兼容或自动恢复所有 latent intent。Prompt、tool、process 和 syscall 可以是 operation records 或 fields; session/span 是字段、容器或 baseline shape, not new profiler objects。

核心 14 数据集产生 42,590 个 operations 和 1,497 个 unique stacks, compression ratio 为 28.45。加入 ScaleCUA 补充样本后, 总量为 47,590 个 operations 和 1,611 个 unique stacks, compression ratio 为 29.541。这些 operations 覆盖 web、mobile、desktop、software、API、tool-agent-user dialogue、expert failure labels、safety labels、human grouped-action labels 和 desktop step-quality labels。所有这些标签都以 operation fields 形式进入同一 pipeline。没有任何数据集需要新增 prompt、session、GUI、safety 或 quality-specific profiler object。

这支持 C1 的机制性版本: agentpprof 可以把异构 agent 轨迹统一为 operations, 并用用户指定 stack 折叠。它不支持所有 agent 数据都容易转换。适合该方法的轨迹通常具备四个特征: 有有序 step 或 turn, 有稳定 session/task

id, 有动作或阶段标签, 有 outcome、quality、group 或 safety 等较高层 oracle。只有静态截图 grounding、缺少顺序、缺少 action label、强依赖大图片归档或 gated access 的数据源更适合作为后续扩展, 而不是当前主证据。

表 3 给出 E1 的证据路径, 后文围绕这些比较解释机制和边界, 而不是把来源核对写成单独实验。

递归 stack-depth sweep. Depth-sweep 主结果在同一批 13,265 个 operations 上扫过 8 个 stack depths。只保留 dataset 时有 9 个 stacks; 加入 task 后为 11 个; phase depth 为 57 个; tool/semantic depth 为 226 个; action depth 为 455 个; 加入固定 session 后膨胀到 3,757 个。相对于 dataset depth, 固定 session 的 unique stacks 增加 417.4 倍。这个结果直接反驳把 session 或 prompt 作为默认 profiling 边界的设计。Session 是有用 drilldown field, 但如果默认写死在 stack 里, 它会把可聚合的行为切碎。

早期 3,797-operation set 上也出现同样信号。Flat/mapped stack 为 103 个 unique stacks, 而固定 demo/session stack 为 1,083 个 unique stacks。这说明固定边界会带来约 10.5 倍碎片化, 而 mapped operation stack 可以保留聚合同时增加语义深度。因此论文中的 novelty 不是“画 flamegraph”, 而是把 agent profiling 的边界选择变成 operation-stack query。

Profile spec 把这个 query 自由度变成可复现实验配置。同一个 AgentNet spec 引用相同 operation JSONL 和 op-map 文件, 默认产生 608 个 diagnostic stacks; 命令行只覆盖 --stack 和输出路径后, 样本数保持 16,741 不变, unique stacks 降到 83。这说明 stack 深度是可审计、可覆盖的查询参数, 而不是写死在 prompt/session 或某个可视化中的层级。

这种可配置性不只改变图的形状, 也改变可验证的问题。Depth sweep、stack tree、transition/top-field、quality、grouped-boundary 和 history-depth views 都服务同一个机制问题, 即 profiler 是否可以把边界选择延后到查询时, 而不是在采集时固定为 prompt、session 或 span tree。当前证据支持三条带范围的结论。第一, 异构轨迹和本地 session 可以先进入同一 operation layer, 再用用户选择的 stack 折叠。第二, recursive stacks 能表达 dataset、task、phase、tool、action、human-group、safety 和 quality-label 等多种深度, 但不能声称恢复所有真实意图边界。第三, field derivation

表 2: 四个研究问题及其证据边界。每行给出 workload、oracle、主要证据和该证据支持的结论。

研究问题	Workload / oracle	主要证据	支持的结论
RQ1/E1: 泛化覆盖、递归折叠和字段派生	15 public labeled trace families / 47,590 operations, plus local-session and standard-trace exchange fixtures. OSWorld-Human and AgentNet provide the strongest boundary and step-quality oracles.	Core sources contain 42,590 operations; Scale- CUA brings the coverage sample to 47,590; the same operations fold from 9 dataset stacks to 57 phase, 226 semantic, 455 action, or 3,757 fixed-session stacks. AgentNet profile-spec override changes 608 stacks to 83 without changing input operations. Automatic operation-stack induction produces variable-depth stacks on 4/6 hidden-label tasks and stops on 2/6 when visible evidence has no material split. Held-out mapping improves compression from 14.049 to 19.091; OSWorld-Human learned boundary F1 reaches 0.7735; boundary backends beat the best simple baseline on 4/5 rows.	Heterogeneous traces enter one operation layer, and stack depth is a recursive query over fields. Mapping, tagging, and boundary backends derive fields before folding; they do not add prompt/session/tool/safety-specific profiler objects or automatic intent boundary discovery.
RQ2/E2: hidden-label 定位和排序	Six failure, safety, quality, and boundary tasks over AgentRewardBench, SATraj-OS, AgentNet, and OSWorld-Human; 34,539 operations / 3,699 positives.	The benchmark scores 144 view/ranker policies. Query-aware operation-stack top-5 groups inspect median 0.0937 work versus 1.0 for flat, improve top-5 recall over fixed-session on 5/6 tasks, and reduce median groups from 285.0 to 157.5. Work-budget, fragmentation, fixed-recall, sequence-scope, oracle-depth, uncertainty, negative-control 和 multi-metric analyses test robustness rather than define separate experiments.	Operation-stack profiling is faithful to dataset-provided hidden labels under this benchmark and gives a better inspection-work/median-fragmentation Pareto point than flat or fixed-session alone. It is not a universal detector, a single best hierarchy, or a work-dominant replacement for drill-down views.
RQ3/E3: 机制隔离和可操作性	The same six labeled tasks, plus held-out OSWorld-Human boundary-backend operations.	Operation-level rank features and ablations expose useful and misleading fields; profile-spec patches improve 5/6 tasks with median AP delta 0.0376 and lift delta 0.5750. Induced depth sweep finds best query-aware median AP at depth 3 and lowest median top-5 work at depth 5. Learned-boundary fields improve OSWorld-Human AP to 0.2583 and reduce groups to 74, but increase top-5 work and first-positive work.	The profiler produces profile-configuration actionability: which operation fields, operation-stack depths, mappings, rankers, lenses, and drilldown views to tune. It keeps automatic action selection, automatic patch selection, and automatic boundary discovery out of scope.
RQ4/E4: 可重放性、离线成本和主张边界	76 operation-JSONL profile 配置, 以及 local-session, agent-trace 和 standard-trace input replay checks.	Deterministic replay 覆盖 152 次 profiler 执行。Semantic determinism 在两种模式下均为 76/76. Deterministic output 将 raw-byte determinism 提升到 76/76, median runtime 为 1.601s, p95 为 2.767s. Source selection, regex tags, trace inputs 和 effective standard-trace args 都通过同一 operation-stack path replay.	The offline profiler path is replayable and cheap enough for artifact evaluation. This result does not measure live eBPF overhead, human productivity, or full trace-ecosystem compatibility.

表 3: E1 主证据表: 同一个 operation layer 可以被递归折叠、mapping、tagging 和 boundary scoring, 而不引入 prompt/session/tool-specific profiler object。

Evaluation question	Workload/oracle	Main evidence	Counterpoint / scope
异构 operation layer	15 个 public labeled trace families / 47,590 operations	Web, mobile, desktop, software, API, dialogue, failure, safety, human-boundary 和 step-quality labels 都作为 operation fields 进入同一 pipeline。	这是 lightweight sampling; image-heavy 或受限访问的完整 benchmarks 仍是 out of scope。
递归 stack choice	同一批 13,265 operations, 加 AgentNet profile-spec override	9 个 dataset stacks, 57 个 phase stacks, 226 个 tool/semantic stacks, 455 个 action stacks 和 3,757 个 fixed-session stacks; AgentNet 在不改变 16,741 个 input operations 的情况下从 608 个 stacks 改成 83 个 stacks。	Fixed sessions 可以作为 drilldown fields, 但 hard-coded 到 stack 里会造成 fragmentation。
先派生 fields 再折叠	Held-out mapping 和 boundary-backend rows	Mapping 把 compression 从 14.049 提到 19.091; leave-dataset-out 在 6/9 个数据集上减少 stacks; boundary backends 在 4/5 rows 上优于 best simple baseline。	Mapping 会把 action-to-phase V-measure 从 0.9343 降到 0.7416; looping 由 repeat_signal_change 解释。
Human-boundary folding	OSWorld-Human exact-aligned tasks	4,011 operations / 2,075 human groups; grouped-depth stacks 把 482 个 action stacks 降到 106 个; group-pattern boundary F1 为 0.627, precision 为 1.0。	这是带范围的人类分组对齐结果, 不是自动恢复所有 latent intent boundary。

是可扩展接口, 因为 mapping 和 supervised backend 只写入 operation fields, profiler 仍按 operation stack 折叠。这些机制结果支撑本文的新意, 但 user-utility、通用 boundary detector 和完整 trace-platform compatibility 仍是后续工作。

Rust operation-stack induction 进一步检验“不是用户给固定 stack 字段链”的实现路径。在 AgentRewardBench looping slice 上, agentpprof 用 `--induce-operation-stack` 从可见 evidence、semantic shift、changed-field density 和 query hint 给相邻边界打分, 并输出 induced operation-only stacks。在六个 hidden-label tasks 上, 同一个实现作为普通 profiler view 运行时, 4/6 tasks 产生 variable-depth stacks; 2/6 AgentNet quality tasks 因可见 evidence 没有 material split 而停在一个 induced segment。其中 AgentRewardBench 和 OSWorld-Human 的 stacks 覆盖深度 2/3/4, SATraj 同时保留深度 1/2/3/4。这个自动 view 的 median groups 为 12.0, 远低于 fixed-session 的 285.0; median top-5 work 为 0.653, 低于 flat summary 的 1.0。同时它的 median AP 为

0.2762, 低于 hand-configured operation-stack query-aware 的 0.3116。同一 induced view 的 depth sweep 进一步说明深度是 profile 配置: query-aware median AP 在 depth 3 最高, 为 0.2865; median top-5 work 在 depth 5 最低, 为 0.4727; 有 material split 的四个任务 AP-best depth 分散在 2、3、4 和 5。这说明同一个 prompt/action 序列可以被自动折叠成参差不齐的 operation stack, 但它支持的是 configurable recursive folding 和 depth tuning, 不是取代 task-specific profile specs, 也不是自动发现所有 intent boundary。表 4 汇总这组三层证据。机制形成、hidden-label localization 消融和深度调优分别支撑不同主张, 并各自保留不支持的边界。

Field derivation 和 boundary probes. 本节支持的是 configurable deterministic/supervised field derivation 在合适标签家族上的迁移, 而不是通用无监督边界发现。Held-out mapping rules 在 3,990 个 operations 上把 compression 从无 mapping baseline 的 14.049 提高到 19.091, held-out stacks 从 284 降到 209, 并把 task/dataset V-measure 从 0.837 提高到 0.853。Phase/action boundary F1 为 0.777、

表 4: 自动 operation-stack induction 的 claim-facing 证据。该表把递归形成、hidden-label 定位消融和深度调优连到同一 profiling claim; hidden labels 只在 profiling 后评分。

证据块	读者问题	主要数字	支持的结论 / 边界
E1 recursive formation	profiler 能否在没有用户指定 field chain 的情况下形成递归 operation stack?	729 个 operations; 15 个 induced stacks; 深度直方图 2:1/3:1/4:13; session-as-evidence view 有 16 个 stacks。	可见边界证据足以诱导参差递归的 operation-only stacks, session 只是可选 evidence field。不能声称自动发现所有 intent boundaries。
E2 localization ablation	induced stacks 能否作为真实 hidden-label tasks 上的可见 profiler view?	4/6 tasks 形成 variable depth, 2/6 tasks 在 material stop 停止; AP 0.2762 vs hand-configured 0.3116; work@5 0.653 vs flat 1; groups 12 vs fixed-session 285。	induction 降低 flat inspection work 和 fixed-session fragmentation, 但 AP 仍弱于 hand-configured specs。不能把它写成 task-specific profile specs 的替代品。
E3 depth actionability	induced-stack depth 是否是实际可调的 profiling surface?	query-aware median AP 在 depth 3 最高 (0.2865); median work@5 在 depth 5 最低 (0.4727); material-split AP-best depths 覆盖 2, 3, 4, 5。	不同目标偏好不同递归深度, 因此 depth 是 profile-configuration knob。不能声称自动 depth selector 或 analyst-productivity 改善。

precision 为 1.0, 说明当前 mapping 保守: 它不会制造 false positive phase changes, 但会合并一些 fine-grained action changes。Leave-dataset-out mapping 在修正 API/tool phase precedence 后, 在 9 个 held-out datasets 中的 6 个减少 unique stacks, 0 个出现 negative stack-reduction regression, weighted stack reduction 为每 1,000 operations 1162.005。这些结果说明 mapping 不是单个数据集的 ad hoc pretty printer, 但它仍是 deterministic taxonomy-seeded field derivation, 不是无监督边界发现。

Boundary backend 提供更强但仍带范围的 field derivation 证据。在 OSWorld-Human exact-aligned sessions 上, held-out adjacent-pair backend 使用非 oracle operation fields 训练, 明确排除 `human_group`、`group_index`、`group_position`、`group_size`、`group_pattern` 和 `group_alignment`。它在 held-out pairs 上达到 precision 0.7400、recall 0.8102、F1 0.7735, 高于 phase-change baseline 0.2919、action-change baseline 0.5142 和 conservative `group_pattern` reference 0.5810; 预测字段写回 `learned_group_pattern` 和 `learned_group_position` 后, Rust agentpprof 在 1,132 个 held-out operations 上折叠得到 74 个 stacks。这支持 supervised boundary fields 可以作为普通 operation fields 被 folding 使用, 不支持新增第三个 profiler object。

Field-derivation analysis 同时保留反例。Mapping 提高 compression, 但把 action-to-phase V-measure 从 0.9343 降到 0.7416, 说明它是聚合机制而不是细粒度边界 oracle。跨标签家族的 boundary suitability check 中, learned boundary backends 在 4/5 rows 上胜过 best simple baseline; 可训练 rows 的 held-out F1 分别是 OSWorld-Human 0.6916、AgentNet step-correct 0.3197、AgentNet step-redundant 0.3361 和 AgentRewardBench looping 0.7833。AgentNet 两个 quality-state boundaries 优于 always-boundary baselines (0.2155 和 0.2645), 但仍有 precision 和 calibration caveat; AgentRewardBench looping 虽然 learned F1 达到 0.7833, 却被 `repeat_signal_change` baseline 的 1.0 F1 完全解释。因此 E1 的结论是: mapping、tagging/rank features、profile specs 和 supervised boundary backends 都只是写入 operation fields, 然后由 operation stack 折叠; 它们

支持 first-class field derivation 和 suitability checks, 不支持 automatic intent boundary discovery。Suitability analysis 把这个扩展策略写成更明确的配置决策。Deterministic mapping 适合 compression, 但会粗化 action boundary; rank features 需要 ablation evidence, 因为真实任务里既有 critical feature rows, 也有 misleading feature rows; boundary-derived fields 必须先过 family-specific suitability。当前 boundary-family 决策包含 1 个 accept、3 个 caution 和 1 个 reject, 因此 field derivation 是有条件的 profile-configuration loop, 不是 universal automatic selector。

Human-boundary oracle. OSWorld-Human 是当前最强的 grouped-boundary oracle。转换器覆盖 369 个 human desktop tasks 和 6,010 个 single-action operations; 只有 grouped-action 序列与 single-action 序列 exact-aligned 的 320 个 tasks 被写入 `human_group`、`group_pattern` 和 `group_position` oracle fields。这些 exact-aligned tasks 含 4,011 个 operations 和 2,075 个 session-local groups; 31 个 content-mismatch tasks 和 18 个 length-mismatch tasks 保留用于 action profiling, 但不被当作 gold group oracle。在同一批 exact-aligned operations 上, action-depth stack 有 482 个 unique stacks, grouped-depth stack 降到 106 个; 保守 `group_pattern` 对人工 `human_group` boundary 的 F1 为 0.627, precision 为 1.0, recall 为 0.456。这不是完美边界 detector, 但它给出有意义结论: operation stack 可以在同一条单动作序列上选择 action-depth 或 group-depth, 并以人工 grouped-action 标签作为 oracle 验证。Prompt 或 session 没有参与这个抽象。

5.2 RQ2/E2: Hidden-label localization 和 ranking

RQ2 检验 operation-stack profiling 能否在真实 labeled traces 上完成 faithful localization 和 ranking。我们把 6 个 oracle-backed tasks 中的 34,539 个 operations 和 3,699 个 hidden positives 作为评分对象, 并比较 flat summary、fixed-session drilldown、dataset-native hierarchy、raw-action stack、operation-stack width、operation-stack query-aware、label-drilldown 和 oracle upper bound。评

分指标包括 precision@k、recall、F1、AUPRC-style AP、nDCG、recall/F1@work budget、work-to-first-positive 和 group count。Flat 和 dataset-native 可以赢 broad-recall 或 nDCG 目标，因此主张必须是 Pareto tradeoff，而不是 metric dominance。这一节的核心问题是 hot stacks 和 top-ranked groups 是否真的对应 hidden positives，并且是否能相对 flat summary 降低 inspection work、相对 fixed-session drilldown proxy 改善 localization-budget/fragmentation tradeoff。

本节的主比较和成功条件是评估结论的入口。E2 把每个 profile group 当作 inspection target，检查 ranked targets 能否用比 flat summary 更少的 work 找到 hidden positives，并比 fixed-session trace-tree proxy 更少碎片化。成功条件不是单一指标第一，而是 Pareto 条件：operation stack 必须降低 flat inspection work，在有意义的 fixed-session localization 或 fragmentation objective 上改善，同时保留 fixed-session early-hit 反例。本节的主实验不是重新定义一个 agent benchmark，而是把真实标注轨迹中的 failure、safety、quality 和 human-boundary labels 当作 profiler localization oracle。6 个任务覆盖 AgentReward-Bench looping/side-effect、SATraj unsafe、AgentNet incorrect/redundant steps 和 OSWorld-Human group starts，总计 34,539 个 operations、3,699 个 positives。E2 scoring pipeline 把每个 view/ranker 的 hot groups 当作 ranked localization result，用 hidden labels 计算 precision@k、recall@budget、F1、AUPRC-style AP、nDCG 和 work-to-first-positive。比较对象包括 flat、fixed-session drilldown、dataset-native hierarchy、raw action stack、operation-stack、label-drilldown oracle view，以及 width、visible-risk、query-aware 和 oracle-upper-bound rankers。非 oracle policies 只使用 visible operation fields；label-drilldown 和 oracle-upper-bound 只作为上界。表 5 给出主要 policies 的 median 结果：operation-stack query-aware 在 top-5 groups 中只检查 0.0937 operation fraction，而 flat summary 必须检查 1.0；相对 fixed-session query-aware drilldown，operation-stack top-5 recall 在 5/6 tasks 上更高，并把 median group count 从 285.0 降到 157.5。这支持的是 inspection-work/fragmentation Pareto tradeoff，而不是 metric dominance：dataset-native hierarchy 的 median top-5 recall 达到 0.8665 但 work 为 0.8539；fixed-session 的 work-to-first-positive 只有 0.0044，但 top-5 recall 只有 0.0233。

Failure interpretation 和 baseline scope 也是结果的一部分。Fixed-session drilldown 是当前已评估的 trace-tree-shaped baseline；这不等价于完整导入 OpenTelemetry、Phoenix、LangSmith、Langfuse 或 Perfetto ecosystem traces。在同一批 scored rows 上，operation-stack query-aware 相对 fixed-session 在 5/6 tasks 上提高 top-5 recall 和 F1，在 4/6 tasks 上提高 budget-30 recall，并在 4/6 tasks 上减少 group count；同时 fixed-session 在 4/6 tasks 上保留更低 top-5 work 和 first-positive work。Depth-aware slice 细化同一主张。Operation-stack rankings 在 20/24 task-depth rows 上超过 fixed-session budget-30 positive-unit recall，并在 22/24 rows 上用更少 groups 到达 50% positive units。如果这些反例从论文里消失，主张就会被写过头；保留它们后，E2 支持的是更好的 localization-budget/fragmentation tradeoff，不是对所有 trace-tree-shaped objectives 的 dominance。Automatic induced operation stacks 给出同一 tradeoff 的机制侧证据。它们在不要用户给固定 stack 字段链的情况下，用可见 boundary evidence 产生 variable-

depth groups 或在证据不足时停止，并在同一 hidden-label scoring pipeline 下取得 median top-5 work 0.653 和 median groups 12.0。同一 induced path 上改变 depth cap 会改变 profile 表面：depth 3 给出最高 query-aware median AP，depth 5 给出最低 median top-5 work，且有 material split 的四个任务 AP-best depth 与 work-best depth 都不同。这个结果比 flat 更省检查、比 fixed-session 更少碎片化，但 AP 仍低于 hand-configured operation-stack，所以 E2 主结论仍以 query-aware operation stack 为主。Case views 只解释 localization result 的可复查性。这些 examples 只使用可见 operation fields，再用隐藏标签事后评分，因此可以展示 top-ranked operation-stack groups 为什么命中或误导，同时保留 flat full-recall 与 fixed-session early-hit 反例。主准确性主张仍然来自统一的 hidden-label scoring，而不是来自 case 展示本身。

同一批 scored groups 也可以组织成 flamegraph 之外的分析视图。主文只保留一个代表性图，把 E2 的 localization/work/fragmentation tradeoff 和 E3 的 profile-configuration knobs 放在同一分析视图中。其他任务级 views 作为补充材料保留，用来解释主实验而不是制造新的主实验。

任务级 views 把主实验的 aggregate result 落到具体诊断结论上。它们显示 6/6 tasks 相比 flat summary 改善 AP 和 top-five inspected work，5/6 tasks 相比 fixed-session drilldown 改善 top-five recall，4/6 tasks 降低 fixed-session group fragmentation，并且 6/6 tasks 都有 actionable configuration result，即 profile-spec patch 或 boundary-field repair。这些 views 也保留负证据：fixed-session 在若干任务上仍然是 first-positive 或 group-count counterpoint，OSWorld-Human 需要 boundary-derived fields，而不是 visible phase/action ranking alone。

E2 的 robustness evidence 只检验 Pareto 结论是否稳健。Bootstrap 和 label-permutation analyses 显示，operation-stack query-aware 的 AP、top-5 work、budget recall 和 group-count deltas 在 6/6 tasks 上方向稳定；AP 在 6/6 tasks 上超过 95% prevalence/group-size null，30% budget recall 在 5/6 tasks 上超过 null。Work-budget、fragmentation 和 oracle-depth analyses 再把收益拆到检查成本上：30% work budget 下 median recall 为 0.3900，高于 fixed-session 的 0.3559 和 flat 的 0.0000；相同 budget 下它在 5/6 tasks 上检查更少 groups，同时保留 fixed-session first-positive-work 反例；在 24 个 task-depth rows 中，它有 20 个提高 fixed-session budget-30 positive-unit recall，并在 22 个 rows 用更少 groups 达到 50% positive units。这些 analyses 合起来支持 faithful localization surface 和 inspection-work/fragmentation tradeoff；它们不支持 single best hierarchy、human productivity 或对所有 trace-tree-shaped objectives 的 dominance。

E2 的带范围结论是 operation-stack profiling 在真实标注轨迹上能把 hot groups 排成对 hidden positives 有信号的 localization surface，相比 flat summary 明显减少 inspection work，相比 fixed-session drilldown 通常改善 median fragmentation tradeoff 或提高同预算 recall。它不能写成 automatic detector、single best hierarchy、human/agent analyst productivity，或对真实 OpenTelemetry/Phoenix/LangSmith/Perfetto span tree 的完整兼容和支配。Work-budget、fragmentation、fixed-recall、sequence-scope、oracle-depth、uncertainty、negative-control 和 multi-

表 5: E2 hidden-label localization benchmark. Hidden 表示 policy 是否读取 oracle label; WTFP 是 work-to-first-positive. 非 oracle policies 只读 visible operation fields, hidden labels 只用于 scoring.

Policy	Hidden	AP	nDCG	P@5	R@5	F1@5	Work@5	R@30%	WTFP
flat:width	no	0.1678	1.0000	0.1678	1.0000	0.2868	1.0000	0.0000	1.0000
fixed-session:query-aware	no	0.3476	0.7642	0.2555	0.0233	0.0427	0.0163	0.3559	0.0044
dataset-native:query-aware	no	0.3572	0.7445	0.1712	0.8665	0.2822	0.8539	0.3377	0.0582
raw-action:query-aware	no	0.2744	0.5012	0.2513	0.2442	0.2195	0.1507	0.3325	0.0374
operation-stack:width	no	0.1610	0.9364	0.1398	0.4746	0.2147	0.5424	0.3372	0.1694
operation-stack:query-aware	no	0.3117	0.5487	0.1991	0.1880	0.1981	0.0937	0.3900	0.0378
operation-stack:oracle-upper	yes	0.5993	0.6372	0.8984	0.3004	0.4029	0.0441	0.5640	0.0122
label-drilldown:oracle-upper	yes	1.0000	1.0000	1.0000	0.6703	0.7972	0.1150	1.0000	0.0377




图 1: 两个非 flamegraph 分析视图。左图把 RQ2/E2 的核心 tradeoff 放在同一坐标系中, operation-stack query-aware 位于 flat summary 的低 work 区域, 同时保留 fixed-session 和 oracle 上界反例。右图把 RQ3/E3 的 actionability 展开为 profile-configuration knobs, 显示多数 objective rows 需要改变 view、ranker、profile spec 或 boundary-derived fields, 而不是使用一个固定默认视图。

metric analyses 共同约束同一个 E2 主实验的适用范围。

5.3 RQ3/E3: 机制隔离和 actionability

RQ3 检验 profiler 是否能够通过 operation fields、operation-stack depth、mapping/tagging rules、ranking policies、profile specs 和 boundary-derived operation fields 暴露 actionable optimization knobs. Hidden labels 仍然只在 profiling 之后用于 scoring, boundary-derived fields 还用 held-out OSWorld-Human boundary positives 评分。我们比较 default semantic-width specs、patched specs、visible feature rankers、transfer policies、learned-boundary stacks、fixed-session 和 semantic-width stacks, 并报告 accepted patches、AP delta、top-5 lift delta、first-positive-work delta、group reduction 和 top-5 work counterpoint. OSWorld-Human 需要 boundary-derived fields, 这说明 RQ3 评估的是可操作机制证据, 而不是自动边界发现或自动 patch 选择。这一节的问题是 localization gain 来自哪些机制, 以及 profile-guided 的 operation fields、operation-stack depth、rank features、mappings 或 boundary-derived fields 能否在不把 hidden labels 泄漏进 profiler input 的前提下改善输出。Rank-feature、mapping、stack-depth、boundary-field、profile-spec patch、case view、diagnostic lens 和 transfer counterpoint 共同支撑同一个 RQ3 主张。

主要机制问题是 E2 的 ranked groups 能不能解释应该怎样改 profile configuration. Hidden labels 只在 profiling 之后用于 scoring; visible inputs 仍然是 operation fields、operation-stack depth、mapping/tagging rules、rank features、profile specs 和 boundary-derived operation fields. 成功条件是 actionable、replayable diagnosis. 每个任务应该指向具体的 operation field、stack depth、ranker、mapping、profile-spec 或 drilldown change, 并且 executable patches 能改善 scored output, 但不能把结果写成 automatic selector。

表 6 是 E3 的主显示, 它把 task-level localization signal 转成 diagnosis table. SATraj unsafe 说明

environment、phase、action 和 risky/write-action ranking 对安全问题有效; looping 说明 repeat_signal 有用但需要 prevalence-aware ranking; side-effect 指向更深的 write/input mapping; AgentNet step-quality 需要 action-family 定位后再进入 fixed-session examples; OSWorld-Human 则需要 boundary-derived fields. 因此 actionability 的第一层结论是: profiler 指出该调 operation field、stack depth、mapping、ranker、profile spec、boundary field 还是 drilldown, 而不是给出唯一默认 view. Task-level verdict synthesis 给出任务级结论: 6/6 任务都是支持但有反例, 不是无条件胜出。其中 5/6 任务有 accepted executable profile-spec patch; 剩下的 OSWorld-Human row 指向 boundary-derived fields, 并保留 top-five 与 first-positive work 反例。这 6 行进一步收敛成三类可复用优化模式。Safety 和 side-effect 任务指向 field 与 ranker 修改, 因为 environment、phase/action 和 write/input fields 会把相关 positives 推到更小的 inspected region. Step-quality 任务指向 drilldown workflow, 因为 desktop phase、repeat 和 action fields 先定位可疑区域, 再由 fixed-session examples 解释单条 trace. Human-boundary 任务指向 representation repair, 因为 action-depth stack 不够, boundary-derived operation fields 能提高 AP 并减少 groups, 但仍保留 inspection-work 反例。这些模式给出的是 profile inputs、operation fields、stack depth 和 rankers 的配置建议, 不是 profiler 自动预测出的标签. Field-suitability decisions 进一步说明这些配置建议何时可用. Deterministic mapping、stack depth 和 predicates、operation-level rank features、supervised boundary fields、boundary-profile repair 分别对应不同的 accept/caution/reject 条件。因此 E3 的 actionability 是 profiler 指出该调哪个 operation-field 或 operation-stack view, 而不是自动选择唯一正确视图或自动发现所有边界. Automatic operation-stack induction 也落在这个 actionability 边界内。它证明 profiler 可以从可见字段递归诱导 operation-only stack, 并把深度参差的 stack 当作可打分 view, 但它的 AP 反例说明 profile-

specific stack 和 ranker 仍然需要按任务调优。Depth sensitivity 把这点变成可操作结论：同一 induced profiler view 在 depth 3 取得最高 query-aware median AP，在 depth 5 取得最低 median top-5 work，而有 material split 的 task-level AP-best depth 跨 2、3、4、5 分布。因此 E3 的建议是调 operation-stack depth 和 ranker objective，而不是把 `analysis_task, phase, action, status` 当成固定 ontology。

机制消融说明这些诊断来自可复现的 profiler 配置。Stack-text rank rules 和 rank mode 可以从 profile spec 复现，但它们对 safety/side-effect 过粗；operation-level rank features 在 folding 前匹配 visible mapped operation tokens，semantic stack 的 feature ranking 在 AP 上赢 5/6 tasks、top-5 lift 赢 4/6、first-positive work 赢 5/6，coarse depth 在 4/6 tasks 上改善 AP 并减少 groups。Leave-one-feature 和 robustness analyses 说明哪些字段有用或有害：`repeat_signal`、`write-action` 和 `status=success` 在不同 family 关键，SATraj loop-like 或 OSWorld-Human input-phase features 会误导；global/equal feature banks 常能保留收益，guided repair 在 2/3 misleading-feature cases 上改善 AP。这些 repair 使用离线评分反馈，因此支持 mechanism isolation；它们不是自动 learned ranker，也不支持 automatic learned ranker。

View、depth 和 budget 审计把机制结果放回 profiling tradeoff。Best AP 和 best top-5 F1 分散在 operation-stack、fixed-session、dataset-native、raw-action 和 flat views；leave-task source selection 不能稳定选中 best view。但 operation-stack query-aware 在 6/6 tasks 上进入 Pareto frontier，相对 flat 在 6/6 tasks 降低 top-5 work，相对 fixed-session 在 5/6 tasks 提高 top-5 recall，并在 5/6 tasks 用更少 groups 达到 50% positives。25% recall target 下它覆盖 6/6 tasks，median work 为 0.2000 而 flat 为 1.0000，median groups 为 16.0 而 fixed-session 为 50.0；50% recall 和 first-positive work 仍保留 fixed-session、dataset-native 或 raw-action counterpoints。Sequence-scope 和 oracle-depth 审计进一步说明：30% work budget 下 positive-session recall 为 0.4669，高于 fixed-session 的 0.3230；24 个 oracle-depth rows 上 budget-30 positive-unit recall median 为 0.4342，并在 20/24 rows 提高 fixed-session unit recall、22/24 rows 用更少 groups 达到 50% positive units。Positive-run proxy units 是 episode-derived proxy units，不是 human intent；`positive-session-without-unit` fixed-session depth-gap counterpoint 仍然保留，所以这只是 depth-aware triage，不是自动发现所有 latent subtask 或 intent boundary。多指标审计也保留反例：30 个 baseline-metric comparisons 支持 operation-stack query-aware，16 个是明确 counterpoints，nDCG 场景下 flat 或 dataset-native 可能胜出。

Actionability view 把这些比较变成可以检查的优化建议。36/36 objective rows 都有具体 profile-configuration action，但 27/36 best visible policies 不是默认 operation-stack query-aware；transfer miss 多数对应 view 或 ranker 变化，而不是不可解释错误。同一证据可以从 diagnostic lenses、case examples 和 baseline contrasts 三个角度检查：6 个 lenses 覆盖 36 objectives，top-5 case groups 在 6/6 tasks 命中 positive，top-1 在 5/6 命中，median top-5 lift 为 1.6508 且 work 为 0.0937；operation-stack 在 6/6 tasks 胜过 flat top-5 work、在 5/6 胜过 fixed-session top-5 recall，同时保留 fixed-session first-positive 和 flat full-recall 反

例。Visible counterfactual 和 held-out transfer results 把行动建议与目标标签泄漏分开：36/36 best rows 是 visible non-oracle，27/36 需要 non-default action，25/36 需要 view change；held-out action transfer 在 35/60 aligned decisions 上 within tolerance，但 exact action-class transfer 只有 7/60，在 non-default target action 上只有 2/42。因此这里的主张是可调诊断界面，不是 label-free automatic selector。

Executable profile-spec patches 关闭一个从诊断到可执行配置的闭环。Default 与 patched profile specs 在同一 visible operation input 上实际运行 Rust `agentpprof --profile-spec`，hidden labels 只在 profiler 输出后评分；5/6 patches 同时改善 AP、top-5 lift 和 first-positive work，median AP delta 为 0.0376，median top-5 lift delta 为 0.5750。这里的 failure interpretation 同样重要：唯一 reject 是 OSWorld-Human，说明 visible phase/action rank features 不足以处理 human-boundary 目标。Held-out boundary-derived fields 随后作为普通 operation fields 折叠，AP 从 semantic-width 的 0.2402 提升到 0.2583，groups 从 108 降到 74；反例是 top-5 work 和 first-positive work 变差。这些 patch 和 boundary-field results 支持 boundary-derived fields 是 actionable operation-field knob，不支持 automatic boundary discovery、automatic patch selector 或第五个核心实验。

5.4 RQ4/E4：可重放性、离线成本和主张边界

RQ4 问复现者能否重放支撑 E1–E3 的离线 profiler 输出，并看清哪些主张仍未被测量。我们把 76 个 profile 配置和对应 operation inputs 当作复现单位，同时检查本地 session、agent-session trace 和 standard trace 这些输入来源是否都进入同一 folding path。我们比较 default output 与 deterministic-output replay，比较 semantic profile hashes 与 raw-byte profile hashes，并验证声明的 input paths 是否实际进入 operation-stack folding path。主要指标包括 spec pass rate、profiler invocation 数量、median/p95 runtime、sample equality、stack equality、raw-byte output equality 和 input-source coverage。这个问题只覆盖离线路径复现，不覆盖 live eBPF overhead、human utility、complete ecosystem compatibility 或 automatic universal selection。

本节只报告可重放性和离线成本。在同一批 operation JSONL inputs 上，agentpprof 重复执行 76 个 profile 配置，共 152 次 profiler invocations。默认模式下所有 specs 在重复运行中保持 semantic profile content、samples 和 unique stacks 稳定，median 每个 spec 运行时间为 1.581s，p95 为 2.719s；raw-byte determinism 只有 4/76，因为输出带生成时间戳。Deterministic replay mode 固定 JSON `generated_at` 和 pprof profile time 后，同一 76 个 specs 的 semantic 与 raw-byte determinism 均为 76/76，median 每个 spec 运行时间为 1.601s，p95 为 2.767s。这些结果说明复现者可以重放离线 profile content，并在需要时得到 byte-stable profile files。它们不等价于 live capture overhead，也不形成另一个经验性 profiling 实验。

输入来源 replay 说明 profile spec 是真正的数据入口配置，而不是只包了一层 output path。Rust profile-spec path 现在可以携带 `session_files`、`trace_files`、`standard_trace_files`、`regex` `tag_rules`、`predicates`、`rank rules`、`stack overrides` 和 `include_standard_trace_args`。回归测试把同一个 public Codex fixture 作为 local session 和 exported agent-session trace replay，并把一个 generic Chrome

表 6: E3 diagnosis/actionability summary. 每行把 hidden-label localization 信号、可执行 profile 配置动作和带范围的 verdict/counterpoint 放在一起, 展示 profiler 如何指向可调的 operation-field、stack-depth、ranker 或 boundary-field 决策。

Task	Localization signal	Profile action	Verdict / counterpoint
Looping	Work@5 0.4938, R@5 0.6508, patch AP +0.1155	保留 repeat_signal , 但加入 prevalence-aware ranking, 因为 positives 很常见。	支持但有反例: raw-action first-positive work 更低。
Side-effect	Work@5 0.1454, R@5 0.1139, patch AP +0.0591	提高 write/input 权重, 或在 ranking 前使用更深的 side-effect mapping。	支持但有反例: fixed-session groups 更少; raw-action top-five lift 更好。
Unsafe operation	Work@5 0.0420, R@5 0.2621, patch AP +0.5081	使用 environment、phase 和 action operation fields, 并选择更深的 operation-stack view; 优先 risky environment 和 write actions。	支持但有反例: fixed-session first-positive work 更低。
Incorrect step	Work@5 0.0014, R@5 0.0034, patch AP +0.0160	使用 desktop environment、phase、repeat 和 action fields, 再进入 fixed-session examples。	支持但有反例: fixed-session 仍是 drill-down baseline。
Redundant step	Work@5 0.0089, R@5 0.0177, patch AP +0.0011	使用 desktop environment、phase、repeat 和 action fields, 再进入 fixed-session examples。	支持但有反例: fixed-session first-positive work 更低。
Group start	Work@5 0.4074, R@5 0.3874, boundary AP 0.2583	使用 group-depth 或 boundary-derived fields; action-depth alone 会 fragment starts。	支持但有反例: boundary fields 把 groups 降到 74, 但 top-five 和 first-positive work 变差。

表 7: E4 可重复性和成本主显示。Runtime 为 Rust binary 已存在后的每个 spec 秒数; semantic hash 去除 JSON **generated_at** 字段, raw-byte hash 单独报告。

Workload	Specs	Med. s	P95 s	Med. stacks
View specs	4	3.448	4.273	631.0
Rank-feature specs	12	1.539	2.692	41.0
Robustness specs	60	1.542	2.640	41.0
All specs	76	1.581	2.719	42.0

表 8: E4 deterministic-output 主显示, 比较同一 76 个 profile specs 的默认输出和 **--deterministic-output** replay。

Config	Mode	Sem.	Raw	Med. s	P95 s
Default	default	76/76	4/76	1.581	2.719
Deterministic	deterministic	76/76	76/76	1.601	2.767

Trace Event 中的非 AgentSight protocol arg 导入为 operation field 后折叠。这些输入在导入后都归一成普通 operations, 再由同一 operation-stack machinery 折叠。这个结果支持 trace exchange 的最低复现要求, 但不支持完整 trace-ecosystem compatibility 主张。表 7 和表 8 是 E4 的两个主显示。前者呈现 replayability/cost result, 后者呈现 deterministic-output repair。表中的 labels 只标识 profile-spec families, 不是新的 accuracy 实验。

除了两张主表, RQ4 还约束论文数字、数据来源选择和明确排除的主张。这些一致性约束只核对已经报告的 profile results 和当前论文文本, 不重新排名、不下载、不同步、不创建、不重标数据集、不重跑 profiler, 也不运行 human/agent analyst task。上一节的 actionability 结论依赖这些可复现 profile 配置和 operation inputs。本节不重新验证 fidelity/accuracy、actionability 或 baseline tradeoff, 只证明复现者能重放这些配置, 并核对正文数字、数据来源选择和主张边界。因此 RQ4/E4 只支持复现和主张边界, 不是人工 analyst 主观解释、live overhead 或新的 profiler accuracy 结果。

E4 的辅助材料只约束正文和可重放结果的一致性。它们把论文主张、数据来源选择、明确排除的结论和 operation/operation-stack 边界对齐到 replayed profiles。这些材料帮助读者判断论文是否把证据写过头, 但不增加 localization、actionability 或 overhead 主张。这些辅助视图可以支持 E1–E4, 但不会形成额外主实验。

6 数据源选择与扩展边界

当前数据选择遵循 oracle-first 原则。Operation-stack profiling 的主张需要有顺序、有动作、并且能隐藏评分标签的真实轨迹。规模更大的数据集如果缺少这些字段, 只能支撑覆盖范围, 不能支撑 localization accuracy。OSWorld-Human 提供 single-action 和 grouped-action, 因此最直接

支撑递归边界验证。AgentNet 同时提供大规模人工桌面任务和 per-step correctness/redundancy, 因此支撑 step-quality profiling。AgentRewardBench 和 SATraj-OS 把评估目标从 action taxonomy 推到 failure、looping、安全和 side-effect diagnostics。GUI-Odyssey、tau-bench 和 Tool-Bench 则作为跨域覆盖来源, 说明 operation abstraction 可以覆盖移动 GUI、user-agent-tool dialogue 和 API/tool traces, 而不局限于桌面轨迹。

ScaleCUA 的作用是扩大 GUI history 覆盖, 而不是提供新的主证据。我们使用的 ScaleCUA stream sample 含 5,000 个 Ubuntu navigation rows, 覆盖 131 个 sessions, 最大 step 为 48。该子集的动作 taxonomy 主要是 click 和 terminate, 所以 phase/action 指标达到 1.0 并不表示强泛化。它更适合证明 multi-step GUI history context 可以被投影为 history_state 和 history_depth fields, 而不是证明复杂边界 detector。

7 相关工作

Profiling, flamegraphs 和 trace analysis. 传统 flamegraph 和 pprof 路线把运行时调用栈折叠成热点视图 [1,16,17]。pprof 不只是固定 call stack: 它支持 sample tags, 也支持用 tagroot/tagleaf 把 tag value 作为 pseudo stack frame 可视化 [17]。Perfetto 则代表系统 trace ingestion、SQL trace analysis、trace summary 和 derived events 的成熟方向 [18]。因此本文不能把新意写成“只有我们支持 query-time aggregation”。本文复用 folded-stack 表示, 但贡献来自三个部分的组合: agent-operation record model、recursive multi-field operation-stack projection, 以及真实标注轨迹上的 hidden-label localization benchmark。Stack frame 来自 agent operation fields, 而不是语言运行时函数调用或通用 trace SQL schema。因此同一批 operations 可以被折叠为 task、phase、tool、action、quality 或 safety 视图, 也可以改成 fixed-session 或 flat baseline。区别不在图形样式, 而在 agent 语义对象、递归多字段 stack projection 和跨数据集 hidden-label scoring。

Agent tracing 和 LLM observability. Open-Telemetry GenAI 和 OpenInference 标准化 GenAI spans、LLM calls、agent reasoning steps、tool invocations、retrieval operations、MCP 和 provider-specific telemetry [2,11]。LangSmith、Langfuse、Phoenix 和 AgentOps 等系统进一步把 LLM call、tool call、latency、token、trace tree、session、observation、evaluation score、goal、plan 和 agent artifact 放进单次 workflow inspection 与生产监控 [12,13,14,15]。这些系统是本文最接近的同问题相关工作。因此本文把

trace/span/session 明确当作 exchange container 或 baseline shape, 而不是加成第三个 profiler 抽象。E2 实际评估的是 fixed-session drilldown 这个 trace-tree-shaped baseline; 真实 OpenTelemetry/OpenInference/Phoenix span-tree import 仍是后续互操作 baseline, 不是当前已完成结果。本文关注跨轨迹 semantic profiling, 把异构标注轨迹或本地 agent 历史统一为 operations, 并允许用户选择 stack 深度、mappings、tagging 和 ranker。因此本文把这些系统作为最接近的基线威胁, 而不是声称替代现有 observability products。

Agent failure 和 span localization. 2026 年的 AgentRx、TELBench/DRIFT、Holistic Evaluation and Failure Diagnosis 和 AgentAtlas 是最接近的同问题威胁 [23–26]。AgentRx 发布带 critical failure step 和 failure category 的失败轨迹, 并用 constraint checking 与 LLM judge 做 root-cause localization。TELBench/DRIFT 把 deep-research agent 轨迹转成 semantic spans, 并标注 harmful error spans。Holistic Diagnosis 把 agent-level diagnosis 和 span-level evaluation 结合起来; AgentAtlas 则强调 outcome leaderboard 不能覆盖 trajectory quality 和 control-decision quality。因此本文不能把新意写成 failure localization、trajectory diagnosis 或 span-level evaluation 本身。本文的差异更窄: 把 profile groups 当作 profiler 输出, 在同一批 operations 上比较 flat、fixed-session drilldown、dataset-native、raw-action 和 operation-stack views, 并用 AP、nDCG、inspection budget recall、work-to-first-positive、fragmentation 和 profile-configuration actionability 评分。AgentRx/TELBench-style traces 是后续 oracle/baseline 候选, 不是当前已完成的 broader span-localization 证据。

Computer-use 和 tool-use benchmarks. Weblinx、Mind2Web、GUI-Odyssey、OSWorld/OSWorld-Human、OpenCUA/AgentNet、SATraj-OS、AgentRewardBench、ToolBench 和 tau-bench 为本文提供真实标注轨迹 [3–10, 19–22]。本文不提出新 benchmark。贡献是把这些 benchmark 的动作、质量、安全和人工 group 标签统一为 operation fields, 并用同一个 profiler 机制比较它们适合回答哪些 profiling 问题。这些 benchmark 提供证据来源和原生序列对照, 不是被本文替代的对象。

新意边界。因此本文的新意不是“第一个 agent observability 系统”、不是“第一个 agent trajectory benchmark”、也不是“第一个 folded-stack 可视化”。本文可支持的新意是只用 operation 和 operation stack 两个 profiler 抽象, 把 trace/session/span 作为输入容器或 baseline, 在真实公开标注轨迹上把 profile groups 当成 ranking/localization outputs, 并用 hidden labels 计算 accuracy、work、fragmentation 和 actionability。更具体地说, 新意不是 query-time aggregation 本身, 而是把 agent-operation record、recursive multi-field stack shape 和 hidden-label localization benchmark 绑在一起。同一批 agent operations 会因为 stack shape 不同形成不同的可定位、可排序、可检查 aggregation units。这不是穷尽式 2026 全量综述; 它只界定当前主张的最近同问题威胁和已评估边界。

8 局限

当前证据支持的是有范围限定的 profiling 主张, 而不是不加限定的 agent-analysis 主张。本节界定哪些结论可以进入正文主张, 哪些仍需要后续实验。第一, 字段派生和边界恢复的范围仍然有限。当前证据支持 deterministic mappings、

label-derived rules 和部分 supervised boundary backends 能派生 stackable operation fields, 但不证明无监督或 LLM-backed intent detector 已经解决, 也不证明一个 backend 能跨所有标签家族工作。AgentRewardBench looping 被简单 repeat_signal_change baseline 完全解释, 这说明每个 family 都需要 suitability、calibration 和 simple-baseline 检查。

第二, E2 支持 profiler-localization 主张, 但不支持人类效用主张。E2 把 failure、safety、quality 和 human-boundary 问题转成 hidden-label ranking/localization benchmark, 并证明 operation-stack profiling 相对 flat summary 和 fixed-session drilldown 有 accuracy/work/fragmentation trade-off。这个 tradeoff 是 task- 和 metric-specific 的: 最佳 visible view 不由单一 hierarchy 垄断, source-task selector 不能稳定自动选中最优 view, 20%/30% inspection budget 下 operation-stack query-aware 的 median recall 更高, 但 fixed-session 仍保留 first-positive 低成本反例。Fixed-session fragmentation 与 operation-work 成本也必须分开解释: operation-stack 支持更少 group fragmentation 和同预算更少 groups, 但 first-positive/work 指标仍不由 operation-stack 支配。相关工作比较只把 closest-system grounding 转成基线威胁, 不增加新的实证结果。可选 analyst-study protocol 已经覆盖 6 个 tasks、3 个 views、24 个 participant slots 和 144 个 trials, 并把 study materials 与 hidden answer key 分离。但该 protocol 现在只用于后续验证开发者或 agent analyst 是否更快或更准。本文当前不能推出开发者准确率、time-to-answer 或 productivity 改善, 也不能声称所有 intent boundary 都能被自动发现。论文主张应固定为 profiler 本身在真实标注 trace 上的定位、排序、归因和 actionability, 而不是 human utility。

第三, 数据和互操作范围是轻量采样。本文避免同步完整测试集、图片归档和 gated 数据, 因此有些来源只覆盖前缀、子配置或 redacted rows。Chrome Trace Event 和 agent-session exchange 当前只提供 exchange/reproducibility evidence, 覆盖本地 session fixture 和真实标注 operation 前缀。这说明 trace 可以作为 exchange container, 但不证明完整 OpenTelemetry/Chrome trace-ecosystem、Perfetto producer 或图像密集 benchmark 兼容。

第四, E4 是复现和主张边界结果, 不是额外的 profiler accuracy 结果。Replay、数字对齐、数据来源选择和两个抽象的表述约束让正文没有越过已有实证结果。如果采样或 oracle 本身有偏差, E4 能暴露不一致并迫使主张收窄, 但不能消除偏差。因此本文最终主张应固定为两个抽象机制和 hidden-label profiler fidelity/work tradeoff, 而不是 universal fixed-session dominance、automatic anomaly detection 或完整 human utility。

9 结论

本文将 agent 语义 profiling 的核心数据模型收敛为 operation 和 operation stack 两个抽象。Prompt、session、tool call、process、syscall、plan、subagent、GUI action 以及安全和质量标签, 都以 operation 的形态或字段进入同一模型。字段派生、查询过滤、权重选择、递归折叠和复现配置都只改变 operation 或查询配置。Profile spec 固定这些选择, deterministic output 让同一 profile 可以 byte-stable replay。在 15 个轻量采样的公开标注轨迹数据源上, 这个模型统一了 web、mobile、desktop、software、API、dialogue、failure、安全、human group 和 step-quality 轨迹, 并产生 flame-

graph 之外的 stack tree、transition、quality、boundary、case views 和 scope reports。这个结果支持本文的核心机制主张，即 agent profiling 的边界可以从 prompt/session/span tree 中释放出来，成为 query-time operation-stack projection。

当前最强经验结论来自四类 oracle-rich 轨迹，它们分别覆盖不同诊断问题。OSWorld-Human 证明同一动作序列可以折叠到人工 grouped-action 深度，AgentNet 证明 step correctness 和 redundancy 可以作为普通 operation fields 进入 profiling，AgentRewardBench 和 SATraj-OS 证明 failure、looping、side-effect、安全和 attack-type diagnostics 可以用同一机制表达。6 个 label-hidden tasks 构成主 hidden-label profiler benchmark。Query-aware operation-stack top-5 groups 用 median 0.0937 work 取得 0.188 recall，flat summary 用 1.0 work 才取得 full recall，fixed-session 用 0.0163 work 但 top-5 recall 只有 0.0233。相对 fixed-session，operation-stack top-5 recall 在 5/6 tasks 上更高，并把 median groups 从 285.0 降到 157.5。

补充分析进一步界定这个 profiler 主张的适用条件。Task-paired uncertainty、label-permutation negative controls、view/depth task-fit、inspection-budget curves、fixed-recall target、sequence-scope scoring 和 oracle-depth scoring 共同说明，operation-stack 的主要优势是 AP/work/fragmentation tradeoff，而不是所有指标支配。Actionability 证据进一步显示 36/36 objective rows 有具体 optimization action，27/36 best visible policies 不是默认 operation-stack query-aware。Diagnostic lenses、case views、baseline contrasts、action counterfactuals 和 held-out transfer results 说明 profiler 暴露的是可调分析界面，而不是 automatic universal selector。Executable profile-spec patch 进一步证明这种 profile-configuration actionability 可以落到 Rust profiler 配置上。在 6 个 patches 中，5 个同时改善 AP、top-5 lift 和 first-positive work。OSWorld-Human reject 再由 boundary-derived operation fields 改善 AP 和 groups，但保留 work 反例。

因此本文的新意不在单个 flamegraph，而在把 agent 轨迹先统一成 operations，再把边界选择推迟到 operation-stack 查询。这个接口与 pprof、Perfetto、OpenTelemetry/OpenInference 和 LLM observability systems 互补，因为它不重新定义通用 trace schema，也不把 dashboard 当作贡献。所有扩展都先写回 operation fields，再由同一 operation-stack query 折叠，包括 mapping/tagging、profile spec、agent-session trace、Chrome/Perfetto-style trace exchange 和 boundary-derived fields。这样的限制让同一批 operations 可以按不同问题选择 view、派生字段和折叠深度，也让读者看到每个数字对应哪一类证据。当前可写入论文的价值主张只覆盖相对 dataset-provided hidden labels 的 profiler fidelity、label-scored ranking/localization、inspection-cost/fragmentation tradeoff 和 profile-configuration actionability。它不覆盖 detector、human utility、baseline dominance、automatic patch selector 或 ecosystem compatibility。后续增强不应该无差别增加数据集。更有价值的方向有两个。第一，field-derivation backend 需要跨家族 calibration，并稳定胜过简单 sequence-derived baselines。第二，我们需要在已有或新增真实 trace 中补更强的 instruction-step、solution-path 或 human subtask oracle。只有当论文要提出 ecosystem-baseline 主张时，才应该导入真实 OTel/Phoenix/LangSmith/Langfuse/Perfetto span-tree

trace。Controlled human 或 agent analyst study 可以作为后续增强，但不是本文主 profiling 主张的前置条件。

参考文献

- [1] Brendan Gregg. Flame Graphs. <https://www.brendangregg.com/flamegraphs.html>.
- [2] OpenTelemetry GenAI semantic conventions. <https://github.com/open-telemetry/semantic-conventions-genai>.
- [3] McGill-NLP WebLINX. <https://huggingface.co/datasets/McGill-NLP/WebLINX>.
- [4] OpenGVLab GUI-Odyssey. <https://huggingface.co/datasets/OpenGVLab/GUI-Odyssey>.
- [5] WukLab OSWorld-Human. <https://github.com/WukLab/osworld-human>.
- [6] xlangai AgentNet. <https://huggingface.co/datasets/xlangai/AgentNet>.
- [7] McGill-NLP AgentRewardBench. <https://huggingface.co/datasets/McGill-NLP/agent-reward-bench>.
- [8] AI45Research SATraj-OS. <https://huggingface.co/datasets/AI45Research/SATraj-OS>.
- [9] AgentSuite tau-bench trajectories. <https://huggingface.co/datasets/AgentSuite/tau-bench-trajectories>.
- [10] OpenGVLab ScaleCUA-Data. <https://huggingface.co/datasets/OpenGVLab/ScaleCUA-Data>.
- [11] OpenInference specification. <https://arize-ai.github.io/openinference/spec/>.
- [12] LangSmith Observability. <https://docs.langchain.com/langsmith/observability>.
- [13] Langfuse Observability. <https://langfuse.com/docs/observability/overview>.
- [14] Arize Phoenix. <https://arize.com/docs/phoenix>.
- [15] AgentOps: Enabling Observability of LLM Agents. <https://arxiv.org/html/2411.05285v2>.
- [16] Brendan Gregg. The Flame Graph. <https://queue.acm.org/detail.cfm?id=2927301>.
- [17] Google pprof documentation. <https://github.com/google/pprof/blob/main/doc/README.md>.
- [18] Perfetto Trace Processor documentation. <https://perfetto.dev/docs/analysis/trace-processor>.
- [19] AgentRewardBench: Evaluating Automatic Evaluations of Web Agent Trajectories. <https://arxiv.org/abs/2504.08942>.
- [20] OSWorld: Benchmarking Multimodal Agents for Open-Ended Tasks in Real Computer Environments. <https://arxiv.org/abs/2404.07972>.
- [21] OpenCUA: Open Foundations for Computer-Use Agents. <https://arxiv.org/abs/2508.09123>.
- [22] Safactory: A Scalable Agentic Infrastructure for Training Trustworthy Autonomous Intelligence. <https://arxiv.org/abs/2605.06230>.
- [23] AgentRx: Diagnosing AI Agent Failures from Execution Trajectories. <https://arxiv.org/abs/2602.02475>.
- [24] Where Do Deep-Research Agents Go Wrong? Span-Level Error Localization in Agent Trajectories. <https://arxiv.org/abs/2606.02060>.
- [25] Holistic Evaluation and Failure Diagnosis of AI Agents. <https://arxiv.org/abs/2605.14865>.
- [26] AgentAtlas: Beyond Outcome Leaderboards for LLM Agents. <https://arxiv.org/abs/2605.20530>.