

面向 AI Agent 轨迹的可配置语义剖析

AgentSight 研究原型

2026 年 7 月 4 日

摘要

AI agent 的执行历史已经不再只是一次 prompt 或一棵 trace tree。一个真实轨迹可能同时包含用户意图、LLM 响应、tool call、API 调用、GUI 动作、浏览器动作、进程、文件、网络、计划步骤、subagent 以及 benchmark 给出的成功、失败、安全、重复和冗余标签。现有 agent observability 工具通常把这些对象固定成 prompt、session 或 span 层级；传统 profiler 则固定成函数或进程层级。这两种做法都会把 profiling 问题过早绑定到某一种边界上，使同一段轨迹很难按任务、阶段、工具、动作、质量标签或人工分组递归折叠。

本文提出一种更小的语义剖析模型：系统只保留两个核心抽象，`operation` 和 `operation stack`。`operation` 是带字段和权重的观测，prompt、session、tool call、process、syscall、GUI action 和 plan step 都只是 `operation` 的不同形态或字段。`operation stack` 是用户从字段中选择的递归投影，mapping 和 tagging 在 stack 构造前派生字段，而不是创建第三种 profiler 对象。我们在 Rust agentpprof 中实现该模型，支持 `--view`、`--stack`、`--op-map`、`--op-map-file`、`--trace-file` 和可复现实验用的 `--profile-spec`，并把 15 个公开标注 agent 轨迹数据源投影为同一类 `operation JSONL`。

评估使用 WebLINX、WebShop、API-Bank、Agent-Trek、SWE-agent、Mind2Web、AndroidControl、GUI-Odyssey、ToolBench、tau-bench、AgentRewardBench、SATraj-OS、OSWorld-Human、AgentNet 和 ScaleCUA 的轻量采样，不同步完整测试集或图片归档。核心 14 数据集包含 42,590 个 operations，补充 ScaleCUA 后为 47,590 个 operations。同一批 operations 可以从 9 个 dataset stacks 递归展开到 57 个 phase stacks、226 个 tool/semantic stacks、455 个 action stacks，加入固定 session 后膨胀到 3,757 个 stacks。在 OSWorld-Human 中，单动作轨迹与人工 grouped-action 边界的保守匹配达到 0.627 F1 且 precision 为 1.0；在 AgentNet 中，1,000 个 Ubuntu 人工桌面任务的 16,741 个 PyAutoGUI operations 全部携带 step correctness 和 redundancy 字段；在 AgentRewardBench 中，action-derived repetition signal 对 expert looping label 的 V-measure 从单步错误标签的 0.011 提升到 0.378。R293 进一步把 AgentNet 的同一 operation-stack 查询写成 profile spec：默认 spec 复现 608 个 stacks，命令行只覆盖 `--stack` 后在同一 16,741 个 operations 上得到 83 个更粗粒度 stacks。R294 显示本地 Codex session 可以导出为 `agentsight.agent-session.trace.v1`，再导入或转成 operation JSONL；两条路径在同一 stack 下产生字节一致的 folded 输出，R303 进一步把该流程脚本化作为一个可复现的 trace exchange reproducer，并验证导出 trace 在 filesystem 字段和 tool command text 上使用 trace-local path、`cwd=repo` 和 command-name-only tool command。R306 又把同一 fixture 导出为 Chrome Trace Event JSON：

6 个 `traceEvents` 可再导入为 6 个 `operations`，direct trace、direct operation 和 Chrome-import operation 三条路径在同一 stack 下都是 6 samples / 5 stacks 且 folded 输出字节一致。R295 从 tracked R282–R294 JSON/folded artifacts 机械生成 claim verdict：C1 支持，C2 在限定范围内支持，C3 只支持 deterministic label-derived mappings，不支持无监督边界发现。R296 进一步把这些证据组织成 reviewer evidence packet：11 个非 flamegraph 与证据导航条目、4 个 reviewer questions 和从 tracked artifacts 派生的 mapping、human-group、diagnostic 与 reproducibility 指标。R297 在 OSWorld-Human 上加入第一个 supervised boundary-backend probe：它在 held-out sessions 上预测人工 human-group 边界，F1 为 0.7735，并把预测结果写回 `learned_group_pattern` 字段后交给 Rust profiler 折叠。R298 将 R295–R297 的证据进一步综合为 6 个真实问题证据块和 4 个 novelty claims，并把当前成熟度限定为机制 claim 的 level-3 conference-paper evidence、接近 level 4。R299 在不同步新数据的前提下对 7 个已有 boundary candidates 做 suitability 和 calibration：4 个候选可训练；OSWorld-Human、AgentNet step-correct、AgentNet step-redundant 和 AgentRewardBench looping 的 held-out learned F1 分别为 0.6916、0.3197、0.3361 和 0.7833，但 AgentRewardBench looping 被更简单的 `repeat_signal_change` baseline 完全解释。R300 进一步把 failure、safety、quality 和 human-boundary 标签转成 6 个自动化分析任务，在 34,539 个已有 operations 上比较 flat、fixed-session、semantic operation-stack 和 label-drilldown views；semantic operation stack 相比 flat 的 median top-positive lift 为 5.726x，覆盖 50% oracle positives 的 inspection fraction 降到 0.2879。R301 将同一任务转成 label-hidden visible packets 和 hidden answer key，只按 stack 宽度排序：在 30% operation budget 下，operation-stack 找回 median 33.6% positives、检查 4.5 groups，而 fixed-session 找回 28.4%、检查 25.5 groups；top-10 width-ranked groups 下 operation-stack 找回 64.1%，fixed-session 为 19.5%，但 operation-stack 消耗更多 operation fraction。R302 再比较 label-hidden ranking policies：top-10 query-aware operation-stack groups 只检查 11.6% operations、lift 为 1.587，而 width ranking 检查 67.1%、lift 为 1.079；在 30% operation budget 下 query-aware recall 从 34.0% 提升到 39.0%，但检查 groups 从 4.5 增至 39.5。R304 把同一任务进一步写成 reviewer-facing case packet：top-5 query-aware operation-stack cases 检查 median 9.37% operations、找回 18.8% positives、lift 为 1.6509，且 visible packet 与 hidden answer key 分离。R305 将同一 case-packet policy 与 flat、fixed-session baseline 对齐：flat 需要检查 100% operations 才有 100% recall，fixed-session 只检查 median 1.63% operations 但 recall 为 2.26%，operation-stack 检查 9.37% operations、recall 为 18.8%，相对 fixed-session 的

median recall ratio 为 3.63, lift ratio 为 1.268, 但 work ratio 为 1.717。这些结果支持一个机制性 claim: agent 轨迹可以被统一为 operations, 并通过可配置 mappings 和 stack specs 递归折叠为多个有用的 analysis views。当前结果仍不支持完整无监督边界发现或人类用户效用 claim。

1 问题

AI agent 轨迹的调试问题正在从单次调用回放变成跨任务剖析问题。开发者不只想知道某个 span 什么时候开始和结束, 也想知道哪类任务导致最多重复点击, 哪些 GUI 轨迹反复输入, 哪个工具调用族对应失败, 哪些安全攻击类型集中在某些操作阶段, 或者一个 prompt 序列能否被折叠成 task、phase、action 和人工 subtask 等多个深度。如果 profiler 把 session、prompt 或 tool call 写死成核心层级, 这些问题会被迫使用同一个边界。如果 profiler 只保留进程或函数栈, 上层语义和 benchmark oracle 又会丢失。

本文的出发点是把 agent trace 中所有可剖析对象都降到同一层。一个 prompt 可以是 operation, 一个 tool call 可以是 operation, 一串 prompt 也可以通过 mapping 被派生为同一个 intent 或 task operation field。同样, GUI action、API call、browser action、process event、syscall、安全标签、step correctness 和人工 grouped-action id 都不是新的 profiler 抽象, 而是 operation fields。Profiler 的核心任务不是决定唯一正确边界, 而是让用户和实验可以在同一批 operations 上选择 stack 字段、派生 mappings, 并得到不同深度的递归折叠。

这个问题有两个系统挑战。第一, 抽象必须足够小, 否则 prompt、session、tool call、plan、subagent 和 process 会各自形成独立 pipeline。第二, 抽象又必须足够可配置, 否则 flamegraph 只会成为固定视图, 不能回答边界、失败、安全和质量诊断问题。本文的目标不是证明某个单一 flamegraph 最好, 而是证明 operation 和 operation stack 足以覆盖多类真实标注 agent 轨迹, 并能产生 flamegraph 以外的质量、边界和转移分析。

2 设计

2.1 两个核心抽象

operation 是唯一的样本级对象。每个 operation 是一个带权重的字段集合, 例如 op=prompt、op=llm、op=tool、tool=browser、action=click、phase=navigate、status=failure 或 step_correct=incorrect。这些字段可以来自本地 Codex/Claude session, 也可以来自外部 benchmark 的标注轨迹。实现上, 外部轨迹使用每行一个 JSON object 的 operation JSONL, 并把原始任务文本、截图和长对话默认排除在提交 artifact 之外。

operation stack 是从 operation fields 中选择出的有序 frame 列表。例如同一批 operations 可以用 project, dataset 查看数据来源, 也可以用 project, dataset, task, phase, op, tool, action, status 查看动作深度, 或者加入 human_group、step_correct、safety 和 looping 做诊断视图。Stack 不是 trace tree, 也不是 session hierarchy。它是一个查询结果, 用户可以按问题改变深度和字段。

2.2 Mapping 和 tagging

Mapping 和 tagging 是派生 operation fields 的一等机制。它们在 stack 构造前运行, 读取 operation 的 key=value 文本, 并写入新的字段。例如 desktop action 中的 type 和

key 应首先被映射到 phase=input, 再考虑通用 web action verb; API/tool traces 应先进入 tool/API phase family, 再处理 search 或 create 这类词。这一顺序是 R285、R289、R290 和 R291 暴露出的关键设计约束。如果通用 action rule 抢在 operation-family rule 前面运行, desktop、web 和 API 轨迹会被错误合并。

Mapping 不引入第三个抽象。它只是在 operation 上写字段, 使同一个 stack specification 可以跨数据集复用。当前 Rust CLI 支持 inline --op-map FIELD:LABEL=REGEX 和文件形式 --op-map-file。script/operation_map_infer.py 可以从已标注 operations 中生成同样格式的规则文件, R281-R285 使用这些规则测试 held-out 和 leave-dataset-out 泛化。--profile-spec 把 operation files、mapping files、view、stack 和输出路径打包成 JSON 配置, 便于 reviewer 复现实验; 命令行参数仍可覆盖 spec 默认值。它不改变模型本身, 只是把已有 operation 和 operation-stack 查询显式记录下来。

2.3 Views 和非火焰图分析

--view 决定采样和权重, 例如 operation count、token、file、network 或 time。--stack 决定递归折叠形状。Folded stack 和 SVG flamegraph 是其中一种输出, 但不是唯一输出。我们同时生成 JSON profile、stack tree、top-field table、parent-child transition、depth sweep、boundary F1、V-measure、coverage report、grouped-action report 和 HTML quality report。这些视图共享同一 operation 输入和 stack 语法, 因此 failure、safety、looping、redundancy 和 human group 可以被当作普通字段评分, 而不是另建 failure profiler 或 safety profiler。

3 实现

agentpprof 是当前被测实现。它是 Rust CLI, 读取本地 Codex/Claude 历史或外部 operation JSONL, 并输出 pprof-compatible profile、folded stacks、SVG 和 JSON。核心命令形态如下:

```
agentpprof --operation-file ops.jsonl --view operations
--stack project,dataset,task,phase,op,tool,
action,status --op-map-file operation-map.txt
-o out.folded
```

外部数据集转换器位于 script/agent_trace_datasets.py。转换器只下载或流式读取所需公开文件的采样前缀。对于包含截图、长 prompt 或完整对话的数据集, 默认保存 redacted rows 和 operation JSONL, 不提交原始数据。本地 agent session 通过 agent-session 解析为 agentsight.agent-session.trace.v1 trace; agentpprof 可以用 --export-trace 写出 filesystem-normalized trace, 用 --trace-file 读回, 也可以通过 script/agent_trace_to_operations.py 转成 operation JSONL。script/agent_trace_exchange_eval.py 将这三步、filesystem/tool-command portability check 和 folded-output equality check 固化为一个可复现实验; 该检查不声称 prompt/LLM preview 已完整脱敏。script/agent_trace_chrome_trace.py 进一步把该 trace 导出为 Chrome/Perfetto-style traceEvents, 也能把标准 trace 再导入为 operation JSONL; script/agent_trace_chrome_exchange_eval.py 验证该路径不改变 folded operation-stack 输出。质量评估脚

本位于 `script/operation_stack_quality.py`, 它复用 `agentpprof` 的 operation mapping contract, 并计算字段覆盖率、oracle V-measure 和序列相邻边界 F1。Stack 结构分析脚本位于 `script/operation_stack_analysis.py`, 用于生成 flamegraph 之外的 tree、top-kind 和 transition 报告。

这个实现刻意保留简单接口。它不像 jq 那样完整表达 JSON 查询语言, 但它已经把 profiler 的关键自由度暴露为 flags 和可提交配置: 数据源由 `--trace-file` 或 `--operation-file` 选择, 权重由 `--view` 选择, 字段派生由 `--op-map` 选择, 递归边界由 `--stack` 选择, 复现实验由 `--profile-spec` 固化。因此 prompt、session、toolcall、process、syscall、plan 和 subagent 都可以在同一套 mechanism 中出现, 而不是成为互不兼容的 object model。

4 实验方法

评估遵循三个原则。第一, 只使用公开的、别人已经标注好的 agent 轨迹或交互轨迹。我们使用 Hugging Face Dataset Viewer、HF repo JSONL、公开 GitHub JSON 和公开 benchmark artifacts 进行轻量采样, 不同步完整测试集, 也不提交原始外部样本。第二, 每个 claim 都必须对应可执行 oracle。对于 phase/action 结构使用 V-measure 和相邻边界 F1; 对于 grouped-action 使用人工 group id; 对于 looping、safety、step correctness 和 redundancy 使用数据集原生标签; 对于递归深度使用同一批 operations 下 unique stack 和 compression 变化。第三, 负结果保留在论文中。例如 AgentNet 的 task status 很弱地预测 per-step correctness, repeat signal 也很弱地预测 step redundancy。这说明 profiler 能承载这些诊断字段, 但简单 mapping 不能替代专门质量模型。第四, 论文 claim 必须从 artifact 机械回溯。R295 的 `script/paper_claim_synthesis.py` 读取 tracked R282–R294 result JSON/folded files, 输出 claim verdict、paper-ready wording、unsupported claims 和 source path。后续论文表述以这个 synthesis artifact 为 gate, 而不是只依赖手写叙述。第五, 论文证据必须能被 reviewer 导航。R296 的 `script/reviewer_evidence_packet.py` 读取 tracked/clean R282–R295 artifacts, 生成 JSON、Markdown 和 HTML packet, 把 claim verdict、非 flamegraph visualizations、evidence-navigation entries、reviewer questions、负结果和 expansion gates 放到同一处。这个 packet 不是新实验, 而是防止结果分散在多个目录后无法审计。第六, boundary backend 必须仍然服从两个抽象。R297 的 `script/operation_boundary_backend_eval.py` 在 OSWorld-Human 上训练 supervised adjacent-boundary model, 但它只写回 operation fields, 例如 `learned_group_pattern` 和 `learned_group_position`。递归折叠仍由 `agentpprof` 使用普通 `--profile-spec` 和 `--stack` 完成。第七, paper value 和 novelty 也必须从 artifact 机械回溯。R298 的 `script/paper_value_novelty_synthesis.py` 读取 R295 claim gate、R296 reviewer packet、R297 boundary report 以及 R288/R289/R291 质量诊断 artifact, 输出 6 个真实问题证据块、4 个 novelty claims、must-not-claim 列表和 remaining level-4 gaps。它不是新实证结果, 而是把“为什么这个 profiler 有价值且有新意”转成 reviewer 可审计的 evidence map。第八, boundary-family replication 必须包含适用性和简单 baseline 校准。R299 的

`script/boundary_family_calibration_eval.py` 只读取已有 tracked operation JSONL, 不同步新测试集。它先判断标签是否形成 session-local adjacent boundary oracle, 再训练同一类 field-derivation backend, 并把预测结果写回 `learned_segment_pattern`、`learned_segment_position` 和 `learned_boundary_prev`。这一步的目的不是证明一个通用 detector, 而是防止把 per-trajectory safety、history context 或 repetition proxy 错当作语义边界。第九, 真实问题价值必须先通过可复现 proxy 任务收敛。R300 的 `script/operation_query_utility_eval.py` 不抓取新数据, 而是从 AgentRewardBench、SATraj-OS、AgentNet 和 OSWorld-Human 的已有 operation JSONL 中构造 6 个 oracle-backed analysis tasks。它比较 flat、fixed-session、semantic operation-stack 和 label-drilldown 四种 stack specs, 并用 positive lift、覆盖 50% positives 的 inspection fraction、group count 和 top-group session support 作为自动化指标。这仍不是人类用户实验, 但能把“profiler 是否解决真实问题”从叙述变成可审计的 proxy result。第十, 默认浏览任务必须避免把答案泄漏进视图。R301 的 `script/operation_analyst_task_eval.py` 复用 R300 的已有 labeled operations, 写出不含 oracle-positive 字段的 visible task packets, 并把 positives 保存在 hidden answer key 中。它只用 width-ranked groups 评分, 因而比 R300 的 oracle-sorted 结果更保守。第十一, 非 flamegraph 分析策略也必须避免读 oracle fields。R302 的 `script/operation_analyst_ranking_eval.py` 在同一任务上比较 width、visible-risk、query-aware 和 oracle upper bound rankers。非 oracle rankers 只读 status、repeat_signal、phase、action 和 environment 等可见字段, 不读 looping、safety、step_correct 或 target_positive。R304 的 `script/operation_case_study_eval.py` 复用 R300/R302 任务, 把每个任务的 top-5 query-aware operation-stack groups 写成 visible case packet, 并把 oracle positives 只写入单独的 answer key。R305 的 `script/operation_case_baseline_eval.py` 使用同一任务、同一 top-5 query-aware policy 和同一 hidden answer key, 把 flat、fixed-session 和 operation-stack 三种 view 写成可比较的 visible case packets。

5 结果

5.1 RQ1: 两个抽象是否覆盖多类轨迹?

核心 14 数据集产生 42,590 个 operations 和 1,497 个 unique stacks, compression ratio 为 28.45。加入 R292 ScaleCUA 补充样本后, 总量为 47,590 个 operations 和 1,611 个 unique stacks, compression ratio 为 29.541。这些 operations 覆盖 web、mobile、desktop、software、API、tool-agent-user dialogue、expert failure labels、safety labels、human grouped-action labels 和 desktop step-quality labels。所有这些标签都以 operation fields 形式进入同一 pipeline。没有任何数据集需要新增 prompt、session、GUI、safety 或 quality-specific profiler object。

这支持 C1 的机制性版本: `agentpprof` 可以把异构 agent 轨迹统一为 operations, 并用用户指定 stack 折叠。它不支持所有 agent 数据都容易转换。适合该方法的轨迹通常具备四个特征: 有有序 step 或 turn, 有稳定 session/task id, 有动作或阶段标签, 有 outcome、quality、group 或 safety 等较高层 oracle。只有静态截图 grounding、缺少顺序、缺

表 1: 公开标注轨迹数据源和当前用途。ScaleCUA 是 R292 补充点, 主结论主要依赖 R279–R291。

数据源	原生标注	转换方式	主要用途
WebLINX, Mind2Web, AgentTrek, WebShop API-Bank, ToolBench, tau-bench	web action、demo/task、reward 或 action history API/tool call、solution path、多轮 user/assistant/tool messages、outcome	HF Dataset Viewer 或 HF repo shard HF rows 或 repo JSONL	web navigation 和 shopping trajectories 的跨源 smoke。 tool/API/dialogue phases 和 user-agent-tool operation 形态。
SWE-agent	issue trajectory、command action、success target	HF Dataset Viewer	software-agent command 轨迹。
AndroidControl, GUI-Odyssey	mobile/cross-app step action 与 instruction	public/HF samples	移动 GUI action depth 和跨 app scale。
AgentRewardBench	expert success、side-effect、looping、optimality	annotation rows 加 cleaned BrowserGym steps	failure、looping、side-effect 的非 flame-graph 诊断。
SATraj-OS	desktop action、success、safety、reward、attack type	HF safety config	桌面安全和 attack-type operation fields。
OSWorld-Human	human single-action 和 grouped-action 轨迹	GitHub JSONL files	人工 grouped-action 边界 oracle。
AgentNet	human desktop PyAutoGUI、task outcome、step correctness、redundancy	HF repo JSONL streaming	最大 human desktop step-quality oracle。
ScaleCUA	GUI navigation action、previous-operation context、gold action	HF annotation JSONL streaming	补充多步 GUI history-depth smoke。

少 action label、强依赖大图片归档或 gated access 的数据源更适合作为后续扩展, 而不是当前主证据。

5.2 RQ2: 递归 stack 是否比固定边界有价值?

R286 在同一批 13,265 个 operations 上扫过 8 个 stack depths。只保留 dataset 时有 9 个 stacks; 加入 task 后为 11 个; phase depth 为 57 个; tool/semantic depth 为 226 个; action depth 为 455 个; 加入固定 session 后膨胀到 3,757 个。相对于 dataset depth, 固定 session 的 unique stacks 增加 417.4 倍。这个结果直接反驳把 session 或 prompt 作为默认 profiling 边界的设计。Session 是有用 drilldown field, 但如果默认写死在 stack 里, 它会把可聚合的行为切碎。

R277 在较早 3,797-operation set 上给出同样信号。Flat/mapped stack 为 103 个 unique stacks, 而固定 demo/session stack 为 1,083 个 unique stacks。这说明固定边界会带来约 10.5 倍碎片化, 而 mapped operation stack 可以保留聚合同时增加语义深度。因此论文中的 novelty 不是“画 flamegraph”, 而是把 agent profiling 的边界选择变成 operation-stack query。

R293 把这个 query 自由度变成可复现实验配置。同一个 AgentNet spec 引用 R291 的 operation JSONL 和 op-map 文件, 默认产生 608 个 diagnostic stacks; 命令行只覆盖 `--stack` 和输出路径后, 样本数保持 16,741 不变, unique stacks 降到 83。这说明 stack 深度是可审计、可覆盖的查询参数, 而不是写死在 prompt/session 或某个可视化中的层级。

R295 进一步把 claim gate 变成可复现 artifact。脚本读取 R282–R294 的 tracked result JSON/folded outputs, 生成 `claim-synthesis.json` 和 `claim-synthesis.md`。它把 C1 判为 supported, 把 C2 判为 supported with scoped limits, 把 C3 判为 partial。这一步没有增加新数据集, 但它把结果表述从“挑选好看的数字”变成“从 artifact 到 claim wording 的可审计映射”。

R296 则把可审计性从 claim wording 扩展到 reviewer navigation。它从 39 个 tracked/clean artifacts 生成 `reviewer-evidence.json`、`reviewer-evidence.md` 和 `index.html`, 索引 11 个非 flamegraph 与证据导航条目, 包括 depth sweep、stack tree、transition/top-field、quality report、grouped-boundary report、history-depth report 和 claim gate。该 packet 还派生出若干 reviewer-facing 数

值: held-out mapping 使 unique stacks 减少 26.408%, OS-World grouped-depth stacks 相比 action-depth stacks 减少 78.008%, AgentRewardBench repeat-signal/looping V-measure 为 0.3777, step-error baseline 为 0.0105, 两者相差 35.971 倍; profile-spec override 在不改变 operations 的情况下使 AgentNet stacks 减少 86.349%。这些数字不替代原始结果文件, 而是把“为什么这些结果有价值”变成可追溯的证据路径。

R298 把这个证据路径进一步收敛成论文价值和新意的 claim gate。它从 R295–R297 和诊断质量报告中生成 6 个真实问题证据块: 异构 trace object model、递归深度选择、field derivation、human/subtask boundaries、failure/safety/quality diagnostics 和 artifact auditability。它还把 novelty 限定为 4 点: two-object agent profiling、query-time recursive stacks、统一 field-derivation extension point 和 non-flamegraph diagnostic views。R298 的结论是当前证据足以支撑机制和诊断价值, 但仍只是 level-3 conference-paper evidence、接近 mechanism claims 的 level 4; boundary-family replication、用户效用实验和 boundary calibration 仍是缺口。R299 部分填补了第一个缺口: 它没有增加新数据, 而是在已有标注 operation JSONL 上检查 7 个候选边界家族, 训练其中 4 个, 并把失败或不适合的候选也保留下来作为 claim 边界。R300 部分填补用户效用缺口的前半步: 它不是 human study, 但把“定位 looping、side-effect、unsafe、incorrect、redundant 和 group-start positives”变成自动化分析任务, 并比较不同 stack 形态的 inspectability。R301 进一步把这些任务变成 label-hidden visible packets 与 hidden answer key, 证明默认宽度排序下 operation stack 仍比 fixed-session 更少碎片化, 但也显示宽度排序本身不是异常检测器。R302 则把可见字段上的排序策略纳入同一任务框架, 说明 operation stack 可以承载 query-aware 分析, 而不仅是 flamegraph 宽度视图。R304 再把这种分析策略转成可审计 case evidence: visible packet 只包含 stack frames、可见特征比例、hashed session examples 和普通 operation examples, answer key 才包含 positives。R305 将该 case evidence 与 flat 和 fixed-session 直接对齐, 显示 operation stack 是一个中间视图: 它远比 flat selective, 相比 fixed-session 有更高 recall 和 lift, 但并不在每个任务上消耗更少 inspected operations。

5.3 RQ3: mapping 是否能泛化？

R281 从 13,265 个 labeled operations 中生成 10 条 mapping rules, 复现手写 mapping 的 folded 输出。R282 使用 dataset-stratified held-out split, 在 9,275 个 train operations 上生成规则, 并在 3,990 个 held-out operations 上评估。Mapped stack 产生 209 个 held-out stacks, compression ratio 为 19.091; 无 mapping baseline 为 284 个 stacks, compression ratio 为 14.049。Task/dataset V-measure 从 0.837 提升到 0.853。Phase/action boundary F1 为 0.777, precision 为 1.0, 说明当前 mapping 是保守的。它不会制造 false positive phase changes, 但会合并一些 fine-grained action changes。

R283-R285 进一步做 leave-dataset-out。在修正 API/tool phase precedence 后, R285 对 9 个 held-out datasets 中的 6 个减少 unique stacks, 0 个出现 negative stack reduction, weighted stack reduction 为每 1,000 operations 1162.005。这说明 mapping 不是单个数据集的 ad hoc pretty printer。它仍然是 deterministic taxonomy-seeded mapping, 不是无监督边界发现。R297 开始测试更强的 boundary backend。它在 OSWorld-Human exact-aligned sessions 上按 session 做 deterministic split: 191 个 train sessions 产生 2,655 个 train adjacent pairs, 96 个 test sessions 产生 1,036 个 test adjacent pairs。模型使用非 oracle operation fields 训练 Bernoulli adjacent-boundary predictor, 明确排除 `human_group`、`group_index`、`group_position`、`group_size`、`group_pattern` 和 `group_alignment`。在 held-out pairs 上, learned backend 的 precision 为 0.7400, recall 为 0.8102, F1 为 0.7735; phase-change baseline 为 0.2919, action-change 为 0.5142, conservative `group_pattern` reference 为 0.5810。随后脚本把预测边界写成 `learned_group_pattern` 和 `learned_group_position` 字段, Rust agentpprof 在 1,132 个 held-out operations 上折叠得到 74 个 stacks。当前可支持的 claim 是 configurable deterministic/supervised field derivation 能在 held-out 设置下改善语义聚合; 完整 model-backed 或 unsupervised boundary detector 仍是后续工作。

R299 将这个 backend 接口复制到现有标注家族, 并加入 suitability/calibration gate。脚本检查 OSWorld-Human human-group、AgentNet step correctness、AgentNet step redundancy、AgentRewardBench looping、SATraj safety、ScaleCUA history state 和 tau-bench tool-dialogue role 共 7 个候选。其中 SATraj safety 在当前样本中没有 session-local adjacent positives, ScaleCUA history state 是 context marker 而不是语义边界, tau-bench 在 R287 没有 tracked operation JSONL, 因此不训练。四个可训练候选的 held-out learned F1 分别是 OSWorld-Human 0.6916、AgentNet step-correct 0.3197、AgentNet step-redundant 0.3361 和 AgentRewardBench looping 0.7833。AgentNet 两个质量状态边界都优于 always-boundary baseline (0.2155 和 0.2645), 但 precision 低且 calibration error 仍明显; AgentRewardBench looping 虽然 learned F1 达到 0.7833, 却被 `repeat_signal_change` baseline 的 1.0 F1 完全解释。这把 C3 的范围收得更清楚: backend 可以统一地派生 stackable operation fields, 但每个标签家族都必须证明它真的是边界 oracle, 并且必须胜过简单 sequence-derived fields。

5.4 RQ4: 能否恢复真实人工边界？

OSWorld-Human 是当前最强的 grouped-boundary oracle。R290 转换全部 369 个 human desktop tasks, 得到 6,010 个 single-action operations。转换器把 grouped-action 序列展平后与 single-action 序列对齐, 只有 exact-aligned tasks 才写入 `human_group`、`group_pattern` 和 `group_position` 字段。最终 320 个 tasks、4,011 个 operations 和 2,075 个 session-local groups 进入 grouped-boundary scoring; 31 个 content-mismatch tasks 和 18 个 length-mismatch tasks 保留用于 action profiling, 但不被当作 gold group oracle。

在 OSWorld-Human 上, 普通 action-depth stack 有 482 个 unique stacks, grouped-depth stack 降到 106 个。Phase/action boundary F1 为 0.638, precision 为 1.0。更重要的是, 保守的 `group_pattern` 对人工 `human_group` boundary 的 F1 为 0.627, precision 为 1.0, recall 为 0.456。这不是完美边界 detector, 但它给出有意义结论: operation stack 可以在同一条单动作序列上选择 action-depth 或 group-depth, 并以人工 grouped-action 标签作为 oracle 验证。Prompt 或 session 没有参与这个抽象。

5.5 RQ5: 能否做失败、安全和质量诊断？

AgentRewardBench、SATraj-OS 和 AgentNet 说明 operation stack 不局限于 flamegraph 热点。AgentRewardBench 的 729 个 expert-reviewed web-agent operations 全部携带 success、side-effect、looping 和 optimality 字段。Action-derived `repeat_signal` 对 expert looping label 的 V-measure 为 0.378, 而单步 `step_error` 对 looping 的 V-measure 只有 0.011。这说明 sequence-derived operation fields 可以捕捉一部分真实 failure mode, 也说明简单错误标签不能替代序列诊断。

SATraj-OS 的 4,285 个 desktop computer-use operations 全部携带 safety、attack type、status 和 reward-related fields。其中 622 个 operations 标为 unsafe, attack type 覆盖 account、induced-text、popup、OS 和 unknown-file。这些标签与 phase/action 关系较弱, 例如 attack-type/action V-measure 只有 0.093。这个负结果是有价值的: 安全攻击类别不是 action taxonomy 的简单函数, 因此应该作为独立 operation field 被折叠和过滤, 而不是强行塞进 phase。

AgentNet 是当前最大的 human desktop step-quality oracle。R291 采样 1,000 个 Ubuntu tasks, 得到 16,741 个 PyAutoGUI operations。所有 operations 都有 task outcome、alignment score、efficiency score、difficulty、step correctness 和 redundancy 字段。Step correctness 覆盖 13,844 correct、874 incorrect 和 2,023 unknown; step redundancy 覆盖 9,334 necessary、733 redundant 和 6,674 unknown。Task status 对 step correctness 的 V-measure 只有 0.015, repeat signal 对 step redundancy 的 V-measure 只有 0.010。这说明 profiler 的价值不是用一个粗标签预测所有质量问题, 而是把质量 oracle 保留为可折叠、可 drilldown、可评分的 operation fields。

R300 把这些诊断目标组织成 6 个自动化 real-problem proxy tasks。任务覆盖 AgentRewardBench looping 和 side-effect、SATraj unsafe、AgentNet incorrect/redundant steps, 以及 OSWorld-Human group starts, 总计 34,539 个 operations。在同一 operation JSONL 上, Rust agentpprof 的 flat profile 只有 6 个 stacks, fixed-session profile 有 2,012 个 stacks, semantic operation-stack profile 有 944 个 stacks, label-drilldown profile 有 318 个 stacks。按 oracle-sorted clustering quality 评价, semantic operation stack 相比 flat

summary 的 median top-positive lift 为 5.726x, 覆盖 50% positives 的 median inspection fraction 从 1.0 降到 0.2879。相比 fixed-session stack, semantic stack 的 group count ratio 为 0.554, top groups 的 session support ratio 为 5.5, 说明它更适合跨轨迹诊断; 但 inspection fraction ratio 为 1.302, 说明 fixed-session drilldown 在部分 instance-local tasks 上仍更快。这支持的是 inspectability 和 aggregation claim, 不是人类效率 claim。

R301 用更严格的 label-hidden analyst-task proxy 复核 R300。它把 visible packet 和 hidden answer key 分开, 默认只按 group width 排序。在 30% inspected-operation budget 下, operation-stack 的 median positive recall 为 0.336, 检查 4.5 groups; fixed-session 为 0.284, 检查 25.5 groups。在 top-10 width-ranked groups 下, operation-stack 的 median recall 为 0.641, 而 fixed-session 为 0.195。这个结果说明 operation stack 能把跨 session 的问题压缩成更少可检查单元, 但它并不保证默认宽度排序总是最省 operation budget。

R302 进一步比较 label-hidden ranking policies。在 top-10 groups 下, query-aware operation-stack ranking 只检查 0.116 operation fraction, positive lift 为 1.587; width ranking 检查 0.671 operation fraction, lift 为 1.079。在 30% operation budget 下, query-aware ranking 把 operation-stack recall 从 0.340 提高到 0.390, 但检查 groups 从 4.5 增加到 39.5。这说明 profiler 可以支持不同分析 policy 的 precision/recall tradeoff, 但这些 policy 仍是 visible-field heuristics, 不是 learned detector。

R304 将 R302 的 ranking policy 变成 reviewer-facing case packet。每个任务取 top-5 query-aware operation-stack groups, visible packet 不包含 oracle fields, hidden answer key 单独保存 positives。在 30 个 case groups 上, median inspected operation fraction 为 0.0937, median positive recall 为 0.188, median positive lift 为 1.6509。SATraj unsafe cases 最集中, work fraction 为 0.042, recall 为 0.262, lift 为 6.238; AgentNet quality cases 的 recall 很低, 但在很小 work fraction 上仍有 1.98 以上 lift。这个结果适合作为 case-study evidence, 而不是 detector evidence。

R305 对同一 case-packet policy 加入 flat 和 fixed-session baseline。Flat view 只有每个任务一个 packet, 因此 median recall 为 1.0, 但必须检查 1.0 operation fraction。Fixed-session view 的 median work fraction 为 0.0163, recall 为 0.0226, lift 为 1.6615。Operation-stack view 的 median work fraction 为 0.0937, recall 为 0.188, lift 为 1.6509。相对 fixed-session, operation-stack 的 median recall ratio 为 3.63, lift ratio 为 1.268, 但 inspected-work ratio 为 1.717。这支持“operation stack 是 flat 与 fixed-session 之间的可配置分析折中”, 而不是“operation stack 在每个任务上都更省 work”。

6 哪些数据集最适合

从当前 15 个方案看, 最适合支撑论文主 claim 的不是“最大”数据集, 而是同时具备顺序、动作、边界或质量 oracle 的数据集。第一类是 OSWorld-Human, 因为它同时给 single-action 和 grouped-action, 是验证递归边界的最直接 oracle。第二类是 AgentNet, 因为它规模大、人工桌面任务多, 并带 per-step correctness/redundancy。第三类是 AgentRewardBench 和 SATraj-OS, 因为它们把 profiler 从 action taxonomy 推到 failure、looping、安全和 side-effect diag-

nostics。第四类是 GUI-Odyssey/tau-bench/ToolBench 这组跨域补充, 它们覆盖移动 GUI、user-agent-tool dialogue 和 API/tool traces, 证明 operation abstraction 不局限于桌面。

ScaleCUA 是有用补充, 但不是当前主证据。R292 流式采样 5,000 个 Ubuntu navigation rows, 覆盖 131 个 sessions, 最大 step 为 48。该子集的动作 taxonomy 主要是 click 和 terminate, 所以 phase/action 指标达到 1.0 并不表示强泛化。它更适合证明 multi-step GUI history context 可以被投影为 history_state 和 history_depth fields, 而不是证明复杂边界 detector。

7 相关工作

Profiling 和 flamegraphs. 传统 flamegraph 把函数调用栈折叠为热点视图。本文复用 folded-stack 表示, 但 stack frame 来自 operation fields, 而不是语言运行时函数调用。因此同一批 operations 可以被折叠为 task、phase、tool、action、quality 或 safety 视图。这与 CPU profiler 的固定调用栈不同, 也与只画一次 agent span tree 的 tracing 工具不同。

Agent tracing 和 LLM observability. LangSmith、Langfuse、Phoenix、AgentOps 和 OpenTelemetry GenAI 等系统记录 LLM call、tool call、latency、token 和 trace tree。这些工具适合单次 workflow inspection。本文关注的是跨轨迹的 semantic profiling: 把异构标注轨迹或本地 agent 历史统一为 operations, 并允许用户选择 stack 深度和 mappings。

Computer-use 和 tool-use benchmarks. Weblinx、Mind2Web、GUI-Odyssey、OSWorld-Human、AgentNet、SATraj-OS、AgentRewardBench、ToolBench 和 tau-bench 为本文提供真实标注轨迹。本文不提出新 benchmark。贡献是把这些 benchmark 的动作、质量、安全和人工 group 标签统一为 operation fields, 并用同一个 profiler 机制比较它们适合回答哪些 profiling 问题。

8 局限

当前结果仍不是 OSDI 或 NeurIPS 最终接收级完整证据。第一, boundary detection 主要是 deterministic mapping 和 label-derived rule inference。R282/R285 证明它们有 held-out 和 leave-dataset-out 泛化, 但不证明无监督或 LLM-backed boundary detector 已经解决。第二, 用户效用还没有完成。我们证明了 profiler 能产生更结构化的 views 和可执行 oracle, 但没有证明开发者使用这些 views 会更快、更准确。第三, 外部数据集采样为了避免同步完整测试集而保持轻量, 有些数据源只覆盖前缀、子配置或 redacted rows。第四, 非文本/图像密集数据集仍需要更好的 streaming 和 artifact policy, 才能在不保存图片归档的前提下做更大规模评估。第五, paper 当前证据支持“operation/operation-stack 是一致且有价值的 profiling abstraction”, 不支持“所有 agent 行为都能自动恢复真实意图边界”。第六, R295 是 claim synthesis, 不是新的经验结果; 如果底层 R282-R294 artifact 有采样偏差, R295 只能暴露和约束 claim, 不能消除这些偏差。第七, R296 是 evidence navigation, 不是新的实证结果; 它提高 reviewer 可审计性, 但不能替代更强 boundary backend 或用户效用实验。第八, R297 是 supervised OSWorld-Human expansion probe; 它不证明无监督 intent discovery, 也没有验证到 AgentNet、tau-bench 或其它轨迹家族。第九, R298 是 paper-value synthesis, 不是额

外数据；它能约束论文 claim 和 novelty 表述，但不能替代 R298 自己列出的 boundary-family replication、用户效用实验和 calibration 缺口。第十，R299 是 boundary-family calibration，不是通用 boundary detector；它证明同一 backend 接口可以复制到多个已有标签家族，也证明部分标签不适合作为 adjacent boundary oracle，且简单 baseline 可能优于 learned backend。第十一，R300 是自动化 proxy，不是人类实验；它使用 oracle 排序评价 grouping quality，因此只能支持 inspectability、aggregation 和 analysis-task framing，不能支持开发者准确率或耗时改善。第十二，R301 是 label-hidden 自动化 proxy，不是人类实验；它消除了 R300 的 oracle 排序乐观假设，但仍只模拟 width-ranked browsing，不能证明默认界面对真实用户最优。第十三，R302 是 label-hidden ranking proxy，不是 detector；它说明 query-aware policy 可以改变 precision/recall tradeoff，但没有证明自动报警或人类效率。第十四，R304 是 case-packet artifact，不是人工 case study；它让 reviewer 可以审计可见例子和隐藏评分的分离，但不能替代受控 analyst study。第十五，R305 是 cross-view case-packet baseline，不是最终 user utility 结果；它证明 operation stack 的相对位置和 tradeoff，但也保留 fixed-session 在低 work fraction 上更便宜的反例。第十六，R306 是标准 trace 互操作 smoke，不是完整 OpenTelemetry/Chrome trace 生态兼容性评估；它证明 Chrome Trace Event JSON 可以作为 exchange container，但不改变 profiler 只接受 operation 和 operation stack 的设计。

9 结论

本文把 agent semantic profiling 收敛为两个核心抽象：operation 和 operation stack。Prompt、session、toolcall、process、syscall、plan、subagent、GUI action、安全标签和质量标签都只是 operation shapes 或 fields。Mapping 和 tagging 负责派生 fields，--view 和 --stack 负责选择权重和递归折叠形状，--trace-file 和 --operation-file 负责数据入口，--profile-spec 只把这些选择变成可复现实验配置。在 15 个公开标注轨迹数据源上的结果显示，这个模型能统一 web、mobile、desktop、software、API、dialogue、failure、安全、human group 和 step-quality 轨迹，并产生 flamegraph、stack tree、transition、quality 和 boundary reports。最强证据来自 OSWorld-Human 的人工 grouped-action 边界、AgentNet 的大规模 human desktop step-quality 标签、AgentRewardBench/SATraj 的 failure/safety diagnostics，以及 R286 的递归深度消融。R295 把这些证据合并为可复现 claim gate：当前可以 claim 统一 operation abstraction 和 scoped recursive operation-stack value，但不能 claim 无监督 intent discovery 或开发者生产力提升。R296 把 claim gate、非 flamegraph 视图和负结果整理成 reviewer evidence packet，使论文主张能从 artifact 直接追溯，而不是依赖手写叙述。R297 进一步验证 boundary backend 的正确接入方式：模型只派生 operation fields，Rust profiler 仍按用户指定 operation stack 折叠。R298 把这些结果压缩成 reviewer-facing 价值和 novelty map：当前可以主张机制性语义剖析和真实诊断价值，但仍必须排除无监督 intent discovery 与用户生产力提升。R299 则把 boundary detector 的下一步条件写清楚：先做 family-specific suitability 和 calibration，再比较简单 sequence-derived baseline，最后才讨论更强模型。R300 把真实问题价值从叙述推进到自动化 task proxy：operation stack 相比 flat summary 更能集中 oracle posi-

tives，并比 fixed-session stack 更能跨 session 聚合。R301 把这个 proxy 推进为 label-hidden task packet，说明默认宽度排序下 operation stack 能减少 fixed-session 碎片化，同时保留 width ranking 不是 detector 的限制。R302 进一步说明同一 operation stack 可以按 query-aware policy 排序，而不局限于 flamegraph width。R304 把这些排序结果转成 visible case packet 和 hidden answer key，为 reviewer 提供具体 case evidence。R305 把这些 case evidence 与 flat 和 fixed-session baseline 对齐，说明 operation stack 的价值是可配置 inspectability tradeoff，而不是无条件支配每个 baseline。R306 则把本地 session 互操作路径扩展到 Chrome/Perfetto-style 标准 trace：标准 trace 负责导出和导入，真正的分析仍落回 operation JSONL 与用户指定的 operation stack。下一步不是继续无差别增加数据集，而是把 mapping backend、calibrated boundary detector 和基于 R301/R302/R304/R305 packets 的受控用户/agent analyst 任务实验推进到能支持更强 claim 的程度。

参考文献

- [1] Brendan Gregg. Flame Graphs. <https://www.brendangregg.com/flamegraphs.html>.
- [2] OpenTelemetry GenAI semantic conventions. <https://opentelemetry.io/docs/specs/semconv/gen-ai/>.
- [3] McGill-NLP WebLINX. <https://huggingface.co/datasets/McGill-NLP/WebLINX>.
- [4] OpenGVLab GUI-Odyssey. <https://huggingface.co/datasets/OpenGVLab/GUI-Odyssey>.
- [5] WukLab OSWorld-Human. <https://github.com/WukLab/osworld-human>.
- [6] xlangai AgentNet. <https://huggingface.co/datasets/xlangai/AgentNet>.
- [7] McGill-NLP AgentRewardBench. <https://huggingface.co/datasets/McGill-NLP/agent-reward-bench>.
- [8] AI45Research SATraj-OS. <https://huggingface.co/datasets/AI45Research/SATraj-OS>.
- [9] AgentSuite tau-bench trajectories. <https://huggingface.co/datasets/AgentSuite/tau-bench-trajectories>.
- [10] OpenGVLab ScaleCUA-Data. <https://huggingface.co/datasets/OpenGVLab/ScaleCUA-Data>.

表 2: 当前最强结果。数值均来自 tracked artifacts 下的 JSON/HTML reports。

结果块	数据规模	关键数值	支持的结论
R286 recursive depth	13,265 operations	9 dataset stacks, 57 phase stacks, 226 tool/semantic stacks, 455 action stacks, 3,757 fixed-session stacks	Stack 深度是 query, 固定 session 是 drilldown 而不是核心边界。
R282/R285 mapping validation	3,990 held-out operations; 9 leave-out datasets	Held-out compression 19.091 vs no-map 14.049; leave-out 6/9 positive, 0 negative	Label-derived mappings 能泛化到 unseen sessions/datasets, 但仍不是无监督 detector。
R290 OSWorld-Human	369 tasks, 6,010 operations; 4,011 exact grouped-oracle operations	grouped stack 106 vs action stack 482; human-group boundary F1 0.627, precision 1.0	同一单动作序列可折叠到人工 grouped-action 深度。
R291 AgentNet	1,000 tasks, 16,741 operations	step correctness/redundancy 100% field coverage; phase/action F1 0.715, precision 1.0	质量标签是 ordinary operation fields, 可被折叠、评分和诊断。
R293 profile spec	同一 16,741 AgentNet operations	spec 复现 608 stacks; CLI stack override 产生 83 stacks	实验配置可复现且可覆盖, stack 不是固定层级。
R294/R303 trace exchange	public Codex fixture	1 trace session, 6 operations; trace_filesystem_portable=true; trace import 与 operation import 均为 6 samples / 5 stacks 且 folded 字节一致; R303 一条脚本复现该流程	本地 session 可导出、导入并桥接到 operation JSONL, 而不会成为第三个 profiler 抽象。
R306 Chrome trace exchange	public Codex fixture	6 Chrome complete events; 6 direct operations; 6 Chrome-import operations; direct trace, direct operation 和 Chrome-import operation 均为 6 samples / 5 stacks 且 folded 字节一致	标准 trace 只是 exchange container; 导入后仍进入 operation JSONL 和 operation-stack folding。
R295 claim synthesis	R282–R294 tracked artifacts	C1 supported; C2 supported with scoped limits; C3 partial	论文 claim gate 明确支持范围和不能 claim 的内容。
R296 reviewer packet	R282–R295 tracked artifacts	11 个非 flamegraph/evidence-navigation entries; 4 个 reviewer questions; 39 个 clean input artifacts	结果可通过 claim-indexed 多视图证据包审计。
R297 boundary backend	OSWorld-Human held-out sessions	1,036 test adjacent pairs; learned F1 0.7735; Rust fold 1,132 ops / 74 stacks	Boundary backend 只是派生 operation fields, 递归折叠仍由 operation stack 完成。
R298 value/novelty synthesis	R295–R297 与诊断质量 artifacts	6 个 real-problem evidence blocks; 4 个 novelty claims; level-3 evidence approaching level 4	论文价值和新意从 tracked artifacts 机械回溯, 且保留 must-not-claim gate。
R299 boundary-family calibration	7 个已有候选; 4 个训练任务; 8,961 folded operations	OSWorld 0.6916 F1; AgentNet step-correct/redundant 0.3197/0.3361 F1; AgentReward learned 0.7833 F1 但 repeat-signal-change baseline 1.0	Boundary backend 接口可复制, 但不是通用 detector; 每个家族需要 suitability, calibration 和简单 baseline gate。
R300 query utility proxy	6 个 oracle-backed tasks; 34,539 operations	flat/fixed/operation/label stacks 分别为 6/2,012/944/318; operation-stack vs flat lift 5.726x, inspection fraction 0.2879; vs fixed-session group ratio 0.554, session-support ratio 5.5	Operation stack 改善自动化 inspectability 和跨 session 聚合, 但仍不是 human user study。
R301 width-ranked task proxy	同一 6 个 tasks; 168 个 task/view/budget scores	30% operation budget 下 operation-stack recall 0.336 / 4.5 groups, fixed-session 0.284 / 25.5 groups; top-10 groups 下 0.641 vs 0.195	Label-hidden 默认浏览仍支持跨 session 聚合, 但 width ranking 不是 detector。
R302 label-hidden ranking	同一 6 个 tasks; 192 个 task/view/ranker/budget scores	top-10 query-correct stack 检查 0.116 operation fraction, lift 1.587, width 为 0.671 和 1.079; 30% budget recall 0.390 vs 0.340	Operation stack 支持 query-aware 分析 policy, 但 ranker 仍是 heuristic。
R304 case packet	同一 6 个 tasks; 30 个 top-5 query-aware case groups	median work fraction 0.0937; recall 0.188; lift 1.6509; visible packet 与 answer key 分离	Case evidence 可审计, 但仍不是 detector 或 human study。
R305 case baseline	同一 6 个 tasks; 18 个 task-view case packets	flat work/recall 1.0/1.0; fixed work 0.0163, recall 0.0226, lift 1.6615; operation work 0.0937, recall 0.188, lift 1.6509	Operation stack 是 selective middle view, 但不是每个任务都比 fixed-session 更省 work。
R288/R289 diagnostics	729 AgentRewardBench ops; 4,285 SATraj ops	repeat-signal/looping V-measure 0.378 vs step-error 0.011; 622 unsafe SATraj ops	Profiler 支持 failure/safety views, 且负结果能揭示粗标签不足。