

AgentFlame: 面向 AI 编程 Agent 系统效应的语义归因剖析

AgentSight 研究原型

2026 年 6 月 19 日

摘要

AI 编程 agent 的可观测性问题不只是“模型调用了哪个 tool”，而是用户语义意图如何导致真实系统副作用：进程、文件、网络、测试、失败重试和 token 消耗。现有 LLM observability 工具擅长展示单次运行的 trace tree、span duration、tool call 和 cost；传统 profiler 和进程工具擅长聚合系统行为。二者分开时，一个用户常问的问题仍然难答：哪个任务语义造成了哪些重复、沉重或越界的系统足迹？本文提出 AgentFlame，一种语义系统效应剖析模型：本地小模型只给 session、prompt 和 LLM call 生成一个词标签；当前 full run 从 agent-native tool logs 继承这些标签；目标模式则让 tool、shell、child process 与 file/network effect 通过确定性 lineage 继承这些标签；最终以 folded stack 形式聚合为 flamegraph。在 R170 current refresh 的 325 个可读 Codex/Claude 真实 session 上，AgentFlame 标注 2,859 个 prompt rows 和 114,837 个 LLM-call events，0 个最终标签失败；它把 183,714 个系统观测折叠成 26,829 条语义系统栈，并记录 35,136 次真实 llama.cpp tag calls。去掉 session/prompt 语义后，nonsemantic baseline 有 90.402% 的观测权重落入混合多个语义区域的 buckets；flat effect baseline 的混合权重为 90.918%。R224 消融进一步显示：在保持同一 183,714 个系统观测总权重不变时，session-only 仍混合 84.407% 的完整语义权重，prompt-only 降到 36.722%，完整 session+prompt 降到 0.000%。这些结果支持一个机制性结论：语义帧，尤其是 prompt 标签，能分开传统 trace 或 process summary 会合并的 task-effect 区域。本文也明确边界：live lineage 证据只支持固定 command-mode 和 controlled scoped workloads，而不是完整系统 provenance。R114/R191/R229/R232/R234 在固定任务、外部仓库和受控 target-network probes 中给出 100.0% scoped precision/recall 且 negative-control joins 为 0；R238/R240 进一步修复并回归测试 direct process/network readiness。但 Codex/Claude-launched target-network rows 仍有 orphan/missing-action cases，full-history projection 仍只是在 generated artifacts 上验证语义帧覆盖。因此用户任务实验、任意仓库泛化、Claude-launched target-network capture、更多 agent family 和 same-tag duplicate prompt-row identity 仍未完成，不能声称用户效用或完整系统 provenance 已被证明。

1 问题

一个 AI 编程 agent 运行结束后，开发者通常不想逐条回放消息。他们想知道：这次运行哪里最重，哪里绕路，哪里反复试错，哪些文件或网络目标被碰过，哪类用户请求导致最多测试、最多读取、最多失败或最多 token。传统工具各自只覆盖一半。LLM trace 工具能展示 agent、LLM call、tool call、prompt、completion、latency 和 cost。进程或文件审计工具能展示 git、cargo、rg、sed、docker 等系统行为。Span-duration flamegraph 甚至已经出现在 multi-agent workflow debugging 中，用于看 critical path、parallelism、




图 1: AgentFlame 的归因模型。小模型只标注 session、prompt、LLM-call 语义；tool/process/file/network effects 通过确定性 lineage 继承语义帧并折叠成 stacks。

error cascade 和 tool overhead。

但是这些视图仍难回答跨层问题：

为了哪个用户任务，agent 反复运行了哪些命令、读取了哪些路径、产生了哪些网络或文件副作用？

本文的核心判断是：agent observability 的对象不应只是 span，也不应只是进程，而应是 *task-grounded system effect*。我们把目标栈写成：

```
sessionTag;promptTag;llmcall/tool;process*;effect
```

这个模型把两类传统工具分开的信息合并起来。上层的 session、prompt、LLM call 用本地小模型压缩成一个词；下层 tool、process、file/network effect 不由模型猜测，而通过确定性关联继承语义上下文。最后用 folded stack 聚合重复路径，让宽度表示 event count、effect weight 或 token weight，而不是只表示 span duration。

本文的贡献不应表述为“agent flamegraph”。已有系统已经把 agent spans 画成 flamegraph。本文的贡献是一个更具体的系统归因模型：在 agent-native local histories 中把用户语义意图与系统行为代理接起来，并为 live AgentSight traces 定义 exact provenance 目标，使跨 session 的重复副作用可聚合、可检查、可比较。

2 设计

图 1 展示了 AgentFlame 的设计。语义层非常小：每个 session、prompt 和 LLM call 只生成一个 lowercase word，例如 refactor、review、test、research。这些词不是固定 ontology，也不是 verdict；它们只是给折叠栈提供短、稳定、可搜索的任务帧。

系统层不交给 LLM 判断。Agent-native 历史模式从 Codex/Claude JSONL 中恢复 tool 类型、命令入口、状态、路径组和粗 effect 类别。AgentSight exact 模式的目标输入是：

```
tool_call -> shell -> child process ->
file/network effect
```

每个 in-scope effect 必须能追溯到 tool call 和 prompt ancestry。如果只能用 PID 或时间戳模糊匹配，就不能作为强 provenance claim。因此，语义由上层继承，系统事实由 instrumentation 或 session parser 产生。

2.1 为什么是一个词

一个词标签有三个工程优点。第一，火焰图帧必须短；长摘要会让图不可读。第二，标签只用于导航和聚合，不承担安全、正确性或因果判决。第三，一个词标签容易本地化和缓存化。当前实现对 session/prompt/LLM 文本各处理一次，后续数十万条系统事件只做普通程序关联和聚合。

这也约束了论文 claim。AgentFlame 不证明标签是真实意图 ontology。它先证明一个更可审计的机制：加入这些短语义帧后，传统 baseline 会合并掉的系统效应是否被分开。

2.2 Stack 语法

系统效应栈形如：

```
project;agent;session;prompt;call:tool/...;process*;effect:path/domain/status
```

Token 栈形如：

```
project;agent;session;prompt;call:llm/...;model;kind
```

完整视图保留 session、prompt、LLM-call 语义。消融视图删除部分语义轴：session-system、prompt-system、llm-token 等。所有视图共享同一事实表；投影不应改变总权重。

2.3 可视化模型

AgentFlame 不把所有信息塞进一张图。面向开发者的核心界面应有四类互补视图。第一，semantic system flamegraph 用宽度表达 system-effect count，用于回答“哪里重、哪里绕、哪里重复”。它适合跨 session 聚合，因为 folded stack 会把同一语义任务下重复出现的 rg、cargo test、文件读取或网络目标折叠到同一横条。Duration 是单独的 projection：当前 R225 只支持 prompt wall-clock baseline，不支持 active runtime 或 tool/LLM span-duration。第二，token flamegraph 使用同样的 session/prompt/LLM-call 语义帧，但叶子变成 model/prompt/completion token，回答“哪类任务消耗上下文和模型预算”。

第三，exact-lineage tree 不是聚合图，而是 provenance drill-down。它展示一个 prompt 下的 tool call、shell、child process 和 file/network effect 链，用来确认某个横条是否真的来自目标 agent process family。R182/R183 说明这个视图不能省略：低层 codex network rows 可以被 join，但只有 R191 这种 target python3 child-process rows 也被观察并 join 后，UI 才能把对应固定 workload 标成 covered。第四，claim/evidence board 把每个 claim 连接到 artifact、oracle 和 status，防止用户把 smoke run 当成完整结论。

因此 flamegraph 与 tree 的职责不同。Flamegraph 负责发现热点和重复模式；tree 负责解释一个热点能不能被信任；claim board 负责告诉用户哪些结论还只是 partial。这种三层设计是传统 profiler 和普通 agent trace 都缺的：前者没有 prompt 语义，后者通常没有系统副作用的 deterministic ancestry，更不会把 claim boundary 作为一等视图。

3 实现

本文的实验结果来自 AgentFlame 研究原型及其生成 artifacts。该原型当时是独立 Rust CLI，并输出 agentflame.json、tags.json、folded stack 文件、SVG 和 HTML dashboard。当前开源仓库的产品化入口已经收敛到 agentpprof/：它复用 agent-session，输出 pprof-compatible .pb.gz、folded、SVG 和 JSON。因此，本文的

headline 数字评估的是 AgentFlame 研究原型；agentpprof 是产品化方向，除 smoke artifacts 外还没有替代本文所有 RQ1-RQ6 结果。默认输出路径是：

```
.agentsight/agentflame/latest/
```

本次 full run 的命令为：

```
cargo run --manifest-path
agentflame/Cargo.toml -- run --project-root
. --scan-files 10000 --max-sessions
10000 --llama-url http://127.0.0.1:18080
--model local-r170 --timeout 60 --out
.agentsight/agentflame/r170-full-current
```

这条命令是研究 artifact 的 provenance，不是当前仓库的用户入口。R170 的 committed summary 记录 repo_dirty=true，因此本文把它作为 dirty-provenance mechanism evidence 使用：数值可以用于当前本机历史 characterization 与 folded-total 检查，但它不是 clean release artifact run，也不支持 C5/C6 outcome claims。当前用户入口示例是：

```
cargo run --manifest-path
agentpprof/Cargo.toml -- --project-root .
-o agent.pb.gz
```

模型为本地 qwen2.5-3b-instruct-q4_k_m.gguf，通过 llama.cpp server 运行，temperature 为 0，并用 grammar 约束输出一个词。AgentFlame 没有 heuristic fallback：如果 LLM server 缺失，或模型重试后仍不能输出合法一词标签，run 失败。

3.1 隐私与可复现

原始 agent trace 不提交。agentflame.json 默认包含 redacted previews、hash、tag、计数和路径组；tags.json 保存 tag cache 和 LLM provenance，不保存原始 prompt 文本。本次 run 遇到一个 root-owned Claude JSONL，不可读；系统没有要求 root 权限读取，而是跳过并写入 warnings。这让覆盖范围可审计，而不是静默假装完整。

3.2 与 AgentSight 的关系

AgentFlame 的第一模式是零 instrumentation 的历史分析。AgentSight 的独特点是运行时 exact provenance：tool_call -> shell -> child process -> file/network effect。正确集成后，AgentFlame 负责语义帧，AgentSight 负责系统效应事实，两者通过 tool/session/prompt ancestry 连接。当前 full run 还不是 live exact-effect 结果。R110-R113 将最小 session/tool envelope 从 fixture、native export、DB backfill 推到 record -- <command> 的 capture path；R114 用 20 个真实 Codex command-mode 任务验证该路径，加入 per-task negative controls，并在 scoped oracle 下达到 1,273/1,273 in-scope effects joined、0 false positives、0 false negatives。R182 暴露并修复 record-mode process runner 没有传 --trace-net 的缺口；修复后 35/35 个低层 codex process network rows 全部 join、0/604 negative controls 被 join，但 target-specific loopback/expected child-process network rows 为 0/0。R191 随后修复两个更细的 capture 边界：record envelope start time 必须使用 target process start timestamp，process filter 必须允许 session 内进程或 tracked PID descendants；在

固定 Codex HTTP probe 上, 4/4 个 target `python3` network rows 全部 join, 0/310 negative controls 被 join, precision/recall 为 100.0%/100.0%。R229 再用同一 oracle 复现 5 个 controlled multi-workspace tasks (repo read, edit/test, shell fix, JSON write, typo edit), 394/394 个 in-scope effects joined, 0/306 negative controls 被 join。R232 把同一 scoped oracle 带到 AgentSight 仓库外: 4 个 fresh external git-repo tasks 覆盖 repo-read, edit-test 和 write categories, 353/353 个 normal in-scope effects joined; 另一个 external HTTP probe join 4/4 个 target network rows; 合计 0/480 negative controls 被 join, precision/recall 为 100.0%/100.0%。R234 进一步做局部泛化: 1 个 Claude command-mode JSON-write task 和 2 个 Codex HTTP-family target-network probes 产生 269 个 in-scope effects, 8/8 个 target network rows 全部 join, 0/331 negative-control effects 被 join, scoped precision/recall 为 100.0%/100.0%。R235 则故意触碰更宽的 network boundary: 单进程 Codex TCP 通过并 join 3/3 个 target network rows, 但 Codex multiprocess TCP 和 Claude-launched HTTP/TCP probe 都执行成功却导出 0 个 target network rows。R236/R237 进一步诊断该边界; R238 将 `record --` 从固定 250ms sleep 改为等待 process tracer `CLOCK_SYNC/start`, 并修复 filtered PID propagation 与 lineage checker 的两个边界。一个 compact supplement 汇总 5/5 direct-only readiness repetitions; 正式 R238 full run 中 4/4 runtime witnesses, 4/4 witness ports observed, direct HTTP 和 direct multiprocess controls 都通过, 13/16 target network rows joined, 0/186 negative controls 被 join; 但 Codex/Claude-launched rows 仍有 3 个 target-network orphan/missing-action cases。R240 将 R239 指出的两个实现风险变成 regression: synthetic guard 证明 command-root fallback 只 join root-self event, 不会把同 root 的 sibling 误归因; BPF runtime test 证明 `-p --trace-net` 下 target child 的 bind/listen/connect 可见且 unrelated port 不被捕获。因此 R238/R240 是更强的 partial-localization 与 regression-guard evidence: 它解决 direct multiprocess readiness race 并守住 over-attribution 边界, 但仍不是广义 Claude-launched 或 raw-socket coverage; direct-only repetitions 没有 negative controls, precision 证据来自正式 full run。R230 则审计 generated full-history projection: 183,714 folded system-observation weight 与 R170 totals 完全一致, 缺失 lineage frame 的 weight 为 0, tool prompt-index coverage 为 100.0%; 但 5 个 sessions 中存在 12 个 duplicate prompt-index rows, prompt-tag drift 为 346 weight (0.188%), LLM prompt-tag drift 为 93 events (0.081%)。R231 将这个缺口拆开: folded display projection 与 event-local prompt-tag weights 精确一致, R230 field-index drift 被完全复现并定位到 duplicate-index Claude sessions; 但 list-position join drift 反而更高 (tool 2,048 weight/1.115%, LLM 1,144 events/0.996%)。R233 因此把裸 prompt index 降级为只在 session 内唯一时才可作 key, duplicate indexes 作为 non-keyed row identity; 归一化后 semantic drift 为 0 tool weight/0 LLM events, 但 same-tag duplicate rows 仍有 row identity ambiguity (tool weight 575, LLM 432 events)。因此, C4 的 live lineage 支持性证据来自 R114/R191/R229/R232/R234 和 R238 direct controls, R235–R240 也提供边界与回归证据 (R182 只是 record-mode `--trace-net` 实现 smoke); R230–R233 支持的

表 1: R170 current full-history refresh 的本机 AgentSight session 运行指标。

指标	数值
Readable sessions	325
Codex / Claude / Claude-subagent	198 / 50 / 77
Raw tool events	142,468
Raw LLM events	114,837
Prompt rows	2,859
Unique prompt tags	328
LLM-call tags	114,837
Unique LLM-call tags	1,423
Tag requests	118,021
Cache hits	82,886
llama.cpp HTTP calls	35,136
Successful final uncached tags	35,135
Final tag failures	0

是 generated full-history projection/normalization audit。它仍不是任意仓库泛化、raw-socket 或 Claude-launched target-network workload、same-tag prompt-row identity、更多 agent family 或 HTTP payload/URL reconstruction 证据。

4 评估

4.1 RQ1: 本地小模型能否全量标注？

表 1 给出 R170 current full-history refresh 结果。AgentFlame 分析了 325 个可读 session, 其中 Codex 198 个、Claude 50 个、Claude subagent 77 个。它处理 2,859 个 prompt rows 和 114,837 个 LLM-call events。标签器共有 118,021 个请求, 82,886 个命中 cache, 35,136 次真实 llama.cpp HTTP calls, 35,135 个成功最终 uncached tags, 0 个最终失败。HTTP calls 比成功最终 tags 多 1 次, 是一次被 retry 吸收的中间无效输出。Prompt 和 LLM-call tag 的非法计数均为 0。这说明一词语法和本地 3B 模型路径在真实历史规模上可运行。R170 是当前全量本机历史刷新证据, 但仍不是 C5/C6 outcome evidence。R180 进一步表明, 在同一组 300 个 redacted fragments 上, 本机可用的 0.6B、1.1B 和 3B GGUF 都能输出符合语法的一词标签; 但该实验只支持 syntax/latency/stability, 不支持 semantic adequacy。

这个结果不等于标签语义充分。例如某些 tag 明显带噪声: `agentsightsm`、`testcodex`、`bashoutput`。因此系统需要区分 raw tag 和 canonical display tag。R189 在 R170 current refresh 上实现了第一版可审计合并层: raw tag 永远保留, 图和聚合默认可使用 canonical tag。它把 prompt-effect tag 从 263 个合并到 216 个, 把 prompt-row tag 从 328 个合并到 279 个, 把 LLM-event tag 从 1,423 个合并到 1,254 个; 同时保持 folded 总权重不变, system stacks 从 26,829 条降到 26,067 条, token stacks 从 8,569 条降到 7,661 条。这说明存在一个可审计的候选长尾降噪空间, 但不能证明这些 raw tags 一定语义冗余。因此 AgentFlame 使用 semantic compaction lifecycle: raw tag 不变, canonical map 只作版本化展示层, pending actions 保存 keep/merge/regenerate/split, 小模型生成的 `regenerated_tag` 只有经过 R203 paired/adjudicated promotion review 和 display-map diff 后才能进入 canonical view。R209 将这个 lifecycle 落成可消费数据契约: active display map 每个 raw tag 一行, drilldown index 保留 raw 支持和 top system profile, reviewed diff 只在人工 promotion




图 2: 当前机制结果。图由 docs/visexp/paper/make_figures.py 从 .agentsight/agentflame/r170-full-current/agentflame.json 重新生成; 它反映 Rust full-run 输出, 而不是旧的 Python sampled-run artifact。

表 2: 语义栈与 baseline mixing。

指标	数值
System observations	183,714
Unique semantic system stacks	26,829
Semantic compression	6.848x
Max stack reuse	6,004
Nonsemantic mixed buckets	4,685
Nonsemantic mixed weight	90.402%
Flat mixed weight	90.918%

后产生。因此 RQ1 支持的是 feasibility 和 syntax claim; tag adequacy 需要单独实验。

4.2 RQ2: projection 方法如何取舍?

R170 full run 产生 183,714 个 system observations, 并折叠成 26,829 条 unique semantic system stacks, 压缩率为 6.848 倍。关键不是压缩本身, 而是 baseline mixing。当删除 session/prompt 语义帧后, nonsemantic folded baseline 有 4,685 个 mixed buckets, 覆盖 166,081 个观测, 也就是 90.402% 的系统权重。如果进一步退化成为 flat effect baseline, mixed weight 占 90.918%。

这为回应“传统工具也能看出来”的质疑提供了机制性证据。传统 flat summary 可以告诉我们 sed read 有 25,755 次、rg read 有 15,336 次、cargo test 有 2,903 次。但是它不知道这些行为分别来自 refactor、review、research、design 还是 test prompt 区域。AgentFlame 的价值是把 heavy/repeated system effects 按任务语义拆开。

R211 将当前 R170/R189 artifact 转成可放入论文的 label distribution 和 baseline-collapse examples。在 R170 full-history 刷新中, rg 覆盖 176 个 prompt tags, sed 覆盖 180 个, git 覆盖 147 个, cargo 覆盖 68 个。具体 collapsed key process:git;effect:read;status:ok 有 116 个 prompt tags, top prompt 只占 24.977%; process:cargo;effect:test;status:ok 有 48 个 prompt tags, non-top-prompt weight 为 68.05%。这说明传统 process/effect summary 不只是少了一层标签, 而是把大量不同用户意图导致的相同行为合并成同一个 bucket。R211 同时输出 tag-distribution-r211.svg 和 process-splits-r211.svg, 用于绘制本文的 baseline failure/semantic split 图; 该 artifact 不调用 LLM, 也不读取 raw trace。

R251 从另一个角度检查 prompt tags 是否只是任意词。它只读取 R170 的 folded stacks, 把 183,714 个 system-effect observations 展开成 behavior observations, 对 process label 做公开 artifact 脱敏, 然后在每个 session 内随机打乱 prompt tags 1,000 次。真实 prompt tags 对 sanitized process/effect/status behavior 的 session-beyond 信息增益

表 3: R224/R170 system-effect 语义轴消融。所有行都保持 183,714 总权重。

Variant	Unique stacks	Bucket	Residual
No semantic	11,967	90.402%	44.716%
Session only	15,027	84.407%	33.434%
Prompt only	24,703	36.722%	7.485%
Session + prompt	26,829	0.000%	0.000%

为 8.419%, 而 session-preserving null 的 p95 只有 1.903% (单侧 $p = 0.0010$, 分辨率 1/1001); prompt top-behavior purity 为 20.196%, 也高于 null p95 的 18.367%。R251 同时记录上游 R170 dirty provenance, 并让公开输出 privacy scan 通过。这个结果支持 tags 与真实系统行为有 weighted association, 但绝不等于人工语义 adequacy: p-value 是对展开后 effect weight 的随机化分数, 不是 independent-session inference; 低绝对 purity 和 analyze/test/build 等 broad tags 仍需要 R124 人工标签。

与 R251 的随机化检验不同, R131/R224 回答 projection 层的问题: 删除某个语义轴后, system-effect buckets 会混合多少。R224 用同一个 checker 在 R170 current refresh 上重跑该消融, 使 semantic-axis rows 与 R212 display-policy rows 共享 183,714 个 system-effect denominator。每个 variant 都从同一个 folded input 投影而来, 并检查总权重保持不变。同时, checker 记录 agentflame.json totals 与 folded inputs 匹配, 并验证已有 nonsemantic/session/prompt folded files 与 projection exact match。表 3 显示, system-effect 分割主要来自 prompt 轴: session-only 只把 mixed full-semantic bucket weight 从 90.402% 降到 84.407%, prompt-only 则降到 36.722%。如果只计算 mixed buckets 中非主导 full semantic variants 的 residual weight, prompt-only 也从 no-semantic 的 44.716% 降到 7.485%。完整 session+prompt 视图的 0.000% mixed weight 是定义上的上界, 不应被解释为用户效用; 它只说明 full semantic key 没有在投影中被合并。

R223 将 RQ2 从“语义栈是否更好”改写成更一般的 projection-selection 问题: 在 R170-derived generated evidence 上, stack schema、display policy 和 tag vocabulary overlay 都应是可插拔选择。该实验只读取 R224/R205/R209/R212/R219 已生成 artifacts, 不读取 raw trace, 不调用 LLM, 也不评分人工 outcome。因此, R223 的 baseline 是 count-weighted process/effect projection, 而不是真实 span-duration workflow flamegraph; 后者回答 critical path/duration 问题, 应作为 C5 用户任务实验中的独立 baseline, 而不是用当前 folded effect counts 替代。它给出的结论不是单一最佳火焰图, 而是分层默认: no-semantic 适合作为 system-hotspot baseline, 因为它只有 11,967 个 stacks、压缩率 15.352x, 但 90.402% 的 effect weight 被混合; prompt-only 是 system-effect profile 的最佳单语义轴, 因为它把 mixed/residual mixed weight 降到 36.722%/7.485%, 同时保持 7.437x 压缩; 完整 session+prompt 是 audit 和 drilldown 视图。在 display policy 上, R209 conservative display 与 alias-only 等价, 只有 26,612 个 stacks 且 0.0% unreviewed active weight; 更激进的 profile-guarded candidate view 可以降到 26,067 个 stacks, 但会激活 2.532% 未审查 effect weight, 因此只能作为上界消融, 不能做默认。在 vocabulary overlay 上, canonical display 把 raw unique tag strings 从 1,546 降到 1,364, top-20 support coverage 从 93.683% 提升到 95.186%, 同时保留 raw drilldown。这个 coverage 只是

display-support concentration, 不是 tag correctness; 在 R124/R190/R203 人工标签返回前, 不能把它写成 tag adequacy、merge quality 或 promotion quality。R225 进一步补上一个 duration 视角的边界实验: 它只读取 R170 agentflame.json 和 semantic-system.folded.txt, 从 prompt timestamps 重构 2,858 个 prompt wall-clock spans, 生成 duration-weighted folded stack 和 SVG。这个 baseline 覆盖 324/325 个有 prompt spans 的 sessions, 并且 covered prompt-index effects 覆盖 183,714/183,714 个 system-effect observations; 总 prompt wall-clock duration 为 859.019 小时; duration top-10 与 effect-count top-10 只重合 7 个, top-20 重合 12 个, prompt-tag rank Spearman correlation 为 0.623。例如 network 在 duration 中排第 8、占 2.837%, 但在 system-effect weight 中排第 93、占 0.040%; benchmark 则在 effect weight 中排第 7、占 2.195%, 但 duration 中排第 34、占 0.198%。这说明 duration flamegraph 与 system-effect profile 相关但回答不同问题。同时, R225 明确记录历史 artifact 没有 tool/LLM start-end span, 因此它不是 active runtime、完整 workflow span-duration trace, 也不能支持 C5。这就是系统设计需要可插拔 projection 的原因: 不同视图优化不同问题, 而不是让小模型一次性决定最终语义真相。

4.3 Case Study: 能看出什么

本次 full run 中, 最大的 semantic stack 是:

```
project:agentsight;agent:codex;session:refactor;prompt:refactor;call:tool/tool;effect:process;status:ok
```

权重为 6,004。另一个明确的系统例子是 cargo test。Flat summary 只会显示 2,903 次 successful cargo test。Nonsemantic stack 会保留 call:tool/shell;process:cargo;effect:test;status:ok, 但仍把不同语义区域混在一起。Semantic stack 将它拆成多个区域, 包括 review/review、refactor/refactor、research/explain、research/refactor、design/review 等。R211 的 R170 刷新版本进一步显示 process:cargo;effect:test;status:ok 在 48 个 prompt tags 中分布, refactor 只占 31.95%, 其余 68.05% 来自 review、research、commitlog、explain、test 等 prompt。这生成了一个可检查的候选分解: 同样是 test process, 语义来源不同; 后续 C5 才能测试开发者是否能更快或更准确地使用它。

这类结果生成可供检查的候选分解, 用来辅助三类 developer questions:

- 哪个任务导致最多重复测试或读取?
- 哪些 prompt tag 反复触碰同一组路径或域名?
- 哪些失败行为集中在特定 semantic region, 而不是全局系统问题?

Trace tree 能回放某次调用, span flamegraph 能看 duration bottleneck, flat summary 能看重命令。但它们都不直接给出跨 session 的 task-effect 聚合。

4.4 RQ3: exact lineage 是否成立?

当前答案是: 固定 command-mode suite 已经成立, 但 broad full-history provenance 仍不足。effect_lineage_smoke.py 先在 AgentSight-shaped fixture 上验证 process/file/network effects 可以连到 session/tool/prompt ancestry。R110-R112 把同一思想推进到 3 个真实 AgentSight SQLite exports: 先由 harness

增加 agent-run envelope, 再移入 native export, 最后写入 DB 副本; 这些旧 snapshots 只能 join 182/318 raw effects, 说明 envelope 存在但覆盖还不够。R113 把 record -- <command> 的 agent-run envelope 放到 capture path; R113-live 随后在 5 个真实只读 codex exec 任务上验证该路径能创建 5/5 sessions/tools 并 join 508/508 raw effects。R114 将这个路径扩展到 20 个固定 Codex tasks, 包括 read-only、edit、test/debug、dependency、failure/retry 和 disposable-workspace write tasks, 并加入 per-task negative-control bursts。在 scoped oracle 下, R114 结果为: 20/20 target tasks completed, 20/20 tasks observed negative controls, 1,273/1,273 in-scope effects joined, 0 false positives, 0 false negatives, precision 和 recall 都是 100.0%, 3,170 个 observed negative-control effects 中 0 个被 join。Raw join 仍只有 22.055%, 这是预期结果: wrapper、sibling 和 out-of-scope effects 应该保持 orphan, 而不是被错误归因给 agent。R182 进一步检查 network-effect case。第一次 loopback run 暴露出 agentsight record 没有给 process eBPF runner 传 --trace-net; 修复后, 35/35 个低层 codex process network audit rows 全部 join, network orphan 为 0, precision/recall 仍是 100.0%, 0/604 negative controls 被 join。严格 oracle 同时显示 target-specific loopback/expected child-process network rows 为 0/0; 因此 R182 只是 record-mode --trace-net 实现证据。R191 将 workload 固定为预置 Python HTTP probe, 并修复 envelope timestamp 与 session-hard-filter 问题; 该 run 观察到 4 个 target python3 network effects (bind、listen、connect), 4/4 全部 join, 0/310 negative controls 被 join, scoped precision/recall 为 100.0%/100.0%。R191 的 broad effect-lineage smoke 仍因 wrapper/out-of-scope orphan 返回非零, 因此论文只把它作为 scoped target-network oracle。R229 进一步复用 R114 oracle, 在 5 个 controlled multi-workspace tasks 上得到 394/394 in-scope effects joined, 0 false positives, 0 false negatives, 0/306 negative-control effects joined; raw join 为 394/1080=36.481%, 因为 out-of-scope、wrapper 和 negative-control effects 必须保持 orphan。R232 在 AgentSight 仓库外复用该 oracle: 4 个 fresh external git-repo tasks 产生 353 个 normal in-scope effects, 353/353 joined; 1 个 external HTTP probe 产生 4 个 target network rows, 4/4 joined; 0/480 negative-control effects 被 join, combined scoped precision/recall 为 100.0%/100.0%。R234 再把同一 gate 扩展到另一个 agent family 和重复 HTTP target-network probes: 1 个 Claude command-mode JSON-write task 产生 34 个 in-scope effects, 2 个 Codex HTTP-family probes 产生 8 个 target python3 network rows; 合计 269 个 in-scope effects, 8/8 target network rows joined, 0/331 negative-control effects joined, scoped precision/recall 为 100.0%/100.0%。R235-R238 随后把同一 gate 推到 raw/multiprocess/Claude-launched boundary, 显示 direct controls 被修复后仍不能推出 broad agent-launched coverage; R240 再用 regression guard 检查 command-root fallback 不会过度归因, 且 target-child network runtime test 能观察 bind/listen/connect 并排除 unrelated port。R230 补充 full-history projection audit: 183,714/183,714 folded system-observation weight 都有 semantic session/prompt tag frames 和 call/effect frames, 且 raw tool-event prompt-index coverage 为 100.0%; 但 12 个 duplicate prompt-index rows 与 346

weight (0.188%) prompt-tag drift 说明裸 index 不能作为 strict key。R231 复现该 drift, 并显示火焰图实际 display projection 与 event-local prompt tags 完全一致 (183,714/183,714), field-index drift 全部来自 duplicate-index Claude sessions, unique-index sessions 中 field drift 为 0 tool weight/0 LLM events; 同时 list-position join 产生 2,048 tool weight (1.115%) 和 1,144 LLM events (0.996%) drift, 说明不能简单改用 list position。R233 将 duplicate prompt indexes 显式标记为 non-keyed row identity, 并用 (prompt_index, prompt_tag) semantic key 重新审计: legacy 346 tool weight/93 LLM events drift 变为 normalized 0/0; 3 个 mixed-tag duplicate groups 可被 tag 消歧, 9 个 same-tag duplicate groups 仍只有语义一致而没有 row identity。整体上, C4 仍不是 HTTP URL 语义恢复、任意 network workload、任意仓库泛化、更多 agent family 或完整历史 row-identity proof。

这个结果已经支持“固定 command-mode suite、controlled external cross-repo workload, 以及一个 Claude command-mode task 加两个 Codex HTTP-family target-network probes 的受控扩展中 exact semantic-effect lineage 成立”。它仍不能支持“任意历史、任意仓库、任意 agent 都有完整 provenance”。完整 OSDI artifact 还需要更多 agent 类型、更丰富的 network workloads、HTTP 语义恢复、child-depth/path/domain breakdown、任意仓库泛化、same-tag prompt-row identity policy, 以及用户任务结果。

4.5 RQ4: 用户效用是否成立？

当前答案是不成立, 或者更准确地说: 未验证。已有 task packet、answer key、scorer 和 launch package, 但没有真实参与者响应。R184 机械 gate 把 C5 状态记录为 ready_for_participant_collection, 而不是 supported。R186 计划审查进一步确认: 下一步应先运行真实 R142 五人 pilot, 然后才进入 R151 纸面规模实验。R187 已把冻结的 R142 assignment 打包成 P01-P05 参与者文件和空白 70 行 response CSV; manifest 检查 launch 目录没有 answer key、参与者 payload 没有 oracle/scoring 字段, 且 real_response_count=0、c5_supported=false。R193/R195/R207 进一步把这个收集路径变成可执行 handoff: R193 汇总空白 R124/R190/R203 label sheets 和 R142 launch 指针, R195 定义返回 CSV 的 ingestion/scoring contract, R207 检查五个 R142 participant packets、70 行空白 response template、两份 300 行 R124 sheets、两份 160 行 R190 sheets、两份 41 行 R203 sheets 以及 R195 inbox 文件名均有效。这些 artifact 只支持 launch readiness; 它们仍记录 0 个参与者响应、0 个人工标签, 不能支持 C5。R242 用 synthetic returned files 验证 R195 contract: 完整 synthetic R142/R124/R190/R203 输入会进入 R195-specific scored outputs, partial/no-input/invalid-return cases 会被检测, canonical empty gates 保持不变。但 R242 的每一行都是 synthetic control, 因此它只支持 collection pipeline correctness, 不是 C5/C6 outcome evidence。R243 进一步把 handoff 包装成静态本地 collection kit: 五个 participant forms、六个 labeler forms、一个把 P01-P05 exports 合并为 r142-pilot-responses.csv 的 coordinator page, 以及记录 source hashes、row counts 和 leak scan 的 manifest; 它降低返回格式错误, 但仍记录 0 个真实响应和 0 个人工标签。R244 用 headless Chrome 和 synthetic CSV exports 检查这个 kit 的可执行性: index/coordinator/P01/R124/R190/R203 页

面可加载, 五个 participant exports 可合并为 70 行 R195 response shape, labeler exports 保留字段和行数且 label cells 为空; 这些 synthetic exports 不进入 R195 inbox。R247 将同一静态 kit 打包成离线可发送的 agentflame-human-evidence-r247.tar.gz, 包含 5 个 participant forms、6 个 labeler forms、1 个 coordinator form、return checklist 和 package manifest; tarball leak scan 排除 answer key、scorer、raw trace 和 R244 synthetic exports, 17 个成员、182,992 bytes, 但仍不包含任何真实返回数据。R249 补上 paper-scale C5 launch logistics: 它从冻结的 R142 task packets 派生 12 个 participant packets、168 行 blank response template 和一份非默认 assignment file; 每个 task-condition 至少有 2 个、最多 3 个重复, scorer 用这份 assignment 读取空模板时仍输出 participant_results_empty 和 c5_supported=false。当前 baseline 应设为 trace tree、event-count-proxy、flat process summary、nonsemantic folded stack 和 semantic folded stack, 比较 accuracy、time、false positives 和 confidence。当前 R142 packet 中原来的 span-like 条件已明确命名为 event-count proxy, 因为 folded artifact 没有真实 duration; 它不能直接当作 span-duration baseline。R225 已经从 R170 timestamps 重构出 prompt wall-clock duration baseline, 并显示它与 effect-count profile 的 top tags 和排序有明显差异; 但该 baseline 可能包含 idle/user-wait time, 且 tool/LLM 调用仍没有 start-end span, 因此它只能作为下一版 preregistered packet 的 prompt-span baseline, 而不是 active runtime 或完整 workflow span-duration baseline。如果这个实验失败, AgentFlame 仍可能是专家 forensic 工具, 但不能写成提升普通开发者效率。

4.6 RQ5: 小模型成本和标签质量

Full run 和 R123 证明 3B 模型路径可用; R180 进一步补上本机 0.6B/1B-class/3B-class syntax-stability smoke。R122 从本机 294 个 parsed sessions 中抽取 300 个 redacted fragments: 100 个 session、100 个 prompt、100 个 LLM-call。R123 用本地 llama.cpp 3B server 对这 300 个 fragments 做三次 identical repeats, 共 900 次请求; 结果是 900/900 valid tags, 285/300 exact-stable fragments (95.000%), 模型加载约 1,002 ms, 请求延迟 p50/p95 为 11/31 ms。R180 用 --reasoning off 对同一个 R122 fragment file 分别运行本机 0.6b、TinyLlama 1.1b 和 3b GGUF: 三者都是 900/900 valid tags; exact-stable fragments 分别是 299/300、279/300 和 285/300; p95 延迟分别为 23/18/32 ms。这支持本机小模型的 syntax、latency 和 repeated-input stability smoke, 但不是同一模型家族的 scaling curve。更重要的是, TinyLlama 1.1b 虽然语法有效, 却大多输出 localization/localized 一类标签, 说明 stability 不能替代 adequacy。R189 的 canonicalization 进一步说明, 即使一个词标签语法有效, 展示层仍需处理长尾碎片。该机制把 dictionary aliases、lexical+profile merges 和 review suggestions 分开报告; 例如 testcodex 合并到 test, docsupdate 合并到 docs, rootpidrefs 合并到 trace。这些合并只能说明展示碎片和聚合抖动有可审计的降低 proxy, 不能证明用户导航质量, 也不能替代 R124 人工 adequacy labels。R190 进一步比较 raw、alias-only、lexical-only 和 profile-guarded variants, 显示 lexical-only 对 LLM-event tags 过于激进 (868 个 unique tags, 而当前 profile-guarded 为 1,254); 同时导出 160 行 merge-risk audit packet。R190-score 当前为 human_labels_empty,

因此 over-merge/under-merge rate 仍需人工标注后才能报告。R196 把剩余长尾显式拆成治理动作，而不是归入 `other`: 231 个 existing canonical merges、114 个 review-merge rows、39 个 regeneration candidates、2 个 contextual-split candidates、1,241 个 kept rare distinct tags 和 184 个 kept head tags。这说明长尾机制可以保留罕见但具体的信号，同时把 `update`、`codex`、`ignored` 这类泛化或噪声标签送入重生成/拆分审核；但它仍只是治理 packet，不证明标签语义正确。R201 进一步做 policy sensitivity: 在 7 个 tail/split/generic-vocabulary 变体中，baseline review-required support 为 1.926%，最大为 expanded generic vocabulary 下的 1.931%；lower/higher tail thresholds 使 long-tail support 在 0.921% 到 3.030% 间变化。这说明 review-required rows/support 在该 grid 中基本稳定，但并未测量人工审核时间；higher-tail-threshold 会把 baseline head stability 降到 65.217%，因此阈值仍是需要报告的展示策略风险。R202 用本机 llama.cpp server 对全部 41 个 regenerate/split candidates 跑候选重标，得到 41/41 grammar-valid one-word outputs、0 invalid；但这些输出仍只是候选，不更新 canonical map。R202 的顶层 summary/attempts 面向公开 artifact，嵌套的 `r196-with-regeneration/` 是 local-audit-only，因为其中可能包含 path/profile buckets。R203 进一步把这些候选变成 promotion review protocol: 41 行 promotion packet、两份空 reviewer sheets、0 final labels、`long_tail_promotion_review_supported=false`，且 `canonical_map_updated=false`。R205 把这套机制转化为 reviewer 可检查的 compaction metrics: raw unique tag strings 从 1,546 降到 canonical unique tag strings 1,364，top-20 support coverage 从 93.683% 到 95.186%，long-tail support 为 1.746%，review-required support 为 1.926%；同时 R203 final labels 仍为 0，R190 over/under-merge rates 仍为 n/a。R209 进一步导出可逆 display-map artifact: 1,811/1,811 raw tag rows 有 active display rows，active display labels 为 1,509，63 个 deterministic alias rows 是 active display merges，168 个 lexical/profile merges 仍是 pending merge candidates，41 个 regenerated labels 仍为 candidate-only，reviewed display-map diff 为 0 行，隐藏 `other` rows 为 0，drilldown support preserved，且 drilldown CSV 包含每个 display bucket 的完整 raw-tag membership。R212 对这个 session/prompt 展示策略做 ablation: raw、alias-only、profile-guarded-candidate-applied 和 R209 conservative display 四个变体都保持 183,714 total system-effect weight 不变；raw 有 26,829 个 system stacks，alias-only 和 R209 conservative display 都有 26,612 个，假设激活所有 profile-guarded candidates 则为 26,067 个。但这个假设视图会在 2.532% 的 total effect weight 上激活未人工审核的 profile merges。因此 R212 支持的是 R209 的保守默认策略: alias 可以 active，profile merge 在人工标签回来前必须 pending；它还没有覆盖 LLM/token display compaction。R213 进一步验证 display-mode data-layer contract: raw/display/pending 三种模式都保持 482,398 support，raw mode 有 1,811 个 buckets，display 和 pending mode 都有 1,748 个 buckets；pending mode 只叠加 209 个 candidate rows 和 323 个 review-required rows，不改变 display membership，且 drilldown membership 精确匹配 active display map。这组数字说明可逆 display overlay 能把长尾展示为可审计的聚合视图、提供 raw drilldown 并量化人工审核负担，

但它没有执行前端 renderer，也不证明合并正确或标签足够好。R214 把这个长尾策略进一步变成控制环: 默认 view 保持 active-alias-only with pending overlays，63 个 deterministic alias rows active，168 个 profile-merge candidates 和 41 个 regenerated/split candidates pending，323 个 rows 需要 review，0 个 candidate merges active。它还输出一个非默认的 seven-bucket rollup preview，将 1,811 个 raw-tag rows 和 482,398 support 按 governance state 精确分区；同时记录 regeneration version policy，当前 41 个 grammar-valid candidates 在没有 R203 human promotion labels 时有 0 个 promotable rows。更重要的是，R214 当前失败两个 gate: prompt-level review-required support 为 3.258%，超过 3% 预算；higher-tail-threshold 下 head stability 只有 65.217%，低于 80% gate。因此系统可以建议长尾合并或重生成，但不能为了让火焰图更干净就自动提高阈值或推广 prompt-level candidates。R215 进一步检查前端 renderer-model 是否遵守同一契约: `frontend/src/utils/agentflameDisplayModes.ts` 在 TypeScript 下编译，并由 Node harness 渲染 R209 display/drilldown rows，同时 cross-check R213/R214 summary counts。该 smoke 保持 482,398 support 不变，raw/display/pending buckets 为 1,811/1,748/1,748，pending 只叠加 209 个 candidate rows 和 323 个 review-required rows，0 个隐藏 `other` rows。两个负例也被拒绝: 错误 raw drilldown membership，以及把 candidate display tag 当成 active membership。这说明 display contract 已被前端 TypeScript 模型消费，但仍不是 browser DOM、visual click path、merge quality、adequacy 或 user utility 证据。R216 接着把同一 display contract 放入真实 headless browser: 脚本把该 TypeScript 模块编译成 browser ES modules，启动临时 localhost DOM harness，用 Chrome 点击 raw/display/pending 三个模式，并保存 DOM dump 与 screenshot。浏览器可见状态仍保持 482,398 support，pending view 显示 1,748 buckets、209 candidate overlays、323 review-required rows 和 63 active merges；同样的 corrupted drilldown 与 candidate-promotion 负例也被拒绝。这支持的是 browser DOM harness smoke，而不是 visual drilldown、merge quality、adequacy 或 user utility 证据。R217 进一步构建真实 Next static frontend，提供一个由 R209 artifacts 支撑的最小 AgentFlame API fixture，并在 headless Chrome 中打开 `/agentflame`。生产 AgentFlameView 默认显示 display mode，包含 1,748 buckets、482,398 support、3 个 mode buttons，且 display/drilldown membership 匹配。这补上 production default rendering smoke，但仍没有点击 production controls 或验证 visual drilldown。R218 则把长尾 merge/regenerate 的 promotion 机制变成 checked gate: 它用真实 R209 pending rows 构造 synthetic review fixtures，接受 2 个 final consensus/adjudicated preview diff rows，拒绝 4 个 unsafe rows (unclear、weak single-label、hidden `other`、missing source)，保持 1,811 raw keys 和 482,398 support 不变，并保持 `canonical_map_updated=false`。因为 R218 的 review labels 是 synthetic，它只证明 reviewed display-map diff gate 的机制，不证明 promotion quality。R219 进一步把当前证据状态机械化成 claim/RQ readiness gate: C1 为 supported，C2 为 syntax/latency supported，C3 为 mechanism supported，C4 为 controlled live lineage plus generated-history audit (live lineage 由 R114/R191/R229/R232/R234 支撑；R230-R233 只是

generated full-history projection/normalization audit), C5 为 unsupported, C6 为 partial syntax/stability only, C7 为 partial。该 gate 读取已生成 artifacts, 不读 raw traces, 不调用 LLM; 它记录 C5 responses 为 0、C6 final adequacy labels 为 0, 并保持 `weak_accept_supported=false`。因此 R219 的价值是把下一步固定为 P0 的 R142 participant returns 和 R124 human labels, 而不是提升论文 claim。R193/R194/R195 已把 R203 sheets 纳入 collection、preflight 和 scoring flow; 默认 run 仍没有返回标签, promotion、map update、C5 和 C6 都为 false。R242 进一步用 synthetic R124/R190/R203 sheets 验证这些 scorer 一旦收到完整输入就能被 R195 调用, 同时 partial/no-input/invalid-return cases 不会升级 canonical empty gates; 这仍不构成人工 adequacy 或 merge-quality evidence。R243 将这些空白 sheets 变成静态 labeler forms, 并保留 R195 文件名、source hashes、row counts 与 false gates, 因此它只是收集可用性证据, 不是标签质量证据。R244 再验证这些 forms 的静态加载与 CSV export shape; labeler smoke exports 仍保持 label cells 为空, 因此不改变 C6。R247 把这些 forms 打包为离线 distribution bundle, 并列如 `r124-labeler-1.csv`、`r124-labeler-2.csv`、`r190-labeler-*` 与 `r203-labeler-*` 的 R195 返回文件名; 这只是收集入口, 不是 adequacy 或 merge-quality evidence。OSDI 版本还需要 R124 人工 adequacy labels。R184 当前把 C6 记录为 `ready_for_independent_label_collection`, 不是 adequacy supported; R186 将 R124 labels 排在 R142 pilot 之后或并行执行。一词标签应该被定位为 lossy navigation frames, 而不是 semantic truth。

4.7 RQ6: 开源 artifact 路径是否可用?

R160 检查的是 artifact usability, 而不是 C5 用户效用或 C6 标签正确性。我们用 8 个固定历史 Codex session 文件运行 Rust CLI, 避免当前活跃 session 在 clean/cached 两次运行之间继续增长。Clean run 写入 `.agentsight/agentflame/r160-smoke-fixed`, 生成 dashboard、folded stacks、SVGs 和 `tags.json`, 在 76 个 tag requests 中发起 60 次真实 llama.cpp calls, 耗时 1.64 s。Cached rerun 使用同一组 `--session-file` 输入和同一个输出目录, 76/76 tag requests 命中 cache, 0 次 LLM call, 耗时 0.11 s。`artifact_usability_r160.py` 进一步检查 expected files、folded total equality、redacted previews、generated report path containment、dirty raw-trace-like paths、sanitized input manifest 和 clean/cached input equality; 结果写入 `docs/visexp/out/artifact-usability-r160.json`。

R200 进一步把输入换成临时 public-safe Codex fixture, 并由脚本管理 llama.cpp server。Clean run 发起 5 次真实 tag calls; cached rerun 为 0 次模型调用和 5/5 cache hits。该脚本显式记录没有读取真实 `.codex/.claude` traces, 临时 fixture 在运行后删除, committed summary 中 0 个非 redacted prompt previews, 且没有新增 raw-trace-like dirty paths。

R220 进一步把用户入口切到产品化的 `agentpprof`, 并从临时 clean clone 运行。脚本在 clone 内创建 public synthetic Codex fixture, 使用 deterministic regex tagger, 不调用 LLM, 也不读取真实 agent histories。它生成 `tasks.pb.gz`、`tools.folded`、`tokens.json`、`files.folded`、`network.folded` 和 `tools.svg`; 五个 projection 的样本数为 6/4/190/3/1; go tool pprof

`-top` 能读取 `tasks.pb.gz` 并报告 6/6 total samples; `tools/files/network/token` 的 expected-stack checks、output containment 和 privacy scan 均通过。R248 将同一思路推进到 installable path: 先用 `cargo install --path agentpprof --locked --force` 安装本地包, 再用安装后的 `agentpprof` 读取 committed public fixture, 并生成同样的 pprof/folded/JSON/SVG outputs; go tool pprof `-top` 仍能读回 6/6 task samples, 且命令显式使用 `--session-file`、`--tagger regex` 和 `--no-cache`, 因此不读取私有历史、不调用 LLM。

这些结果说明 bounded local artifact path、public-safe fixture path 和本机 clean-clone `agentpprof` pprof readback 在固定输入下是可审计、可重复的。但它们不等于 external-machine install, 也不等于社区开发者已经能顺利使用; 本地 `.agentsight` report 仍包含 trace roots/session metadata, 因此不是 public-release artifact。一个更大的 36-session discovery run 首次标注耗时 173.05 s; 其 cached rerun 又出现 34 次新 LLM call, 因为当前 Codex session 在两次 discovery 之间增长。这暴露出默认体验问题: artifact smoke 和 cache benchmark 必须固定输入, 而交互式工具的默认模式应该明确采样、缓存和活跃 session 漂移。

4.8 评估完整性审计

表 4 把当前证据按 claim gate 汇总。这个表的作用不是装饰, 而是防止论文把 smoke evidence 写成系统结论。OSDI reviewer 最可能挑战的点是 C4、C5 和 C6: C4 已经有固定 command-mode suite、external cross-repo, 以及一次由 1 个 Claude command-mode task 加 2 个 Codex HTTP-family target-network probes 组成的受控扩展证据, R235 又证明单进程 Codex raw TCP 可以被 join; R238 进一步修复 process-tracer readiness race, 使 direct HTTP 和 direct multiprocess controls 在 compact direct-only readiness supplement 以及正式 full run 中通过; R240 又把 command-root over-attribution 与 target-child network capture 变成 regression tests。但更宽的 capture boundary 仍未关闭: R238 full run 的 Codex/Claude-launched rows 仍有 3 个 target-network orphan/missing-action cases。因此还要证明这些 agent-launched capture 边界、更多 agent family 和任意仓库 scope 不是过窄; C5 要证明用户能更快或更准确地回答 forensic questions; C6 要证明一词标签不只是语法稳定, 而是足够可用。R184/R186/R187/R188 的作用是防止过度声明: 它们把当前状态固定为 `not_weak_accept`, 把 launch material 与 outcome evidence 分开, 并把下一步执行顺序限定为 R142 pilot、R124 labels、R151 paper run。R245 在 R244 之后再次机械检查这个边界: 它读取 generated gate artifacts 和当前 paper/docs, 不读 raw traces、不调用 LLM; 9/9 个 hard evidence checks、13/13 个 wording checks 通过, 且 forbidden strong-claim hits 为 0。它同时记录 R219 已经是较早的 readiness board, R238/R240/R242–R244 必须作为 post-R219 addenda 或通过 R245 一起阅读。R246 进一步记录 post-R245 OSDI review 的 author response: C5/C6 仍是 must-fix outcome blockers, 同时把 R170 标成 dirty-provenance evidence, 并补充 R224 是 `checker_id=R131` 在 R170 denominator 上的 rerun, 而不是新的 checker 或 outcome evidence。因此当前最诚实的定位是 “supported mechanism plus partial systems artifact”。

4.9 R183: 为什么降级本身重要

R183 的价值在于防止把 “有网络事件” 写成 “目标 workload 的网络事件已被 lineage 捕获”。R182 的低层

codex network rows 已经能被 join, 但 target-specific loopback/child-process rows 仍为 0/0。因此 gate 被降级为 target-specific oracle: 只有观察到并 join 目标 loopback 或 expected child-process network rows, 才允许把 C4 扩展到 network workload coverage。R191 正是该 gate 的后续实例: 它没有把 R182 的低层 agent runtime rows 当作充分证据, 而是要求固定 Codex task 执行预置 Python HTTP probe, 并以 4/4 target rows joined、0 negative joins 作为升级条件。R229 则把同一逻辑用于 controlled multi-workspace replication: 不同 workspace/category 必须分别通过 scoped lineage 和 negative-control gates; 其 raw join 为 36.481%, 这不是失败, 而是因为 out-of-scope 与 negative-control rows 应保持 orphan, 不能用 aggregate raw join rate 冒充完整 provenance。R230 把 gate 推到 full-history projection 层: 所有 folded system-observation weight 都必须带有 semantic session/prompt tag frames 和 call/effect frames, 且 raw tool events 的 prompt-index 必须可解析; 该 gate 通过, 但 duplicate prompt-index rows 和 0.188% tool-weight prompt-tag drift 仍存在。R231 随后证明 display projection 本身与 event-local prompt tags 完全一致, 并把 field-index drift 定位到 duplicate-index Claude sessions; R232 则把 live lineage replication 推到 AgentSight 仓库外的 controlled workloads。R233 最后把 prompt-row key 语义规范化: 裸 index 只在唯一时作 key, duplicate index 显式 non-keyed; 归一化后 semantic drift 为 0, 但 same-tag duplicate row identity 不再被伪装成可证明 lineage。R234 进一步把同一 oracle 用到 1 个 Claude command-mode task 和 2 个 Codex HTTP target-network probes 上, 说明 gate 可以承载 agent family 与 network probe 的局部扩展。R235 则把这个 gate 推到 raw TCP、multiprocess TCP 和 Claude-launched target-network, 结果只有单进程 Codex TCP 通过; R236 进一步把边界缩小为两类问题: Claude-launched delayed HTTP 仍没有 target rows, 而 direct controls 虽能观察 target rows, 但仍有 orphan。R237 加入 runtime witness 后, 4/4 witnesses 通过, 使 failure 不能再简单解释为“probe 没有运行”。R238 修复 record -- 的 process-tracer readiness race 后, direct multiprocess control 稳定通过, 但 Codex/Claude-launched rows 仍有 target-network orphan/missing-action cases。R240 将这一路径中的 command-root fallback 和 target-child network capture 写成 regression tests, 说明系统现在能防止一类 over-attribution 回归。这说明 gate 有能力暴露 capture 边界, 而不是把 partial workload 包装成支持性证据; 下一步应针对 agent-launched process-time matching 和 Claude/Bun thread/process attribution 继续缩小边界。这体现本文的系统性: AgentFlame 不是把 trace 与 process summary 并排展示, 而是把 claim 也放入同一 lineage model 下审计, 区分用户任务 effect、agent runtime 噪声和必须保持 orphan 的事件。

5 相关工作

Flamegraphs 与 profiling. Brendan Gregg 的 flamegraph 让用户通过宽度定位 hot stacks。Grafana/Pyroscope、Datadog、Sentry 等系统已经把 flamegraph 用于 CPU、内存、profile 和 traces。AgentFlame 借用 folded stack 表示, 但 stack frame 来自 agent semantic context 与 system-effect lineage, 而不是函数调用栈。

Distributed tracing 与 agent observability.

OpenTelemetry/Dapper 风格 tracing 把一次请求表示为 span tree。LangSmith、Langfuse、Phoenix、AgentOps 等工具已经记录 agent、LLM、tool、retrieval、cost 和 latency。SigNoz/Inkeep 公开展示了 multi-agent workflow 的 span-duration flamegraph。这些系统擅长解释单次 workflow 如何执行; AgentFlame 的目标是跨 session 聚合“哪个语义任务造成哪些系统副作用”。

Token/context profiling. Context 和 token profiling 工具关注 prompt/context window 中的热点。AgentFlame 包含 token flamegraph, 但当前只作为 source-local accounting。论文主贡献是 token/semantic/tool/process/effect 共享同一 folded-stack 语法, 而不是 token cost 本身。

6 局限与下一步

当前版本仍不到 OSDI weak accept。Exact lineage 是最强系统贡献, 但证据分两类: live lineage 由 R114 的 20 个固定 command-mode Codex 任务、R191 的固定 Codex target-process HTTP workload、R229 的 5 个 controlled multi-workspace tasks、R232 的外部 fresh git-repo/HTTP-probe workload, 以及 R234 的 1 个 Claude command-mode task 加 2 个 Codex HTTP-family target-network probes 的受控扩展支撑; R182 只是 record-mode --trace-net 的低层 agent-process network smoke。R235–R240 新增 raw/Claude target-network 边界实验与 regression guard: R235 只让单进程 Codex TCP 通过; R236 显示 Codex delayed multiprocess 可以通过, 但 Claude-launched delayed HTTP 仍没有 target rows, direct controls 仍有 orphan rows; R237 进一步加入 runtime witness; R238 修复 process-tracer readiness race 后, compact direct-only supplement 汇总 5/5 repetitions 通过, 正式 full run 中 4/4 witnesses 与 4/4 witness ports observed、direct controls joined、13/16 target network rows joined、0/186 negative-control effects joined, 但 Codex/Claude-launched rows 仍 partial; R240 将 command-root fallback 和 target-child network capture 加入 regression suite。因此它们缩小并定位 C4 缺口, 不把广义 raw-socket/Claude-launched coverage 升级为 supported; direct-only repetitions 没有 negative controls, 不能替代正式 full run 的 precision evidence。R230–R233 支撑的是 generated full-history projection correctness: R230 证明 system-effect stacks 都带有 semantic session/prompt tag frames 和 call/effect frames, R231 证明 display projection 与 event-local prompt tags 一致并定位 prompt-row drift, R233 把 duplicate prompt indexes 显式降级为 non-keyed row identity 并把 normalized semantic drift 降为 0; 但 same-tag prompt-row identity、R238 暴露的 Codex/Claude-launched target-network orphan/missing-action 边界、任意仓库泛化、更多 agent 类型和更丰富的 network workloads 仍缺。用户效用也没有 outcome data: R142 已冻结五种视图的任务包、answer key 和 scorer, R187 已生成可发放的 P01–P05 pilot launch package, R207 已确认 launch handoff 和 R195 return-file mapping, R249 已生成 12 人 paper-scale launch package, 但仍需要真实参与者响应; 纸面 C5 还需要 12–20 个参与者或明确限定的 expert study。标签 adequacy 仍需使用 blinded R124 label sheet 对 300 个 session/prompt/LLM fragments 收集人工标签; R251 只说明 prompt tags 与 sanitized system behavior 有 weighted association, 并且 p-value

统化方向和真实 characterization 的语义系统效应 profiler, 而不是已经完成的 BOLD/ReAct。

7 结论

AgentFlame 的核心不是再画一张 agent flamegraph，而是把用户语义意图、LLM/tool 历史和系统副作用放入同一个可折叠、可聚合、可审计的栈模型。当前 full run 说明该模型在真实本地 agent 历史上可运行，并且语义帧能分开 nonsemantic 和 flat baselines 大量混合的系统效应。R114 进一步说明固定 command-mode suite 中 exact semantic-effect lineage 可以做到高精度，并拒绝并发 negative controls；R182 说明同一路径在启用 record-mode --trace-net 后能 join 低层 agent-process network rows；R191 说明固定 Codex target-process HTTP network rows 也能被 join；R229 说明同一 oracle 能在 controlled multi-workspace tasks 上复现；R232 说明该 oracle 能迁移到 AgentSight 仓库外的 controlled git-repo 与 HTTP-probe workload；R234 说明它还能承载 1 个 Claude command-mode task 和 2 个 Codex HTTP-family target-network probes 的受控扩展；R235–R238 说明 raw/Claude target-network scope 仍是 partial，R238 在受控条件下修复 direct multiprocess readiness，但 Codex/Claude-launched target-network orphan/missing-action 仍要继续修；R240 把 command-root over-attribution 和 target-child network capture 写入 regression guard；R230 说明 full-history projection coverage 可审计，R231 说明 display projection 与 event-local prompt tags 一致，R233 说明 prompt-row semantic consistency 可通过 non-keyed duplicate-index normalization 成立。R160、R200 和 R220 说明 bounded artifact path、public-safe fixture path、cache rerun 和本机 clean-clone pprof readback 已经可审计，但还不是社区级 artifact 结论。但顶会版本必须继续证明 R238 暴露的 Codex/Claude-launched target-network 边界、更多 agent family 和任意仓库 scope、same-tag prompt-row identity policy、标签 adequacy 和用户任务收益。在当前证据下，最诚实的论文定位是：一个有完整系

- [1] Brendan Gregg. Flame Graphs. <https://www.brendangregg.com/flamegraphs.html>.
- [2] Benjamin H. Sigelman et al. Dapper, a Large-Scale Distributed Systems Tracing Infrastructure. Google Technical Report, 2010.
- [3] SigNoz. Understanding Flame Graphs for Visualizing Distributed Tracing. <https://signoz.io/blog/flamegraphs/>.
- [4] SigNoz. How Inkeep Monitors Their AI Agent Framework with SigNoz. <https://signoz.io/blog/inkeep-ai-agent-monitoring/>.
- [5] Datadog. Trace View. https://docs.datadoghq.com/tracing/trace_explorer/trace_view/.
- [6] LangChain. LangSmith tracing documentation. <https://docs.langchain.com/langsmith/>.
- [7] Langfuse. Observability documentation. <https://langfuse.com/docs/observability>.
- [8] Arize Phoenix. Tracing documentation. <https://arize.com/docs/phoenix>.

表 4: 当前 claim gate。Supported 表示已有当前 artifact 支持; partial 表示机制成立但 scope 仍窄; unsupported 表示缺少必要实验。

Claim	当前证据	Verdict	缺口
C1 folded aggregation	183,714 system observations 折叠为 26,829 semantic stacks; folded totals 与 R170 report 匹配。	supported	需要把 full-run artifact packaging 固化成 fresh-clone release workflow。
C2 one-word tags	2,859 prompt rows 和 114,837 LLM calls 全部满足一词 grammar; 0 final tag failures。	supported	Syntax 不等于 adequacy; 需要人工标签质量评估。
C3 semantic partitioning and display contract	Nonsemantic/flat baselines 分别有 90.402% 和 90.918% mixed weight; R224/R170 中 prompt-only 将 system bucket/residual mixed weight 降到 36.722%/7.485%; R211 给出 RQ2 figure inputs, 其中 git/read/ok 有 116 个 prompt tags, cargo/test/ok 有 48 个 prompt tags; R209/R212 证明可逆 display map 与保守 display policy: R209/alias-only 为 26,612 stacks, profile-guarded hypothetical 为 26,067 stacks 但会激活 2.532% 未审查 effect weight; R223 将这些结果汇总为 projection tradeoff; R225 生成 prompt-span duration baseline, top-10 duration/effect tags 只重合 7/10, Spearman 为 0.623。	partitioning supported; display mechanics supported	需要更多仓库和用户任务证明不是单仓库 workload 特例; R213-R218 只是 renderer/data contract 和 update-gate smokes, 不是 C3 scientific outcome evidence; 还需要 LLM/token display-compaction ablation、真实用户交互证据, 以及 R190/R203 标签返回后的 merge/promotion quality。
C4 exact lineage	Live lineage: R114 在 20 个固定 codex tasks 上 join 1,273/1,273 in-scope effects, 0 false positives, 0 false negatives, 0/3,170 negative-control effects joined; R182 join 35/35 低层 codex process network rows, 0 network orphans, 0/604 negative-control effects joined; R191 在固定 Codex HTTP probe 上 join 4/4 target python3 network rows, 0/310 negative-control effects joined; R229 在 5 个 controlled multi-workspace tasks 上 join 394/394 in-scope effects, 0/306 negative-control effects joined; R232 在 AgentSight 仓库外 join 353/353 normal in-scope effects 与 4/4 target network rows, 0/480 negative-control effects joined; R234 在 1 个 Claude command-mode task 和 2 个 Codex HTTP-family target-network probes 上 join 269/269 in-scope effects, 其中 8/8 target network rows joined, 0/331 negative-control effects joined; R235 raw/Claude target-network run 为 partial, 1/4 tasks passed, 只有单进程 Codex TCP 的 3/3 target network rows joined, 0/305 negative-control effects joined; R236 boundary run 仍为 partial, 3/4 tasks 观察到 target rows, 5/7 target network rows joined, 0/11 negative-control effects joined; R237 runtime-witness run 仍为 partial, 4/4 witnesses 通过, 3/4 witness ports observed, 8/9 target network rows joined, 0/7 negative-control effects joined; R238 修复 process-tracer readiness race 后, compact direct-only supplement 汇总 5/5 repetitions 通过, 正式 full run 中 4/4 witnesses 与 4/4 witness ports observed, direct HTTP/direct multiprocess controls joined, 13/16 target network rows joined, 0/186 negative-control effects joined, 但 Codex/Claude-launched rows 仍 partial; R240 regression guard 检查 5 个 synthetic lineage events (3 joined, 2 expected orphan), 并用 BPF/Rust tests	supported for fixed and controlled scoped workloads; partial broadly	需要 same-tag duplicate prompt-row identity policy、R238 仍暴露的 Codex/Claude-launched target-network orphan/missing-action 边界、任意仓库泛化、更多 agent 类型和更丰富的 target-specific network workloads; R230-R233 不是 live provenance, R191/R229/R232/R234/R235-R238 也不证明 HTTP payload/URL reconstruction、任意 network workload 或完整历史 row identity。