

面向 AI Agent 轨迹的可配置语义剖析

AgentSight 研究原型

2026 年 7 月 4 日

摘要

AI agent 的执行历史已经不再只是一次 prompt 或一棵 trace tree。一个真实轨迹可能同时包含用户意图、LLM 响应、tool call、API 调用、GUI 动作、浏览器动作、进程、文件、网络、计划步骤、subagent 以及 benchmark 给出的成功、失败、安全、重复和冗余标签。现有 agent observability 工具通常把这些对象固定成 prompt、session 或 span 层级；传统 profiler 则固定成函数或进程层级。这两种做法都会把 profiling 问题过早绑定到某一种边界上，使同一段轨迹很难按任务、阶段、工具、动作、质量标签或人工分组递归折叠。

本文提出一种更小的语义剖析模型：系统只保留两个核心抽象，**operation** 和 **operation stack**。**operation** 是带字段和权重的观测，prompt、tool call、process、syscall、GUI action 和 plan step 可以是 operation 记录或派生字段；session、span、task 和 trace id 是 operation fields、交换容器或 baseline shape，不是新的 profiler 对象。**operation stack** 是用户从字段中选择的递归投影，mapping 和 tagging 在 stack 构造前派生字段，而不是创建第三种 profiler 对象。关键点是聚合不是第三个对象，也不是固定 trace tree；聚合由 query time 选择的 stack 形态决定。这不是单纯的 query-time aggregation 或 flamegraph renderer claim；scoped novelty 是 agent-operation record、recursive multi-field operation-stack projection 和 hidden-label profile-group scoring 的组合。我们在 Rust agentpprof 中实现该模型，并把论文评估组织成三个核心经验性 profiling 实验 (RQ1/E1 到 RQ3/E3) 加一个 artifact/reproducibility block (RQ4/E4)，而不是按 R 编号罗列小实验。RQ1/E1 验证泛化覆盖和递归 operation-stack 形成：在 15 个轻量采样的公开标注轨迹来源上，agentpprof 把 47,590 个 samples 投影到同一 operation layer；同一批 13,265 个 operations 可以从 9 个 dataset stacks 折叠为 57 个 phase stacks、226 个 semantic stacks、455 个 action stacks，或 3,757 个 fixed-session stacks，而不改变输入 operation。这说明 prompt、tool、GUI action、process 和人工边界都进入 operation layer；session/span 只作为字段、容器或对照视图参与 stack 查询，不是新的 profiler 抽象。

RQ2/E2 是 hidden-label localization/ranking 主实验。在 AgentRewardBench、SATraj-OS、AgentNet 和 OSWorld-Human 的 4 个 oracle-rich 数据集、6 个任务、34,539 个 operations 和 3,699 个 positives 上，我们把 profile groups 当作 ranked localization outputs，比较 flat、fixed-session drilldown、dataset-native、raw-action 和 operation-stack views。Task-query operation-stack profiling 的 top-5 median work 为 0.0937，而 flat summary 为 1.0；相对 fixed-session drilldown，它在 5/6 tasks 上提高 top-5 recall，并把 median groups 从 285.0 降到 157.5。

RQ3/E3 隔离机制和 profile-configuration actionability。Rank feature、stack depth、mapping、transfer、diagnos-

tic lens、case packet 和 counterfactual 分析显示：有效配置随 task 和 objective 变化，operation-stack 是 Pareto point，不是 universal default。Executable profile-spec patches 在 5/6 tasks 上改善 AP、top-5 lift 和 first-positive work；supervised held-out boundary-field ablation 把 OSWorld-Human AP 从 0.2402 提到 0.2583，并把 groups 从 108 降到 74，但保留 work 反例。RQ4/E4 则验证 replayability、offline cost 和 artifact hygiene：76 个 tracked profile specs 可确定性 replay；profile-spec input regressions 覆盖 local-session、agent-trace 和 standard-trace replay；source status、数字、guardrails、rubric coverage 和 two-abstraction boundary 检查只作为 artifact hygiene，不作为第四个经验性 profiling 实验或 profiler 的 empirical accuracy evidence。

因此本文支持的是 scoped profiling claim：operation-stack profiling 能在公开真实标注 trace 的 dataset-provided hidden labels 下定位、排序和解释任务相关 failure、quality problem 和 dataset-provided semantic boundary，并相对 flat summary 减少 inspection work、相对 fixed-session drilldown proxy 改善 median fragmentation tradeoff。本文不声称提升 human productivity，不声称自动发现所有 intent boundary，不声称 metric dominance，也不声称完整兼容现有 trace ecosystem。

1 问题

AI agent 轨迹的调试问题正在从单次调用回放变成跨任务剖析问题。开发者不只想知道某个 span 什么时候开始和结束，也想知道哪类任务导致最多重复点击，哪些 GUI 轨迹反复输入，哪个工具调用族对应失败，哪些安全攻击类型集中在某些操作阶段，或者一个 prompt 序列能否被折叠成 task、phase、action 和人工 subtask 等多个深度。如果 profiler 把 session、prompt 或 tool call 写死成核心层级，这些问题会被迫使用同一个边界。如果 profiler 只保留进程或函数栈，上层语义和 benchmark oracle 又会丢失。

本文的出发点是把 agent trace 中所有可剖析对象都降到同一层。一个 prompt 可以是 operation，一个 tool call 可以是 operation，一串 prompt 也可以通过 mapping 被派生为同一个 intent 或 task operation field。同样，GUI action、API call、browser action、process event、syscall、安全标签、step correctness 和人工 grouped-action id 都不是新的 profiler 抽象，而是 operation fields。Profiler 的核心任务不是决定唯一正确边界，而是让用户和实验可以在同一批 operations 上选择 stack 字段、派生 mappings，并得到不同深度的递归折叠。

这个问题有两个系统挑战。第一，抽象必须足够小，否则 prompt、session、tool call、plan、subagent 和 process 会各自形成独立 pipeline。第二，抽象又必须足够可配置，否则 flamegraph 只会成为固定视图，不能回答边界、失败、安全和质量诊断问题。本文的目标不是证明某个单一 flamegraph 最好，而是证明 operation 和 operation stack 足以覆盖多类真实标注 agent 轨迹，并且 stack shape 与

aggregation 的选择会系统性改变质量、边界、定位、work 和碎片化分析结果。

2 设计

2.1 两个核心抽象

operation 是唯一的样本级对象。每个 operation 是一个带权重的字段集合，例如 `op=prompt`、`op=llm`、`op=tool`、`tool=browser`、`action=click`、`phase=navigate`、`status=failure` 或 `step_correct=incorrect`。这些字段可以来自本地 Codex/Claude session，也可以来自外部 benchmark 的标注轨迹。实现上，外部轨迹使用每行一个 JSON object 的 operation JSONL，并把原始任务文本、截图和长对话默认排除在提交 artifact 之外。

operation stack 是从 operation fields 中选择出的有序 frame 列表。例如同一批 operations 可以用 `project`、`dataset` 查看数据来源，也可以用 `project`、`dataset`、`task`、`phase`、`op`、`tool`、`action`、`status` 查看动作深度，或者加入 `human_group`、`step_correct`、`safety` 和 `looping` 做诊断视图。Stack 不是 trace tree，也不是 session hierarchy。它是一个查询结果，用户可以按问题改变深度和字段。

2.2 Mapping 和 tagging

Mapping 和 tagging 是派生 operation fields 的一等机制。它们在 stack 构造前运行，读取 operation 的 `key=value` 文本，并写入新的字段。例如 desktop action 中的 `type` 和 `key` 应先被映射到 `phase=input`，再考虑通用 web action verb；API/tool traces 应先进入 tool/API phase family，再处理 `search` 或 `create` 这类词。这一顺序来自跨 web、desktop、API/tool 和 step-quality 轨迹时暴露出的关键设计约束。如果通用 action rule 抢在 operation-family rule 前面运行，desktop、web 和 API 轨迹会被错误合并。

Mapping 不引入第三个抽象。它只是在 operation 上写字段，使同一个 stack specification 可以跨数据集复用。当前 Rust CLI 支持 inline `--op-map FIELD:LABEL=REGEX` 和文件形式 `--op-map-file`、`--where FIELD=REGEX` 和 `FIELD!=REGEX` 在 mapping 之后、stack 构造之前选择 operation 子集，多条 predicate 取 AND；它实现形式化模型里的 ϕ ，不是新的 profiler 对象。`script/operation_map_infer.py` 可以从已标注 operations 中生成同样格式的规则文件，并用这些规则测试 held-out 和 leave-dataset-out 泛化。`--profile-spec` 把 operation files、mapping files、predicate、view、stack 和输出路径打包成 JSON 配置，便于 reviewer 复现实验；命令行参数仍可覆盖 spec 默认值。`--deterministic-output` 或 spec 中的 `deterministic_output` 可以把 JSON generated_at 和 pprof profile time 固定为可复现值，用于 byte-stable artifact checks。它不改变模型本身，只是把已有 operation 和 operation-stack 查询显式记录下来。

2.3 Views 和非火焰图分析

`--view` 决定采样和权重，例如 operation count、token、file、network 或 time。`--stack` 决定递归折叠形状。Folded stack 和 SVG flamegraph 是其中一种输出，但不是唯一输出。我们同时生成 JSON profile、stack tree、top-field table、parent-child transition、depth sweep、boundary F1、V-measure、coverage report、grouped-action report 和 HTML quality report。这些视图共享同一 operation 输入和 stack 语法，因此 failure、safety、looping、redundancy 和 hu-

man group 可以被当作普通字段评分，而不是另建 failure profiler 或 safety profiler。

3 实现

agentpprof 是当前被测实现。它是 Rust CLI，读取本地 Codex/Claude 历史或外部 operation JSONL，并输出 pprof-compatible profile、folded stacks、SVG 和 JSON。核心命令形态如下：

```
agentpprof --operation-file ops.jsonl --view operations
--stack project,dataset,task,phase,op,tool,
action,status --op-map-file operation-map.txt
--where task=verify
-o out.folded
```

外部数据集转换器位于 `script/agent_trace_datasets.py`。转换器只下载或流式读取所需公开文件的采样前缀。对于包含截图、长 prompt 或完整对话的数据集，默认保存 redacted rows 和 operation JSONL，不提交原始数据。本地 agent session 通过 `agent-session` 解析为 `agentsight.agent-session.trace.v1 trace`；agentpprof 可以用 `--export-trace` 写出 filesystem-normalized trace，用 `--trace-file` 读回，也可以通过 `script/agent_trace_convert.py to-operations` 转成 operation JSONL。`script/agent_trace_exchange_eval.py` 将这三步、filesystem/tool-command portability check 和 folded-output equality check 固化为一个可复现实验；该检查不声称 prompt/LLM preview 已完整脱敏。agentpprof 还可以用 `--export-standard-trace` 写出 Chrome/Perfetto-style traceEvents，再用 `--standard-trace-file` 导入为普通 operations 后折叠。`script/agent_trace_convert.py export-standard` `--format chrome` 和 `import-standard` `--format chrome` 保留为显式中间文件脚本；`script/agent_trace_chrome_exchange_eval.py` 验证 session fixture 路径不改变 folded operation-stack 输出。R353 进一步用 tracked R324 real labeled visible-operation JSONL 的 512-row prefix 验证 operation-file 路径：512 operations 导出为 512 个 Chrome complete events，经 `--standard-trace-file` 导入后仍得到 byte-identical 的 512-sample / 11-stack folded 输出；这仍是 exchange check，不是新的 accuracy result。质量评估脚本位于 `script/operation_stack_quality.py`，它复用 agentpprof 的 operation mapping contract，并计算字段覆盖率、oracle V-measure 和序列相邻边界 F1。Stack 结构分析脚本位于 `script/operation_stack_analysis.py`，用于生成 flamegraph 之外的 tree、top-kind 和 transition 报告。

这个实现刻意保留简单接口。它不像 jq 那样完整表达 JSON 查询语言，但它已经把 profiler 的关键自由度暴露为 flags 和可提交配置：数据源由 `--trace-file` 或 `--operation-file` 选择，权重由 `--view` 选择，查询子集由 `--where` 选择，字段派生由 `--op-map` 选择，递归边界由 `--stack` 选择，JSON group 排序由 `--rank-rule`、`--rank-op-rule` 和 `--rank-mode` 选择，复现实验由 `--profile-spec` 固化。实现证据只作为 E1-E4 的接口验证进入论文，而不是形成额外主实验。Profile-spec predicate 证明 mapping-derived `where_rules` 可以在 folding 前选择 729/729、714/714 和 4,285/4,285 个预期 operations；profile-spec composition 证明 operation source、predicate、

visible rank rule、rank mode 和显式 stack depth 可以在 12/12 variants 中组合，且不引入 prompt/session frame；standard-trace exchange 证明 tracked real labeled operation prefix 经 trace container 往返后仍保持 512 samples 和 11 stacks。这些结果的 run IDs 是 R321、R342 和 R353，但它们的角色是 E1 的接口 provenance，而不是新的 experiment block。

Ranker 和 actionability 的实现证据被归入 E3。Stack-text rule 与 rank-mode variants 可以从 profile spec 复现，但对 safety/side-effect 过粗；operation-level visible feature density 在 folding 前匹配 mapped operation token，并在 semantic stack 上使 AP 赢 5/6 tasks、top-5 lift 赢 4/6、first-positive work 赢 5/6，coarse stack 也在 AP 上赢 4/6。Leave-one-feature、robustness 和 transfer checks 说明 repeat_signal、write-action、status=success 等字段在不同 family 中作用不同，误导性 safety-like 或 input-phase features 会伤害 AP 或 first-positive work；global/equal feature banks 常能保留收益，但 guided repair 使用离线评分反馈，因此不是 label-free automatic ranker。这些结果对应 R322-R326 和 R329，只作为一个 E3 mechanism/actionability block 的 provenance。

Profile-spec replay、input-source replay 和 deterministic output 归入 E4。同一批 76 个 tracked specs 覆盖 R300 views、R324 rank-feature specs 和 R326 robustness specs；Rust agentpprof --profile-spec 重复运行两次后 semantic profile hash 全部稳定，默认 raw-byte hash 只有 4/76 稳定，因为 JSON profile 包含生成时间戳。启用 --deterministic-output 后 raw-byte hash 达到 76/76。R392 进一步验证 profile spec 可以 replay session_files、trace_files、standard_trace_files、regex tag_rules、where_rules、rank rules、stack override 和 include_standard_trace_args；这些输入源最后仍归一成 operations 并由 operation stack 折叠。这关闭的是 artifact byte-stability 缺口，不是新的 accuracy benchmark、live overhead benchmark 或第五个主实验。因此 prompt、session、toolcall、process、syscall、plan 和 subagent 都可以在同一套 mechanism 中出现，而不是成为互不兼容的 object model。

4 实验方法

评估遵循八个原则。第一，只使用公开的、别人已经标注好的 agent 轨迹或交互轨迹。我们使用 Hugging Face Dataset Viewer、HF repo JSONL、公开 GitHub JSON 和公开 benchmark artifacts 进行轻量采样，不同步完整测试集，也不提交原始外部样本。第二，每个 claim 都必须对应可执行 oracle。对于 phase/action 结构使用 V-measure 和相邻边界 F1；对于 grouped-action 使用人工 group id；对于 looping、safety、step correctness 和 redundancy 使用数据集原生标签；对于递归深度使用同一批 operations 下 unique stack 和 compression 变化。第三，负结果保留在论文中。例如 AgentNet 的 task status 很弱地预测 per-step correctness，repeat signal 也很弱地预测 step redundancy。这说明 profiler 能承载这些诊断字段，但简单 mapping 不能替代专门质量模型。第四，论文 claim 必须从 artifact 机械回溯。Claim synthesis、reviewer evidence packet、paper value/novelty synthesis、paper evidence matrix 和 submission audit 都只读取 tracked/clean result files，并输出 claim verdict、paper-ready wording、must-not-claim 和 source

paths。这些文件不是新实验，也不是 profiler object。它们的作用是防止摘要、结果、局限和结论在数字、scope 或 unsupported claim 上漂移。第五，boundary backend 必须仍然服从两个抽象。监督式 adjacent-boundary backend 只写回 learned_group_pattern、learned_segment_pattern、learned_segment_position 和 learned_boundary_prev 等 operation fields。递归折叠仍由 agentpprof 使用普通 --profile-spec 和 --stack 完成。每个候选标签家族还必须先通过 suitability 和 simple-baseline gate，防止把 safety、history context 或 repetition proxy 错当作语义边界。第六，真实问题价值必须先通过可复现 proxy 任务收敛。我们从 AgentRewardBench、SATraj-OS、AgentNet 和 OSWorld-Human 的已有 operation JSONL 构造 6 个 oracle-backed analysis tasks，比较 flat、fixed-session、semantic operation-stack 和 label-drilldown 四种 stack specs。指标包括 positive lift、覆盖 50% positives 的 inspection fraction、group count、top-group session support、selected recall 和 selected work。这仍不是人类用户实验，但它把“profiler 是否解决真实问题”从叙述变成可审计的 proxy result。第七，默认浏览、ranking 和 case evidence 都必须避免答案泄漏。Visible packets 不包含 oracle-positive 字段，hidden answer key 单独保存 positives。非 oracle rankers 只读 status、repeat_signal、phase、action 和 environment 等可见字段，不读 looping、safety、step_correct 或 target_positive。因此 first-positive、first-enriched 和 high-lift evidence 只是对同一 operation/operation-stack packet 的隐藏标签回放评分，而不是 automatic detection 或 human utility。第八，R320 把 profiler 输出直接当作 ranking/localization result。它在同一 6 个真实标注任务上比较 flat、fixed-session、dataset-native hierarchy、raw action stack、operation-stack、label-drilldown oracle view，以及 width、visible-risk、query-aware 和 oracle-upper-bound rankers。非 oracle policies 只使用可见 operation fields，隐藏标签只用于 scoring。指标包括 precision@k、recall@operation-budget、F1@k、AUPRC-style average precision、nDCG、work-to-first-positive、groups-to-50% recall、group count 和 task-level profile-configuration insight。这个设置把 profiling paper 的主 claim 从“analyst 是否更快”改为“profiler 自身是否能在真实 workload 上相对 dataset-provided hidden labels 定位、排序并指导优化”。

4.1 Hierarchy ablation baselines

本文比较的是 hierarchy choices，而不是把每个已有 observability 产品完整复刻一遍。Flat profile 把每个任务压成一个 summary packet，用来检验 operation stack 是否比无层级摘要更 selective。Fixed-session drilldown 把 session 或 demo id 放进 stack，用来模拟 session/prompt-first 调试界面和传统 trace-tree drilldown 的碎片化风险。Prompt/session tree、tool-call hierarchy 和 OTel/span-like trace tree 在本实验中都被建模为不同 stack specs：它们仍然读取同一批 operations，只是把 session、prompt、tool、process 或 trace id 放在更靠前的 frames。Label-drilldown 是 oracle-aware upper-bound style view，它把 hidden label 直接放入 stack，用来界定“如果答案字段已经可见”时的上限，而不作为真实用户界面 baseline。这些 ablations 的目的，是隔离边界选择对聚合、selectivity、recall 和 inspected work 的影响。因此本文不会声称 agentpprof 支配所有生产 observability UI，只声称 operation stack 把这些边界选择统一成可配置查询。

表 1: 公开标注轨迹数据源和当前用途。15 个来源支撑 E1 覆盖; ScaleCUA 是补充点。RQ2 hidden-label 主结论依赖 AgentRewardBench、SATraj-OS、OSWorld-Human 和 AgentNet 四个 oracle-rich 数据源。

数据源	原生标注	转换方式	主要用途
WebLINX, Mind2Web, AgentTrek, WebShop	web action, demo/task, reward 或 action history	HF Dataset Viewer 或 HF repo shard	web navigation 和 shopping trajectories 的跨源 smoke。
API-Bank, ToolBench, tau-bench	API/tool call, solution path, 多轮 user/assistant/tool messages, outcome	HF rows 或 repo JSONL	tool/API/dialogue phases 和 user-agent-tool operation 形态。
SWE-agent	issue trajectory, command action, success target	HF Dataset Viewer	software-agent command 轨迹。
AndroidControl, GUI-Odyssey	mobile/cross-app step action 与 instruction	public/HF samples	移动 GUI action depth 和跨 app scale。
AgentRewardBench	expert success, side-effect, looping, optimality	annotation rows 加 cleaned BrowserGym steps	failure, looping, side-effect 的非 flame-graph 诊断。
SATraj-OS	desktop action, success, safety, reward, attack type	HF safety config	桌面安全和 attack-type operation fields。
OSWorld-Human	human single-action 和 grouped-action 轨迹	GitHub JSON files	人工 grouped-action 边界 oracle。
AgentNet	human desktop PyAutoGUI, task outcome, step correctness, redundancy	HF repo JSONL streaming	最大 human desktop step-quality oracle。
ScaleCUA	GUI navigation action, previous-operation context, gold action	HF annotation JSONL streaming	补充多步 GUI history-depth smoke。

5 结果

本文的结果不应按 R 编号或零散 probe 展开。论文主体收敛为三个核心经验性 profiling 实验加一个 artifact/reproducibility block: RQ1/E1、RQ2/E2、RQ3/E3 是三个经验性 profiling 实验, RQ4/E4 是系统/复现和 artifact hygiene block。RQ1/E1 验证 operation generality、递归 stack folding、field derivation 和人工边界都能落在同一个两抽象模型中; RQ2/E2 是 hidden-label localization/ranking 主实验; RQ3/E3 通过 ranker、stack、mapping、transfer、case 和 profile-spec patch 消融隔离机制与 actionability; RQ4/E4 检查 profile-spec 可复现性、离线成本和 claim hygiene, claim-integrity guardrails 只作为 artifact hygiene, 不作为第四个 accuracy result 或第四个经验性 profiling 实验。R 编号只作为 provenance, 不是论文的小节结构。

后续 evaluation 继续保持这个结构。E1 证明两个 profiler objects 足以表达异构轨迹和递归折叠选择。E2 是唯一的 hidden-label localization/ranking 主实验。E3 解释哪些 stack fields、mappings、rankers 和 profile specs 造成或修复 E2 的结果。E4 只负责 reproducibility 和 claim hygiene。完整 run-role map、claim gates、reviewer evidence packets、negative controls 和 table-generation checks 保留在 artifact ledger; 它们只能支撑或约束 E1–E4, 不形成额外主实验。Reviewer 应该沿着这条 evidence path 读本文: E1 先证明两个对象能表达 workload 和递归折叠选择; E2 是唯一的 hidden-label accuracy 与 baseline tradeoff 主比较; E3 解释哪些机制和 profile configuration 让 E2 的结果变成 actionable; E4 只证明 replayability 和 hygiene。如果 E2 的 Pareto 条件或 E3 的 mechanism/actionability 条件不成立, 本文应该收窄 claim, 而不是再增加一个 R 编号结果。

5.1 RQ1/E1: 泛化覆盖、递归折叠和边界字段

实验契约: RQ1/E1 的 claim 是两抽象模型能覆盖异构 agent traces 且不把 prompt/session/tool 边界写死; oracle 是 public dataset labels、native trajectory fields、OSWorld-Human human boundary 和 AgentNet quality labels; baseline 包括 dataset-native stacks、no-map folding、fixed-session stacks、profile-spec replay 和 trace round trip; metric 包括 operation coverage、unique-stack range、mapping

compression、boundary F1/V-measure 和 replay equality; counterpoint 是这只能支持 configurable operation stack folding, 不能支持完整生态兼容或自动恢复所有 latent intent。Prompt、tool、process 和 syscall 可以是 operation records 或 fields; session/span 是字段、容器或 baseline shape, not new profiler objects。Claim-test: RQ1/E1 问的是: 同一 operation layer 能否只通过改变 mappings 和 stack fields, 被递归折叠成 task、phase、action、boundary 和 fixed-session 等多种 stack, 而不改变输入记录、不引入第三个 profiler 抽象。

核心 14 数据集产生 42,590 个 operations 和 1,497 个 unique stacks, compression ratio 为 28.45。加入 ScaleCUA 补充样本后, 总量为 47,590 个 operations 和 1,611 个 unique stacks, compression ratio 为 29.541。这些 operations 覆盖 web、mobile、desktop、software、API、tool-agent-user dialogue、expert failure labels、safety labels、human grouped-action labels 和 desktop step-quality labels。所有这些标签都以 operation fields 形式进入同一 pipeline。没有任何数据集需要新增 prompt、session、GUI、safety 或 quality-specific profiler object。

这支持 C1 的机制性版本: agentpprof 可以把异构 agent 轨迹统一为 operations, 并用用户指定 stack 折叠。它不支持所有 agent 数据都容易转换。适合该方法的轨迹通常具备四个特征: 有有序 step 或 turn, 有稳定 session/task id, 有动作或阶段标签, 有 outcome、quality、group 或 safety 等较高层 oracle。只有静态截图 grounding、缺少顺序、缺少 action label、强依赖大图片归档或 gated access 的数据源更适合作为后续扩展, 而不是当前主证据。

表 3 是 E1 的主证据表; 后文只展开这些行, 不新增主实验。

递归 stack-depth sweep。R286 在同一批 13,265 个 operations 上扫过 8 个 stack depths。只保留 dataset 时有 9 个 stacks; 加入 task 后为 11 个; phase depth 为 57 个; tool/semantic depth 为 226 个; action depth 为 455 个; 加入固定 session 后膨胀到 3,757 个。相对于 dataset depth, 固定 session 的 unique stacks 增加 417.4 倍。这个结果直接反驳把 session 或 prompt 作为默认 profiling 边界的设计。Session 是有用 drilldown field, 但如果默认写死在 stack 里, 它会把可聚合的行为切碎。

表 2: 三个经验性 profiling 实验加一个 artifact/reproducibility block。R 编号只作为 provenance、ablation、counterpoint 或 audit gate 保留在 evaluation ledger; 该表从 tracked artifacts 重新生成。

RQ / paper block	Workload / oracle	Main evidence	Scoped conclusion
RQ1/E1: generality, recursive folding, and field derivation	15 public labeled trace families / 47,590 operations, plus local-session and standard-trace exchange fixtures. OSWorld-Human and AgentNet provide the strongest boundary and step-quality oracles.	Core sources contain 42,590 operations; Scale-CUA brings the smoke test to 47,590; the same operations fold from 9 dataset stacks to 57 phase, 226 semantic, 455 action, or 3,757 fixed-session stacks. AgentNet profile-spec override changes 608 stacks to 83 without changing input operations. Held-out mapping improves compression from 14.049 to 19.091; OSWorld-Human learned boundary F1 reaches 0.7735; boundary backends beat the best simple baseline on 4/5 rows.	Heterogeneous traces enter one operation layer, and stack depth is a recursive query over fields. Mapping, tagging, and boundary backends derive fields before folding; they do not add prompt/session/tool/safety-specific profiler objects or automatic intent boundary discovery.
RQ2/E2: hidden-label localization and ranking	Six failure, safety, quality, and boundary tasks over AgentRewardBench, SATraj-OS, AgentNet, and OSWorld-Human; 34,539 operations / 3,699 positives.	The benchmark scores 144 view/ranker policies. Query-aware operation-stack top-5 groups inspect median 0.0937 work versus 1.0 for flat, improve top-5 recall over fixed-session on 5/6 tasks, and reduce median groups from 285.0 to 157.5. Work-budget, fragmentation, fixed-recall, sequence-scope, oracle-depth, uncertainty, negative-control 和 multi-metric slices are support, not separate experiments.	Operation-stack profiling is faithful to dataset-provided hidden labels under this benchmark and gives a better inspection-work/median-fragmentation Pareto point than flat or fixed-session alone. It is not a universal detector, a single best hierarchy, or a work-dominant replacement for drill-down views.
RQ3/E3: mechanism and actionability	The same six labeled tasks, plus held-out OSWorld-Human boundary-backend operations.	Operation-level rank features and ablations expose useful and misleading fields; profile-spec patches improve 5/6 tasks with median AP delta 0.0376 and lift delta 0.5750. Learned-boundary fields improve OSWorld-Human AP to 0.2583 and reduce groups to 74, but increase top-5 work and first-positive work.	The profiler produces profile-configuration actionability: which stack fields, mappings, rankers, lenses, and drilldown depths to tune. It keeps automatic action selection, automatic patch selection, and automatic boundary discovery out of scope.
RQ4/E4: artifact replayability, offline cost, and hygiene	76 tracked operation-JSONL profile specs, plus local-session, agent-trace and standard-trace profile-spec input replay regressions; no dataset sync or human/agent analyst task.	Deterministic replay covers 152 profiler invocations. Semantic determinism is 76/76 in both modes; deterministic output makes raw-byte determinism 76/76 with median runtime 1.601s and p95 2.767s in the clean rerun. R392 confirms source selection, regex tags, trace inputs 和 effective standard-trace args 都通过同一 operation-stack path replay.	The offline profiling artifact is replayable and cheap enough for artifact evaluation; this is an artifact/reproducibility block, not a hidden-label accuracy result, live capture overhead result, human productivity result, or trace-ecosystem compatibility result.

表 3: E1 主证据表: 同一个 operation layer 可以被递归折叠、mapping、tagging 和 boundary scoring, 而不引入 prompt/session/tool-specific profiler object。

Claim test	Workload/oracle	Main evidence	Counterpoint / scope
异构 operation layer	15 个 public labeled trace families / 47,590 operations	Web, mobile, desktop, software, API, dialogue, failure, safety, human-boundary 和 step-quality labels 都作为 operation fields 进入同一 pipeline。	这是 lightweight sampling; image-heavy 或 gated full benchmarks 仍是 out of scope。
递归 stack choice	同一批 13,265 operations, 加 AgentNet profile-spec override	9 个 dataset stacks, 57 个 phase stacks, 226 个 tool/semantic stacks, 455 个 action stacks 和 3,757 个 fixed-session stacks; AgentNet 在不改变 16,741 个 input operations 的情况下从 608 个 stacks 改成 83 个 stacks。	Fixed sessions 可以作为 drilldown fields, 但 hard-coded 到 stack 里会造成 fragmentation。
先派生 fields 再折叠	Held-out mapping 和 boundary-backend rows	Mapping 把 compression 从 14.049 提到 19.091; leave-dataset-out 在 6/9 个数据集上减少 stacks; boundary backends 在 4/5 rows 上优于 best simple baseline。	Mapping 会把 action-to-phase V-measure 从 0.9343 降到 0.7416; looping 由 repeat_signal_change 解释。
Human-boundary folding	OSWorld-Human exact-aligned tasks	4,011 operations / 2,075 human groups; grouped-depth stacks 把 482 个 action stacks 降到 106 个; group-pattern boundary F1 为 0.627, precision 为 1.0。	这是 scoped human-group alignment, 不是自动恢复所有 latent intent boundary。

早期 3,797-operation set 上也出现同样信号。Flat/mapped stack 为 103 个 unique stacks, 而固定 demo/session stack 为 1,083 个 unique stacks。这说明固定边界会带来约 10.5 倍碎片化, 而 mapped operation stack 可以保留聚合同时增加语义深度。因此论文中的 novelty 不是“画 flamegraph”, 而是把 agent profiling 的边界选择变成 operation-stack query。

Profile spec 把这个 query 自由度变成可复现实验配置。同一个 AgentNet spec 引用相同 operation JSONL 和 op-map 文件, 默认产生 608 个 diagnostic stacks; 命令行只覆盖 --stack 和输出路径后, 样本数保持 16,741 不变, unique stacks 降到 83。这说明 stack 深度是可审计、可覆盖的查询参数, 而不是写在 prompt/session 或某个可视化中的层级。

这种可配置性不只改变图的形状, 也改变 reviewer 能验证的问题。同一套 outputs 同时给出 depth sweep、stack tree、transition/top-field、quality report、grouped-boundary report 和 history-depth report。这些报告回答同一个机制问题: 一个 profiler 是否可以把边界选择延后到查询时, 而不是在采集时固定为 prompt、session 或 span tree。当前证据支持三条 scoped 结论。第一, 异构轨迹和

本地 session 可以先进入同一 operation layer, 再用用户选择的 stack 折叠。第二, recursive stacks 能表达 dataset、task、phase、tool、action、human-group、safety 和 quality-label 等多种深度, 但不能声称恢复所有真实意图边界。第三, field derivation 是可扩展接口, 因为 mapping 和 supervised backend 只写入 operation fields, profiler 仍按 operation stack 折叠。这些机制结果给出 paper novelty, 但 user-utility、通用 boundary detector 和完整 trace-platform compatibility 仍是后续 gate。

Field derivation 和 boundary probes. 本节支持的是 configurable deterministic/supervised field derivation 在合适标签家族上的迁移, 而不是通用无监督边界发现。Held-out mapping rules 在 3,990 个 operations 上把 compression 从无 mapping baseline 的 14.049 提高到 19.091, held-out stacks 从 284 降到 209, 并把 task/dataset V-measure 从 0.837 提高到 0.853。Phase/action boundary F1 为 0.777, precision 为 1.0, 说明当前 mapping 保守: 它不会制造 false positive phase changes, 但会合并一些 fine-grained action changes。Leave-dataset-out mapping 在修正 API/tool phase precedence 后, 在 9 个 held-out datasets 中的 6

个减少 unique stacks, 0 个出现 negative stack-reduction regression, weighted stack reduction 为每 1,000 operations 1162.005。这些结果说明 mapping 不是单个数据集的 ad hoc pretty printer, 但它仍是 deterministic taxonomy-seeded field derivation, 不是无监督边界发现。

Boundary backend 提供更强但仍 scoped 的 field derivation 证据。在 OSWorld-Human exact-aligned sessions 上, held-out adjacent-pair backend 使用非 oracle operation fields 训练, 明确排除 `human_group`、`group_index`、`group_position`、`group_size`、`group_pattern` 和 `group_alignment`。它在 held-out pairs 上达到 precision 0.7400、recall 0.8102、F1 0.7735, 高于 phase-change baseline 0.2919、action-change baseline 0.5142 和 conservative `group_pattern` reference 0.5810; 预测字段写回 `learned_group_pattern` 和 `learned_group_position` 后, Rust agentpprof 在 1,132 个 held-out operations 上折叠得到 74 个 stacks。这支持 supervised boundary fields 可以作为普通 operation fields 被 folding 使用, 不支持新增第三个 profiler object。

Field-derivation audit 同时保留反例。Mapping 提高 compression, 但把 action-to-phase V-measure 从 0.9343 降到 0.7416, 说明它是聚合机制而不是细粒度边界 oracle。跨标签家族的 boundary suitability check 中, learned boundary backends 在 4/5 rows 上胜过 best simple baseline; 可训练 rows 的 held-out F1 分别是 OSWorld-Human 0.6916、AgentNet step-correct 0.3197、AgentNet step-redundant 0.3361 和 AgentRewardBench looping 0.7833。AgentNet 两个 quality-state boundaries 优于 always-boundary baselines (0.2155 和 0.2645), 但仍有 precision 和 calibration caveat; AgentRewardBench looping 虽然 learned F1 达到 0.7833, 却被 `repeat_signal_change` baseline 的 1.0 F1 完全解释。因此 E1 的结论是: mapping、tagging/rank features、profile specs 和 supervised boundary backends 都只是写入 operation fields, 然后由 operation stack 折叠; 它们支持 first-class field derivation 和 suitability checks, 不支持 automatic intent boundary discovery。

Human-boundary oracle. OSWorld-Human 是当前最强的 grouped-boundary oracle。转换器覆盖 369 个 human desktop tasks 和 6,010 个 single-action operations; 只有 grouped-action 序列与 single-action 序列 exact-aligned 的 320 个 tasks 被写入 `human_group`、`group_pattern` 和 `group_position` oracle fields。这些 exact-aligned tasks 含 4,011 个 operations 和 2,075 个 session-local groups; 31 个 content-mismatch tasks 和 18 个 length-mismatch tasks 保留用于 action profiling, 但不被当作 gold group oracle。在同一批 exact-aligned operations 上, action-depth stack 有 482 个 unique stacks, grouped-depth stack 降到 106 个; 保守 `group_pattern` 对人工 `human_group` boundary 的 F1 为 0.627, precision 为 1.0, recall 为 0.456。这不是完美边界 detector, 但它给出有意义结论: operation stack 可以在同一条单动作序列上选择 action-depth 或 group-depth, 并以人工 grouped-action 标签作为 oracle 验证。Prompt 或 session 没有参与这个抽象。

5.2 RQ2/E2: Hidden-label localization 和 ranking

实验契约: RQ2/E2 的 claim 是 operation-stack profiling 能在真实 labeled traces 上 faithful localization 和 rank-

ing; oracle 是 6 个 oracle-backed tasks 中 34,539 个 operations 和 3,699 个 hidden positives; baseline 包括 flat summary、fixed-session drilldown、dataset-native hierarchy、raw-action stack、operation-stack width、operation-stack query-aware、label-drilldown 和 oracle upper bound; metric 包括 precision@k、recall、F1、AUPRC-style AP、nDCG、recall/F1@work budget、work-to-first-positive 和 group count; counterpoint 是 flat 和 dataset-native 可以赢 broad-recall 或 nDCG 目标, 所以主 claim 是 Pareto tradeoff, 不是 metric dominance。Claim-test: RQ2/E2 问的是: hot stacks 和 top-ranked groups 是否真的对应 hidden positives, 并且相对 flat summary 需要更少 inspection work、相对 fixed-session drilldown proxy 改善 localization-budget/fragmentation tradeoff。

Primary comparison 和 success criterion 是本节的核心。E2 把每个 profile group 当作 inspection target, 问 ranked targets 能否用比 flat summary 更少的 work 找到 hidden positives, 并比 fixed-session trace-tree proxy 更少碎片化。成功条件不是单一指标第一, 而是 Pareto 条件: operation stack 必须降低 flat inspection work, 在有意义的 fixed-session localization 或 fragmentation objective 上改善, 同时保留 fixed-session early-hit 反例。本节的主实验不是重新定义一个 agent benchmark, 而是把真实标注轨迹中的 failure、safety、quality 和 human-boundary labels 当作 profiler localization oracle。6 个任务覆盖 AgentRewardBench looping/side-effect、SATraj unsafe、AgentNet incorrect/redundant steps 和 OSWorld-Human group starts, 总计 34,539 个 operations、3,699 个 positives。R320 把每个 view/ranker 的 hot groups 当作 ranked localization result, 用 hidden labels 计算 precision@k、recall@budget、F1、AUPRC-style AP、nDCG 和 work-to-first-positive。比较对象包括 flat、fixed-session drilldown、dataset-native hierarchy、raw action stack、operation-stack、label-drilldown oracle view, 以及 width、visible-risk、query-aware 和 oracle-upper-bound rankers。非 oracle policies 只使用 visible operation fields; label-drilldown 和 oracle-upper-bound 只作为上界。表 4 给出主要 policies 的 median 结果: operation-stack query-aware 在 top-5 groups 中只检查 0.0937 operation fraction, 而 flat summary 必须检查 1.0; 相对 fixed-session query-aware drilldown, operation-stack top-5 recall 在 5/6 tasks 上更高, 并把 median group count 从 285.0 降到 157.5。这支持的是 inspection-work/fragmentation Pareto tradeoff, 而不是 metric dominance: dataset-native hierarchy 的 median top-5 recall 达到 0.8665 但 work 为 0.8539; fixed-session 的 work-to-first-positive 只有 0.0044, 但 top-5 recall 只有 0.0233。

Failure interpretation 和 baseline scope 也是结果的一部分。R368 把 fixed-session drilldown 作为当前已评估的 trace-tree-shaped baseline, 而不是声称完整导入 OpenTelemetry、Phoenix、LangSmith、Langfuse 或 Peretto ecosystem traces。在同一批 R320 rows 上, operation-stack query-aware 相对 fixed-session 在 5/6 tasks 上提高 top-5 recall 和 F1, 在 4/6 tasks 上提高 budget-30 recall, 并在 4/6 tasks 上减少 group count; 同时 fixed-session 在 4/6 tasks 上保留更低 top-5 work 和 first-positive work。R355 给出 depth-aware 版本: operation-stack rankings 在 20/24 task-depth rows 上超过 fixed-session budget-30 positive-unit recall, 并在 22/24 rows 上用更少 groups 到达 50% positive units。如果这些反例从论文

里消失, claim 就会被写过头; 保留它们后, E2 支持的是更好的 localization-budget/fragmentation tradeoff, 不是对所有 trace-tree-shaped objectives 的 dominance。R300–R305 只作为 setup 和 case-packet provenance: 它们验证 visible packet 与 hidden answer key 分离、top-ranked operation-stack groups 能形成 reviewer-facing cases, 并暴露 flat full-recall 与 fixed-session early-hit 反例; 主 accuracy claim 由 R320 统一评分。

R363 把同一批 scored outputs 组织成非 flamegraph 的 paper-facing views, 而不是只输出 flamegraph。主文只保留一个代表性图: 左图服务 E2, 展示 localization/work/fragmentation tradeoff; 右图服务 E3, 展示 profile-configuration knobs。其余 portfolio table、headline rows、task case cards 和 verdict matrix 保留在 artifact ledger, 作为 paper-integration material, 而不是主文中的额外实验。

这些生成的 case 和 verdict artifacts 仍然有用, 但现在只作为三个核心实验的检查材料, 而不是主文表格。它们显示: 6/6 tasks 相比 flat summary 改善 AP 和 top-five inspected work; 5/6 tasks 相比 fixed-session drilldown 改善 top-five recall; 4/6 tasks 降低 fixed-session group fragmentation; 6/6 tasks 都有 actionable configuration result, 即 R354 profile-spec patch 或 R358 boundary-field repair。同时它们保留负证据: fixed-session 在若干任务上仍然是 first-positive 或 group-count counterpoint, OSWorld-Human 需要 boundary-derived fields, 而不是 visible phase/action ranking alone。

E2 的 support audits 只用于检验这个 Pareto 结论是否稳健, 而不是形成新的主实验。Bootstrap 和 label-permutation checks 显示, operation-stack query-aware 的 AP、top-5 work、budget recall 和 group-count deltas 在 6/6 tasks 上方向稳定; AP 在 6/6 tasks 上超过 95% prevalence/group-size null, 30% budget recall 在 5/6 tasks 上超过 null。Work-budget、fragmentation 和 oracle-depth slices 再把收益拆到 reviewer 关心的检查成本上: 30% work budget 下 median recall 为 0.3900, 高于 fixed-session 的 0.3559 和 flat 的 0.0000; 相同 budget 下它在 5/6 tasks 上检查更少 groups, 同时保留 fixed-session first-positive-work 反例; 在 24 个 task-depth rows 中, 它有 20 个提高 fixed-session budget-30 positive-unit recall, 并在 22 个 rows 用更少 groups 达到 50% positive units。这些 slices 合起来支持 faithful localization surface 和 inspection-work/fragmentation tradeoff; 它们不支持 single best hierarchy、human productivity 或对所有 trace-tree-shaped objectives 的 dominance。

E2 的结论因此是 scoped profiler result: operation-stack profiling 在真实标注轨迹上能把 hot groups 排成对 hidden positives 有信号的 localization surface, 相比 flat summary 明显减少 inspection work, 相比 fixed-session drilldown 通常改善 median fragmentation tradeoff 或提高同预算 recall。它不能写成 automatic detector、single best hierarchy、human/agent analyst productivity, 或对真实 OpenTelemetry/Phoenix/LangSmith/Perfetto span tree 的完整兼容和支配。

5.3 RQ3/E3: 机制隔离和 actionability

实验契约: RQ3/E3 的 claim 是 profiler 通过 stack fields、mapping/tagging rules、ranking policies、profile specs 和 boundary-derived operation fields 暴露 actionable opti-

mization knobs; oracle 是 hidden labels only after profiling, R358 还用 held-out OSWorld-Human boundary positives 评分; baseline 包括 default semantic-width specs、patched specs、visible feature rankers、transfer policies、learned-boundary stacks、fixed-session 和 semantic-width stacks; metric 包括 accepted patches、AP delta、top-5 lift delta、first-positive-work delta、group reduction 和 top-5 work counterpoint; counterpoint 是 OSWorld-Human 需要 boundary-derived fields, 因此这是 actionable mechanism evidence, not automatic boundary discovery、not automatic patch selection。Claim-test: RQ3/E3 问的是: localization gain 来自哪些机制, profile-guided 的 stack fields、rank features、mappings 或 boundary-derived fields 能否在不把 hidden labels 泄漏进 profiler input 的前提下改善输出。

Primary mechanism question 是: E2 的 ranked outputs 能不能解释应该怎样改 profile configuration。Hidden labels 只在 profiling 之后用于 scoring; visible inputs 仍然是 stack fields、mapping/tagging rules、rank features、profile specs 和 boundary-derived operation fields。成功条件是 actionable、replayable diagnosis: 每个任务应该指向具体的 stack、field、ranker、mapping、profile-spec 或 drilldown change, 并且 executable patches 能改善 scored output, 但不能把结果写成 automatic selector。

R320 首先把 localization 分数解释成任务级诊断, 而不是只给 policy 排名。SATraj unsafe 说明 environment、phase、action 和 risky/write-action ranking 对安全问题有效; looping 说明 repeat_signal 有用但需要 prevalence-aware ranking; side-effect 指向更深的 write/input mapping; AgentNet step-quality 需要 action-family 定位后再进入 fixed-session examples; OSWorld-Human 则需要 boundary-derived fields。因此 actionability 的第一层结论是: profiler 指出该调 stack field、mapping、ranker 还是 drilldown, 而不是给出唯一默认 view。

Rust 机制消融说明这些诊断来自可复现的 profiler 配置, 而不是来自又一组独立小实验。第一, stack-text rank rules 和 rank mode 可以从 profile spec 复现, 但它们对 safety/side-effect 过粗。第二, operation-level rank features 在 folding 前匹配 visible mapped operation tokens; semantic stack 的 feature ranking 在 AP 上赢 5/6 tasks、top-5 lift 赢 4/6、first-positive work 赢 5/6, coarse depth 在 4/6 tasks 上改善 AP 并减少 groups。第三, leave-one-feature 和 robustness checks 说明哪些字段有用或有害: repeat_signal、write-action 和 status=success 在不同 family 关键, SATraj loop-like 或 OSWorld-Human input-phase features 会误导; global/equal feature banks 常能保留收益, guided repair 在 2/3 misleading-feature cases 上改善 AP, 但这些 repair 使用离线评分反馈, 因此不是自动 learned ranker。R322–R326 只是这个 E3 mechanism block 的 provenance。

View、depth 和 budget 审计把机制结果放回 profiling tradeoff。Best AP 和 best top-5 F1 分散在 operation-stack、fixed-session、dataset-native、raw-action 和 flat views; leave-task source selection 不能稳定选中 best view。但 operation-stack query-aware 在 6/6 tasks 上进入 Pareto frontier, 相对 flat 在 6/6 tasks 降低 top-5 work, 相对 fixed-session 在 5/6 tasks 提高 top-5 recall, 并在 5/6 tasks 用更少 groups 达到 50% positives。25% recall target 下它覆盖

表 4: E2 hidden-label localization benchmark. R320 是 source artifact; Hidden 表示 policy 是否读取 oracle label; WTFP 是 work-to-first-positive. 非 oracle policies 只读 visible operation fields, hidden labels 只用于 scoring.

Policy	Hidden	AP	nDCG	P@5	R@5	F1@5	Work@5	R@30%	WTFP
flat:width	no	0.1678	1.0000	0.1678	1.0000	0.2868	1.0000	0.0000	1.0000
fixed-session:query-aware	no	0.3476	0.7642	0.2555	0.0233	0.0427	0.0163	0.3559	0.0044
dataset-native:query-aware	no	0.3572	0.7445	0.1712	0.8665	0.2822	0.8539	0.3377	0.0582
raw-action:query-aware	no	0.2744	0.5012	0.2513	0.2442	0.2195	0.1507	0.3325	0.0374
operation-stack:width	no	0.1610	0.9364	0.1398	0.4746	0.2147	0.5424	0.3372	0.1694
operation-stack:query-aware	no	0.3117	0.5487	0.1991	0.1880	0.1981	0.0937	0.3900	0.0378
operation-stack:oracle-upper	yes	0.5993	0.6372	0.8984	0.3004	0.4029	0.0441	0.5640	0.0122
label-drilldown:oracle-upper	yes	1.0000	1.0000	1.0000	0.6703	0.7972	0.1150	1.0000	0.0377

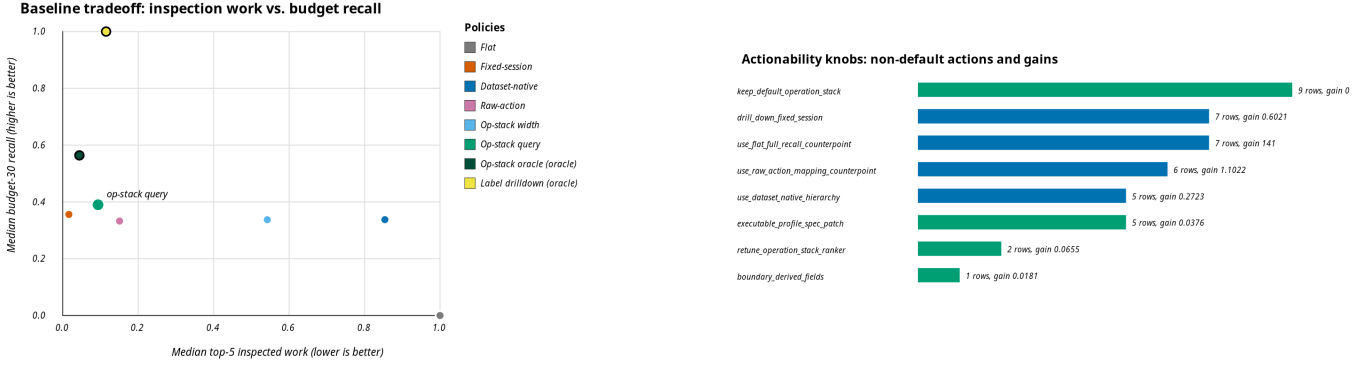


图 1: R363 的两个 paper-facing 非 flamegraph 视图。左图把 RQ2/E2 的核心 tradeoff 放在同一坐标系中: operation-stack query-aware 位于 flat summary 的低 work 区域, 同时保留 fixed-session 和 oracle 上界反例。右图把 RQ3/E3 的 actionability 展开为 profile-configuration knobs: 多数 objective rows 需要改变 view、ranker、profile spec 或 boundary-derived fields, 而不是使用一个固定默认视图。

6/6 tasks, median work 为 0.2000 而 flat 为 1.0000, median groups 为 16.0 而 fixed-session 为 50.0; 50% recall 和 first-positive work 仍保留 fixed-session、dataset-native 或 raw-action counterpoints. Sequence-scope 和 oracle-depth 审计进一步说明: 30% work budget 下 positive-session recall 为 0.4669, 高于 fixed-session 的 0.3230; 24 个 oracle-depth rows 上 budget-30 positive-unit recall median 为 0.4342, 并在 20/24 rows 提高 fixed-session unit recall、22/24 rows 用更少 groups 达到 50% positive units. Positive-run proxy units 是 episode-derived proxy units, 不是 human intent; positive-session-without-unit fixed-session depth-gap counterpoint 仍然保留, 所以这只是 depth-aware triage, 不是自动发现所有 latent subtask 或 intent boundary. R344 也保留多指标反例: 30 个 baseline-metric comparisons 支持 operation-stack query-aware, 16 个是明确 counterpoints, nDCG 场景下 flat 或 dataset-native 可能胜出。

Actionability portfolio 把这些比较变成 reviewer 可以检查的优化建议。36/36 objective rows 都有具体 profile-configuration action, 但 27/36 best visible policies 不是默认 operation-stack query-aware; transfer miss 多数对应 view 或 ranker 变化, 而不是不可解释错误。同一证据被组织成 diagnostic lenses、case packets 和 baseline contrasts: 6 个 lenses 覆盖 36 objectives, top-5 case groups 在 6/6 tasks 命中 positive, top-1 在 5/6 命中, median top-5 lift 为 1.6508 且 work 为 0.0937; operation-stack 在 6/6 tasks 胜过 flat top-5 work、在 5/6 胜过 fixed-session top-5 recall, 同时保留 fixed-session first-positive 和 flat full-recall 反例。Visible counterfactual 和 held-out transfer checks 把行动建议与目标标签泄漏分开: 36/36 best rows 是 visible non-oracle, 27/36 需要 non-default action, 25/36 需要 view change; held-out action transfer 在 35/60 aligned decisions 上 within tolerance, 但 exact action-class transfer 只有 7/60, 在 non-default target action 上只有 2/42。这些支持运行 (R335、R341、R345–R350) 合起来只是一个 E3

actionability block。因此这里的 claim 是可调诊断 surface, 不是 label-free automatic selector。

Executable profile-spec patches 关闭一个从诊断到可执行配置的闭环。Default 与 patched profile specs 在同一 visible operation input 上实际运行 Rust agentpprof --profile-spec, hidden labels 只在 profiler 输出后评分; 5/6 patches 同时改善 AP、top-5 lift 和 first-positive work, median AP delta 为 0.0376, median top-5 lift delta 为 0.5750。这里的 failure interpretation 同样重要: 唯一 reject 是 OSWorld-Human, 说明 visible phase/action rank features 不足以处理 human-boundary 目标。Held-out boundary-derived fields 随后作为普通 operation fields 折叠, AP 从 semantic-width 的 0.2402 提升到 0.2583, groups 从 108 降到 74; 反例是 top-5 work 和 first-positive work 变差。R354/R358 支持 boundary-derived fields 是 actionable operation-field knob, 不支持 automatic boundary discovery 或 automatic patch selector, 也不是第五个核心实验。表 5 是 E3 的主显示; 它把 R365/R373 task-card evidence 压缩成 paper-facing diagnosis table, source artifacts 只作为 provenance, 不新增主实验。

5.4 RQ4/E4: Replayability、离线成本和 artifact hygiene

实验契约: RQ4/E4 的 claim 是 offline profiler path 可以在 tracked inputs 上低成本 replay; oracle 是 tracked profile specs、tracked operation inputs、profile-spec input replay regressions、repeated profile outputs、runtime logs 和 source-status rows; baseline 包括 default output versus deterministic-output replay、semantic profile hashes versus raw-byte profile hashes, 以及 effective input metadata versus silently ignored source paths; metric 包括 deterministic spec pass rate、profiler invocations、median/p95 runtime、sample equality、stack equality、raw-byte output equality 和 input-source replay coverage; counterpoint 是 not live eBPF overhead、not human utility、not complete ecosys-

表 5: E3 task diagnosis cards。每行把 hidden-label localization 信号、可执行 profile 配置动作和反例放在一起；它是 R365/R373 task-card evidence 的压缩主文本版本，不是新增实验。

Task	Localization signal	Profile action	Counterpoint
Looping	Work@5 0.4938, R@5 0.6508, patch AP +0.1155	保留 repeat_signal ，但加入 prevalence-aware ranking，因为 positives 很常见。	Raw-action first-positive work 更低。
Side-effect	Work@5 0.1454, R@5 0.1139, patch AP +0.0591	提高 write/input 权重，或在 ranking 前使用更深的 side-effect mapping。	Fixed-session groups 更少；raw-action top-five lift 更好。
Unsafe operation	Work@5 0.0420, R@5 0.2621, patch AP +0.5081	使用 environment、phase、action stack fields，并优先 risky environment 和 write actions。	Fixed-session first-positive work 更低。
Incorrect step	Work@5 0.0014, R@5 0.0034, patch AP +0.0160	使用 desktop environment、phase、repeat 和 action fields，再进入 fixed-session examples。	Fixed-session 仍是 drilldown baseline。
Redundant step	Work@5 0.0089, R@5 0.0177, patch AP +0.0011	使用 desktop environment、phase、repeat 和 action fields，再进入 fixed-session examples。	Fixed-session first-positive work 更低。
Group start	Work@5 0.4074, R@5 0.3874, boundary AP 0.2583	使用 group-depth 或 boundary-derived fields；action-depth alone 会 fragment starts。	Boundary fields 把 groups 降到 74，但 top-five 和 first-positive work 变差。

tem compatibility、not universal selector。Claim-integrity、rubric 和 reviewer-style checks 是 artifact hygiene，不是 empirical evidence。Claim-test: RQ4/E4 问的是：reviewer 能否 replay offline profile-spec path，并验证 source provenance、paper numbers、two-abstraction wording 和 non-claims 都保持一致。

本节的 empirical content 是一个 replayability/cost block。它在 tracked operation JSONL inputs 上重复执行 76 个 profile specs，共 152 次 profiler invocations。默认模式下所有 specs 在重复运行中保持 semantic profile content、samples 和 unique stacks 稳定，median 每个 spec 运行时间为 1.581s，p95 为 2.719s；raw-byte determinism 只有 4/76，因为输出带生成时间戳。Deterministic artifact mode 固定 JSON **generated_at** 和 pprof profile time 后，同一 76 个 specs 的 semantic 与 raw-byte determinism 均为 76/76，clean rerun 记录空的 git/code status，median 每个 spec 运行时间为 1.601s，p95 为 2.767s。R327/R328 只是这个 E4 replayability block 的 provenance；这些结果支持 artifact/reproducibility claim，但不等价于 live capture overhead。

R392 补齐 input-source replay guardrail。Rust profile-spec path 现在可以携带 **session_files**、**trace_files**、**standard_trace_files**、**regex_tag_rules**、**predicates**、**rank rules**、**stack overrides** 和 **include_standard_trace_args**。回归测试把同一个 public Codex fixture 作为 local session 和 exported agent-session trace replay，并把一个 generic Chrome Trace Event 中的非 AgentSight protocol arg 导入为 operation field 后折叠。这些检查证明 profile spec 不会只 replay operation JSONL，也不会把输入源静默忽略；但它们仍然是 E4 replay/hygiene evidence，不是新的 hidden-label accuracy experiment、第三个 profiler object 或完整 trace-ecosystem compatibility claim。表 6 和表 7 是 E4 的主显示：前者呈现 replayability/cost result，后者呈现 deterministic-output repair；R327/R328 是 source artifacts，不是新的 accuracy 实验。

其余 paper gates 是 artifact hygiene，不是新的 empirical evidence。R338 把 paper claim 本身纳入审计：它复用 R320–R350 的 tracked-clean artifacts，不重新排名、不下载、不同步、不创建、不重标数据集，只检查论文数字、source policy、must-not-claim guardrails 和 operation/operation-stack 边界是否一致。R352 再把当前结果集映射到 OSDI-style profiling-paper rubric：它复用 tracked R320–R351 artifacts 和当前论文文本，不下载、不同步、不重跑 profiler，也不运行 human/agent analyst task。26/26 required checks

表 6: E4 replayability/cost 主显示，来自 R327。Runtime 为 Rust binary 已存在后的每个 spec 秒数；semantic hash 去除 JSON **generated_at** 字段，raw-byte hash 单独报告。

Workload	Specs	Med. s	P95 s	Med. stacks
R300 views	4	3.448	4.273	631.0
R324 rank	12	1.539	2.692	41.0
R326 robust	60	1.542	2.640	41.0
All specs	76	1.581	2.719	42.0

表 7: E4 deterministic-output 主显示，来自 R327/R328 在同一 76 个 profile specs 上的 determinism 检查。R328 使用 **--deterministic-output**。

Run	Mode	Sem.	Raw	Med. s	P95 s
R327	default	76/76	4/76	1.581	2.719
R328	deterministic	76/76	76/76	1.601	2.767

和 10/10 rubric areas 通过，覆盖 fidelity/accuracy、actionability、baseline tradeoff、generality、mechanism isolation、robustness/statistics、reproducibility/overhead 和 claim-scope guardrails。上一节的 actionability 结论依赖这些可复现 profile specs 和 tracked operation inputs；本节只证明 reviewer 能重放这些 artifacts 并检查 source provenance、paper numbers 和 non-claims。因此 RQ4/E4 是 replayability/claim-hygiene 证据，不是人工 analyst 主观解释、live overhead 或新的 profiler accuracy 结果。

剩余 paper gates 是 artifact hygiene，不是新的 empirical evidence。它们检查表格生成、claim wording、source provenance、non-claims 和 operation/operation-stack boundary 是否与 tracked outputs 对齐。我们把这些检查保留在 evaluation ledger，方便 reviewer 审计一致性；但它们不增加 localization、actionability 或 overhead claim。表格生成器、visualization portfolios、headline selectors 和 reviewer gates 可以支持 E1–E4，但不会形成额外主实验。

6 哪些数据集最适合

从当前 15 个方案看，最适合支撑论文主 claim 的不是“最大”数据集，而是同时具备顺序、动作、边界或质量 oracle 的数据集。第一类是 OSWorld-Human，因为它同时给 single-action 和 grouped-action，是验证递归边界的最直接 oracle。第二类是 AgentNet，因为它规模大、人工桌面任务多，并带 per-step correctness/redundancy。第三类是 AgentRewardBench 和 SATraj-OS，因为它们把 profiler 从 action taxonomy 推到 failure、looping、安全和 side-effect diagnostics。第四类是 GUI-Odyssey/tau-bench/ToolBench 这组跨域补充，它们覆盖移动 GUI、user-agent-tool dialogue 和 API/tool traces，证明 operation abstraction 不局限于

桌面。

ScaleCUA 是有用补充, 但不是当前主证据。R292 流式采样 5,000 个 Ubuntu navigation rows, 覆盖 131 个 sessions, 最大 step 为 48。该子集的 action taxonomy 主要是 click 和 terminate, 所以 phase/action 指标达到 1.0 并不表示强泛化。它更适合证明 multi-step GUI history context 可以被投影为 history_state 和 history_depth fields, 而不是证明复杂边界 detector。

7 相关工作

Profiling, flamegraphs 和 trace analysis. 传统 flamegraph 和 pprof 路线把运行时调用栈折叠成热点视图 [1,16,17]。pprof 不只是固定 call stack: 它支持 sample tags, 也支持用 tagroot/tagleaf 把 tag value 作为 pseudo stack frame 可视化 [17]。Perfetto 则代表系统 trace ingestion、SQL trace analysis、trace summary 和 derived events 的成熟方向 [18]。因此本文不能把 novelty 写成“只有我们支持 query-time aggregation”。本文复用 folded-stack 表示, 但 scoped novelty 是 agent-operation record model、recursive multi-field operation-stack projection 和真实标注轨迹上的 hidden-label localization benchmark 这三者的组合。Stack frame 来自 agent operation fields, 而不是语言运行时函数调用或通用 trace SQL schema。因此同一批 operations 可以被折叠为 task、phase、tool、action、quality 或 safety 视图, 也可以改成 fixed-session 或 flat baseline。区别不在图形样式, 而在 agent 语义对象、递归多字段 stack projection 和 R320 的跨数据集 hidden-label scoring。

Agent tracing 和 LLM observability. OpenTelemetry GenAI 和 OpenInference 标准化 GenAI spans、LLM calls、agent reasoning steps、tool invocations、retrieval operations、MCP 和 provider-specific telemetry [2,11]。LangSmith、Langfuse、Phoenix 和 AgentOps 等系统进一步把 LLM call、tool call、latency、token、trace tree、session、observation、evaluation score、goal、plan 和 agent artifact 放进单次 workflow inspection 与生产监控 [12,13,14,15]。这些系统是本文最接近的同问题相关工作。因此本文把 trace/span/session 明确当作 exchange container 或 baseline shape, 而不是加成第三个 profiler 抽象。R320 实际评估的是 fixed-session drilldown 这个 trace-tree-shaped baseline; 真实 OpenTelemetry/OpenInference/Phoenix span-tree import 仍是后续互操作 baseline, 不是当前已完成结果。本文关注跨轨迹 semantic profiling, 把异构标注轨迹或本地 agent 历史统一为 operations, 并允许用户选择 stack 深度、mappings、tagging 和 ranker。R314 专门检查这些 closest systems 是否进入 novelty map 和 baseline guard。

Agent failure 和 span localization. 2026 年的 AgentRx、TELBench/DRIFT、Holistic Evaluation and Failure Diagnosis 和 AgentAtlas 是最接近的同问题威胁 [23–26]。AgentRx 发布带 critical failure step 和 failure category 的失败轨迹, 并用 constraint checking 与 LLM judge 做 root-cause localization。TELBench/DRIFT 把 deep-research agent 轨迹转成 semantic spans, 并标注 harmful error spans。Holistic Diagnosis 把 agent-level diagnosis 和 span-level evaluation 结合起来; AgentAtlas 则强调 outcome leaderboard 不能覆盖 trajectory quality 和 control-decision quality。因此本文不能把 novelty 写成 failure localization、trajectory diagnosis 或 span-level evaluation 本身。本文的差异更窄: 把 profile groups 当作 pro-

filer 输出, 在同一批 operations 上比较 flat、fixed-session drilldown、dataset-native、raw-action 和 operation-stack views, 并用 AP、nDCG、inspection budget recall、work-to-first-positive、fragmentation 和 profile-configuration actionability 评分。AgentRx/TELBench-style traces 是后续 oracle/baseline 候选, 不是当前已完成的 broader span-localization 证据。

Computer-use 和 tool-use benchmarks. WeBLINX、Mind2Web、GUI-Odyssey、OSWorld/OSWorld-Human、OpenCUA/AgentNet、SATraj-OS、AgentReward-Bench、ToolBench 和 tau-bench 为本文提供真实标注轨迹 [3–10,19–22]。本文不提出新 benchmark。贡献是把这些 benchmark 的动作、质量、安全和人工 group 标签统一为 operation fields, 并用同一个 profiler 机制比较它们适合回答哪些 profiling 问题。这些 benchmark 是 evidence source 和 native-sequence baseline, 不是被本文替代的对象。

Novelty 边界. 因此本文的新意不是“第一个 agent observability 系统”、不是“第一个 agent trajectory benchmark”、也不是“第一个 folded-stack 可视化”。当前可 defend 的 scoped novelty 是: 只用 operation 和 operation stack 两个 profiler 抽象, 把 trace/session/span 作为输入容器或 baseline, 在真实公开标注轨迹上把 profile groups 当成 ranking/localization outputs, 并用 hidden labels 计算 accuracy、work、fragmentation 和 actionability。更具体地说, 新意不是 query-time aggregation 本身, 而是把 agent-operation record、recursive multi-field stack shape 和 hidden-label localization benchmark 绑在一起: 同一批 agent operations 因 stack shape 不同形成不同的可定位、可排序、可检查 aggregation units。这不是穷尽式 2026 全量综述; 它是围绕当前 paper claim 的 closest-threat audit。

8 局限

当前结果仍不是 OSDI 或 NeurIPS 最终接收级完整证据。第一, field derivation 和 boundary recovery 的范围仍然有限。当前证据支持 deterministic mappings、label-derived rules 和部分 supervised boundary backends 能派生 stackable operation fields, 但不证明无监督或 LLM-backed intent detector 已经解决, 也不证明一个 backend 能跨所有标签家族工作。AgentRewardBench looping 被简单 repeat_signal_change baseline 完全解释, 这说明每个 family 都需要 suitability、calibration 和 simple-baseline gate。

第二, E2 支持 profiler-localization claim, 但不支持人类效用 claim。E2 把 failure、safety、quality 和 human-boundary 问题转成 hidden-label ranking/localization benchmark, 并证明 operation-stack profiling 相对 flat summary 和 fixed-session drilldown 有 accuracy/work/fragmentation tradeoff。这个 tradeoff 是 task- 和 metric-specific 的: 最佳 visible view 不由单一 hierarchy 垄断, source-task selector 不能稳定自动选中最优 view, 20%/30% inspection budget 下 operation-stack query-aware 的 median recall 更高, 但 fixed-session 仍保留 first-positive 低成本反例。Fixed-session fragmentation 与 operation-work 成本也必须分开解释: operation-stack 支持更少 group fragmentation 和同预算更少 groups, 但 first-positive/work 指标仍不由 operation-stack 支配。Related-work/baseline audit 只把 grounding 转成可失败检查, 不增加新的实证结果。Protocol artifact 仍然有用, 因为它

把现有 visible packets 和 hidden answer key 固化为 6 个 tasks、3 个 views、24 个 participant slots 和 144 个 trials 的 balanced analyst-study protocol, 并通过 visible-packet leakage check。但该 study 现在只是可选增强, 用来验证开发者或 agent analyst 是否更快或更准。本文当前不能推出开发者准确率、time-to-answer 或 productivity 改善, 也不能声称所有 intent boundary 都能被自动发现。论文主 claim 应固定为 profiler 本身在真实标注 trace 上的定位、排序、归因和 actionability, 而不是 human utility。

第三, 数据和互操作范围是轻量采样。本文避免同步完整测试集、图片归档和 gated 数据, 因此有些来源只覆盖前缀、子配置或 redacted rows。Chrome Trace Event 和 agent-session exchange 当前只是 exchange/reproducibility smoke: 它们覆盖本地 session fixture 和 tracked real labeled operation prefix, 证明 trace 可以作为 exchange container, 但不证明完整 OpenTelemetry/Chrome trace-ecosystem、Perfetto producer 或图像密集 benchmark 兼容。

第四, E4 和 audit artifacts 是 claim-control surface, 不是额外实证结果。Replay、paper-number、source-policy、guardrail 和两抽象边界检查提高了论文表述、source path、负结果、related-work grounding、evaluation-rubric coverage 和 must-not-claim 边界的一致性; 当前 profiling-paper rubric coverage 为 26/26 required checks。但这些 checks 只能审计底层 empirical artifacts。如果底层采样或 oracle 本身有偏差, audit 能暴露并收窄 claim, 不能消除偏差。因此本文最终主张应固定为 two-abstraction mechanism 和 hidden-label profiler fidelity/work tradeoff, 而不是 universal fixed-session dominance、automatic anomaly detection 或完整 human utility。

9 结论

本文把 agent semantic profiling 收敛为两个核心抽象: operation 和 operation stack。Prompt、session、toolcall、process、syscall、plan、subagent、GUI action、安全标签和质量标签都只是 operation shapes 或 fields。Mapping 和 tagging 负责派生 fields, --view、--where 和 --stack 负责选择权重、查询子集和递归折叠形状, --trace-file 和 --operation-file 负责数据入口, --profile-spec 只把这些选择变成可复现实验配置, --deterministic-output 只把 profile artifact 时间戳固定为可复现值。在 15 个轻量采样的公开标注轨迹数据源上, 这个模型统一了 web、mobile、desktop、software、API、dialogue、failure、安全、human group 和 step-quality 轨迹, 并产生 flamegraph 之外的 stack tree、transition、quality、boundary、case packet 和 claim-audit reports。这支持本文的核心机制 claim: agent profiling 的边界可以从 prompt/session/span tree 中释放出来, 成为 query-time operation-stack projection。

当前最强经验结论来自四类 oracle-rich 轨迹。OSWorld-Human 证明同一动作序列可以折叠到人工 grouped-action 深度; AgentNet 证明 step correctness 和 redundancy 可以作为普通 operation fields 进入 profiling; AgentRewardBench 和 SATraj-OS 证明 failure、looping、side-effect、安全和 attack-type diagnostics 可以用同一机制表达。6 个 label-hidden tasks 构成主 hidden-label profiler benchmark: query-aware operation-stack top-5 groups 用 median 0.0937 work 取得 0.188 recall, flat summary 用 1.0 work 才取得 full recall, fixed-session 用 0.0163 work 但 top-5 recall 只有 0.0233; 相对 fixed-session, operation-

stack top-5 recall 在 5/6 tasks 上更高, 并把 median groups 从 285.0 降到 157.5。

后续证据不是新的主实验, 而是解释这个 profiler claim 何时成立。Task-paired uncertainty、label-permutation negative controls、view/depth task-fit、inspection-budget curves、fixed-recall target、sequence-scope scoring 和 oracle-depth scoring 共同说明: operation-stack 的主要优势是 AP/work/fragmentation tradeoff, 而不是所有指标支配。Actionability 证据进一步显示 36/36 objective rows 有具体 optimization action, 27/36 best visible policies 不是默认 operation-stack query-aware; diagnostic lenses、case packets、baseline contrasts、action counterfactuals 和 held-out transfer guardrails 说明 profiler 暴露的是可调分析 surface, 而不是 automatic universal selector。Executable profile-spec patch 进一步证明这种 profile-configuration actionability 可以落到 Rust profiler 配置上: 5/6 patches 改善 AP、top-5 lift 和 first-positive work; OSWorld-Human reject 再由 boundary-derived operation fields 改善 AP 和 groups, 但保留 work 反例。

因此本文的新意不在单个 flamegraph, 而在两个抽象形成的统一接口。它也不在通用 query-time aggregation、trace schema 或 observability dashboard 本身; 这些能力已经由 pprof、Perfetto、OpenTelemetry/OpenInference 和 LLM observability systems 覆盖到不同程度。Mapping、tagging、profile specs、agent-session trace、Chrome/Perfetto-style trace exchange、boundary backends 和 reviewer evidence packets 都只围绕 operation fields 与 operation-stack queries 工作。它们让用户和实验者能在同一批 operations 上选择不同 view、派生不同 fields、折叠不同深度, 并审计每个 claim 的证据来源。当前 value claim 是相对 dataset-provided hidden labels 的 profiler fidelity、label-scored ranking/localization、inspection-cost/fragmentation tradeoff 和 profile-configuration actionability; 不是 detector、human utility、baseline dominance、automatic patch selector 或 ecosystem compatibility。下一步不应无差别增加数据集, 而应沿两个方向提高 claim 强度: 一是把 field-derivation backend 做到跨家族 calibration 并稳定胜过简单 sequence-derived baselines, 二是在已有或新增真实 trace 中补更强的 instruction-step、solution-path 或 human subtask oracle; 只有在要写 ecosystem baseline claim 时才导入真实 OTel/Phoenix/LangSmith/Langfuse/Perfetto span-tree trace。Controlled human 或 agent analyst study 可以作为后续增强, 但不再是本文主 profiling claim 的前置条件。

参考文献

- [1] Brendan Gregg. Flame Graphs. <https://www.brendangregg.com/flamegraphs.html>.
- [2] OpenTelemetry GenAI semantic conventions. <https://github.com/open-telemetry/semantic-conventions-genai>.
- [3] McGill-NLP WebLINX. <https://huggingface.co/datasets/McGill-NLP/WebLINX>.
- [4] OpenGVLab GUI-Odyssey. <https://huggingface.co/datasets/OpenGVLab/GUI-Odyssey>.
- [5] WukLab OSWorld-Human. <https://github.com/WukLab/osworld-human>.
- [6] xlangai AgentNet. <https://huggingface.co/datasets/xlangai/AgentNet>.
- [7] McGill-NLP AgentRewardBench. <https://huggingface.co/datasets/McGill-NLP/agent-reward-bench>.
- [8] AI45Research SATraj-OS. <https://huggingface.co/datasets/AI45Research/SATraj-OS>.
- [9] AgentSuite tau-bench trajectories. <https://huggingface.co/datasets/AgentSuite/tau-bench-trajectories>.
- [10] OpenGVLab ScaleCUA-Data. <https://huggingface.co/datasets/OpenGVLab/ScaleCUA-Data>.
- [11] OpenInference specification. <https://arize-ai.github.io/openinference/spec/>.
- [12] LangSmith Observability. <https://docs.langchain.com/langsmith/observability>.
- [13] Langfuse Observability. <https://langfuse.com/docs/observability/overview>.
- [14] Arize Phoenix. <https://arize.com/docs/phoenix>.
- [15] AgentOps: Enabling Observability of LLM Agents. <https://arxiv.org/html/2411.05285v2>.
- [16] Brendan Gregg. The Flame Graph. <https://queue.acm.org/detail.cfm?id=2927301>.
- [17] Google pprof documentation. <https://github.com/google/pprof/blob/main/doc/README.md>.
- [18] Perfetto Trace Processor documentation. <https://perfetto.dev/docs/analysis/trace-processor>.
- [19] AgentRewardBench: Evaluating Automatic Evaluations of Web Agent Trajectories. <https://arxiv.org/abs/2504.08942>.

- [20] OSWorld: Benchmarking Multimodal Agents for Open-Ended Tasks in Real Computer Environments. <https://arxiv.org/abs/2404.07972>.
- [21] OpenCUA: Open Foundations for Computer-Use Agents. <https://arxiv.org/abs/2508.09123>.
- [22] Safactory: A Scalable Agentic Infrastructure for Training Trustworthy Autonomous Intelligence. <https://arxiv.org/abs/2605.06230>.
- [23] AgentRx: Diagnosing AI Agent Failures from Execution Trajectories. <https://arxiv.org/abs/2602.02475>.
- [24] Where Do Deep-Research Agents Go Wrong? Span-Level Error Localization in Agent Trajectories. <https://arxiv.org/abs/2606.02060>.
- [25] Holistic Evaluation and Failure Diagnosis of AI Agents. <https://arxiv.org/abs/2605.14865>.
- [26] AgentAtlas: Beyond Outcome Leaderboards for LLM Agents. <https://arxiv.org/abs/2605.20530>.