

面向 AI Agent 轨迹的可配置语义剖析

AgentSight 研究原型

2026 年 7 月 4 日

摘要

AI agent 的执行历史已经不再只是一次 prompt 或一棵 trace tree。一个真实轨迹可能同时包含用户意图、LLM 响应、tool call、API 调用、GUI 动作、浏览器动作、进程、文件、网络、计划步骤、subagent 以及 benchmark 给出的成功、失败、安全、重复和冗余标签。现有 agent observability 工具通常把这些对象固定成 prompt、session 或 span 层级；传统 profiler 则固定成函数或进程层级。这两种做法都会把 profiling 问题过早绑定到某一种边界上，使同一段轨迹很难按任务、阶段、工具、动作、质量标签或人工分组递归折叠。

本文提出一种更小的语义剖析模型：系统只保留两个核心抽象，**operation** 和 **operation stack**。**operation** 是带字段和权重的观测，prompt、session、tool call、process、syscall、GUI action 和 plan step 都只是 operation 的不同形态或字段。**operation stack** 是用户从字段中选择的递归投影，mapping 和 tagging 在 stack 构造前派生字段，而不是创建第三种 profiler 对象。关键点是聚合不是第三个对象，也不是固定 trace tree；聚合由 query time 选择的 stack 形态决定。我们在 Rust agentpprof 中实现该模型，支持 `--view`、`--where`、`--stack`、`--op-map`、`--op-map-file`、`--trace-file`、`--standard-trace-file`、`--deterministic-output` 和可复现实验用的 `--profile-spec`，并把 15 个公开标注 agent 轨迹数据源投影为同一类 operation JSONL。

我们在 15 个轻量采样的公开标注轨迹来源上评估该模型，不同步完整测试集、图片归档或 gated corpus。核心结果显示，Web、mobile、desktop、software、API、tool-dialogue、failure、安全、human group 和 step-quality 轨迹都可以进入同一 operation layer，核心 14 个数据集包含 42,590 个 operations，补充 ScaleCUA 后为 47,590 个 operations。同一批 13,265 个 operations 可以从 9 个 dataset stacks 递归展开到 57 个 phase stacks、226 个 tool/semantic stacks 和 455 个 action stacks，而把固定 session 加入默认层级会膨胀到 3,757 个 stacks。本地 agent session、Chrome/Perfetto-style trace 和 operation-file standard-trace path 只作为 exchange/reproducibility smoke 使用，完整 benchmark conversion、image-heavy corpora 和真实 OpenTelemetry/Perfetto producer 兼容性仍是后续工作。

第二组结果验证 stack 不是 prompt/session/span 的别名。OSWorld-Human 的单个动作轨迹可以按人工 grouped-action 边界折叠，保守边界 F1 为 0.627 且 precision 为 1.0。AgentNet 的 1,000 个 Ubuntu 人工桌面任务产生 16,741 个 PyAutoGUI operations，并把 step correctness 和 redundancy 作为普通字段保留下来。Mapping/backend 的可支持范围是 deterministic 或 supervised field derivation：4 个标签家族可训练，但 AgentRewardBench looping 被更简单的 `repeat_signal_change` baseline 完全解释，所以当前

证据不支持通用无监督 intent detector。

第三组结果把 value claim 提升为真实标注 trace 上的 profiler localization 和 ranking claim，但仍不声称用户效用。在 AgentRewardBench、SATraj-OS、AgentNet 和 OSWorld-Human 的 4 个数据集、6 个 oracle-backed tasks、34,539 个 operations 和 3,699 个 positives 上，operation-stack packet 比 flat summary 更 selective 的任务为 6/6，含 positive group 的任务为 6/6，含 high-lift evidence 的任务为 5/6。相对 fixed-session，operation-stack selected recall 更高的任务为 5/6，但 selected work 更低的任务只有 2/6，fixed-session 在 4/6 tasks 上 selected work 更低。把 162 个非 oracle view/ranker/budget points 放入 Pareto frontier 后，operation-stack 在 6/6 tasks 上 nondominated，在 4/6 tasks 上取得 best lift，并在 4/6 tasks 上取得 30% work 内 best recall；flat 和 fixed-session 也在 6/6 tasks 上保留 frontier counterpoints。R320 进一步把 profiler 输出当作 ranking/localization result，用隐藏标签计算 precision@k、recall@budget、F1、AUPRC-style AP、nDCG 和 work-to-first-positive。Top-5 query-aware operation-stack profiling 的 median work 为 0.0937，而 flat summary 为 1.0；相对 fixed-session query-aware drilldown，operation stack 在 5/6 tasks 上提高 top-5 recall，并把 median groups 从 285.0 降到 157.5。Query-aware visible ranking 相比 width-only operation-stack ranking 在 6/6 tasks 上提高 AP，但 top-5 F1 和 work 仍暴露 prevalence 与 calibration 反例。R330 对 R320 的 6 个任务做成对 bootstrap 不确定性审计：operation-stack query-aware 相比 flat 的 AP、top-5 work、30% budget recall 和 work-to-first-positive 方向稳定；相比 fixed-session 的 top-5 recall、top-5 F1 和 group 数方向稳定；相比 width-only operation-stack 的 AP、top-5 work 和 work-to-first-positive 方向稳定，同时保留 flat top-5 recall 与 fixed-session first-positive work 反例。R331 再做 prevalence/group-size 负控：固定 visible ranking 顺序，只把 hidden positives 随机重分配到同样大小的 groups。Operation-stack query-aware 的 AP 在 6/6 tasks 上超过 95% permutation null，median AP delta 为 0.0759；30% budget recall 在 5/6 tasks 上超过 null，但 top-5 precision 只有 3/6、work-to-first-positive 为 0/6，因此不能把所有 hot-group 指标都归因给 ranking。R332 再审计 view/depth task fit：best visible AP 分散在 operation-stack、fixed-session 和 dataset-native 三类视图，best top-5 F1 分散在 raw-action、dataset-native、fixed-session、flat 和 operation-stack；operation-stack query-aware 只在 AP 和 30% budget recall 上各为 3/6 tasks 最优，因此 view/depth 必须是 query-time knob，而不是固定 hierarchy 或自动 selector。R333 进一步导出 inspection-efficiency curves：在 30% inspected-work 内，operation-stack query-aware 的 median recall 为 0.3900，而 flat、fixed-session、dataset-native 和 raw-action 分别为 0、0.3559、0.3377 和 0.3325；相对 fixed-session，它 top-5 recall 更高为 5/6 tasks、groups 更少为 4/6

tasks, 但 work-to-first-positive 更低只有 2/6 tasks。R334 再把 fixed-session fragmentation 和 operation work 分开: operation-stack query-aware 在 5/6 tasks 上用更少 ranked groups 覆盖 50% positives, 并在同一 30% work budget 下用更少 groups, 但 lower work-to-first-positive 仍只有 2/6 tasks。R335 把 actionability 做成六个任务级 cards: 6/6 都有具体 optimization action 且 query-aware ranking 相比 width 提高 AP; mapping 只在 2/6 有正收益并在 4/6 伤害结果, critical features 出现在 4/6, misleading features 出现在 2/6, coarse depth 在 6/6 减少 groups 但 AP-preferred 只有 2/6。R336 再把 actionability 转成 objective-specific selection audit: 15 个 visible policies, 6 个 tasks, 6 个 diagnostic objectives 中, operation-stack query-aware 在 6/6 tasks 上属于 Pareto frontier, top-5 work 低于 flat 为 6/6, top-5 recall 高于 fixed-session 为 5/6, groups-to-50% positives 低于 fixed-session 为 5/6; 但每个 task 都有多个 objective-specific best policies, lower work-to-first-positive 仍只有 2/6。R337 进一步把曲线转成 fixed-recall cost: 25% recall target 下 operation-stack query-aware 覆盖 6/6 tasks, median work 为 0.2000, median groups 为 16.0; flat 需要 median work 1.0000, fixed-session 需要 median groups 50.0; 50% target 下它只覆盖 5/6, 保留其他 view/ranker 反例。R339 再把 ranked groups 转成 trajectory/session scope 指标: top-5 下 operation-stack query-aware 的 median work 为 0.0937, positive-session recall 为 0.2629, 而 fixed-session positive-session recall 为 0.0160, flat work 为 1.0000; 30% work 下它的 positive-session recall 为 0.4669, 高于 fixed-session 的 0.3230, 并且 session work 为 0.3467, 低于 raw-action 的 0.9103。R355 继续把同一批 visible-ranked profiles 按 dataset-provided oracle depth 评分: 在 24 个 task-depth rows 上, operation-stack query-aware 的 median top-5 oracle-unit work 为 0.1307, budget-30 positive-unit recall 为 0.4342, unit F1 为 0.4484, positive-run recall 为 0.4908; 它相对 flat 在 24/24 rows 降低 top-5 unit work, 相对 fixed-session 在 20/24 rows 提高 budget-30 unit recall, 18/24 rows 提高 unit F1, 22/24 rows 用更少 groups 达到 50% positive units, 但 depth-gap 相对 fixed-session 仍是反例。R340 再把 policy selection 做成 cross-task/cross-dataset audit: selection 只用非目标任务或非目标数据集的 visible policy scores, 目标 hidden labels 只用于 held-out scoring; R338 检查 selected/best policies 在 96/96 decisions 上都是 visible 且 non-oracle, leave-task/leave-dataset train scopes 在 96/96 decisions 上排除了目标任务或目标数据集; 96 个 decisions 中有 62/96 within tolerance, 且相对 width, fixed-session, flat 分别 strict win 72/96, 69/96, 41/96。Operation-stack 只被选中 16/96 次, 所以结论是 objective-specific policy transfer 和 stack/view 调参, 而不是默认 operation-stack 单一支配。R341 再把 actionability 做成 mechanism/error attribution: 36/36 objective rows 都有 optimization action, 27/36 best visible policies 不是默认 operation-stack, 34/96 transfer misses 被归类为 view/ranker 或 baseline-counterpoint explanations, 其中 32/34 需要换 view, 26/34 需要换 ranker。R342 再把 profile-spec composition 和递归 stack-depth tradeoff 做成机制审计: 它复用 tracked-clean R324/R300 real labeled Rust outputs, 12/12 variants 都能组合 operation files, `where_rules`, `rank_op_rules`, `rank_mode=rule-score` 和 explicit stack depth, 且 12/12 不含 prompt/session frames; visible operation-feature ranking 在 9/12 variants 上提高

AP, coarse depth 在 6/6 tasks 上减少 groups, median reduction 为 0.8267。R344 再把 R320 的 metric surface 做成一致性审计: 50 个 baseline-metric comparisons 中有 30 个支持 operation-stack query-aware, 16 个是明确 counterpoints, 4 个 mixed/weak; AP, 30% work-budget recall/F1, inspection work, work-to-first-positive 和 groups 支撑主 tradeoff, 而 nDCG 与 coarse top-k recall 只能作为 secondary/counterpoint metrics。R345 再把 actionability 和 metric counterpoints 组织成 diagnostic-lens portfolio: 6 diagnostic lenses 覆盖 36 objective rows, operation-stack-family views 赢 11/36 objectives, 非 operation-stack counterpoints 赢 25/36, 且 6/6 tasks 至少需要 3 种 best views。这个结果说明 profiler 的价值来自按任务选择 ranked-stack, hot-stack, budgeted-inspection, first-positive 和 fragmentation lenses, 而不是单一 flamegraph 或 automatic universal selector。R346 再把 top-ranked operation-stack groups 做成 diagnostic casebook: 30 个 case groups 中 top-5 groups 在 6/6 tasks 上命中 positive, top-1 groups 在 5/6 tasks 上命中 positive; median top-5 lift 为 1.6508, median top-5 work 为 0.0937, 并且 6/6 case cards 都连接到 optimization action 和 counterpoint。R347 再把 case-level evidence 放回 baseline contrast: 5 个 visible views 覆盖 flat, fixed-session, dataset-native, raw-action 和 operation-stack, 30 个 view-task rows 都用同一 top-5 visible ranking 协议评分。Operation-stack 在 6/6 tasks 上胜过 flat top-5 work, 在 5/6 tasks 上胜过 fixed-session top-5 recall, 在 4/6 tasks 上胜过 fixed-session group count, 同时 fixed-session first-positive 和 flat full-work recall 仍是 counterpoints。R348 再把 actionability 做成 objective-level counterfactual audit: 36/36 best rows 都是 visible non-oracle, 27/36 objective rows 需要非默认动作, 25/36 需要换 view, 2/36 需要 operation-stack ranker tuning; median gain over default 为 0.1447, 且 6/6 tasks 都至少有 3 类 action 和 case counterpoints。因此 profiler 暴露的是可审计 tuning surface, 不是 label-free universal selector。R350 再把 R346–R349 组合成 evidence-packet budget audit: 6/6 tasks 的 top-5 operation-stack packet 都含 positive, 5/6 top-1 含 positive, 4/6 在严格 30% operation-work budget 内, median top-5 work/recall/lift 为 0.0937/0.188/1.6508; 同一 packet 还保留 27/36 non-default objective rows, 6/6 baseline counterpoints 和 R349 的 35/60 within-tolerance, 7/60 exact-action guardrail。因此 actionability 的结论是 bounded evidence packet 和可审计反例, 而不是自动 action selector。R338 最后把这些结果变成论文级 claim-integrity audit: 它读取 tracked-clean 的 R320–R350 profiler-evidence artifacts, 并哈希当前中英文稿; result invariants, source-policy checks, guardrail checks 和 two-abstraction boundary 均通过。这个 audit 不增加新的 empirical claim, 只防止论文越界到 human utility, automatic boundary discovery, trace-ecosystem compatibility 或 automatic universal selector。R352 再把同一证据映射到 OSDI-style profiling-paper rubric: 它读取 tracked R320–R351 artifacts 和当前论文文本, 不下载、不同步、不重跑 profiler; 26/26 required checks 和 10/10 rubric areas 通过, 结论是当前 claim 达到 scoped profiler-benchmark evidence gate, 而不是 human/agent analyst utility, automatic boundary discovery 或完整 trace-ecosystem compatibility。R326 进一步说明 rank policy 的收益不只是某一组手调权重: global equal visible features 在 semantic/coarse stack 上分别赢 4/6 和 5/6 tasks, equal-

weight task policy 在 8/12 variants 上接近 weighted policy; 但 repaired policy 使用 R325 离线评分结果, 因此只支持 actionability, 不支持已部署的 label-free universal ranker。R329 把 rank-policy selection 做成目标任务标签留下的 transfer probe: 选择 policy 时不看目标任务 hidden labels; leave-task 和 leave-dataset 在 semantic/coarse stack 上 AP 均为 4/6 胜过 width, semantic first-positive work 均为 6/6 改善, 7/12 variants 不低于 target-equal policy 超过 0.02 AP。R327 复用 R300/R324/R326 已提交的 76 个 profile specs 和已提交 operation JSONL, 执行 152 次 Rust profiler 调用: 去除 JSON generated_at 后, semantic profile hash、samples 和 unique stacks 均为 76/76 稳定; median runtime 为 1.581s, p95 为 2.719s, 最大为 4.273s。R328 在同一 workload 上启用 --deterministic-output, 把 JSON generated_at 和 pprof profile time 固定为可复现值, 使 semantic 与 raw-byte determinism 均达到 76/76; clean rerun 记录空的 git/code status, 该 run 的 median runtime 为 1.601s, p95 为 2.767s。Task-level narrative 进一步显示, SATraj safety 是最强 selective win, AgentNet quality 是 high-lift/low-recall, AgentRewardBench looping 是 prevalence aggregation, side-effect 和 OSWorld-Human boundary 对 ranker 与 depth 敏感。因此本文支持的 claim 是 operation-stack profiling 能在这些真实标注 trace 的 dataset-provided hidden labels 下定位、排序和归因任务相关问题, 并提供可审计的 accuracy/work/fragmentation tradeoff, 而不是人类用户效用、自动异常检测或相对 fixed-session 的无条件支配。

1 问题

AI agent 轨迹的调试问题正在从单次调用回放变成跨任务剖析问题。开发者不只想知道某个 span 什么时候开始和结束, 也想知道哪类任务导致最多重复点击, 哪些 GUI 轨迹反复输入, 哪个工具调用族对应失败, 哪些安全攻击类型集中在某些操作阶段, 或者一个 prompt 序列能否被折叠成 task、phase、action 和人工 subtask 等多个深度。如果 profiler 把 session、prompt 或 tool call 写死成核心层级, 这些问题会被迫使用同一个边界。如果 profiler 只保留进程或函数栈, 上层语义和 benchmark oracle 又会丢失。

本文的出发点是把 agent trace 中所有可剖析对象都降到同一层。一个 prompt 可以是 operation, 一个 tool call 可以是 operation, 一串 prompt 也可以通过 mapping 被派生为同一个 intent 或 task operation field。同样, GUI action、API call、browser action、process event、syscall、安全标签、step correctness 和人工 grouped-action id 都不是新的 profiler 抽象, 而是 operation fields。Profiler 的核心任务不是决定唯一正确边界, 而是让用户和实验可以在同一批 operations 上选择 stack 字段、派生 mappings, 并得到不同深度的递归折叠。

这个问题有两个系统挑战。第一, 抽象必须足够小, 否则 prompt、session、tool call、plan、subagent 和 process 会各自形成独立 pipeline。第二, 抽象又必须足够可配置, 否则 flamegraph 只会成为固定视图, 不能回答边界、失败、安全和质量诊断问题。本文的目标不是证明某个单一 flamegraph 最好, 而是证明 operation 和 operation stack 足以覆盖多类真实标注 agent 轨迹, 并且 stack shape 与 aggregation 的选择会系统性改变质量、边界、定位、work 和碎片化分析结果。

2 设计

2.1 两个核心抽象

operation 是唯一的样本级对象。每个 operation 是一个带权重的字段集合, 例如 op=prompt、op=llm、op=tool、tool=browser、action=click、phase=navigate、status=failure 或 step_correct=incorrect。这些字段可以来自本地 Codex/Claude session, 也可以来自外部 benchmark 的标注轨迹。实现上, 外部轨迹使用每行一个 JSON object 的 operation JSONL, 并把原始任务文本、截图和长对话默认排除在提交 artifact 之外。

operation stack 是从 operation fields 中选择出的有序 frame 列表。例如同一批 operations 可以用 project,dataset 查看数据来源, 也可以用 project,dataset,task,phase,op,tool,action,status 查看动作深度, 或者加入 human_group、step_correct、safety 和 looping 做诊断视图。Stack 不是 trace tree, 也不是 session hierarchy。它是一个查询结果, 用户可以按问题改变深度和字段。

2.2 Mapping 和 tagging

Mapping 和 tagging 是派生 operation fields 的一等机制。它们在 stack 构造前运行, 读取 operation 的 key=value 文本, 并写入新的字段。例如 desktop action 中的 type 和 key 应先被映射到 phase=input, 再考虑通用 web action verb; API/tool traces 应先进入 tool/API phase family, 再处理 search 或 create 这类词。这一顺序来自跨 web、desktop、API/tool 和 step-quality 轨迹时暴露出的关键设计约束。如果通用 action rule 抢在 operation-family rule 前面运行, desktop、web 和 API 轨迹会被错误合并。

Mapping 不引入第三个抽象。它只是在 operation 上写字段, 使同一个 stack specification 可以跨数据集复用。当前 Rust CLI 支持 inline --op-map FIELD:LABEL=REGEX 和文件形式 --op-map-file.--where FIELD=REGEX 和 FIELD!=REGEX 在 mapping 之后、stack 构造之前选择 operation 子集, 多条 predicate 取 AND; 它实现形式化模型里的 ϕ , 不是新的 profiler 对象。script/operation_map_infer.py 可以从已标注 operations 中生成同样格式的规则文件, 并用这些规则测试 held-out 和 leave-dataset-out 泛化。--profile-spec 把 operation files、mapping files、predicate、view、stack 和输出路径打包成 JSON 配置, 便于 reviewer 复现实验; 命令行参数仍可覆盖 spec 默认值。--deterministic-output 或 spec 中的 deterministic_output 可以把 JSON generated_at 和 pprof profile time 固定为可复现值, 用于 byte-stable artifact checks。它不改变模型本身, 只是把已有 operation 和 operation-stack 查询显式记录下来。

2.3 Views 和非火焰图分析

--view 决定采样和权重, 例如 operation count、token、file、network 或 time。--stack 决定递归折叠形状。Folded stack 和 SVG flamegraph 是其中一种输出, 但不是唯一输出。我们同时生成 JSON profile、stack tree、top-field table、parent-child transition、depth sweep、boundary F1、V-measure、coverage report、grouped-action report 和 HTML quality report。这些视图共享同一 operation 输入和 stack 语法, 因此 failure、safety、looping、redundancy 和 human group 可以被当作普通字段评分, 而不是另建 failure profiler 或 safety profiler。

3 实现

agentpprof 是当前被测实现。它是 Rust CLI，读取本地 Codex/Claude 历史或外部 operation JSONL，并输出 pprof-compatible profile、folded stacks、SVG 和 JSON。核心命令形态如下：

```
agentpprof --operation-file ops.jsonl --view operations
--stack project,dataset,task,phase,op,tool,
action,status --op-map-file operation-map.txt
--where task=verify
-o out.folded
```

外部数据集转换器位于 `script/agent_trace_datasets.py`。转换器只下载或流式读取所需公开文件的采样前缀。对于包含截图、长 prompt 或完整对话的数据集，默认保存 redacted rows 和 operation JSONL，不提交原始数据。本地 agent session 通过 `agent-session` 解析为 `agentsight.agent-session.trace.v1 trace`；agentpprof 可以用 `--export-trace` 写出 filesystem-normalized trace，用 `--trace-file` 读回，也可以通过 `script/agent_trace_convert.py to-operations` 转成 operation JSONL。`script/agent_trace_exchange_eval.py` 将这三步、filesystem/tool-command portability check 和 folded-output equality check 固化为一个可复现实验；该检查不声称 prompt/LLM preview 已完整脱敏。agentpprof 还可以用 `--export-standard-trace` 写出 Chrome/Perfetto-style `traceEvents`，再用 `--standard-trace-file` 导入为普通 operations 后折叠。`script/agent_trace_convert.py export-standard --format chrome` 和 `import-standard --format chrome` 保留为显式中间文件脚本；`script/agent_trace_chrome_exchange_eval.py` 验证 session fixture 路径不改变 folded operation-stack 输出。R353 进一步用 tracked R324 real labeled visible-operation JSONL 的 512-row prefix 验证 operation-file 路径：512 operations 导出为 512 个 Chrome complete events，经 `--standard-trace-file` 导入后仍得到 byte-identical 的 512-sample / 11-stack folded 输出；这仍是 exchange check，不是新的 accuracy result。质量评估脚本位于 `script/operation_stack_quality.py`，它复用 agentpprof 的 operation mapping contract，并计算字段覆盖率、oracle V-measure 和序列相邻边界 F1。Stack 结构分析脚本位于 `script/operation_stack_analysis.py`，用于生成 flamegraph 之外的 tree、top-kind 和 transition 报告。

这个实现刻意保留简单接口。它不像 jq 那样完整表达 JSON 查询语言，但它已经把 profiler 的关键自由度暴露为 flags 和可提交配置：数据源由 `--trace-file` 或 `--operation-file` 选择，权重由 `--view` 选择，查询子集由 `--where` 选择，字段派生由 `--op-map` 选择，递归边界由 `--stack` 选择，JSON group 排序由 `--rank-rule`、`--rank-op-rule` 和 `--rank-mode` 选择，复现实验由 `--profile-spec` 固化。R321 用同一份 R300 真实标注 operation JSONL 验证该实现路径：profile spec 中的 mapping-derived `where_rules` 分别选出 729/729、714/714 和 4,285/4,285 个预期 operations 后再折叠。R322 进一步让 Rust JSON profile 输出 visible-rule ranked operation-stack groups；在同一 6 个标注任务上，`rank_rules` 相比 width ranking 的 AP 提升覆盖 4/6 tasks，top-5 lift 提升覆盖 3/6 tasks，同时 SATraj 和 side-effect 反例显示二

值 stack-text boost 仍弱于 R320 的 group-feature query-aware ranker。R323 把该反例转化为 rank-mode 机制隔离：`rule-score` 相比 `width-boost` 的 AP 提升覆盖 4/6 tasks、top-5 lift 提升覆盖 4/6 tasks，并把 SATraj first-positive work 从 0.6376 降到 0.0842；side-effect 和 OSWorld-Human 仍保留为 depth/ranker counterexamples。R324 把 per-operation visible feature density 接到 Rust profiler：脚本先从 R300 source 派生删除 oracle fields 的 visible-operation JSONL，再让 `rank_op_rules` 匹配 mapping/filtering 后的单个 operation field=value token，并在 folded group 内聚合 matched operation weight；semantic stack 上 AP 相比 width 提升 5/6 tasks、top-5 lift 提升 4/6 tasks、first-positive work 改善 5/6 tasks，coarse stack 也在 AP 上提升 4/6 tasks，同时保留 OSWorld-Human 反例。R325 在同一 Rust profile-spec 路径上做 leave-one-feature ablation：它发现 7 个 critical feature instances、3 个 misleading feature instances，并显示 coarse stack 只在 2/6 tasks 上 AP 更好但在 6/6 tasks 上减少 group 数。R326 进一步测试 rank-policy robustness：global equal visible feature bank 在 semantic/coarse stack 上 AP 相比 width 分别赢 4/6 和 5/6 tasks，task-equal 在 8/12 task/depth variants 上与 weighted task policy 的 AP 差距不超过 0.02，R325-guided repair 在 2/3 misleading-feature cases 上改善 AP、在 2/3 cases 上改善 first-positive work，其中 1/3 同时改善两者；repair 是 post-hoc actionability check，不是 label-free deployment policy。R329 再做 target-held-out transfer：候选 policy 包括 global equal bank 和 6 个 source-task equal-weight policies，选择 leave-task 或 leave-dataset policy 时只使用非目标任务的离线评分，目标 hidden labels 仅用于最终 scoring；semantic/coarse stack 的 AP wins 都是 4/6，semantic first-positive work 在 6/6 tasks 改善，但 side-effect、SATraj 和 boundary 反例说明这仍不是通用 label-free ranker。R327 再把这些可提交 profile specs 作为 reproducibility/cost workload：R300 的 4 个 view specs、R324 的 12 个 rank-feature specs 和 R326 的 60 个 robustness specs 均由 Rust agentpprof `--profile-spec` 重复执行两次；semantic profile hash 全部稳定，raw-byte hash 只有 4/76 稳定，因为 JSON profile 包含生成时间戳。R328 在同一 76 个 specs 上启用 `--deterministic-output`，使 raw-byte hash 也达到 76/76 稳定；这关闭的是 artifact byte-stability 缺口，不是新的 accuracy benchmark。因此 prompt、session、toolcall、process、syscall、plan 和 sub-agent 都可以在同一套 mechanism 中出现，而不是成为互不兼容的 object model。

4 实验方法

评估遵循八个原则。第一，只使用公开的、别人已经标注好的 agent 轨迹或交互轨迹。我们使用 Hugging Face Dataset Viewer、HF repo JSONL、公开 GitHub JSON 和公开 benchmark artifacts 进行轻量采样，不同步完整测试集，也不提交原始外部样本。第二，每个 claim 都必须对应可执行 oracle。对于 phase/action 结构使用 V-measure 和相邻边界 F1；对于 grouped-action 使用人工 group id；对于 looping、safety、step correctness 和 redundancy 使用数据集原生标签；对于递归深度使用同一批 operations 下 unique stack 和 compression 变化。第三，负结果保留在论文中。例如 AgentNet 的 task status 很弱地预测 per-step correctness，repeat signal 也很弱地预测 step redundancy。

这说明 profiler 能承载这些诊断字段, 但简单 mapping 不能替代专门质量模型。第四, 论文 claim 必须从 artifact 机械回溯。Claim synthesis、reviewer evidence packet、paper value/novelty synthesis、paper evidence matrix 和 submission audit 都只读取 tracked/clean result files, 并输出 claim verdict、paper-ready wording、must-not-claim 和 source paths。这些文件不是新实验, 也不是 profiler object。它们的作用是防止摘要、结果、局限和结论在数字、scope 或 unsupported claim 上漂移。第五, boundary backend 必须仍然服从两个抽象。监督式 adjacent-boundary backend 只写回 learned_group_pattern、learned_segment_pattern、learned_segment_position 和 learned_boundary_prev 等 operation fields。递归折叠仍由 agentpprof 使用普通 --profile-spec 和 --stack 完成。每个候选标签家族还必须先通过 suitability 和 simple-baseline gate, 防止把 safety、history context 或 repetition proxy 错当作语义边界。第六, 真实问题价值必须先通过可复现 proxy 任务收敛。我们从 AgentRewardBench、SATraj-OS、AgentNet 和 OSWorld-Human 的已有 operation JSONL 构造 6 个 oracle-backed analysis tasks, 比较 flat、fixed-session、semantic operation-stack 和 label-drilldown 四种 stack specs。指标包括 positive lift、覆盖 50% positives 的 inspection fraction、group count、top-group session support、selected recall 和 selected work。这仍不是人类用户实验, 但它把“profiler 是否解决真实问题”从叙述变成可审计的 proxy result。第七, 默认浏览、ranking 和 case evidence 都必须避免答案泄漏。Visible packets 不包含 oracle-positive 字段, hidden answer key 单独保存 positives。非 oracle rankers 只读 status、repeat_signal、phase、action 和 environment 等可见字段, 不读 looping、safety、step_correct 或 target_positive。因此 first-positive、first-enriched 和 high-lift evidence 只是对同一 operation/operation-stack packet 的隐藏标签回放评分, 而不是 automatic detection 或 human utility。第八, R320 把 profiler 输出直接当作 ranking/localization result。它在同一 6 个真实标注任务上比较 flat、fixed-session、dataset-native hierarchy、raw action stack、operation-stack、label-drilldown oracle view, 以及 width、visible-risk、query-aware 和 oracle-upper-bound rankers。非 oracle policies 只使用可见 operation fields, 隐藏标签只用于 scoring。指标包括 precision@k、recall@operation-budget、F1@k、AUPRC-style average precision、nDCG、work-to-first-positive、groups-to-50% recall、group count 和 task-level optimization insight。这个设置把 profiling paper 的主 claim 从“analyst 是否更快”改为“profiler 自身是否能在真实 workload 上相对 dataset-provided hidden labels 定位、排序并指导优化”。

4.1 Hierarchy ablation baselines

本文比较的是 hierarchy choices, 而不是把每个已有 observability 产品完整复刻一遍。Flat profile 把每个任务压成一个 summary packet, 用来检验 operation stack 是否比无层级摘要更 selective。Fixed-session drilldown 把 session 或 demo id 放进 stack, 用来模拟 session/prompt-first 调试界面和传统 trace-tree drilldown 的碎片化风险。Prompt/session tree、tool-call hierarchy 和 OTel/span-like trace tree 在本实验中都被建模为不同 stack specs: 它们仍然读取同一批 operations, 只是把 session、prompt、tool、process 或 trace id 放在更靠前的 frames。Label-drilldown 是 oracle-aware upper-bound style view, 它把 hidden label

直接放入 stack, 用来界定“如果答案字段已经可见”时的上限, 而不作为真实用户界面 baseline。这些 ablations 的目的, 是隔离边界选择对聚合、selectivity、recall 和 inspected work 的影响。因此本文不会声称 agentpprof 支配所有生产 observability UI, 只声称 operation stack 把这些边界选择统一成可配置查询。

5 结果

本文的结果不应按 R 编号或零散 probe 展开。论文主体收敛为四个核心实验: E1 验证 operation coverage、递归 stack folding、field derivation 和人工边界都能落在同一个两抽象模型中; E2 是 hidden-label localization/ranking 主实验; E3 通过 ranker、stack、mapping、transfer、case 和 profile-spec patch 消融隔离机制与 actionability; E4 检查 profile-spec 可复现性、离线成本和 claim-integrity guardrails。R 编号只作为 provenance, 不是论文的小节结构。

5.1 E1: 覆盖、递归折叠和边界字段

核心 14 数据集产生 42,590 个 operations 和 1,497 个 unique stacks, compression ratio 为 28.45。加入 Scale-CUA 补充样本后, 总量为 47,590 个 operations 和 1,611 个 unique stacks, compression ratio 为 29.541。这些 operations 覆盖 web、mobile、desktop、software、API、tool-agent-user dialogue、expert failure labels、safety labels、human grouped-action labels 和 desktop step-quality labels。所有这些标签都以 operation fields 形式进入同一 pipeline。没有任何数据集需要新增 prompt、session、GUI、safety 或 quality-specific profiler object。

这支持 C1 的机制性版本: agentpprof 可以把异构 agent 轨迹统一为 operations, 并用用户指定 stack 折叠。它不支持所有 agent 数据都容易转换。适合该方法的轨迹通常具备四个特征: 有有序 step 或 turn, 有稳定 session/task id, 有动作或阶段标签, 有 outcome、quality、group 或 safety 等较高层 oracle。只有静态截图 grounding、缺少顺序、缺少 action label、强依赖大图片归档或 gated access 的数据源更适合作为后续扩展, 而不是当前主证据。

递归 stack-depth sweep. R286 在同一批 13,265 个 operations 上扫过 8 个 stack depths。只保留 dataset 时有 9 个 stacks; 加入 task 后为 11 个; phase depth 为 57 个; tool/semantic depth 为 226 个; action depth 为 455 个; 加入固定 session 后膨胀到 3,757 个。相对于 dataset depth, 固定 session 的 unique stacks 增加 417.4 倍。这个结果直接反驳把 session 或 prompt 作为默认 profiling 边界的设计。Session 是有用 drilldown field, 但如果默认写死在 stack 里, 它会把可聚合的行为切碎。

早期 3,797-operation set 上也出现同样信号。Flat/mapped stack 为 103 个 unique stacks, 而固定 demo/session stack 为 1,083 个 unique stacks。这说明固定边界会带来约 10.5 倍碎片化, 而 mapped operation stack 可以保留聚合同时增加语义深度。因此论文中的 novelty 不是“画 flamegraph”, 而是把 agent profiling 的边界选择变成 operation-stack query。

Profile spec 把这个 query 自由度变成可复现实验配置。同一个 AgentNet spec 引用相同 operation JSONL 和 op-map 文件, 默认产生 608 个 diagnostic stacks; 命令行只覆盖 --stack 和输出路径后, 样本数保持 16,741 不变, unique stacks 降到 83。这说明 stack 深度是可审计、可覆盖的查询参数, 而不是写死在 prompt/session 或某个可视

表 1: 公开标注轨迹数据源和当前用途。ScaleCUA 是补充点, 主结论主要依赖前 14 个 oracle-rich 数据源。

数据源	原生标注	转换方式	主要用途
WebLINX, Mind2Web, Agent-Trek, WebShop API-Bank, Tool-Bench, tau-bench	web action、demo/task、reward 或 action history API/tool call、solution path、多轮 user/assistant/tool messages、outcome	HF Dataset Viewer 或 HF repo shard HF rows 或 repo JSONL	web navigation 和 shopping trajectories 的跨源 smoke。 tool/API/dialogue phases 和 user-agent-tool operation 形态。
SWE-agent	issue trajectory、command action、success target	HF Dataset Viewer	software-agent command 轨迹。
AndroidControl, GUI-Odyssey, AgentRewardBench	mobile/cross-app step action 与 instruction expert success、side-effect、looping、optimality	public/HF samples annotation rows 加 cleaned BrowserGym steps	移动 GUI action depth 和跨 app scale。 failure、looping、side-effect 的非 flame-graph 诊断。
SATraj-OS	desktop action、success、safety、reward、attack type	HF safety config	桌面安全和 attack-type operation fields。
OSWorld-Human	human single-action 和 grouped-action 轨迹	GitHub JSON files	人工 grouped-action 边界 oracle。
AgentNet	human desktop PyAutoGUI、task outcome、step correctness、redundancy	HF repo JSONL streaming	最大 human desktop step-quality oracle。
ScaleCUA	GUI navigation action、previous-operation context、gold action	HF annotation JSONL streaming	补充多步 GUI history-depth smoke。

化中的层级。

这种可配置性不只改变图的形状, 也改变 reviewer 能验证的问题。同一套 outputs 同时给出 depth sweep、stack tree、transition/top-field、quality report、grouped-boundary report 和 history-depth report。这些报告回答同一个机制问题: 一个 profiler 是否可以把边界选择延后到查询时, 而不是在采集时固定为 prompt、session 或 span tree。当前证据支持三条 scoped 结论。第一, 异构轨迹和本地 session 可以先进入同一 operation layer, 再用用户选择的 stack 折叠。第二, recursive stacks 能表达 dataset、task、phase、tool、action、human-group、safety 和 quality-label 等多种深度, 但不能声称恢复所有真实意图边界。第三, field derivation 是可扩展接口, 因为 mapping 和 supervised backend 只写入 operation fields, profiler 仍按 operation stack 折叠。这些机制结果给出 paper novelty, 但 user-utility、通用 boundary detector 和完整 trace-platform compatibility 仍是后续 gate。

真实问题 proxy 把“定位 looping、side-effect、unsafe、incorrect、redundant 和 group-start positives”变成 6 个自动化分析任务, 并比较 flat、fixed-session、semantic operation-stack 和 label-drilldown。Visible packets 不含 oracle-positive 字段, hidden answer key 单独保存 positives; query-aware rankers 只读可见字段。这些任务显示 operation-stack 是 flat summary 与 fixed-session drill-down 之间的中间视图: 它远比 flat selective, 相比 fixed-session 通常有更高 selected recall 和跨 session 聚合, 但并不总是消耗更少 inspected operations。Paper evidence matrix 和 reviewer-stress audit 因此把 C4 固定为 automated inspectability tradeoff: operation-stack 在 6/6 tasks 上比 flat 更 selective, 6/6 含 positive group, 5/6 含 high-lift evidence, 5/6 selected recall 高于 fixed-session; 反例是 selected work 只在 2/6 tasks 低于 fixed-session。因此 C4 不能写成 user-utility、automatic detection 或 baseline-dominance claim。

R313 将同一批 visible-field rankers 和 case-packet baselines 放进 Pareto frontier, 而不是只做成对比较。Frontier 同时优化 recall、lift、inspected work 和 inspected groups。结果是 operation-stack 在 6/6 tasks 上都 non-dominated, 并在 4/6 tasks 上给出最高 non-oracle lift、在 4/6 tasks 上给出 30% inspected-work budget 内最高 recall。但 flat 和 fixed-session 也分别在 6/6 tasks 上保留

frontier points。这使 C4 更像一个 systems claim: profiler 的价值是把 view、ranker 和 stack depth 暴露成可配置分析 surface, 而不是替用户固定一个永远最优的层级。

Field derivation 和 boundary probes。本节支持的是 configurable deterministic/supervised field derivation 在合适标签家族上的迁移, 而不是通用无监督边界发现。

R281 从 13,265 个 labeled operations 中生成 10 条 mapping rules, 复现手写 mapping 的 folded 输出。R282 使用 dataset-stratified held-out split, 在 9,275 个 train operations 上生成规则, 并在 3,990 个 held-out operations 上评估。Mapped stack 产生 209 个 held-out stacks, compression ratio 为 19.091; 无 mapping baseline 为 284 个 stacks, compression ratio 为 14.049。Task/dataset V-measure 从 0.837 提升到 0.853。Phase/action boundary F1 为 0.777, precision 为 1.0, 说明当前 mapping 是保守的。它不会制造 false positive phase changes, 但会合并一些 fine-grained action changes。

R283-R285 进一步做 leave-dataset-out。在修正 API/tool phase precedence 后, R285 对 9 个 held-out datasets 中的 6 个减少 unique stacks, 0 个出现 negative stack reduction, weighted stack reduction 为每 1,000 operations 1162.005。这说明 mapping 不是单个数据集的 ad hoc pretty printer。它仍然是 deterministic taxonomy-seeded mapping, 不是无监督边界发现。R297 开始测试更强的 boundary backend。它在 OSWorld-Human exact-aligned sessions 上按 session 做 deterministic split: 191 个 train sessions 产生 2,655 个 train adjacent pairs, 96 个 test sessions 产生 1,036 个 test adjacent pairs。模型使用非 oracle operation fields 训练 Bernoulli adjacent-boundary predictor, 明确排除 human_group、group_index、group_position、group_size、group_pattern 和 group_alignment。在 held-out pairs 上, learned backend 的 precision 为 0.7400, recall 为 0.8102, F1 为 0.7735; phase-change baseline 为 0.2919, action-change 为 0.5142, conservative group_pattern reference 为 0.5810。随后脚本把预测边界写成 learned_group_pattern 和 learned_group_position 字段, Rust agentpprof 在 1,132 个 held-out operations 上折叠得到 74 个 stacks。当前可支持的 claim 是 configurable deterministic/supervised field derivation 能在 held-out 设置下改善语义聚合; 完整

表 2: R311 task-level reviewer-stress audit. OS 表示 operation-stack top-5 packet, FS 表示 fixed-session top-5 packet; work 和 recall 都是 selected packet 覆盖比例。

Task	数据集	Query family	OS work	OS recall	OS lift	FS recall	主要结论和反例
incorrect step	AgentNet	step-quality	0.0014	0.0034	2.406	0.0126	很小 work 下有 high lift, 但 selected recall 极低且低于 FS.
redundant step	AgentNet	step-quality	0.0089	0.0177	1.984	0.0123	OS recall/lift 更高, 但 FS work 略低且更早命中 positive.
looping	AgentRewardBench	failure	0.4938	0.6508	1.318	0.2381	Positives 过于普遍, OS recall 高但没有 $\geq 1.5\times$ high-lift group.
side effect	AgentRewardBench	failure	0.1454	0.1139	0.783	0.0000	OS 找到 positives 且 work 低于 FS, 但 top-5 lift 低于 prevalence.
group start	OSWorld-Human	boundary	0.4074	0.3874	0.951	0.0327	OS recall 高但 work 大, ranking depth 决定是否有 high-quality packet.
unsafe operation	SATraj-OS	safety	0.0420	0.2621	6.238	0.0579	最强 selective win, OS recall/lift 明显高于 FS, 但 FS first-positive work 更低.

model-backed 或 unsupervised boundary detector 仍是后续工作。

R299 将这个 backend 接口复制到现有标注家族, 并加入 suitability/calibration gate。脚本检查 OSWorld-Human human-group、AgentNet step correctness、AgentNet step redundancy、AgentRewardBench looping、SATraj safety、ScaleCUA history state 和 tau-bench tool-dialogue role 共 7 个候选。其中 SATraj safety 在当前样本中没有 session-local adjacent positives, ScaleCUA history state 是 context marker 而不是语义边界, tau-bench 在 R287 没有 tracked operation JSONL, 因此不训练。四个可训练候选的 held-out learned F1 分别是 OSWorld-Human 0.6916、AgentNet step-correct 0.3197、AgentNet step-redundant 0.3361 和 AgentRewardBench looping 0.7833。AgentNet 两个质量状态边界都优于 always-boundary baseline (0.2155 和 0.2645), 但 precision 低且 calibration error 仍明显; AgentRewardBench looping 虽然 learned F1 达到 0.7833, 却被 repeat_signal_change baseline 的 1.0 F1 完全解释。这把 C3 的范围收得更清楚: backend 可以统一地派生 stackable operation fields, 但每个标签家族都必须证明它真的是边界 oracle, 并且必须胜过简单 sequence-derived fields。

Human-boundary oracle. OSWorld-Human 是当前最强的 grouped-boundary oracle。R290 转换全部 369 个 human desktop tasks, 得到 6,010 个 single-action operations。转换器把 grouped-action 序列展平后与 single-action 序列对齐, 只有 exact-aligned tasks 才写入 human_group、group_pattern 和 group_position 字段。最终 320 个 tasks、4,011 个 operations 和 2,075 个 session-local groups 进入 grouped-boundary scoring; 31 个 content-mismatch tasks 和 18 个 length-mismatch tasks 保留用于 action profiling, 但不被当作 gold group oracle。

在 OSWorld-Human 上, 普通 action-depth stack 有 482 个 unique stacks, grouped-depth stack 降到 106 个。Phase/action boundary F1 为 0.638, precision 为 1.0。更重要的是, 保守的 group_pattern 对人工 human_group boundary 的 F1 为 0.627, precision 为 1.0, recall 为 0.456。这不是完美边界 detector, 但它给出有意义结论: operation stack 可以在同一条单动作序列上选择 action-depth 或 group-depth, 并以人工 grouped-action 标签作为 oracle 验证。Prompt 或 session 没有参与这个抽象。

5.2 E2: Hidden-label localization 和 ranking

AgentRewardBench、SATraj-OS 和 AgentNet 说明 operation stack 不局限于 flamegraph 热点。AgentRewardBench 的 729 个 expert-reviewed web-agent operations 全部携带 success、side-effect、looping 和 optimality 字段。

Action-derived repeat_signal 对 expert looping label 的 V-measure 为 0.378, 而单步 step_error 对 looping 的 V-measure 只有 0.011。这说明 sequence-derived operation fields 可以捕捉一部分真实 failure mode, 也说明简单错误标签不能替代序列诊断。

SATraj-OS 的 4,285 个 desktop computer-use operations 全部携带 safety、attack type、status 和 reward-related fields。其中 622 个 operations 标为 unsafe, attack type 覆盖 account、induced-text、popup、OS 和 unknown-file。这些标签与 phase/action 关系较弱, 例如 attack-type/action V-measure 只有 0.093。这个负结果是有价值的: 安全攻击类别不是 action taxonomy 的简单函数, 因此应该作为独立 operation field 被折叠和过滤, 而不是强行塞进 phase。

AgentNet 是当前最大的 human desktop step-quality oracle。R291 采样 1,000 个 Ubuntu tasks, 得到 16,741 个 PyAutoGUI operations。所有 operations 都有 task outcome、alignment score、efficiency score、difficulty、step correctness 和 redundancy 字段。Step correctness 覆盖 13,844 correct、874 incorrect 和 2,023 unknown; step redundancy 覆盖 9,334 necessary、733 redundant 和 6,674 unknown。Task status 对 step correctness 的 V-measure 只有 0.015, repeat signal 对 step redundancy 的 V-measure 只有 0.010。这说明 profiler 的价值不是用一个粗标签预测所有质量问题, 而是把质量 oracle 保留为可折叠、可 drilldown、可评分的 operation fields。

R300 把这些诊断目标组织成 6 个自动化 real-problem proxy tasks。任务覆盖 AgentRewardBench looping 和 side-effect、SATraj unsafe、AgentNet incorrect/redundant steps, 以及 OSWorld-Human group starts, 总计 34,539 个 operations。在同一 operation JSONL 上, Rust agentpprof 的 flat profile 只有 6 个 stacks, fixed-session profile 有 2,012 个 stacks, semantic operation-stack profile 有 944 个 stacks, label-drilldown profile 有 318 个 stacks。按 oracle-sorted clustering quality 评价, semantic operation stack 相比 flat summary 的 median top-positive lift 为 5.726x, 覆盖 50% positives 的 median inspection fraction 从 1.0 降到 0.2879。相比 fixed-session stack, semantic stack 的 group count ratio 为 0.554, top groups 的 session support ratio 为 5.5, 说明它更适合跨轨迹诊断; 但 inspection fraction ratio 为 1.302, 说明 fixed-session drilldown 在部分 instance-local tasks 上仍更快。这支持的是 inspectability 和 aggregation claim, 不是人类效率 claim。

R301 用更严格的 label-hidden analyst-task proxy 复核 R300。它把 visible packet 和 hidden answer key 分开, 默认只按 group width 排序。在 30% inspected-operation budget 下, operation-stack 的 median positive recall 为 0.336, 检查 4.5 groups; fixed-session 为 0.284, 检查 25.5

groups。在 top-10 width-ranked groups 下, operation-stack 的 median recall 为 0.641, 而 fixed-session 为 0.195。这个结果说明 operation stack 能把跨 session 的问题压缩成更少可检查单元, 但它并不保证默认宽度排序总是最省 operation budget。

R302 进一步比较 label-hidden ranking policies。在 top-10 groups 下, query-aware operation-stack ranking 只检查 0.116 operation fraction, positive lift 为 1.587; width ranking 检查 0.671 operation fraction, lift 为 1.079。在 30% operation budget 下, query-aware ranking 把 operation-stack recall 从 0.340 提高到 0.390, 但检查 groups 从 4.5 增加到 39.5。这说明 profiler 可以支持不同分析 policy 的 precision/recall tradeoff, 但这些 policy 仍是 visible-field heuristics, 不是 learned detector。

R304 将 R302 的 ranking policy 变成 reviewer-facing case packet。每个任务取 top-5 query-aware operation-stack groups, visible packet 不包含 oracle fields, hidden answer key 单独保存 positives。在 30 个 case groups 上, median inspected operation fraction 为 0.0937, median positive recall 为 0.188, median positive lift 为 1.6509。SATraj unsafe cases 最集中, work fraction 为 0.042、recall 为 0.262、lift 为 6.238; AgentNet quality cases 的 recall 很低, 但在很小 work fraction 上仍有 1.98 以上 lift。这个结果适合作为 case-study evidence, 而不是 detector evidence。

R305 对同一 case-packet policy 加入 flat 和 fixed-session baseline。Flat view 只有每个任务一个 packet, 因此 median recall 为 1.0, 但必须检查 1.0 operation fraction。Fixed-session view 的 median work fraction 为 0.0163、recall 为 0.0226、lift 为 1.6615。Operation-stack view 的 median work fraction 为 0.0937、recall 为 0.188、lift 为 1.6509。相对 fixed-session, operation-stack 的 median recall ratio 为 3.63、lift ratio 为 1.268, 但 inspected-work ratio 为 1.717。这支持“operation stack 是 flat 与 fixed-session 之间的可配置分析折中”, 而不是“operation stack 在每个任务上都更省 work”。

R320 把前面的 case-packet proxy 升级为 hidden-label profiler benchmark。它不再只报告 selected recall/lift, 而是把每个 view/ranker 的 hot groups 当作 ranked localization results, 用 hidden labels 计算 precision@k、recall@budget、F1、AUPRC-style AP、nDCG 和 work-to-first-positive。比较对象包括 flat、fixed-session、dataset-native hierarchy、raw action stack、operation-stack、label-drilldown oracle view, 以及 width、visible-risk、query-aware 和 oracle-upper-bound rankers。非 oracle policies 只使用可见字段; label-drilldown 和 oracle-upper-bound 只作为上界。表 3 给出主要 policies 的 median 结果。

Operation-stack query-aware profiling 在 top-5 groups 中只检查 median 0.0937 operation fraction, 而 flat summary 必须检查 1.0。相对 fixed-session query-aware drilldown, operation-stack top-5 recall 在 5/6 tasks 上更高, 并把 median group count 从 285.0 降到 157.5。它并不在所有 accuracy 指标上支配其他 hierarchy。Dataset-native hierarchy 的 median top-5 recall 达到 0.8665, 但 work 高达 0.8539; fixed-session 的 work-to-first-positive 只有 0.0044, 但 top-5 recall 只有 0.0233。这正是 profiling paper 可以支持的 scoped claim: operation-stack 是一个 nondominated Pareto point, 它降低 flat summary 的检查 work, 并在多数任务上减少 fixed-session 的 group fragmentation, 但不

替代所有 drilldown 视图。

R330 对 R320 的 task-level policy scores 做 10,000 次成对 bootstrap, 单位是 6 个真实标注 task family, 而不是单个 operation。相对 flat width, operation-stack query-aware 的 AP mean delta 为 0.1219, 95% CI 为 [0.0406, 0.2175]; top-5 inspected work mean delta 为 -0.8168, CI 为 [-0.9653, -0.6568]; 30% budget recall mean delta 为 0.4510, CI 为 [0.3450, 0.6143]; work-to-first-positive mean delta 为 -0.9303, CI 为 [-0.9855, -0.8650], 四项都是 6/6 tasks 同向。相对 fixed-session query-aware, operation-stack 的 top-5 recall mean delta 为 0.1801, CI 为 [0.0542, 0.3127], top-5 F1 mean delta 为 0.1702, CI 为 [0.0549, 0.2870], group count mean delta 为 -178.0, CI 为 [-340.0, -39.0]。相对 width-only operation-stack, query-aware ranking 的 AP mean delta 为 0.0932, CI 为 [0.0110, 0.2184], top-5 work mean delta 为 -0.3101, CI 为 [-0.4209, -0.1997]。同一个审计也保留反例: flat top-5 recall 由于检查全任务而更高, fixed-session 的 top-5 work、work-to-first-positive 和 AP 与 operation-stack 是混合 tradeoff, raw-action stack 的 mapping comparison 也不稳定。因此 R330 支持的是 task-family 层面的方向稳健性, 不是 per-operation 独立性、human utility 或单一层级支配。

R331 进一步检查 R320/R330 的 ranking signal 是否只是正例比例、group 大小或排序长度造成。它固定每个 visible policy 的 group 和 ranking order, 只把同一任务的 hidden positive operations 随机分配到同样大小的 group positions, 做 2,000 次 label-permutation null。Operation-stack query-aware 的 AP 在 6/6 tasks 上超过 95% null, median observed-minus-null AP 为 0.0759; 30% budget recall 在 5/6 tasks 上超过 null, median delta 为 0.0904。这说明主 AP/预算召回信号不能被 prevalence 和 group size 单独解释。但 R331 也保留边界: top-5 precision 只有 3/6 tasks 超过 null, work-to-first-positive 为 0/6; width-only operation-stack AP 在 5/6 tasks 超过 null, fixed-session 和 raw-action AP 都在 6/6 tasks 超过 null。因此 R331 支持 mechanism-isolation 和 baseline-realism, 不支持所有 hot-group 指标、label-free ranker 或 operation-stack 单一支配。

R332 进一步把 R320 的 visible policies 做成 view/depth task-fit audit, 不重新 profiling, 也不读取 oracle policies 做选择。Best visible AP 分散在 operation-stack、fixed-session 和 dataset-native 上, 计数分别为 3/6、2/6 和 1/6。Best top-5 F1 更分散: raw-action stack 为 2/6, dataset-native、fixed-session、flat 和 operation-stack 各为 1/6。Operation-stack query-aware 是 3/6 tasks 的 best AP policy、3/6 tasks 的 best 30% budget-recall policy、1/6 tasks 的 best top-5 F1 policy 和 2/6 tasks 的 best work-to-first-positive policy。同时, operation-stack query-aware 相对 fixed-session query-aware 在 4/6 tasks 上减少 group fragmentation, median group ratio 为 0.5543。Leave-task source selection 不能自动解决 view 选择: AP 和 top-5 F1 的 selected-equals-best 都是 0/6; AP 的 median selected regret 为 0.0593, 而默认 operation-stack query-aware 的 median regret 为 0.0045。因此 R332 的结论不是引入第三个 profiler 对象, 而是把 view、stack fields、predicates 和 ranker 都作为同一 operation 上的 query-time 配置暴露出来; fixed-session、span tree 和 dataset-native hierarchy 保留为 baseline 或 drilldown 视图。

R333 把 R320 scorer 在同一 tracked operation JSONL 上重跑一次, 导出完整 top-k 和 operation-budget inspection curves; 它不下载、不同步、不创建数据集, 也不改变 hidden-label-after-ranking 规则。该审计生成 810 个 visible inspection points 和 252 条 task-policy curve rows。在 30% inspected-work 内, operation-stack query-aware 的 median recall 为 0.3900; flat width 为 0.0000, fixed-session query-aware 为 0.3559, dataset-native query-aware 为 0.3377, raw-action query-aware 为 0.3325。在 20% inspected-work 内, operation-stack query-aware 的 median recall 为 0.2763, fixed-session query-aware 为 0.2422; 30% budget 是更清晰的 budgeted-recall 证据点。相对 flat width, operation-stack query-aware 在 6/6 tasks 上 top-5 inspected work 更低, 并且在 30% budget 下有正召回而 flat 没有。相对 fixed-session query-aware, operation-stack query-aware 的 top-5 recall 更高为 5/6 tasks、groups 更少为 4/6 tasks, 但 work-to-first-positive 更低只有 2/6 tasks。因此 R333 支持 inspection-cost 与 fragmentation tradeoff, 不支持 operation-stack 在所有成本指标上支配 fixed-session。

R334 进一步把 “less fragmentation” 从 “less work” 中拆开审计。它读取 tracked R320 policy scores 和 R333 inspection curves, 不下载、不同步、不创建或重标数据集。相对 fixed-session query-aware, operation-stack query-aware 在 4/6 tasks 上减少 total groups 和 positive groups, 在 5/6 tasks 上用更少 ranked groups 覆盖 50% positives, median groups-to-50% delta 为 -31.5。在同一 30% inspected-work budget 下, operation-stack query-aware 在 5/6 tasks 上比 fixed-session query-aware 检查更少 groups, median group delta 为 -54.0, 同时 median recall delta 为 0.0275。但 R334 也保留 fixed-session work 反例: operation-stack query-aware 的 work-to-50% recall 更低只有 1/6 tasks, top-5 work 更低只有 2/6 tasks, work-to-first-positive 更低也只有 2/6 tasks。因此本文可以 claim fixed-session fragmentation reduction 和 budgeted-recall tradeoff, 不能 claim operation-stack 在所有 work 指标上支配 span-tree drill-down。

5.3 E3: 机制隔离和 actionability

R320 还把结果转成 actionable optimization insight。SATraj unsafe 的 best visible policy 是 operation-stack query-aware, 说明 environment, phase, action 与 risky/write-action ranking 对安全定位有效。AgentReward-Bench looping 中, repeat_signal mapping 明显改善 top-5 F1, 但 positives 过于普遍, 需要 prevalence-aware ranking。Side-effect 和 OSWorld-Human boundary 留下 oracle AP gap, 说明当前 ranker 和 stack depth 需要为 side-effect writes 与 boundary-derived fields 分别调参。AgentNet step-quality 上 raw action stack 和 fixed-session drill-down 仍有优势, 说明 quality problem 需要先定位到可疑 action family, 再进入 session-level examples。R322 将其中一个 ranker surface 放入 Rust profiler 本体: 它证明 visible rank policy 可以作为 JSON operation-stack projection 被复现和评分, 也明确暴露 SATraj safety 对 group-level feature density 的需求。R323 进一步说明 ranking policy 本身是可操作的优化旋钮: 当排序从 width-dominated 切换到 score-first, SATraj 和 AgentNet incorrect-step 的 first-positive work 明显下降, 但 side-effect 与 OSWorld-Human 的 top-5 lift/recall 下降, 提示它们需要更深的 side-effect mapping 或 boundary-derived fields。R324 则把 group-

level feature density 作为 Rust profile-spec policy 实现出来: Rust 只读取 scrubbed visible-operation profiler input, hidden labels 不传给 Rust, 只用于 offline scoring; semantic stack 的 operation-feature ranking 在 AP 上赢 5/6 tasks, 在 first-positive work 上赢 5/6 tasks; coarse stack 的 group 数从数百级降到几十级时仍在 4/6 tasks 上提升 AP。R325 进一步把 actionability 具体化: 删除 repeat_signal 会显著伤害 looping 定位, 删除 write-action 会伤害 side-effect 定位, SATraj 的 status=success 是关键排序信号, 但 SATraj 的 loop-like 规则和 OSWorld-Human 的 input-phase 规则会误导排序。R326 再检查这些结论是否过度依赖手调权重: global equal visible feature bank 在 semantic/coarse stack 上分别有 4/6 和 5/6 AP wins, equal-weight task policy 在 8/12 variants 上接近 weighted policy, R325-guided repair 在 2/3 misleading-feature cases 上改善 AP, 在 2/3 cases 上改善 first-positive work, 其中 1/3 同时改善两者。R329 进一步检查 policy selection 是否依赖目标 oracle: leave-task 和 leave-dataset protocol 都在目标任务 hidden labels 留出的情况下选择 policy; 最终 held-out scoring 显示 semantic/coarse AP 均为 4/6 胜过 width, semantic first-positive work 为 6/6 改善, 平均 gap-to-oracle candidate 约 0.032 AP。这支持可迁移 rank-policy 作为机制隔离证据, 但不能升级成 label-free deployment claim, 因为 selection 仍使用其他标注任务。R330 进一步把这些比较转成不确定性审计: 在 task-paired bootstrap 下, 10 个主指标方向稳定, 10 个指标被归为 mixed/counterpoint。这使论文可以明确 claim 哪些 tradeoff 稳定, 同时把 flat recall、fixed-session first-positive work 和 raw-action/mapping sensitivity 作为保守边界写入结果。R331 再把 AP 和 budget-recall 结果放入 label-permutation 负控: operation-stack query-aware AP 为 6/6 超过 95% null, budget30 recall 为 5/6 超过 null; 但 top-5 precision 和 work-to-first-positive 不能由这个负控升级 claim。R332 则把 view/depth choice 变成可审计的 task-fit 结果: best AP 和 best top-5 F1 都不是单一 hierarchy 垄断, leave-task source selection 也不能稳定选中 best view, 所以论文应把不同 stack depth、baseline drilldown 和 ranker policy 写成可配置分析旋钮, 而不是自动最优层级。R333 进一步把这个结论变成检查预算曲线: operation-stack query-aware 在 20%/30% budget 下给出更好的 median recall, 但 fixed-session 仍是 first-positive 低成本反例。R334 再把可操作结论压得更具体: 如果目标是减少 analyst 面前的 groups 和 positive-group fragmentation, 应调 stack depth/mapping; 如果目标是 first-positive work, 应保留 fixed-session drilldown 作为低成本补充视图。R335 最后把这些分散证据合并成 mechanism ledger: ranker、mapping/tagging、operation-level rank features、stack depth、cross-task/global rank-policy transfer 和 fixed-session drilldown 都是可配置优化旋钮; 其中 ranker 是最稳定信号, mapping 和 depth 是任务相关 tradeoff, fixed-session 是 first-positive work counterpoint。R336 再把这个 ledger 转成 selection audit: 同一批 visible policies 在不同 objective 下选出不同 best policy, operation-stack query-aware 仍在 6/6 tasks 上进入 Pareto frontier, 并保持相对 flat 的低 top-5 work、相对 fixed-session 的高 top-5 recall 和更少 groups-to-50% positives; 但 flat 是 pure group-count objective 的反例, fixed-session 仍是 first-positive work 反例。因此 actionability 的 claim 是 “指出该调哪些 knobs”, 不是自动选择唯一最优 view。R337 把这个 tradeoff 改写成 reviewer 更容易检查

的 fixed-recall cost: 25% recall target 下 operation-stack query-aware 覆盖全部 6 个任务, median work 为 0.2000, 而 flat 的 median work 为 1.0000; 相对 fixed-session, 它用 median 16.0 groups 达到目标, 而 fixed-session 为 50.0 groups。10% recall 下两者都覆盖 6/6, 但 groups 为 12.5 vs 37.5; 50% recall 下 operation-stack query-aware 只覆盖 5/6, 说明高召回目标仍需要切换 stack depth 或 baseline drilldown。R339 把同一 ranking 输出重新按 trajectory/session scope 评分: 一个 hot group 不只要包含 positive operations, 还要把 analyst 带到含有问题的 session, 同时避免把过多 session 拖入检查。top-5 下, operation-stack query-aware 只检查 median 0.0937 work, 却覆盖 median 0.2629 positive-session recall; fixed-session top-5 的 positive-session recall 只有 0.0160, flat 则需要 1.0000 work。30% work budget 下, operation-stack query-aware 的 positive-operation recall 为 0.3900、positive-session recall 为 0.4669、session work 为 0.3467; fixed-session positive-session recall 为 0.3230, raw-action positive-session recall 更高为 0.5147 但 session work 达到 0.9103。因此 R339 支持 sequence-scope triage tradeoff, 而不是 single-view dominance。R355 再把 R339 的 session-scope audit 向下扩展到已有标注能支持的 oracle depth。它复用 tracked R300 operation JSONL、R320 profile-accuracy report 和 R339 sequence-adequacy report, 不下载、不同步、不创建、不重标数据集; visible policies 先完成 ranking, hidden labels 只在之后用于 scoring。24 个 accuracy task-depth rows 覆盖 session、operation/step、positive-run proxy, 以及 AgentRewardBench turn、AgentNet/SATraj step、OSWorld-Human human group 等 task-specific units; ScaleCUA 的 history-depth 只作为 context-only row, 不进入 accuracy claim。默认 operation-stack query-aware 的 median top-5 oracle-unit work 为 0.1307, budget-30 positive-unit recall 为 0.4342, budget-30 unit F1 为 0.4484, positive-run recall 为 0.4908。相对 flat, 它在 24/24 rows 降低 top-5 unit work; 相对 fixed-session, 它在 20/24 rows 提高 budget-30 positive-unit recall、18/24 rows 提高 unit F1、22/24 rows 用更少 groups 达到 50% positive units; 相对 raw-action, 它在 24/24 rows 降低 positive units per group。反例也必须写清楚: **positive-session-without-unit** depth gap 相对 fixed-session 没有改善, 因此 R355 支持 depth-aware localization 和 inspection-cost accounting, 不支持自动发现所有 latent subtask 或 intent boundary。R340 再检查 objective-specific policy choice 是否可以在目标任务标签留出的情况下转移: 它复用 R320/R339 已评分 artifacts, leave-task 和 leave-dataset 只从非目标 tasks/families 选择 visible policy, 然后在 held-out target 上 scoring。R338 对 R340 的 isolation checks 显示 selected/best policies 在 96/96 decisions 上都是 visible 且 non-oracle, leave-task/leave-dataset train scopes 在 96/96 decisions 上排除了目标任务或目标数据集。96 个 decisions 中有 31/96 exact-best、62/96 within tolerance, 且 selected policies 相对 width、fixed-session、flat 分别 strict win 72/96、69/96、41/96。因为 operation-stack 只被选中 16/96, R340 的结论是 policy/view/stack-depth selection 可被审计并用于 actionability, 而不是自动 selector 或默认 hierarchy dominance。R341 再把 R335/R336/R340 的 actionability 证据转成 mechanism/error attribution: 36/36 objective-task rows 都有具体 optimization action, 27/36 best visible policies 不是默认 operation-stack query-aware, 说明可操作性来自 view/ranker/stack-depth 选择而

不是单一默认层级。34/96 transfer decisions 超出 tolerance, 其中 32/34 与 held-out best 相比需要换 view, 26/34 需要换 ranker, 29/34 是 high-regret miss; 因此 transfer 失败也能指向具体调参方向或 baseline counterpoint。R342 再把 R324/R300 real labeled Rust outputs 上的 profile-spec composition 做成审计: 12/12 task-depth variants 都能组合 operation sources、query predicates、operation-level rank rules、**rank_mode=rule-score** 和 explicit stack depth, 且 12/12 不含 prompt/session frames。相对 width, visible operation-feature ranking 在 9/12 variants 上提高 AP, 在 10/12 variants 上降低 first-positive work; coarse depth 在 6/6 tasks 上减少 groups, median reduction 为 0.8267, 但 best AP depth 仍在 semantic 4 / coarse 2 之间分裂。因此 R342 支持 configurable recursive folding 和 stack-depth actionability, 不支持 universal stack-depth selector。R344 再把 R320 已评分输出按多指标重算成 claim-control surface: 50 个 baseline-metric comparisons 中, 30 个支持 operation-stack query-aware, 16 个是 counterpoints, 4 个 mixed/weak; 相对 flat, AP、30% budget recall/F1、top-5 work 和 work-to-first-positive 都为 6/6; 相对 fixed-session, top-5 precision/recall/F1 为 5/6, 但 work-to-first-positive 仍是反例; 相对 width-only operation-stack, AP 为 6/6、budget recall/F1 为 5/6。nDCG 和 coarse top-k recall 可以 favor flat 或 dataset-native, 因此 R344 支持 multi-metric tradeoff accounting, 不支持 metric dominance。R345 再把 R335/R341/R344 的已评分证据组织成 diagnostic-lens portfolio: 6 diagnostic lenses 覆盖 36 objective rows, operation-stack-family views 赢 11/36 objectives, 非 operation-stack counterpoints 赢 25/36; 6/6 tasks 至少需要 3 种 best views, 46 counterpoint rows 保留 fixed-session、flat、raw-action、dataset-native 和 metric-surface 反例。因此 R345 支持“选 lens 和调 knobs”的 actionability, 不支持 single flamegraph、metric dominance 或 automatic universal selector。R346 再把 R335/R345 的 actionability 证据和现有 labeled operation JSONL 做成 diagnostic casebook: 30 个 top-ranked operation-stack case groups 覆盖 6 tasks / 4 datasets, top-5 groups 在 6/6 tasks 上包含 positive, top-1 groups 在 5/6 tasks 上包含 positive; median top-5 recall 为 0.188, precision 为 0.1991, lift 为 1.6508, work 为 0.0937, median first-positive work 为 0.0378。该结果支持“case-level evidence 可连接到 action/counterpoint”, 不支持 human utility。R347 再把 R346 的 case-level evidence 和现有 labeled operation JSONL 放到 5 个 visible views 上对比: flat、fixed-session、dataset-native、raw-action 和 operation-stack 都先按 visible top-5 协议排名, hidden labels 只在之后评分。Operation-stack top-5 groups 在 6/6 tasks 上包含 positive、top-1 在 5/6 tasks 上包含 positive; 它在 6/6 tasks 上胜过 flat top-5 work、在 5/6 tasks 上胜过 fixed-session top-5 recall、在 4/6 tasks 上胜过 fixed-session group count。固定 first-positive 和 full-recall 反例仍保留, 因此 R347 支持 case-level baseline tradeoff, 不支持 universal selector。R348 再把 R335/R341/R347 的 actionability 证据做成 objective-level counterfactual audit: 它只读取已评分 visible policy artifacts, 不下载、不同步、不创建、不重标数据集, 也不把 hidden labels 变成部署 selector。36/36 best rows 都是 visible non-oracle, 27/36 objective rows 需要非默认动作, 25/36 需要换 view, 2/36 需要 operation-stack ranker tuning; 25/36 是 non-operation-stack counterpoints, 6/6 tasks 都至少有 3 类 action 和 case

counterpoints。Median gain over default 为 0.1447, median non-default gain 为 0.6188。该结果支持 objective-level actionable optimization insight, 不支持 label-free universal selector。R349 再把 R340 的 held-out policy transfer 映射到 R348 的 action oracle: 96 个 transfer decisions 中有 60 个与 R348 objective-level counterfactual 对齐, 36 个 sequence-only decisions 被排除。Held-out selection 在 35/60 decisions 上 within tolerance、在 30/60 上 beats default, 但 exact action-class transfer 只有 7/60, 非默认 target action 上只有 2/42。该结果支持 protocol-sensitivity/actionability tradeoff, 不支持 label-free automatic action selector。R350 再把 R346–R349 的 casebook、baseline contrast、action counterfactual 和 held-out guardrail 合成 evidence-packet budget audit: 6/6 tasks 的 top-5 operation-stack packets 含 positive, 5/6 top-1 含 positive, 4/6 满足严格 30% operation-work budget 和 first-positive $\leq 10\%$ work; median top-5 work/recall/lift 为 0.0937/0.188/1.6508。它同时保留 6/6 baseline counterpoints、27/36 non-default objective rows、36/36 visible non-oracle best rows, 以及 R349 的 35/60 within tolerance、7/60 exact action。两个 strict-budget 反例分别是 high-prevalence looping 和 human-boundary group-start, 因此 R350 支持 bounded actionable evidence packets, 不支持 universal budget dominance 或 automatic action selector。R354 把 actionability 再推进到可执行 profile-spec patch: 脚本读取 tracked R324 visible-operation input 和 R348 action cards, 为 6 个任务分别写出 default semantic-width spec 与 profile-guided patched spec, 实际运行 Rust `agentpprof --profile-spec` 后才用 hidden labels 评分。Patch 在 5/6 tasks 上被接受, 并在 5/6 tasks 上同时改善 AP、top-5 lift 和 first-positive work; median delta AP 为 0.0376, median top-5 lift delta 为 0.5750, median first-positive work delta 为 -0.0859。唯一 reject 是 OSWorld-Human: visible phase/action rank-feature patch 不够, 需要 boundary-derived fields 或 boundary backend。这说明 profiler 的 actionability 可以落成可复现 profile-spec 编辑和 before/after 复测, 但仍不支持自动 patch selector 或 human utility claim。R358 对这个 OSWorld-Human reject 做机制性 follow-up: 它复用 R297 held-out boundary-backend operations, 把 `learned_group_pattern` 和 `learned_group_position` 当作普通 operation fields 交给 Rust profile specs 折叠, hidden labels 只在 profiler 输出后评分。Learned-boundary stack 的 AP 为 0.2583, 高于 semantic-width 的 0.2402 和 visible-rank patch 的 0.2253; group 数为 74, 少于 semantic 的 108 和 fixed-session 的 96; top-5 recall 相比 semantic 增加 0.1111。反例也必须保留: top-5 operation work 和 first-positive work 在这个 held-out subset 上变差, learned-boundary rank rules 相比 width 还降低 AP。因此 R358 支持 boundary-derived fields 是一个 actionability knob, 不支持 automatic boundary discovery 或 automatic patch selector。

5.4 E4: 可复现性、成本和 claim integrity

R338 再把 paper claim 本身纳入审计: 它复用 R320–R350 的 tracked-clean artifacts, 不重新排名、不下载或重标数据集, 只检查论文数字、source policy、must-not-claim guardrails 和 operation/operation-stack 边界是否一致。因此它支持“论文表述与证据一致”这个提交前 gate, 而不是新的 profiler accuracy 结果。R352 再把当

前结果集映射到 OSDI-style profiling-paper rubric: 它复用 tracked R320–R351 artifacts 和当前论文文本, 不下载、不同步、不重跑 profiler, 也不运行 human/agent analyst task。26/26 required checks 和 10/10 rubric areas 通过, 覆盖 fidelity/accuracy、actionability、baseline tradeoff、generality、mechanism isolation、robustness/statistics、reproducibility/overhead 和 claim-scope guardrails。因此它支持“当前 scoped profiling claim 的证据形态达到 profiler paper gate”, 不是新的 empirical result。R327 则检查 profile-spec 本身是否可复现、成本是否可报告: 所有 76 个 profile specs 在重复运行中保持 semantic profile content、samples 和 unique stacks 稳定, median 每个 spec 运行时间为 1.581s, p95 为 2.719s; 默认 JSON profile 的 raw-byte determinism 只有 4/76, 因为输出带生成时间戳。R328 再启用 deterministic artifact mode, 固定 JSON `generated_at` 和 pprof profile time; 同一 76 个 specs 的 semantic 与 raw-byte determinism 均为 76/76, clean rerun 记录空的 git/code status, median 每个 spec 运行时间为 1.601s, p95 为 2.767s。这些结果支持 artifact/reproducibility claim, 但不等价于 live capture overhead。这说明 profiler 输出不仅告诉我们哪里有问题, 还告诉我们哪类 stack depth、field mapping 和 rank policy 值得调。这些结论是 profiler 输出对优化方向的归因, 而不是人工 analyst 的主观解释。

R360 把表 6 的核心数字做成可复现 artifact: 脚本只读取 R360 source-status 中列出的 tracked upstream results 和当前 paper/docs, 输出 JSON、CSV、Markdown、HTML 和 LaTeX table fragment; 6/6 checks 通过。它不是新的 empirical result, 也不重新排名或同步数据集。R361 进一步把 E1–E4 表格整理成 claim-evidence ledger: 每个核心实验都必须给出 claim、research question、oracle、baselines、primary metrics、headline result、actionable insight、counterpoint、scoped wording 和 source runs。该 gate 10/10 checks 通过, 覆盖 hidden-label scale/metric surface、baseline tradeoff 而不是 metric dominance、oracle-depth/fragmentation、mechanism/actionability counterpoints、reproducibility/reviewer gates、two-abstraction boundary 和 must-not-claim guardrails。R361 仍然只是 paper-structure artifact, 不是新的实验, 不重新跑 profiler, 也不做 dataset sync、creation 或 relabeling。

6 哪些数据集最适合

从当前 15 个方案看, 最适合支撑论文主 claim 的不是“最大”数据集, 而是同时具备顺序、动作、边界或质量 oracle 的数据集。第一类是 OSWorld-Human, 因为它同时给 single-action 和 grouped-action, 是验证递归边界的最直接 oracle。第二类是 AgentNet, 因为它规模大、人工桌面任务多, 并带 per-step correctness/redundancy。第三类是 AgentRewardBench 和 SATraj-OS, 因为它们把 profiler 从 action taxonomy 推到 failure、looping、安全和 side-effect diagnostics。第四类是 GUI-Odyssey/tau-bench/ToolBench 这组跨域补充, 它们覆盖移动 GUI、user-agent-tool dialogue 和 API/tool traces, 证明 operation abstraction 不局限于桌面。

ScaleCUA 是有用补充, 但不是当前主证据。R292 流式采样 5,000 个 Ubuntu navigation rows, 覆盖 131 个 sessions, 最大 step 为 48。该子集的动作 taxonomy 主要是 click 和 terminate, 所以 phase/action 指标达到 1.0 并不表示强泛化。它更适合证明 multi-step GUI history context 可

表 3: R320 hidden-label profiler benchmark. Hidden 表示 policy 是否读取 oracle label; WTFP 是 work-to-first-positive. 非 oracle policies 只读 visible operation fields, hidden labels 只用于 scoring.

Policy	Hidden	AP	nDCG	P@5	R@5	F1@5	Work@5	R@30%	WTFP
flat:width	no	0.1678	1.0000	0.1678	1.0000	0.2868	1.0000	0.0000	1.0000
fixed-session:query-aware	no	0.3476	0.7642	0.2555	0.0233	0.0427	0.0163	0.3559	0.0044
dataset-native:query-aware	no	0.3572	0.7445	0.1712	0.8665	0.2822	0.8539	0.3377	0.0582
raw-action:query-aware	no	0.2744	0.5012	0.2513	0.2442	0.2195	0.1507	0.3325	0.0374
operation-stack:width	no	0.1610	0.9364	0.1398	0.4746	0.2147	0.5424	0.3372	0.1694
operation-stack:query-aware	no	0.3117	0.5487	0.1991	0.1880	0.1981	0.0937	0.3900	0.0378
operation-stack:oracle-upper	yes	0.5993	0.6372	0.8984	0.3004	0.4029	0.0441	0.5640	0.0122
label-drilldown:oracle-upper	yes	1.0000	1.0000	1.0000	0.6703	0.7972	0.1150	1.0000	0.0377

表 4: R327 profile-spec 可复现性与离线执行成本。Runtime 为 Rust binary 已存在后的每个 spec 秒数; semantic hash 去除 JSON generated_at 字段, raw-byte hash 单独报告。

Workload	Specs	Med. s	P95 s	Med. stacks
R300 views	4	3.448	4.273	631.0
R324 rank	12	1.539	2.692	41.0
R326 robust	60	1.542	2.640	41.0
All specs	76	1.581	2.719	42.0

表 5: R327/R328 在同一 76 个 profile specs 上的 determinism 检查。R328 使用 --deterministic-output。

Run	Mode	Sem.	Raw	Med. s	P95 s
R327	default	76/76	4/76	1.581	2.719
R328	deterministic	76/76	76/76	1.601	2.767

以被投影为 history_state 和 history_depth fields, 而不是证明复杂边界 detector。

7 相关工作

Profiling, flamegraphs 和 trace analysis. 传统 flamegraph 和 pprof 路线把运行时调用栈折叠成热点视图 [1,16,17]。pprof 不只是固定 call stack: 它支持 sample tags, 也支持用 tagroot/tagleaf 把 tag value 作为 pseudo stack frame 可视化 [17]。Perfetto 则代表系统 trace ingestion、SQL trace analysis、trace summary 和 derived events 的成熟方向 [18]。因此本文不能把 novelty 写成“只有我们支持 query-time aggregation”。本文复用 folded-stack 表示, 但 scoped novelty 是 agent-operation record model、recursive multi-field operation-stack projection 和真实标注轨迹上的 hidden-label localization benchmark 这三者的组合。Stack frame 来自 agent operation fields, 而不是语言运行时函数调用或通用 trace SQL schema。因此同一批 operations 可以被折叠为 task、phase、tool、action、quality 或 safety 视图, 也可以改成 fixed-session 或 flat baseline。区别不在图形样式, 而在 agent 语义对象、递归多字段 stack projection 和 R320 的跨数据集 hidden-label scoring。

Agent tracing 和 LLM observability. OpenTelemetry GenAI 和 OpenInference 标准化 GenAI spans、LLM calls、agent reasoning steps、tool invocations、retrieval operations、MCP 和 provider-specific telemetry [2,11]。LangSmith、Langfuse、Phoenix 和 AgentOps 等系统进一步把 LLM call、tool call、latency、token、trace tree、session、observation、evaluation score、goal、plan 和 agent artifact 放进单次 workflow inspection 与生产监控 [12,13,14,15]。这些系统是本文最接近的同问题相关工作。因此本文把 trace/span/session 明确当作 exchange container 或 baseline shape, 而不是加成第三个 profiler 抽象。R320 实际评估的是 fixed-session drilldown 作为 span-tree proxy; 真实 OpenTelemetry/OpenInference/Phoenix span-tree import 仍是后续互操作 baseline, 不是当前已完成结果。本文关注跨轨迹 semantic profiling, 把异构标注轨迹或本地 agent 历史统一为 operations, 并允许用户选择 stack 深度、

mappings、tagging 和 ranker。R314 专门检查这些 closest systems 是否进入 novelty map 和 baseline guard。

Computer-use 和 tool-use benchmarks. Weblinx、Mind2Web、GUI-Odyssey、OSWorld/OSWorld-Human、OpenCUA/AgentNet、SATraj-OS、AgentReward-Bench、ToolBench 和 tau-bench 为本文提供真实标注轨迹 [3–10,19–22]。本文不提出新 benchmark。贡献是把这些 benchmark 的动作、质量、安全和人工 group 标签统一为 operation fields, 并用同一个 profiler 机制比较它们适合回答哪些 profiling 问题。这些 benchmark 是 evidence source 和 native-sequence baseline, 不是被本文替代的对象。

Novelty 边界. 因此本文的新意不是“第一个 agent observability 系统”、不是“第一个 agent trajectory benchmark”、也不是“第一个 folded-stack 可视化”。当前可 defend 的 scoped novelty 是: 只用 operation 和 operation stack 两个 profiler 抽象, 把 trace/session/span 作为输入容器或 baseline, 在真实公开标注轨迹上把 profile groups 当成 ranking/localization outputs, 并用 hidden labels 计算 accuracy、work、fragmentation 和 actionability。更具体地说, 新意不是 query-time aggregation 本身, 而是把 agent-operation record、recursive multi-field stack shape 和 hidden-label localization benchmark 绑在一起: 同一批 agent operations 因 stack shape 不同形成不同的可定位、可排序、可检查 aggregation units。这不是穷尽式 2026 全量综述; 它是围绕当前 paper claim 的 closest-threat audit。

8 局限

当前结果仍不是 OSDI 或 NeurIPS 最终接收级完整证据。第一, field derivation 和 boundary recovery 的范围仍然有限。当前证据支持 deterministic mappings、label-derived rules 和部分 supervised boundary backends 能派生 stackable operation fields, 但不证明无监督或 LLM-backed intent detector 已经解决, 也不证明一个 backend 能跨所有标签家族工作。AgentRewardBench looping 被简单 repeat_signal_change baseline 完全解释, 这说明每个 family 都需要 suitability、calibration 和 simple-baseline gate。

第二, R320 支持 profiler-localization claim, 但不支持人类效用 claim。R320 已经把 failure、safety、quality 和 human-boundary 问题转成 hidden-label ranking/localization benchmark, 并证明 operation-stack profiling 对 flat summary 和 fixed-session drilldown 有 accuracy/work/fragmentation tradeoff。R332 进一步显示这个 tradeoff 是 task- 和 metric-specific 的: 最佳 visible view 不由单一 hierarchy 垄断, source-task selector 也不能稳定自动选中最优 view。R333 进一步显示 20%/30% inspection budget 下 operation-stack query-aware 的 median recall 更高, 但 fixed-session 仍保留 first-positive 低成本反例。R334 把 fixed-session fragmentation 与 operation-work 成本拆开: 它支持更少 group fragmentation 和同预算更少 groups,

表 6: 四个 paper-facing 核心实验。R 编号只作为 provenance、ablation、counterpoint 或 audit gate 保留在 evaluation ledger; R360 从 tracked artifacts 重新生成该表的 headline metrics。

Core experiment	Workload / oracle	Main evidence	Scoped conclusion
E1: coverage, recursive folding, and field derivation	15 public labeled trace families / 47,590 operations, plus local-session and standard-trace exchange fixtures. OSWorld-Human and AgentNet provide the strongest boundary and step-quality oracles.	Core sources contain 42,590 operations, Scale-CUA brings the smoke set to 47,590, and the same R286 operations fold from 9 dataset stacks to 57 phase, 226 semantic, 455 action, or 3,757 fixed-session stacks. AgentNet profile-spec override changes 608 stacks to 83 without changing input operations. Held-out mapping improves compression from 14.049 to 19.091; OSWorld-Human learned boundary F1 reaches 0.7735 on held-out pairs.	Heterogeneous traces enter one operation layer, and stack depth is a recursive query over fields. Mapping, tagging, and boundary backends derive fields before folding; they do not add prompt/session/tool/safety-specific profiler objects.
E2: hidden-label localization and ranking	Six failure, safety, quality, and boundary tasks over AgentRewardBench, SATraj-OS, AgentNet, and OSWorld-Human; 34,539 operations / 3,699 positives.	R320 scores 144 view/ranker policies. Query-aware operation-stack top-5 groups inspect median 0.0937 work versus 1.0 for flat, improve top-5 recall over fixed-session on 5/6 tasks, and reduce median groups from 285.0 to 157.5. R333/R334/R337/R339/R355 add work-budget, fragmentation, fixed-recall, sequence-scope, and oracle-depth checks; R330/R331/R344 add uncertainty, permutation negative control, and multi-metric guardrails.	Operation-stack profiling is faithful to dataset-provided hidden labels under this benchmark and gives a better inspection-work/fragmentation Pareto point than flat or fixed-session alone. It is not a universal detector, a single best hierarchy, or a work-dominant replacement for drilldown views.
E3: mechanism and actionability	The same six labeled tasks, plus held-out OSWorld-Human boundary-backend operations from R297.	R324/R325/R326 show operation-level rank features, leave-one-feature ablations, and equal/global policies expose useful and misleading fields. R340/R341/R345-R350 show policy transfer, mechanism attribution, diagnostic lenses, casebook, baseline contrast, action counterfactuals, and evidence packets. R354 materializes 5/6 profile-spec patches; R358 shows learned-boundary fields improve OSWorld-Human AP to 0.2583 and reduce groups to 74, but increase top-5 work and first-positive work.	The profiler produces actionable optimization insight: which stack fields, mappings, rankers, lenses, and drilldown depths to tune. R349/R354/R358 keep automatic action selection, automatic patch selection, and automatic boundary discovery out of scope.
E4: reproducibility, cost, and claim integrity	Tracked profile specs, tracked operation inputs, current paper/docs hashes, and no dataset sync or human/agent analyst task.	R327/R328 repeat 76 profile specs over tracked operation JSONL inputs. Semantic determinism is 76/76 in both modes; deterministic output makes raw-byte determinism 76/76 with median runtime 1.601s and p95 2.767s in the clean rerun. R319/R338/R352/R356/R357 audit implementation consistency, paper numbers, source provenance, rubric coverage, reviewer acceptance, and the two-abstraction boundary. R360 regenerates the 4-row core result table and 20 metric rows from tracked artifacts.	The artifact path is replayable and cheap enough for offline profiling-paper evidence. The current claim gates support scoped profiler-benchmark readiness, not live eBPF overhead, human productivity, full ecosystem compatibility, or universal selectors.

但同时确认 first-positive/work 指标仍不由 operation-stack 支配。Related-work/baseline audit 只把 grounding 转成可失败检查，不增加新的实证结果。Protocol artifact 仍然有用，因为它把现有 visible packets 和 hidden answer key 固化为 6 个 tasks、3 个 views、24 个 participant slots 和 144 个 trials 的 balanced analyst-study protocol，并通过 visible-packet leakage check。但该 study 现在只是可选增强，用来验证开发者或 agent analyst 是否更快或更准。本文当前不能推出开发者准确率、time-to-answer 或 productivity 改善，也不能声称所有 intent boundary 都能被自动发现。论文主 claim 应固定为 profiler 本身在真实标注 trace 上的定位、排序、归因和 actionability，而不是 human utility。

第三，数据和互操作范围是轻量采样。本文避免同步完整测试集、图片归档和 gated 数据，因此有些来源只覆盖前缀、子配置或 redacted rows。Chrome Trace Event 和 agent-session exchange 当前是 exchange/reproducibility smoke; R306 覆盖本地 session fixture, R353 覆盖 tracked real labeled operation prefix。它们证明 trace 可以作为 exchange container，但不证明完整 OpenTelemetry/Chrome trace-ecosystem、Perfetto producer 或图像密集 benchmark 兼容。

第四，audit artifacts 是 claim-control surface，不是额外实证结果。R338 进一步把 R320-R350 的论文数字、source policy、guardrails 和两抽象边界做成机械检查；result invariants、source-policy checks 和 guardrail checks 均通过。R352 再把这些底层结果映射到 profiling-paper rubric, 26/26 required checks 通过。这些 audit artifacts 提高了论文表述、source path、负结果、related-work grounding、evaluation-rubric coverage 和 must-not-claim 边界的一致性，但它们只能审计底层 empirical artifacts。如果底层采样或 oracle 本身有偏差，audit 能暴露并收窄 claim，不能消除偏差。因此本文最终主张应固定为 two-abstraction

mechanism 和 hidden-label profiler fidelity/work trade-off，而不是 universal fixed-session dominance、automatic anomaly detection 或完整 human utility。

9 结论

本文把 agent semantic profiling 收敛为两个核心抽象：operation 和 operation stack。Prompt、session、toolcall、process、syscall、plan、subagent、GUI action、安全标签和质量标签都只是 operation shapes 或 fields。Mapping 和 tagging 负责派生 fields，--view、--where 和 --stack 负责选择权重、查询子集和递归折叠形状，--trace-file 和 --operation-file 负责数据入口，--profile-spec 只把这些选择变成可复现实验配置，--deterministic-output 只把 profile artifact 时间戳固定为可复现值。在 15 个轻量采样的公开标注轨迹数据源上，这个模型统一了 web、mobile、desktop、software、API、dialogue、failure、安全、human group 和 step-quality 轨迹，并产生 flamegraph 之外的 stack tree、transition、quality、boundary、case packet 和 claim-audit reports。这支持本文的核心机制 claim：agent profiling 的边界可以从 prompt/session/span tree 中释放出来，成为 query-time operation-stack projection。

当前最强经验结论来自四类 oracle-rich 轨迹。OSWorld-Human 证明同一单动作序列可以折叠到人工 grouped-action 深度。AgentNet 证明大规模 human desktop step-quality 标签可以作为普通 operation fields 进入 profiling。AgentRewardBench 和 SATraj-OS 证明 failure、looping、side-effect、安全和 attack-type diagnostics 可以用同一机制表达。6 个 label-hidden 任务进一步表明，operation stacks 相比 flat summary 更 selective，并在多数任务上比 fixed-session 取得更高 selected recall。R320 把这个结论推进到 hidden-label profiler benchmark：query-aware operation-stack top-5 groups 用 median 0.0937 work 取得 0.188 recall，flat summary 用 1.0 work 取得 full

recall, fixed-session 用 0.0163 work 但 top-5 recall 只有 0.0233。相对 fixed-session, operation-stack top-5 recall 在 5/6 tasks 上更高, 并把 median groups 从 285.0 降到 157.5。Related-work audit 则确认 pprof/tag pseudo frames、Perfetto SQL trace analysis、trace/span observability systems 和 public benchmark native views 都应保留为 baseline threats。Pareto frontier 又显示 operation-stack 在所有任务上 nondominated, 但 flat 和 fixed-session 仍是真实 counterpoints。R320 的 per-task insights 最终把这些 proxy 结果压成六个任务的强项与反例: safety 和部分 step-quality 支持 selective triage, looping 更像 prevalence aggregation, side-effect 与 human-boundary 需要明确 ranker 和 stack depth。R330/R331 进一步把这些比较做成 task-paired uncertainty 和 label-permutation negative controls, 支持 AP/预算召回的稳健性, 同时限制 top-5 precision、WTFP 和 single-view dominance claim。R332 再显示 best visible view 随任务和指标变化, leave-task source selection 不能稳定找到 best view, 因此本文 claim 是 configurable profiler surface, 不是自动 view selector。R333 进一步把 inspection budget curve 做成 artifact: 30% work 内 operation-stack query-aware 的 median recall 为 0.3900, 高于 flat/fixed-session/dataset-native/raw-action 的对应值, 但不消除 fixed-session first-positive 反例。R334 再说明 fragmentation 和 work 是两个不同目标: operation-stack query-aware 在 5/6 tasks 上用更少 ranked groups 达到 50% positives, 也在 30% work budget 下比 fixed-session 检查更少 groups, 但 work-to-first-positive 更低仍只有 2/6 tasks。R335 把这些结果汇总成 actionability cards: 6/6 cards 有具体 optimization action, ranker AP gain 为 6/6, mapping/feature/depth/transfer/fixed-session 都保留为可审计机制和反例。R336 再显示 objective-specific selection: operation-stack query-aware 在 6/6 tasks 上是 Pareto-frontier point, top-5 work 低于 flat 为 6/6, top-5 recall 高于 fixed-session 为 5/6, groups-to-50% positives 低于 fixed-session 为 5/6; 但每个 task 都有多个 objective-specific best policies, 说明 actionability 不是 automatic universal selector。R337 再把 tradeoff 固定到 recall target: 25% recall 下 operation-stack query-aware 覆盖 6/6 tasks, median work 0.2000 vs flat 1.0000, median groups 16.0 vs fixed-session 50.0; 但 50% recall 下只覆盖 5/6, 继续限制 universal dominance claim。R339 再补 trajectory/session scope: 30% work 下 operation-stack query-aware 的 positive-session recall 为 0.4669, 高于 fixed-session 的 0.3230; raw-action 的 positive-session recall 更高但触达 0.9103 sessions, 因此它是 sequence-scope tradeoff 而不是单一胜利。R355 再补 oracle-depth adequacy: 同一批 visible-ranked profiles 在 24 个 task-depth rows 上按 session、operation/step、positive-run 和 task-specific units 评分, operation-stack query-aware 的 median budget-30 positive-unit recall 为 0.4342, 且相对 fixed-session 在 20/24 rows 提高 unit recall、22/24 rows 用更少 groups 达到 50% positive units; 但 depth-gap 没有胜过 fixed-session, 因此它支持 depth-aware triage, 不支持完整 latent boundary recovery。R340 再补 non-target policy-transfer: 96 个 held-out decisions 中 62/96 within tolerance, 并在 72/96、69/96、41/96 decisions 上分别赢过 width、fixed-session、flat, 但 operation-stack selected 只有 16/96, 因此它支持可审计调参而不是 automatic selector。R341 再补 mechanism/error attribution: 36/36 objective rows 有 optimization action, 27/36 best visible poli-

cies 非默认, 34/96 transfer misses 被归因到 view/ranker 或 baseline counterpoint, 其中 32/34 需要换 view、26/34 需要换 ranker。R344 再补 multi-metric consistency: 50 个 baseline-metric comparisons 中 30 个支持、16 个 counterpoint、4 个 mixed/weak, 且 required metrics 包含 groups; 这确保最终 value claim 是 AP/work/fragmentation trade-off, 而不是 nDCG 或 top-k recall 的单指标胜利。R345 再补 diagnostic-lens portfolio: 6 diagnostic lenses / 36 objective rows 中 operation-stack-family views 赢 11/36, 非 operation-stack counterpoints 赢 25/36, 且 6/6 tasks 至少需要 3 种 best views, 因此最终 value claim 是多 lens actionability, 而不是单一 flamegraph 或 automatic selector。R346 再补 diagnostic casebook: 30 个 case groups 中 top-5 groups 在 6/6 tasks 上命中 positive, top-1 在 5/6 tasks 上命中 positive, median top-5 lift 为 1.6508, 说明 paper 的 actionability claim 有可审计 case-level evidence。R347 再补 case-level baseline contrast: 5 个 visible views / 30 view-task rows 中 operation-stack 在 6/6 tasks 上降低 flat top-5 work、在 5/6 tasks 上提高 fixed-session top-5 recall、在 4/6 tasks 上减少 fixed-session group count, 同时保留 fixed-session first-positive 和 flat full-work recall counterpoints。R348 再补 action-counterfactual audit: 36/36 best rows 是 visible non-oracle, 27/36 objectives 需要非默认 action, 25/36 需要 view change, 2/36 需要 operation-stack ranker tuning, median gain over default 为 0.1447, 说明 actionability 是可量化 tuning surface。R349 再补 held-out action-transfer guardrail: 60 aligned decisions 中 35/60 within tolerance、30/60 beats default, 但 exact action-class transfer 只有 7/60, 非默认 target action 上只有 2/42, 因此它支持 protocol-sensitivity/actionability tradeoff, 而不是 automatic action selector。R350 再补 evidence-packet budget audit: 6/6 top-5 packets 含 positive, 5/6 top-1 含 positive, 4/6 满足严格 30% work budget, 27/36 objective rows 需要 non-default action, 同时保留 35/60 within-tolerance 和 7/60 exact-action transfer guardrail; 这把 actionability 收敛为 bounded evidence packet, 而不是 automatic action selector。R354 再补 executable profile-spec patch audit: 6 个任务各自生成 default 与 patched profile specs 并实际运行 Rust profiler, 5/6 patches 同时改善 AP、top-5 lift 和 first-positive work; OSWorld-Human patch 被拒绝, 说明 boundary 任务需要 boundary-derived fields, 而不是 visible rank-feature universal patch。R338 已把中英文论文和 R320–R350 artifacts 对齐检查, result invariants、source-policy checks 和 guardrail checks 通过; R356 再把 R354/R355 纳入完整 claim-integrity refresh, 检查 R354 的 5/6 patches、0.0376 AP delta、0.5750 top-5 lift delta, 以及 R355 的 24 个 oracle-depth rows、0.4342 budget-30 unit recall、20/24 fixed-session recall wins 和 22/24 groups-to-50% wins。当前 value claim 仍停留在 profiler fidelity、actionable tradeoff、mechanism attribution、oracle-depth triage、profile-spec composition、metric-surface accounting、diagnostic-lens portfolio、case-level evidence、case-level baseline contrast、action-counterfactual insight、action-transfer guardrail 与 evidence-packet budget, 而不是 human utility、automatic patch selector 或 ecosystem compatibility。R352 再把这个 accepted paper state 放进 OSDI-style profiling-paper rubric: 26/26 required checks 通过, 10/10 rubric areas 覆盖 fidelity、actionability、baselines、generality、mechanism isolation、ro-

bustness、reproducibility 和 guardrails, 因此它证明的是 scoped profiler-benchmark readiness, 不是新实证结果或 human utility。因此本文的 value claim 是相对 dataset-provided hidden labels 的 profiler fidelity、label-scored ranking/localization 和 actionable tradeoff, 而不是 detector、human utility 或 baseline dominance。

论文的新意不在单个 flamegraph, 而在两个抽象形成的统一接口。Mapping、tagging、profile specs、agent-session trace、Chrome/Perfetto-style trace exchange、boundary backends 和 reviewer evidence packets 都只围绕 operation fields 与 operation-stack queries 工作。它们让用户和实验者能在同一批 operations 上选择不同 view、派生不同 fields、折叠不同深度, 并审计每个 claim 的证据来源。下一步不应无差别增加数据集, 而应沿两个方向提高 claim 强度: 一是把 field-derivation backend 做到跨家族 calibration 并稳定胜过简单 sequence-derived baselines, 二是在已有或新增真实 trace 中补更强的 instruction-step、solution-path 或 human subtask oracle; 只有在要写 ecosystem baseline claim 时才导入真实 OTel/Phoenix/LangSmith/Langfuse/Perfetto span-tree trace。Controlled human 或 agent analyst study 可以作为后续增强, 但不再是本文主 profiling claim 的前置条件。

参考文献

- [1] Brendan Gregg. Flame Graphs. <https://www.brendangregg.com/flamegraphs.html>.
- [2] OpenTelemetry GenAI semantic conventions. <https://github.com/open-telemetry/semantic-conventions-genai>.
- [3] McGill-NLP WebLINX. <https://huggingface.co/datasets/McGill-NLP/WebLINX>.
- [4] OpenGVLab GUI-Odyssey. <https://huggingface.co/datasets/OpenGVLab/GUI-Odyssey>.
- [5] WukLab OSWorld-Human. <https://github.com/WukLab/osworld-human>.
- [6] xlangai AgentNet. <https://huggingface.co/datasets/xlangai/AgentNet>.
- [7] McGill-NLP AgentRewardBench. <https://huggingface.co/datasets/McGill-NLP/agent-reward-bench>.
- [8] AI45Research SATraj-OS. <https://huggingface.co/datasets/AI45Research/SATraj-OS>.
- [9] AgentSuite tau-bench trajectories. <https://huggingface.co/datasets/AgentSuite/tau-bench-trajectories>.
- [10] OpenGVLab ScaleCUA-Data. <https://huggingface.co/datasets/OpenGVLab/ScaleCUA-Data>.
- [11] OpenInference specification. <https://arize-ai.github.io/openinference/spec/>.
- [12] LangSmith Observability. <https://docs.langchain.com/langsmith/observability>.
- [13] Langfuse Observability. <https://langfuse.com/docs/observability/overview>.
- [14] Arize Phoenix. <https://arize.com/docs/phoenix>.
- [15] AgentOps: Enabling Observability of LLM Agents. <https://arxiv.org/html/2411.05285v2>.
- [16] Brendan Gregg. The Flame Graph. <https://queue.acm.org/detail.cfm?id=2927301>.
- [17] Google pprof documentation. <https://github.com/google/pprof/blob/main/doc/README.md>.
- [18] Perfetto Trace Processor documentation. <https://perfetto.dev/docs/analysis/trace-processor>.
- [19] AgentRewardBench: Evaluating Automatic Evaluations of Web Agent Trajectories. <https://arxiv.org/abs/2504.08942>.
- [20] OSWorld: Benchmarking Multimodal Agents for Open-Ended Tasks in Real Computer Environments. <https://arxiv.org/abs/2404.07972>.
- [21] OpenCUA: Open Foundations for Computer-Use Agents. <https://arxiv.org/abs/2508.09123>.
- [22] Safactory: A Scalable Agentic Infrastructure for Training Trustworthy Autonomous Intelligence. <https://arxiv.org/abs/2605.06230>.