

面向 AI Agent 轨迹的可配置语义剖析

AgentSight 研究原型

2026 年 7 月 4 日

摘要

AI agent 的执行历史已经不再只是一次 prompt 或一棵 trace tree。一个真实轨迹可能同时包含用户意图、LLM 响应、tool call、API 调用、GUI 动作、浏览器动作、进程、文件、网络、计划步骤、subagent 以及 benchmark 给出的成功、失败、安全、重复和冗余标签。现有 agent observability 工具通常把这些对象固定成 prompt、session 或 span 层级；传统 profiler 则固定成函数或进程层级。这两种做法都会把 profiling 问题过早绑定到某一种边界上，使同一段轨迹很难按任务、阶段、工具、动作、质量标签或人工分组递归折叠。

本文提出一种更小的语义剖析模型：系统只保留两个核心抽象，operation 和 operation stack。operation 是带字段和权重的观测，prompt、session、tool call、process、syscall、GUI action 和 plan step 都只是 operation 的不同形态或字段。operation stack 是用户从字段中选择的递归投影，mapping 和 tagging 在 stack 构造前派生字段，而不是创建第三种 profiler 对象。我们在 Rust agentpprof 中实现该模型，支持 --view、--stack、--op-map、--op-map-file、--trace-file、--standard-trace-file 和可复现实验用的 --profile-spec，并把 15 个公开标注 agent 轨迹数据源投影为同一类 operation JSONL。

我们在 15 个轻量采样的公开标注轨迹来源上评估该模型，不同步完整测试集、图片归档或 gated corpus。核心结果显示，Web、mobile、desktop、software、API、tool-dialogue、failure、安全、human group 和 step-quality 轨迹都可以进入同一 operation layer，核心 14 个数据集包含 42,590 个 operations，补充 ScaleCUA 后为 47,590 个 operations。同一批 13,265 个 operations 可以从 9 个 dataset stacks 递归展开到 57 个 phase stacks、226 个 tool/semantic stacks 和 455 个 action stacks，而把固定 session 加入默认层级会膨胀到 3,757 个 stacks。本地 agent session 和 Chrome/Perfetto-style trace 只作为 fixture-level exchange smoke 使用，完整 benchmark conversion、image-heavy corpora 和真实 OpenTelemetry/Perfetto producer 兼容性仍是后续工作。

第二组结果验证 stack 不是 prompt/session/span 的别名。OSWorld-Human 的单个动作轨迹可以按人工 grouped-action 边界折叠，保守边界 F1 为 0.627 且 precision 为 1.0。AgentNet 的 1,000 个 Ubuntu 人工桌面任务产生 16,741 个 PyAutoGUI operations，并把 step correctness 和 redundancy 作为普通字段保留下来。Mapping/backend 的可支持范围是 deterministic 或 supervised field derivation：4 个标签家族可训练，但 AgentRewardBench looping 被更简单的 repeat_signal_change baseline 完全解释，所以当前证据不支持通用无监督 intent detector。

第三组结果把 value claim 限定为自动化 inspectability proxy。在 AgentRewardBench、SATraj-OS、AgentNet 和 OSWorld-Human 的 4 个数据集、6 个 oracle-backed tasks、

34,539 个 operations 和 3,699 个 positives 上，operation-stack packet 比 flat summary 更 selective 的任务为 6/6，含 positive group 的任务为 6/6，含 high-lift evidence 的任务为 5/6。相对 fixed-session，operation-stack selected recall 更高的任务为 5/6，但 selected work 更低的任务只有 2/6，fixed-session 在 4/6 tasks 上 selected work 更低。把 162 个非 oracle view/ranker/budget points 放入 Pareto frontier 后，operation-stack 在 6/6 tasks 上 nondominated，在 4/6 tasks 上取得 best lift，并在 4/6 tasks 上取得 30% work 内 best recall；flat 和 fixed-session 也在 6/6 tasks 上保留 frontier counterpoints。因此本文支持的 claim 是可配置 operation stacks 能在真实标注问题上提供可审计的 inspectability tradeoff，而不是人类用户效用、自动异常检测或相对 fixed-session 的无条件支配。

1 问题

AI agent 轨迹的调试问题正在从单次调用回放变成跨任务剖析问题。开发者不只想知道某个 span 什么时候开始和结束，也想知道哪类任务导致最多重复点击，哪些 GUI 轨迹反复输入，哪个工具调用族对应失败，哪些安全攻击类型集中在某些操作阶段，或者一个 prompt 序列能否被折叠成 task、phase、action 和人工 subtask 等多个深度。如果 profiler 把 session、prompt 或 tool call 写死成核心层级，这些问题会被迫使用同一个边界。如果 profiler 只保留进程或函数栈，上层语义和 benchmark oracle 又会丢失。

本文的出发点是把 agent trace 中所有可剖析对象都降到同一层。一个 prompt 可以是 operation，一个 tool call 可以是 operation，一串 prompt 也可以通过 mapping 被派生为同一个 intent 或 task operation field。同样，GUI action、API call、browser action、process event、syscall、安全标签、step correctness 和人工 grouped-action id 都不是新的 profiler 抽象，而是 operation fields。Profiler 的核心任务不是决定唯一正确边界，而是让用户和实验可以在同一批 operations 上选择 stack 字段、派生 mappings，并得到不同深度的递归折叠。

这个问题有两个系统挑战。第一，抽象必须足够小，否则 prompt、session、tool call、plan、subagent 和 process 会各自形成独立 pipeline。第二，抽象又必须足够可配置，否则 flamegraph 只会成为固定视图，不能回答边界、失败、安全和质量诊断问题。本文的目标不是证明某个单一 flamegraph 最好，而是证明 operation 和 operation stack 足以覆盖多类真实标注 agent 轨迹，并能产生 flamegraph 以外的质量、边界和转移分析。

2 设计

2.1 两个核心抽象

operation 是唯一的样本级对象。每个 operation 是一个带权重的字段集合，例如 op=prompt、op=llm、op=tool、tool=browser、action=click、phase=navigate、

`status=failure` 或 `step_correct=incorrect`。这些字段可以来自本地 Codex/Claude session，也可以来自外部 benchmark 的标注轨迹。实现上，外部轨迹使用每行一个 JSON object 的 operation JSONL，并把原始任务文本、截图和长对话默认排除在提交 artifact 之外。

`operation stack` 是从 `operation fields` 中选择出的有序 frame 列表。例如同一批 operations 可以用 `project, dataset` 查看数据来源，也可以用 `project, dataset, task, phase, op, tool, action, status` 查看动作深度，或者加入 `human_group`、`step_correct`、`safety` 和 `looping` 做诊断视图。Stack 不是 trace tree，也不是 session hierarchy。它是一个查询结果，用户可以按问题改变深度和字段。

2.2 Mapping 和 tagging

Mapping 和 tagging 是派生 operation fields 的一等机制。它们在 stack 构造前运行，读取 operation 的 `key=value` 文本，并写入新的字段。例如 desktop action 中的 `type` 和 `key` 应先被映射到 `phase=input`，再考虑通用 web action verb；API/tool traces 应先进入 tool/API phase family，再处理 `search` 或 `create` 这类词。这一顺序来自跨 web、desktop、API/tool 和 step-quality 轨迹时暴露出的关键设计约束。如果通用 action rule 抢在 operation-family rule 前面运行，desktop、web 和 API 轨迹会被错误合并。

Mapping 不引入第三个抽象。它只是在 operation 上写字段，使同一个 stack specification 可以跨数据集复用。当前 Rust CLI 支持 `inline --op-map FIELD:LABEL=REGEX` 和文件形式 `--op-map-file`。`script/operation_map_infer.py` 可以从已标注 operations 中生成同样格式的规则文件，并用这些规则测试 held-out 和 leave-dataset-out 泛化。`--profile-spec` 把 operation files、mapping files、view、stack 和输出路径打包成 JSON 配置，便于 reviewer 复现实验；命令行参数仍可覆盖 spec 默认值。它不改变模型本身，只是把已有 operation 和 operation-stack 查询显式记录下来。

2.3 Views 和非火焰图分析

`--view` 决定采样和权重，例如 operation count、token、file、network 或 time。`--stack` 决定递归折叠形状。Folded stack 和 SVG flamegraph 是其中一种输出，但不是唯一输出。我们同时生成 JSON profile、stack tree、top-field table、parent-child transition、depth sweep、boundary F1、V-measure、coverage report、grouped-action report 和 HTML quality report。这些视图共享同一 operation 输入和 stack 语法，因此 failure、safety、looping、redundancy 和 human group 可以被当作普通字段评分，而不是另建 failure profiler 或 safety profiler。

3 实现

agentpprof 是当前被测实现。它是 Rust CLI，读取本地 Codex/Claude 历史或外部 operation JSONL，并输出 pprof-compatible profile、folded stacks、SVG 和 JSON。核心命令形态如下：

```
agentpprof --operation-file ops.jsonl --view operations
--stack project,dataset,task,phase,op,tool,
action,status --op-map-file operation-map.txt
-o out.folded
```

外部数据集转换器位于 `script/agent_trace_datasets.py`。转换器只下载

或流式读取所需公开文件的采样前缀。对于包含截图、长 prompt 或完整对话的数据集，默认保存 redacted rows 和 operation JSONL，不提交原始数据。本地 agent session 通过 `agent-session` 解析为 `agentsight.agent-session.trace.v1 trace`；agentpprof 可以用 `--export-trace` 写出 filesystem-normalized trace，用 `--trace-file` 读回，也可以通过 `script/agent_trace_convert.py to-operations` 转成 operation JSONL。`script/agent_trace_exchange_eval.py` 将这三步、filesystem/tool-command portability check 和 folded-output equality check 固化为一个可复现实验；该检查不声称 prompt/LLM preview 已完整脱敏。agentpprof 还可以用 `--export-standard-trace` 写出 Chrome/Perfetto-style traceEvents，再用 `--standard-trace-file` 导入为普通 operations 后折叠。`script/agent_trace_convert.py export-standard --format chrome` 和 `import-standard --format chrome` 保留为显式中间文件脚本；`script/agent_trace_chrome_exchange_eval.py` 验证该路径不改变 folded operation-stack 输出。质量评估脚本位于 `script/operation_stack_quality.py`，它复用 agentpprof 的 operation mapping contract，并计算字段覆盖率、oracle V-measure 和序列相邻边界 F1。Stack 结构分析脚本位于 `script/operation_stack_analysis.py`，用于生成 flamegraph 之外的 tree、top-kind 和 transition 报告。

这个实现刻意保留简单接口。它不像 jq 那样完整表达 JSON 查询语言，但它已经把 profiler 的关键自由度暴露为 flags 和可提交配置：数据源由 `--trace-file` 或 `--operation-file` 选择，权重由 `--view` 选择，字段派生由 `--op-map` 选择，递归边界由 `--stack` 选择，复现实验由 `--profile-spec` 固化。因此 prompt、session、toolcall、process、syscall、plan 和 subagent 都可以在同一套 mechanism 中出现，而不是成为互不兼容的 object model。

4 实验方法

评估遵循三个原则。第一，只使用公开的、别人已经标注好的 agent 轨迹或交互轨迹。我们使用 Hugging Face Dataset Viewer、HF repo JSONL、公开 GitHub JSON 和公开 benchmark artifacts 进行轻量采样，不同步完整测试集，也不提交原始外部样本。第二，每个 claim 都必须对应可执行 oracle。对于 phase/action 结构使用 V-measure 和相邻边界 F1；对于 grouped-action 使用人工 group id；对于 looping、safety、step correctness 和 redundancy 使用数据集原生标签；对于递归深度使用同一批 operations 下 unique stack 和 compression 变化。第三，负结果保留在论文中。例如 AgentNet 的 task status 很弱地预测 per-step correctness，repeat signal 也很弱地预测 step redundancy。这说明 profiler 能承载这些诊断字段，但简单 mapping 不能替代专门质量模型。第四，论文 claim 必须从 artifact 机械回溯。Claim synthesis、reviewer evidence packet、paper value/novelty synthesis、paper evidence matrix 和 submission audit 都只读取 tracked/clean result files，并输出 claim verdict、paper-ready wording、must-not-claim 和 source paths。这些文件不是新实验，也不是 profiler object。它们的作用是防止摘要、结果、局限和结论在数字、scope 或 unsupported claim 上漂移。第五，boundary backend 必须仍

然服从两个抽象。监督式 adjacent-boundary backend 只写回 `learned_group_pattern`、`learned_segment_pattern`、`learned_segment_position` 和 `learned_boundary_prev` 等 operation fields。递归折叠仍由 agentpprof 使用普通 `--profile-spec` 和 `--stack` 完成。每个候选标签家族还必须先通过 suitability 和 simple-baseline gate, 防止把 safety、history context 或 repetition proxy 错当作语义边界。第六, 真实问题价值必须先通过可复现 proxy 任务收敛。我们从 AgentRewardBench、SATraj-OS、AgentNet 和 OSWorld-Human 的已有 operation JSONL 构造 6 个 oracle-backed analysis tasks, 比较 flat、fixed-session、semantic operation-stack 和 label-drilldown 四种 stack specs。指标包括 positive lift、覆盖 50% positives 的 inspection fraction、group count、top-group session support、selected recall 和 selected work。这仍不是人类用户实验, 但它把“profiler 是否解决真实问题”从叙述变成可审计的 proxy result。第七, 默认浏览、ranking 和 case evidence 都必须避免答案泄漏。Visible packets 不包含 oracle-positive 字段, hidden answer key 单独保存 positives。非 oracle rankers 只读 status、repeat_signal、phase、action 和 environment 等可见字段, 不读 looping、safety、step_correct 或 target_positive。因此 first-positive、first-enriched 和 high-lift evidence 只是对同一 operation/operation-stack packet 的隐藏标签回放评分, 而不是 automatic detection 或 human utility。

4.1 Hierarchy ablation baselines

本文比较的是 hierarchy choices, 而不是把每个已有 observability 产品完整复刻一遍。Flat profile 把每个任务压成一个 summary packet, 用来检验 operation stack 是否比无层级摘要更 selective。Fixed-session drilldown 把 session 或 demo id 放进 stack, 用来模拟 session/prompt-first 调试界面和传统 trace-tree drilldown 的碎片化风险。Prompt/session tree、tool-call hierarchy 和 OTel/span-like trace tree 在本实验中都被建模为不同 stack specs: 它们仍然读取同一批 operations, 只是把 session、prompt、tool、process 或 trace id 放在更靠前的 frames。Label-drilldown 是 oracle-aware upper-bound style view, 它把 hidden label 直接放入 stack, 用来界定“如果答案字段已经可见”时的上限, 而不作为真实用户界面 baseline。这些 ablations 的目的, 是隔离边界选择对聚合、selectivity、recall 和 inspected work 的影响。因此本文不会声称 agentpprof 支配所有生产 observability UI, 只声称 operation stack 把这些边界选择统一成可配置查询。

5 结果

5.1 RQ1: 两个抽象是否覆盖多类轨迹?

核心 14 数据集产生 42,590 个 operations 和 1,497 个 unique stacks, compression ratio 为 28.45。加入 ScaleCUA 补充样本后, 总量为 47,590 个 operations 和 1,611 个 unique stacks, compression ratio 为 29.541。这些 operations 覆盖 web、mobile、desktop、software、API、tool-agent-user dialogue、expert failure labels、safety labels、human grouped-action labels 和 desktop step-quality labels。所有这些标签都以 operation fields 形式进入同一 pipeline。没有任何数据集需要新增 prompt、session、GUI、safety 或 quality-specific profiler object。

这支持 C1 的机制性版本: agentpprof 可以把异构

agent 轨迹统一为 operations, 并用用户指定 stack 折叠。它不支持所有 agent 数据都容易转换。适合该方法的轨迹通常具备四个特征: 有有序 step 或 turn, 有稳定 session/task id, 有动作或阶段标签, 有 outcome、quality、group 或 safety 等较高层 oracle。只有静态截图 grounding、缺少顺序、缺少 action label、强依赖大图片归档或 gated access 的数据源更适合作为后续扩展, 而不是当前主证据。

5.2 RQ2: 递归 stack 是否比固定边界有价值?

R286 在同一批 13,265 个 operations 上扫过 8 个 stack depths。只保留 dataset 时有 9 个 stacks; 加入 task 后为 11 个; phase depth 为 57 个; tool/semantic depth 为 226 个; action depth 为 455 个; 加入固定 session 后膨胀到 3,757 个。相对于 dataset depth, 固定 session 的 unique stacks 增加 417.4 倍。这个结果直接反驳把 session 或 prompt 作为默认 profiling 边界的设计。Session 是有用 drilldown field, 但如果默认写死在 stack 里, 它会把可聚合的行为切碎。

早期 3,797-operation set 上也出现同样信号。Flat/mapped stack 为 103 个 unique stacks, 而固定 demo/session stack 为 1,083 个 unique stacks。这说明固定边界会带来约 10.5 倍碎片化, 而 mapped operation stack 可以保留聚合同时增加语义深度。因此论文中的 novelty 不是“画 flamegraph”, 而是把 agent profiling 的边界选择变成 operation-stack query。

Profile spec 把这个 query 自由度变成可复现实验配置。同一个 AgentNet spec 引用相同 operation JSONL 和 op-map 文件, 默认产生 608 个 diagnostic stacks; 命令行只覆盖 `--stack` 和输出路径后, 样本数保持 16,741 不变, unique stacks 降到 83。这说明 stack 深度是可审计、可覆盖的查询参数, 而不是写死在 prompt/session 或某个可视化中的层级。

Claim synthesis 和 reviewer evidence packet 把可审计性从单个图扩展到 claim wording 与 reviewer navigation。它们读取 tracked result JSON/folded outputs, 生成 claim-synthesis.json、reviewer-evidence.json、reviewer-evidence.md 和 index.html, 索引 11 个非 flamegraph 与证据导航条目, 包括 depth sweep、stack tree、transition/top-field、quality report、grouped-boundary report、history-depth report 和 claim gate。Claim synthesis 把 C1 判为 supported, 把 C2 判为 supported with scoped limits, 把 C3 判为 partial。该 packet 还派生出若干 reviewer-facing 数值: held-out mapping 使 unique stacks 减少 26.408%, OSWorld grouped-depth stacks 相比 action-depth stacks 减少 78.008%, AgentRewardBench repeat-signal/looping V-measure 为 0.3777, step-error baseline 为 0.0105, 两者相差 35.971 倍; profile-spec override 在不改变 operations 的情况下使 AgentNet stacks 减少 86.349%。这些数字不替代原始结果文件, 而是把“为什么这些结果有价值”变成可追溯的证据路径。

后续 paper gates 把这个证据路径进一步收敛成论文价值和新意。它们从 claim synthesis、boundary backend 和诊断质量报告中生成 6 个真实问题证据块: 异构 trace object model、递归深度选择、field derivation、human/subtask boundaries、failure/safety/quality diagnostics 和 artifact auditability。它还把 novelty 限定为 4 点: two-object agent profiling、query-time recursive stacks、统一 field-derivation extension point 和 non-flamegraph diagnostic views。当前证据足以支撑机制和诊断价值, 但仍

表 1: 公开标注轨迹数据源和当前用途。ScaleCUA 是补充点, 主结论主要依赖前 14 个 oracle-rich 数据源。

数据源	原生标注	转换方式	主要用途
WebLINX, Mind2Web, AgentTrek, WebShop API-Bank, ToolBench, tau-bench	web action, demo/task, reward 或 action history API/tool call, solution path, 多轮 user/assistant/tool messages, outcome	HF Dataset Viewer 或 HF repo shard HF rows 或 repo JSONL	web navigation 和 shopping trajectories 的跨源 smoke。 tool/API/dialogue phases 和 user-agent-tool operation 形态。
SWE-agent	issue trajectory, command action, success target	HF Dataset Viewer	software-agent command 轨迹。
AndroidControl, GUI-Odyssey, AgentRewardBench	mobile/cross-app step action 与 instruction expert success, side-effect, looping, optimality	public/HF samples annotation rows 加 cleaned BrowserGym steps	移动 GUI action depth 和跨 app scale。 failure, looping, side-effect 的非 flame-graph 诊断。
SATraj-OS	desktop action, success, safety, reward, attack type	HF safety config	桌面安全和 attack-type operation fields。
OSWorld-Human	human single-action 和 grouped-action 轨迹	GitHub JSONL files	人工 grouped-action 边界 oracle。
AgentNet	human desktop PyAutoGUI, task outcome, step correctness, redundancy	HF repo JSONL streaming	最大 human desktop step-quality oracle。
ScaleCUA	GUI navigation action, previous-operation context, gold action	HF annotation JSONL streaming	补充多步 GUI history-depth smoke。

只是 level-3 conference-paper evidence、接近 mechanism claims 的 level 4; boundary-family replication、用户效用实验和 boundary calibration 仍是缺口。

真实问题 proxy 把“定位 looping、side-effect、unsafe、incorrect、redundant 和 group-start positives”变成 6 个自动化分析任务, 并比较 flat、fixed-session、semantic operation-stack 和 label-drilldown。Visible packets 不含 oracle-positive 字段, hidden answer key 单独保存 positives; query-aware rankers 只读可见字段。这些任务显示 operation-stack 是 flat summary 与 fixed-session drill-down 之间的中间视图: 它远比 flat selective, 相比 fixed-session 通常有更高 selected recall 和跨 session 聚合, 但并不总是消耗更少 inspected operations。Paper evidence matrix 和 reviewer-stress audit 因此把 C4 固定为 automated inspectability tradeoff: operation-stack 在 6/6 tasks 上比 flat 更 selective, 6/6 含 positive group, 5/6 含 high-lift evidence, 5/6 selected recall 高于 fixed-session; 反例是 selected work 只在 2/6 tasks 低于 fixed-session。因此 C4 不能写成 user-utility、automatic detection 或 baseline-dominance claim。

R313 将同一批 visible-field rankers 和 case-packet baselines 放进 Pareto frontier, 而不是只做成对比较。Frontier 同时优化 recall、lift、inspected work 和 inspected groups。结果是 operation-stack 在 6/6 tasks 上都 non-dominated, 并在 4/6 tasks 上给出最高 non-oracle lift、在 4/6 tasks 上给出 30% inspected-work budget 内最高 recall。但 flat 和 fixed-session 也分别在 6/6 tasks 上保留 frontier points。这使 C4 更像一个 systems claim: profiler 的价值是把 view、ranker 和 stack depth 暴露成可配置分析 surface, 而不是替用户固定一个永远最优的层级。

5.3 RQ3: label-derived mappings 在什么条件下迁移?

本节支持的是 configurable deterministic/supervised field derivation 在合适标签家族上的迁移, 而不是通用无监督边界发现。

R281 从 13,265 个 labeled operations 中生成 10 条 mapping rules, 复现手写 mapping 的 folded 输出。R282 使用 dataset-stratified held-out split, 在 9,275 个 train operations 上生成规则, 并在 3,990 个 held-out operations 上评估。Mapped stack 产生 209 个 held-out stacks, compres-

sion ratio 为 19.091; 无 mapping baseline 为 284 个 stacks, compression ratio 为 14.049。Task/dataset V-measure 从 0.837 提升到 0.853。Phase/action boundary F1 为 0.777, precision 为 1.0, 说明当前 mapping 是保守的。它不会制造 false positive phase changes, 但会合并一些 fine-grained action changes。

R283–R285 进一步做 leave-dataset-out。在修正 API/tool phase precedence 后, R285 对 9 个 held-out datasets 中的 6 个减少 unique stacks, 0 个出现 negative stack reduction, weighted stack reduction 为每 1,000 operations 1162.005。这说明 mapping 不是单个数据集的 ad hoc pretty printer。它仍然是 deterministic taxonomy-seeded mapping, 不是无监督边界发现。R297 开始测试更强的 boundary backend。它在 OSWorld-Human exact-aligned sessions 上按 session 做 deterministic split: 191 个 train sessions 产生 2,655 个 train adjacent pairs, 96 个 test sessions 产生 1,036 个 test adjacent pairs。模型使用非 oracle operation fields 训练 Bernoulli adjacent-boundary predictor, 明确排除 human_group、group_index、group_position、group_size、group_pattern 和 group_alignment。在 held-out pairs 上, learned backend 的 precision 为 0.7400, recall 为 0.8102, F1 为 0.7735; phase-change baseline 为 0.2919, action-change 为 0.5142, conservative group_pattern reference 为 0.5810。随后脚本把预测边界写成 learned_group_pattern 和 learned_group_position 字段, Rust agentpprof 在 1,132 个 held-out operations 上折叠得到 74 个 stacks。当前可支持的 claim 是 configurable deterministic/supervised field derivation 能在 held-out 设置下改善语义聚合; 完整 model-backed 或 unsupervised boundary detector 仍是后续工作。

R299 将这个 backend 接口复制到现有标注家族, 并加入 suitability/calibration gate。脚本检查 OSWorld-Human human-group、AgentNet step correctness、AgentNet step redundancy、AgentRewardBench looping、SATraj safety、ScaleCUA history state 和 tau-bench tool-dialogue role 共 7 个候选。其中 SATraj safety 在当前样本中没有 session-local adjacent positives, ScaleCUA history state 是 context marker 而不是语义边界, tau-bench 在 R287 没有 tracked operation JSONL, 因此不训练。四个可训练候选的 held-out learned F1 分别是 OSWorld-Human 0.6916、Agent-

表 2: R311 task-level reviewer-stress audit. OS 表示 operation-stack top-5 packet, FS 表示 fixed-session top-5 packet; work 和 recall 都是 selected packet 覆盖比例。

Task	数据集	Query family	OS work	OS recall	OS lift	FS recall	主要结论和反例
incorrect step	AgentNet	step-quality	0.0014	0.0034	2.406	0.0126	很小 work 下有 high lift, 但 selected recall 极低且低于 FS.
redundant step	AgentNet	step-quality	0.0089	0.0177	1.984	0.0123	OS recall/lift 更高, 但 FS work 略低且更早命中 positive.
looping	AgentRewardBench	failure	0.4938	0.6508	1.318	0.2381	Positives 过于普遍, OS recall 高但没有 $\geq 1.5\times$ high-lift group.
side effect	AgentRewardBench	failure	0.1454	0.1139	0.783	0.0000	OS 找到 positives 且 work 低于 FS, 但 top-5 lift 低于 prevalence.
group start	OSWorld-Human	boundary	0.4074	0.3874	0.951	0.0327	OS recall 高但 work 大, ranking depth 决定是否有 high-quality packet.
unsafe operation	SATraj-OS	safety	0.0420	0.2621	6.238	0.0579	最强 selective win, OS recall/lift 明显高于 FS, 但 FS first-positive work 更低.

Net step-correct 0.3197, AgentNet step-redundant 0.3361 和 AgentRewardBench looping 0.7833。AgentNet 两个质量状态边界都优于 always-boundary baseline (0.2155 和 0.2645), 但 precision 低且 calibration error 仍明显; AgentRewardBench looping 虽然 learned F1 达到 0.7833, 却被 `repeat_signal_change` baseline 的 1.0 F1 完全解释。这把 C3 的范围收得更清楚: backend 可以统一地派生 stackable operation fields, 但每个标签家族都必须证明它真的是边界 oracle, 并且必须胜过简单 sequence-derived fields。

5.4 RQ4: 能否恢复真实人工边界?

OSWorld-Human 是当前最强的 grouped-boundary oracle。R290 转换全部 369 个 human desktop tasks, 得到 6,010 个 single-action operations。转换器把 grouped-action 序列展平后与 single-action 序列对齐, 只有 exact-aligned tasks 才写入 `human_group`, `group_pattern` 和 `group_position` 字段。最终 320 个 tasks、4,011 个 operations 和 2,075 个 session-local groups 进入 grouped-boundary scoring; 31 个 content-mismatch tasks 和 18 个 length-mismatch tasks 保留用于 action profiling, 但不被当作 gold group oracle。

在 OSWorld-Human 上, 普通 action-depth stack 有 482 个 unique stacks, grouped-depth stack 降到 106 个。Phase/action boundary F1 为 0.638, precision 为 1.0。更重要的是, 保守的 `group_pattern` 对人工 `human_group` boundary 的 F1 为 0.627, precision 为 1.0, recall 为 0.456。这不是完美边界 detector, 但它给出有意义结论: operation stack 可以在同一条单动作序列上选择 action-depth 或 group-depth, 并以人工 grouped-action 标签作为 oracle 验证。Prompt 或 session 没有参与这个抽象。

5.5 RQ5: 能否做失败、安全和质量诊断?

AgentRewardBench、SATraj-OS 和 AgentNet 说明 operation stack 不局限于 flamegraph 热点。AgentRewardBench 的 729 个 expert-reviewed web-agent operations 全部携带 success、side-effect、looping 和 optimality 字段。Action-derived `repeat_signal` 对 expert looping label 的 V-measure 为 0.378, 而单步 `step_error` 对 looping 的 V-measure 只有 0.011。这说明 sequence-derived operation fields 可以捕捉一部分真实 failure mode, 也说明简单错误标签不能替代序列诊断。

SATraj-OS 的 4,285 个 desktop computer-use operations 全部携带 safety、attack type、status 和 reward-related fields。其中 622 个 operations 标为 unsafe, attack type 覆盖 account、induced-text、popup、OS 和 unknown-file。这些标签与 phase/action 关系较弱, 例如 attack-type/action V-measure 只有 0.093。这个负结果是有价值的: 安全攻击类别不是 action taxonomy 的简单函数, 因此应该作为独立 operation field 被折叠和过滤, 而不是强行塞进 phase。

AgentNet 是当前最大的 human desktop step-quality oracle。R291 采样 1,000 个 Ubuntu tasks, 得到 16,741 个 PyAutoGUI operations。所有 operations 都有 task outcome、alignment score、efficiency score、difficulty、step correctness 和 redundancy 字段。Step correctness 覆盖 13,844 correct、874 incorrect 和 2,023 unknown; step redundancy 覆盖 9,334 necessary、733 redundant 和 6,674 unknown。Task status 对 step correctness 的 V-measure 只有 0.015, repeat signal 对 step redundancy 的 V-measure 只有 0.010。这说明 profiler 的价值不是用一个粗标签预测所有质量问题, 而是把质量 oracle 保留为可折叠、可 drilldown、可评分的 operation fields。

R300 把这些诊断目标组织成 6 个自动化 real-problem proxy tasks。任务覆盖 AgentRewardBench looping 和 side-effect、SATraj unsafe、AgentNet incorrect/redundant steps, 以及 OSWorld-Human group starts, 总计 34,539 个 operations。在同一 operation JSONL 上, Rust agentpprof 的 flat profile 只有 6 个 stacks, fixed-session profile 有 2,012 个 stacks, semantic operation-stack profile 有 944 个 stacks, label-drilldown profile 有 318 个 stacks。按 oracle-sorted clustering quality 评价, semantic operation stack 相比 flat summary 的 median top-positive lift 为 5.726x, 覆盖 50% positives 的 median inspection fraction 从 1.0 降到 0.2879。相比 fixed-session stack, semantic stack 的 group count ratio 为 0.554, top groups 的 session support ratio 为 5.5, 说明它更适合跨轨迹诊断; 但 inspection fraction ratio 为 1.302, 说明 fixed-session drilldown 在部分 instance-local tasks 上仍更快。这支持的是 inspectability 和 aggregation claim, 不是人类效率 claim。

R301 用更严格的 label-hidden analyst-task proxy 复核 R300。它把 visible packet 和 hidden answer key 分开, 默认只按 group width 排序。在 30% inspected-operation budget 下, operation-stack 的 median positive recall 为 0.336, 检查 4.5 groups; fixed-session 为 0.284, 检查 25.5 groups。在 top-10 width-ranked groups 下, operation-stack 的 median recall 为 0.641, 而 fixed-session 为 0.195。这个结果说明 operation stack 能把跨 session 的问题压缩成更少可检查单元, 但它并不保证默认宽度排序总是最省 operation budget。

R302 进一步比较 label-hidden ranking policies。在 top-10 groups 下, query-aware operation-stack ranking 只检查 0.116 operation fraction, positive lift 为 1.587; width ranking 检查 0.671 operation fraction, lift 为 1.079。在 30% operation budget 下, query-aware ranking 把 operation-stack recall 从 0.340 提高到 0.390, 但检查 groups 从 4.5 增加到 39.5。这说明 profiler 可以支持不同分析 policy 的 precision/recall tradeoff, 但这些 policy 仍是 visible-field

heuristics, 不是 learned detector。

R304 将 R302 的 ranking policy 变成 reviewer-facing case packet。每个任务取 top-5 query-aware operation-stack groups, visible packet 不包含 oracle fields, hidden answer key 单独保存 positives。在 30 个 case groups 上, median inspected operation fraction 为 0.0937, median positive recall 为 0.188, median positive lift 为 1.6509。SATraj unsafe cases 最集中, work fraction 为 0.042、recall 为 0.262、lift 为 6.238; AgentNet quality cases 的 recall 很低, 但在很小 work fraction 上仍有 1.98 以上 lift。这个结果适合作为 case-study evidence, 而不是 detector evidence。

R305 对同一 case-packet policy 加入 flat 和 fixed-session baseline。Flat view 只有每个任务一个 packet, 因此 median recall 为 1.0, 但必须检查 1.0 operation fraction。Fixed-session view 的 median work fraction 为 0.0163、recall 为 0.0226、lift 为 1.6615。Operation-stack view 的 median work fraction 为 0.0937、recall 为 0.188、lift 为 1.6509。相对 fixed-session, operation-stack 的 median recall ratio 为 3.63、lift ratio 为 1.268, 但 inspected-work ratio 为 1.717。这支持“operation stack 是 flat 与 fixed-session 之间的可配置分析折中”, 而不是“operation stack 在每个任务上都更省 work”。

6 哪些数据集最适合

从当前 15 个方案看, 最适合支撑论文主 claim 的不是“最大”数据集, 而是同时具备顺序、动作、边界或质量 oracle 的数据集。第一类是 OSWorld-Human, 因为它同时给 single-action 和 grouped-action, 是验证递归边界的最直接 oracle。第二类是 AgentNet, 因为它规模大、人工桌面任务多, 并带 per-step correctness/redundancy。第三类是 AgentRewardBench 和 SATraj-OS, 因为它们把 profiler 从 action taxonomy 推到 failure、looping、安全和 side-effect diagnostics。第四类是 GUI-Odyssey/tau-bench/ToolBench 这组跨域补充, 它们覆盖移动 GUI、user-agent-tool dialogue 和 API/tool traces, 证明 operation abstraction 不局限于桌面。

ScaleCUA 是有用补充, 但不是当前主证据。R292 流式采样 5,000 个 Ubuntu navigation rows, 覆盖 131 个 sessions, 最大 step 为 48。该子集的动作 taxonomy 主要是 click 和 terminate, 所以 phase/action 指标达到 1.0 并不表示强泛化。它更适合证明 multi-step GUI history context 可以被投影为 history_state 和 history_depth fields, 而不是证明复杂边界 detector。

7 相关工作

Profiling 和 flamegraphs. 传统 flamegraph 把函数调用栈折叠为热点视图。本文复用 folded-stack 表示, 但 stack frame 来自 operation fields, 而不是语言运行时函数调用。因此同一批 operations 可以被折叠为 task、phase、tool、action、quality 或 safety 视图。这与 CPU profiler 的固定调用栈不同, 也与只画一次 agent span tree 的 tracing 工具不同。

Agent tracing 和 LLM observability. LangSmith、Langfuse、Phoenix、AgentOps 和 OpenTelemetry GenAI 等系统记录 LLM call、tool call、latency、token 和 trace tree。这些工具适合单次 workflow inspection。本文关注的是跨轨迹的 semantic profiling: 把异构标注轨迹或本地 agent 历史统一为 operations, 并允许用户选择 stack 深度

和 mappings。

Computer-use 和 tool-use benchmarks. WebLINX、Mind2Web、GUI-Odyssey、OSWorld-Human、AgentNet、SATraj-OS、AgentRewardBench、ToolBench 和 tau-bench 为本文提供真实标注轨迹。本文不提出新 benchmark。贡献是把这些 benchmark 的动作、质量、安全和人工 group 标签统一为 operation fields, 并用同一个 profiler 机制比较它们适合回答哪些 profiling 问题。

8 局限

当前结果仍不是 OSDI 或 NeurIPS 最终接收级完整证据。第一, field derivation 和 boundary recovery 的范围仍然有限。当前证据支持 deterministic mappings、label-derived rules 和部分 supervised boundary backends 能派生 stackable operation fields, 但不证明无监督或 LLM-backed intent detector 已经解决, 也不证明一个 backend 能跨所有标签家族工作。AgentRewardBench looping 被简单 repeat_signal_change baseline 完全解释, 这说明每个 family 都需要 suitability、calibration 和 simple-baseline gate。

第二, 用户效用仍是缺口。R300–R313 把 failure、safety、quality 和 human-boundary 问题转成 label-hidden 或 hidden-answer-key proxy, 并证明 operation stacks 对 flat summary 和 fixed-session drilldown 有有用 trade-off。这些结果仍不能推出开发者准确率、time-to-answer 或 productivity 改善。受控 human/agent analyst study 必须使用相同 visible packet、hidden answer key 和 flat/fixed/operation-stack/query-aware interfaces 才能支持更强 claim。

第三, 数据和互操作范围是轻量采样。本文避免同步完整测试集、图片归档和 gated 数据, 因此有些来源只覆盖前缀、子配置或 redacted rows。Chrome Trace Event 和 agent-session exchange 当前是 fixture-level smoke, 它证明 trace 可以作为 exchange container, 但不证明完整 OpenTelemetry/Chrome trace-ecosystem、Perfetto producer 或图像密集 benchmark 兼容。

第四, audit artifacts 是 claim-control surface, 不是额外实证结果。R295–R312 提高了论文表述、source path、负结果和 must-not-claim 边界的一致性, 但它们只能审计底层 R282–R311 artifacts。如果底层采样或 oracle 本身有偏差, audit 能暴露并收窄 claim, 不能消除偏差。因此本文最终主张仍应固定为 two-abstraction mechanism 和 automated inspectability tradeoff, 而不是 universal fixed-session dominance、automatic anomaly detection 或完整 human utility。

9 结论

本文把 agent semantic profiling 收敛为两个核心抽象: operation 和 operation stack。Prompt、session、toolcall、process、syscall、plan、subagent、GUI action、安全标签和质量标签都只是 operation shapes 或 fields。Mapping 和 tagging 负责派生 fields, --view 和 --stack 负责选择权重和递归折叠形状, --trace-file 和 --operation-file 负责数据入口, --profile-spec 只把这些选择变成可复现实验配置。在 15 个轻量采样的公开标注轨迹数据源上, 这个模型统一了 web、mobile、desktop、software、API、dialogue、failure、安全、human group 和 step-quality 轨迹, 并产生 flamegraph 之外的 stack tree、transition、quality、boundary、

case packet 和 claim-audit reports。这支持本文的核心机制 claim: agent profiling 的边界可以从 prompt/session/span tree 中释放出来, 成为 query-time operation-stack projection。

当前最强经验结论来自四类 oracle-rich 轨迹。OSWorld-Human 证明同一单动作序列可以折叠到人工 grouped-action 深度。AgentNet 证明大规模 human desktop step-quality 标签可以作为普通 operation fields 进入 profiling。AgentRewardBench 和 SATraj-OS 证明 failure、looping、side-effect、安全和 attack-type diagnostics 可以用同一机制表达。R300-R313 的 6 个任务进一步表明, operation stacks 相比 flat summary 更 selective, 并在多数任务上比 fixed-session 取得更高 selected recall。Pareto frontier 又显示 operation-stack 在所有任务上 nondominated, 但 flat 和 fixed-session 仍是真实 counterpoints。因此本文的 value claim 是 automated inspectability surface/tradeoff, 而不是 detector、human utility 或 baseline dominance。

论文的新意不在单个 flamegraph, 而在两个抽象形成的统一接口。Mapping、tagging、profile specs、agent-session trace、Chrome/Perfetto-style trace exchange、boundary backends 和 reviewer evidence packets 都只围绕 operation fields 与 operation-stack queries 工作。它们让用户和实验者能在同一批 operations 上选择不同 view、派生不同 fields、折叠不同深度, 并审计每个 claim 的证据来源。下一步不应无差别增加数据集, 而应沿两个方向提高 claim 强度: 一是把 field-derivation backend 做到跨家族 calibration 并稳定胜过简单 sequence-derived baselines, 二是用当前 visible packets 和 hidden answer keys 做受控 human/agent analyst study, 验证这种 inspectability tradeoff 是否转化为真实准确率和耗时收益。

参考文献

- [1] Brendan Gregg. Flame Graphs. <https://www.brendangregg.com/flamegraphs.html>.
- [2] OpenTelemetry GenAI semantic conventions. <https://opentelemetry.io/docs/specs/semconv/gen-ai/>.
- [3] McGill-NLP WebLINX. <https://huggingface.co/datasets/McGill-NLP/WebLINX>.
- [4] OpenGVLab GUI-Odyssey. <https://huggingface.co/datasets/OpenGVLab/GUI-Odyssey>.
- [5] WukLab OSWorld-Human. <https://github.com/WukLab/osworld-human>.
- [6] xiangai AgentNet. <https://huggingface.co/datasets/xiangai/AgentNet>.
- [7] McGill-NLP AgentRewardBench. <https://huggingface.co/datasets/McGill-NLP/agent-reward-bench>.
- [8] AI45Research SATraj-OS. <https://huggingface.co/datasets/AI45Research/SATraj-OS>.
- [9] AgentSuite tau-bench trajectories. <https://huggingface.co/datasets/AgentSuite/tau-bench-trajectories>.
- [10] OpenGVLab ScaleCUA-Data. <https://huggingface.co/datasets/OpenGVLab/ScaleCUA-Data>.

表 3: 当前最强结果。数值均来自 tracked artifacts 下的 JSON/HTML reports。

结果块	数据规模	关键数值	支持的结论
R286 recursive depth	13,265 operations	9 dataset stacks, 57 phase stacks, 226 tool/semantic stacks, 455 action stacks, 3,757 fixed-session stacks	Stack 深度是 query, 固定 session 是 drilldown 而不是核心边界。
R282/R285 mapping validation	3,990 held-out operations; 9 leave-out datasets	Held-out compression 19.091 vs no-map 14.049; leave-out 6/9 positive, 0 negative	Label-derived mappings 能泛化到 unseen sessions/datasets, 但仍不是无监督 detector。
R290 OSWorld-Human	369 tasks, 6,010 operations; 4,011 exact grouped-oracle operations	grouped stack 106 vs action stack 482; human-group boundary F1 0.627, precision 1.0	同一单动作序列可折叠到人工 grouped-action 深度。
R291 AgentNet	1,000 tasks, 16,741 operations	step correctness/redundancy 100% field coverage; phase/action F1 0.715, precision 1.0	质量标签是 ordinary operation fields, 可被折叠、评分和诊断。
R293 profile spec	同一 16,741 AgentNet operations	spec 复现 608 stacks; CLI stack override 产生 83 stacks	实验配置可复现且可覆盖, stack 不是固定层级。
R294/R303 trace exchange	public Codex fixture	1 trace session, 6 operations; trace_filesystem_portable=true; trace import 与 operation import 均为 6 samples / 5 stacks 且 folded 字节一致; R303 一条脚本复现该流程	本地 session 可导出、导入并桥接到 operation JSONL, 而不会成为第三个 profiler 抽象。
R306 Chrome trace exchange	public Codex fixture	6 Chrome complete events; 6 direct operations; 6 Chrome-import operations; direct trace, direct operation and Chrome-import operation 均为 6 samples / 5 stacks 且 folded 字节一致	标准 trace 只是 exchange container; 导入后仍进入 operation JSONL 和 operation-stack folding。
R295 claim synthesis	R282–R294 tracked artifacts	C1 supported; C2 supported with scoped limits; C3 partial	论文 claim gate 明确支持范围和不能 claim 的内容。
R296 reviewer packet	R282–R295 tracked artifacts	11 个非 flamegraph/evidence-navigation entries; 4 个 reviewer questions; 39 个 clean input artifacts	结果可通过 claim-indexed 多视图证据包审计。
R297 boundary backend	OSWorld-Human held-out sessions	1,036 test adjacent pairs; learned F1 0.7735; Rust fold 1,132 ops / 74 stacks	Boundary backend 只是派生 operation fields, 递归折叠仍由 operation stack 完成。
R298 value/novelty synthesis	R295–R297 与诊断质量 artifacts	6 个 real-problem evidence blocks; 4 个 novelty claims; level-3 evidence approaching level 4	论文价值和新意从 tracked artifacts 机械回溯, 且保留 must-not-claim gate。
R299 boundary-family calibration	7 个已有候选; 4 个训练任务; 8,961 folded operations	OSWorld 0.6916 F1; AgentNet step-correct/redundant 0.3197/0.3361 F1; AgentReward learned 0.7833 F1 但 repeat-signal-change baseline 1.0	Boundary backend 接口可复制, 但不是通用 detector; 每个家族需要 suitability, calibration 和简单 baseline gate。
R300 query utility proxy	6 个 oracle-backed tasks; 34,539 operations	flat/fixed/operation/label stacks 分别为 6/2,012/944/318; operation-stack vs flat lift 5.726x, inspection fraction 0.2879; vs fixed-session group ratio 0.554, session-support ratio 5.5	Operation stack 改善自动化 inspectability 和跨 session 聚合, 但仍不是 human user study。
R301 width-ranked task proxy	同一 6 个 tasks; 168 task/view/budget scores	30% operation budget 下 operation-stack recall 0.336 / 4.5 groups, fixed-session 0.284 / 25.5 groups; top-10 groups 下 0.641 vs 0.195	Label-hidden 默认浏览仍支持跨 session 聚合, 但 width ranking 不是 detector。
R302 label-hidden ranking	同一 6 个 tasks; 192 task/view/ranker/budget scores	top-10 query-aware stack 检查 0.116 operation fraction, lift 1.587, width 为 0.671 和 1.079; 30% budget recall 0.390 vs 0.340	Operation stack 支持 query-aware 分析 policy, 但 ranker 仍是 heuristic。
R304 case packet	同一 6 个 tasks; 30 个 top-5 query-aware case groups	median work fraction 0.0937; recall 0.188; lift 1.6509; visible packet 与 answer key 分离	Case evidence 可审计, 但仍不是 detector 或 human study。
R305 case baseline	同一 6 个 tasks; 18 个 task-view case packets	flat work/recall 1.0/1.0; fixed work 0.0163, recall 0.0226, lift 1.6615; operation work 0.0937, recall 0.188, lift 1.6509	Operation stack 是 selective middle view, 但不是每个任务都比 fixed-session 更省 work。
R307 claim readiness	R295/R298, R303 与 R300–R306 tracked artifacts	C1 supported; C2 supported with scoped limits; C3 partial; C4 automated proxy only; analysis suite 6 tasks / 34,539 operations	当前 paper wording 可以强化机制 claim, 但 user utility 仍需 controlled analyst study。
R308 analyst outcome	R305 visible packets 与 hidden answer key; 6 tasks / 18 task-view packets	operation-stack positive/high-lift coverage 为 6/6 和 5/6; fixed-session 为 5/6 和 4/6; flat 为 6/6 和 0/6; operation-stack top-group lift median 1.5739	First-evidence proxy 支持 operation-stack inspectability, 但仍不是 human utility。
R309 problem value	R298/R300/R302/R305/R308 tracked artifacts; 4 datasets; 6 tasks	34,539 task-operations; 3,699 positives; operation-stack 比 flat selective 的任务为 6/6; high-lift coverage 为 5/6; 比 fixed-session selected recall 更高的任务为 5/6	真实问题卡片增强 value/novelty 叙事, 同时保留 fixed-session 在 4/6 tasks 上 selected work 更低。
R310 evidence matrix	R307/R309 tracked artifacts	C1/C2/C4 scoped paper-ready; C3 partial; 5-format audit outputs	把 claim、证据数字和 must-not-claim 边界对齐成 paper audit surface, 而不是新实验。
R311 robustness audit	R302/R305/R308/R309/R310 tracked artifacts	6/6 比 flat selective; 6/6 positive group; 5/6 high-lift; 5/6 selected recall 高于 fixed-session; 仅 2/6 selected work 低于 fixed-session	Reviewer-stress 结果支持 inspectability tradeoff, 明确排除 human utility, automatic detection 和 universal fixed-session dominance。
R313 view frontier	R300/R302/R305/R311 tracked artifacts; 162 non-oracle candidate points	operation-stack frontier 6/6; best lift 4/6; best recall under 30% work 4/6; flat/fixed frontier counterpoints 均为 6/6	C4 是 configurable analysis-surface claim, 而不是 single-view dominance。
R288/R289 diagnostics	729 AgentRewardBench ops; 4,285 SATraj ops	repeat-signal/looping V-measure 0.378 vs step-error 0.011; 622 unsafe SATraj ops	Profiler 支持 failure/safety views, 且负结果能揭示粗标签不足。